

8. ПРОГРАММНОЕ СРЕДСТВО СЕМАНТИЧЕСКОГО АНАЛИЗА ТЕКСТА ДЛЯ РЕШЕНИЯ ЗАДАЧИ РАСПОЗНАВАНИЯ КОНТЕНТА WEB-САЙТОВ С ПОМОЩЬЮ НЕЙРОСЕТЕВЫХ ТЕХНОЛОГИЙ

Количество информации в мире неуклонно возрастает, и сложно дать оценку величины циркулирующих в сети Интернет данных в настоящее время. По мнению специалистов IDC (International Data Corporation), в конце 2022 г. количество данных в мире превысит 80 Зеттабайт (1 зеттабайт составляет 10^{21} байт или 2^{70} байт), а в следующем году приблизится к 100 Збайт. К концу 2025 г. эта величина может достигнуть уже 160 Збайт (рис. 8.1).

Количество данных в мире




Рисунок 8.1. Оценка количества данных в мире

Для обработки такого гигантского количества данных необходимо развитие новых информационных технологий и средств обработки данных, а также переход на более современные парадигмы программирования.

Современное программирование имеет тенденцию к упрощению процесса разработки. Сегодня обычный пользователь, даже не знакомый с какими-либо языками программирования, способен построить несложную блок-схему алгоритма из интеллектуально-понятных блоков [98].

Далее, программа преобразует её в машинный код. Вместе с тем, в этой сфере существует пространство для новых решений и развития дальнейших исследований с целью улучшения взаимодействия между компьютером и человеком. Следующим этапом в развитии новых технологий обработки данных может стать компьютерное распознавание естественных языков [99].

Уже сейчас существуют программные решения, позволяющие человеку общаться с компьютером, как с живым существом, используя не прописанные команды, а обычный стиль разговорной речи. Примером могут служить как зарубежные программные интеллектуальные средства, такие как «Siri» и «Алеха», так и отечественные аналоги, к которым относятся «Алиса» и «Олег».

Распознавание естественных языков (смысла речи и написанного текста) является важной сферой исследования в алгоритмах машинного обучения. Появляются всё новые технологии и методы работы с естественной речью, а это значит, что возникает необходимость проводить аналитические исследования данных технологий и искать их возможное применение в научной сфере, для замены устаревших алгоритмов управления компьютерными технологиями.

При обработке естественных языков и семантическом анализе текстов, обучение имитационной модели речи обычно основано на выявлении правил и закономерностей в конкретном языке. Использование нейронных сетей и больших объёмов входных данных, использующих, в том числе, парсинг Интернет–страниц, может предоставить имитацию речи, но это всё ещё будет являться имитацией. Такая программа ещё не сможет понять иронию, или же точно распознать смысл слов, имеющих одновременно несколько различных смысловых значений. Для семантического анализа и улучшения смыслового распознавания текстов актуальна разработка новых программных решений.

Объектом исследования предлагаемого проекта является семантический анализ текста, *предметом исследования* – разработка программного средства, обладающего функциями семантического анализа и формализации текста.

Целью исследования является формализация текстов с использованием технологии *word2vec* для создания числового представления слов. Для достижения поставленной цели необходимо провести анализ предметной области; определить функционал, реализуемый программным средством; исследовать алгоритмы, используемые для достижения поставленной цели; а затем – реализовать необходимые алгоритмы формализации в программном коде; а также провести тестирование готового программного продукта.

8.1. Аналитический обзор программных средств семантического анализа

8.1.1. Обзор предметной области обработки естественных языков

Данное исследование включает в себя способы семантического анализа и формализации текстов. К этому направлению относятся как программы, использующие алгоритмы подсчёта встречаемости слов в тексте, так и более сложные системы с обученными нейронными сетями и большими данными (Big Data), состоящими из текстов, полученных из различных источников [98].

Обработка естественного языка (Natural Language Processing, NLP) – это направление искусственного интеллекта и математической лингвистики. Оно изучает проблемы компьютерного анализа и синтеза естественных языков. Применительно к искусственному интеллекту, компьютерный анализ означает понимание языка (смысла текста, написанного на этом языке), а синтез – генерацию грамотного текста. Решение этих проблем будет означать создание более удобной формы взаимодействия человека с компьютером [99].

При анализе и синтезе речи, основной проблемой в понимании смысла текста является многозначность языка и неопределенность объектов реального мира, а также – большое число правил и исключений из них для каждого из естественных языков. Если говорить о русском языке, то он, являясь одним из самых сложных языков в мире, на данный момент является непреодолимым препятствием для систем NLP. Несмотря на исчислимое значение языковых правил, обилие исключений затрудняет работу программы распознавания естественной речи, особенно учитывая тот факт, что русский язык насчитывает около 300 тысяч слов, подавляющее число которых могут иметь другой смысл при добавлении приставок или суффиксов, а также могут состоять в одной из 36 форм. Все это делает практически неприменимым для русского языка подход к обычному вводу языковых правил в программу анализа текстов.

В процессе обработки естественного языка (NLP) определяют два типа алгоритмов распознавания естественных языков: статистические и точные.

Статистический алгоритм предполагает формирование корпуса слов из текста, проведение его частотного анализа, вычисление вероятности встречаемости слов, и обработку текста на основе математических методов.

Точный алгоритм работает на основе точных правил и основан на конвейерном методе, где текст последовательно проходит через морфемный, морфологический, лексический и семантический анализ. Алгоритм использует преимущественно не математические, а лингвистические методы [100].

8.1.2. Обзор существующих проектов семантического анализа

Прежде чем приступать к формированию концептуальной модели программного средства, нужно проанализировать существующие проекты, оценить их роль в формировании решений проблемы распознавания текстов, рассмотреть их плюсы и минусы. Первая рассмотренная технология – BERT.

BERT – это нейронная сеть от Google, показавшая с большим отрывом результаты, близкие к произведению искусства (state-of-the-art) на целом ряде задач. С помощью сети BERT можно создавать программные средства с использованием искусственного интеллекта, для обработки естественного языка: отвечать на вопросы, заданные в произвольной форме, создавать чат-боты, разрабатывать автоматические переводчики, анализировать тексты и др. Русскоязычная версия этой нейросети носит название *SlavicBERT*.

Нейронная сеть *SlavicBERT* обучалась по русским новостным статьям и четырём Википедиям: болгарской, чешской, польской и русской. На основе этих данных был построен *словарь субтокенов*. Многоязычная сеть BERT была использована в качестве инициализации для нейронной сети *SlavicBERT*. Сеть BERT обучалась на англоязычных ресурсах Twitter, Reddit, Daily_Dialogues, Open_Subtitles, Debates, Blogs и Facebook. Эти обучающие данные были использованы для построения словаря английских субтокенов и переработки английской базовой версии BERT-base, в качестве основы для английской разговорной версии BERT. В то же время, разговорная версия *SlavicBERT* была обучена на ресурсах Open_Subtitles, Dirty, Pikabu и сегменте социальных сетей Taiga corpus на русском языке. На основе этих данных был собран новый словарь для разговорной модели *RuBERT-a* и обучена русскоязычная модель.

8.1.3. Концептуальная модель программы для формализации текста

С использованием технологии *Word2Vec* можно реализовать модель нейронной сети, обученную на корпусе текстов научных статей различной направленности. Полученная модель будет получать на вход текст, не входящий в первоначальную выборку. Задачей программного средства будет являться определение смысла и направленности текста, исходя из данных, поступивших при обучении, и составление краткой аннотации темы статьи с помощью алгоритмов BagOfWords. Аннотация (реферат) будет представлена выборкой из предложений текста, наиболее полно раскрывающих его содержание.

Готовое программное средство будет содержать консольный интерфейс для выбора текста и вывода результатов на экран. Программа будет выводить вероятность, с которой она определила текст в ту или иную категорию.

Обучение модели, в рамках программного решения, не предусмотрено. тесты будут проводиться на предварительно обученных моделях нейронной сети, в рамках данного исследования. Успех при анализе и верном определении тематики будет оцениваться при помощи метода экспертных оценок.

8.2. Алгоритмическое построение средства семантического анализа

Опишем современные алгоритмы семантического анализа текста, используемые в разрабатываемом программном средстве. Представим анализ входных и выходных данных, и схемы работы используемых алгоритмов. Рассмотрим основные принципы семантического анализа и выберем технологии, используемые при создании кода программного средства.

8.2.1. Анализ входных и выходных данных

Для определения необходимой структуры программного средства следует выделить его входные и выходные данные. Поскольку разрабатываемая программа предназначена для работы с текстами, то входные данные также будут состоять из текстов. Первоначально следует выбрать большой корпус текстов, разделенный по тематикам для обучения. Далее, из этих тематик нужно выделить тексты, которые не вошли в первичную выборку, для их последующего использования для проверочного тестирования.

Выходными данными в разрабатываемом программном средстве является список соответствий тестируемых текстов и тематик, к которым они относятся. Названия тематик в процессе обучения модели задаются вручную.

8.2.2. Алгоритм градиентного бустинга с деревом решений

Первым из рассмотренных алгоритмов является алгоритм градиентного бустинга с деревом решений. *Градиентный бустинг* — это техника машинного обучения для задач классификации и регрессии, которая строит модель предсказания в форме ансамбля слабых предсказывающих моделей, обычно деревьев решений. Обучение ансамбля проводится последовательно, в отличие, например, от *бэггинга*. На каждой итерации вычисляются отклонения предсказаний уже обученного ансамбля на обучающей выборке [101].

Следующая модель, добавленная в ансамбль будет предсказывать эти отклонения. Так, добавив предсказания нового дерева к предсказаниям обученного ансамбля, можно уменьшить среднее отклонение модели, которое является целевой функцией (таргетом) оптимизационной задачи [102].

В реалиях технологии распознавания смысла текста и анализа естественных языков, алгоритм градиентного бустинга применяется в семантической модели предложений. При построении дерева зависимостей слов в предложении и выделении его основы, зависимых слов и принадлежности прилагательных и наречий к тем или иным словам, такая методика применяется в реализации библиотек для языка Python, таких, как *XGboost*, *Tensorflow* и *Keras* [102].

Визуальное представление работы алгоритма, на примере предложения «Однажды в студёную зимнюю пору я из лесу вышел...» показано на рис. 8.2.



Рисунок 8.2. Схема семантических связей в предложении

Используя такой подход, можно выделить основную мысль каждого предложения, полагая, что само предложение является законченной мыслью.

На базе выявленных основ можно построить ёмкую последовательность основных идей текста, добавляя их зависимыми словами. Полученный результат не означает, что вычислительное устройство распознало смысл предложения, но оно выявило его основную идею и смогло сжать повествовательный объём текста в n раз. Пример работоспособности алгоритма градиентного бустинга представлен в статье его разработчика *Адама Гитги* [103].

8.2.3. Алгоритм NLP–конвейера

Вторым алгоритмом является NLP–конвейер (NLP—это Natural Language Processing, распознавание естественных языков). В основе алгоритма заложен принцип последовательной обработки каждого предложения текста.

Пропуская предложения через конвейер преобразовательных функций, на выходе можно получить информацию о каждом предложении, необходимую для распознавания его смысла. Как и в предыдущем алгоритме, предложение принимается за законченную мысль, и точно так же компьютер не способен понимать смысловой нагрузки предложений, а лишь выделяет главную мысль.

Модернизация алгоритма NLP–конвейера для выделения ключевых слов и предложений: в начале рассмотрим стандартную структуру NLP–конвейера:

Шаг 1: сегментация текста – разбивка его на предложения;

Шаг 2: лексический анализ слова как единицы русского языка;

Шаг 3: разметка частей речи предложения по их функционалу;

Шаг 4: определение начальной формы слов текста (лемматизация);

Шаг 5: выявление стоп–слов предложения (удаление таких стоп–слов из каждого предложения текста не только не нарушает его смысла, а наоборот, делает его более понятным, простым и ясным для восприятия);

Шаг 6: синтаксический анализ на основе грамматики зависимостей;

Шаг 7: поиск именных групп (в форме словосочетаний) в предложении;

Шаг 8: выделение именованных сущностей, выделяющих эти субъекты или объекты из ряда однотипных предметов или явлений (имеющих имена);

Шаг 9: разрешение кореферентности имён в предложении [104].

Визуально распознавание естественного языка отображено на рис. 8.3 в представлении пирамиды, где в основе лежит морфологический анализ, за ним идёт синтаксический разбор и семантический и смысловой анализ всего текста.



Рисунок 8.3. Распределение задач анализа текста при распознавании естественного языка

Сложность в машинном распознавании естественной речи состоит как раз на шаге разрешения кореферентности имён, поскольку компьютер не может эмпирически оценивать данные для создания связей между ними.

Но если данные, поступающие на NLP–конвейер между шагами 5 и 6, будут систематизированы, то это облегчит задачу проведения синтаксического, семантического и смыслового анализа текста предложения.

В связи с наличием необходимых библиотек и словарей на русском языке, именно этот, второй из представленных алгоритмов, имеет смысл модернизировать для решения поставленных задач этого исследования.

Идеей модернизации исходного алгоритма является внедрение анализа встречаемости слов в предложении и расчёт смысловой нагрузки предложений по формуле (1). В рамках этого исследования предполагается, что предложения с наибольшим коэффициентом встречаемости слов могут нести наибольшую смысловую нагрузку, и могут повествовать о смысле всего текста.

Для модернизации исходного алгоритма и проверки его работы следует разработать программное средство на языке Python. Первыми шагами обновлённого алгоритма останутся четыре шага стандартного NLP–конвейера. Далее начинаются модификации, оптимизирующие исходный алгоритм.

В пункте 5.1 должно быть проведено выявление и удаление стоп–слов предложения, не участвующих в смысловой нагрузке предложения.

В пункте 5.2 необходимо построение двумерного массива, включающего номера предложений и встречаемые слова, а на пересечении строк и столбцов должно отображаться, сколько раз в предложении встречается каждое слово. В конце обработки массива нужно просуммировать столбцы, отсортировать их по убыванию и отобрать 100 первых слов – элементов, являющихся существительными, прилагательными или глаголами. Так, получится 100 ключевых слов, отсортированных в порядке их встречаемости [105].

Пункт 5.3 направлен на расчёт *коэффициента встречаемости ключевых слов* в предложениях. Чтобы в выборку не попадали только самые длинные предложения, выполняется нормализация коэффициентов по формуле (1), путём умножения вычитаемой длины предложения на среднюю длину всех предложений, встречающихся в анализируемом тексте.

$$K_i = \sum_{j=1}^{100} m_j - d_i \cdot (\sum_{n=1}^t d_n / t), \quad (8.1)$$

где: K_i – коэффициент i –го предложения; m_j – число j –х ключевых слов в этом предложении; d – длина предложения; t –число предложений в тексте [106].

Чтобы проверить гипотезу о том, что выборка предложений с самым высоким коэффициентом встречаемости говорит о смысле всего произведения – нужно провести тестирование алгоритма путем экспертной оценки.

Экспертное оценивание – это процедура получения оценки проблемы на основе мнения специалистов (экспертов) с целью последующего принятия решения (выбора). *Эксперты* – это лица, обладающие знаниями и способные высказать аргументированное мнение по изучаемому явлению [107].

В качестве исследуемого текста был выбран роман–антиутопия «451° по Фаренгейту» американского писателя–фантаста Рэя Брэдбери, а в качестве экспертов были приглашены 113 студентов, знакомых с этой книгой.

Экспертам была представлена выборка, в которую входило 0,5 процента исходного текста, разбитого по предложениям в хронологическом порядке, обладающим наибольшим коэффициентом, рассчитанным по формуле (1).

Необходимо было по 10–бальной системе оценить тот факт, имеется ли в данной выборке информация о главном действующем лице, месте действия и сути происходящего. Результаты оценивания представлены на рис. 8.4.



Рисунок 8.4. Экспертное оценивание работоспособности алгоритма

В построенной диаграмме, по горизонтали указаны выставленные оценки от 1 до 10, а по вертикали – число экспертов, поставивших ту или иную оценку. Средняя оценка работоспособности алгоритма по результатам исследования составляет 6,59 баллов, исходя из чего можно заключить, что гипотеза, выдвинутая в этом пункте исследования, была подтверждена [108].

8.2.4. Алгоритм векторных представлений слов

Word2vec представляет собой технологию, разработанную Google для нахождения семантических связей между словами. Это современный инструмент для анализа семантики естественных языков, основанный на дистрибутивной семантике (смысловой близости между лингвистическими единицами), машинном обучении и векторном представлении слов [109].

Алгоритм Word2vec был создан в 2013 году в компании Google, группой исследователей во главе с чешским учёным Томашем Миколовым. Встраивание векторов, созданных с использованием алгоритма Word2vec, имеет много преимуществ по сравнению с более ранними алгоритмами, такими, как алгоритм *скрытого семантического анализа* [110].

Принцип работы Word2vec заключается в ряде пунктов. Сперва читается корпус текста и рассчитывается встречаемость каждого слова в этом корпусе. Затем массив слов сортируется по частоте встречаемости слов (все слова сохраняются в хэш–таблице), и удаляются редкие слова. Строится дерево Хаффмана, которое часто применяется для кодирования словаря – это значительно снижает вычислительную и временную сложность алгоритма.


Из корпуса вычленяется субпредложение (subsentence) и проводится субсэмплирование наиболее частотных слов (subsampling, процесс изъятия наиболее часто встречающихся слов из анализа), что ускоряет процесс обучения алгоритма и способствует значительному улучшению качества модели.

Субпредложение обрабатывается с помощью *окна* (размер окна задаётся в качестве параметра на входе алгоритма). Под «окном» подразумевается максимальная дистанция между текущим и предсказываемым словом в предложении. Применяется нейронная сеть прямого распространения, с функцией активации (Hierarchical Softmax) или негативное сэмплирование (Negative Sampling). Нейросеть Hierarchical Softmax проявляет себя лучше при работе со словами, встречающимися не слишком часто (не высоко частотными словами), и работает медленнее. Нейросеть Negative Sampling лучше работает с высоко частотными словами, и выполняется быстрее [110].


В итоге получается словарь, где каждому слову соответствует своё векторное представление. При близком значении векторных представлений можно полагать, что и соответствующие им слова близки по смыслу [111].

За годы существования технология получила широкое распространение, и, поскольку алгоритм Word2vec ещё считается относительно новым, поиск его новых применений продолжается (примеры показаны на рис. 8.5).

Наиболее широкое распространение в данный момент эта технология получила в различных поисковых системах и алгоритмах продвижения SMM (Social Media Marketing – продвижение продаж товаров и услуг в социальных сетях). Рассмотрим подробнее все сферы применения Word2vec подробнее.



подсказки



имитация разговорной речи

Рисунок 8.5. Примеры использования технологии Word2vec

Задача классификации текстов. Первая возможная сфера применения алгоритма Word2vec – классификация текстов. Так, при обучении на корпусе текстов с ручным определением сферы научной работы, есть возможность дальнейшего автоматического определения УДК (универсальной десятичной классификации). Это связано с тем фактом, что лингвистические единицы, к примеру, в статье по информационной безопасности и в докладе об эпидемиологической обстановке в мире будут иметь различные векторные значения. Технология Word2vec применяется в сфере классификации на основе статистических алгоритмов. Ценность её состоит в автоматизации процессов классификации текстов, а также в проверке правильности УДК, указанных студентами, аспирантами и преподавателями в их научных работах.

Использование в чатботах и наборе текстов. Вторая сфера применения алгоритма Word2vec – это предугадывание слов в тексте пользователя, которое также применяется в статистических алгоритмах. Режим T9 в ручном наборе текстов получил новое развитие с появлением Word2vec. Программа просто предлагает слово, расположенное в векторном представлении наиболее близко по отношению к набранному слову. И это применимо не только в автонаборе, но и в программировании чатботов (программ, имитирующих реальный разговор с пользователями или покупателями), позволяющих общаться с помощью текстовых или аудио сообщений на Web-сайтах, в мессенджерах, мобильных приложениях или по телефону, построенных на принципе *вопрос-ответ*. Чатботы широко применяются в большинстве Web-приложений. В этом случае модели нейронных сетей обучаются на больших корпусах текстов, в качестве которых используются анонимизированные переписки, взятые из Web-сайтов, мобильных приложений, социальных сетей и мессенджеров.

Применение в семантическом анализе. Когда говорят об алгоритме Word2vec, то первое, о чем вспоминают знающие люди в этой сфере – пример от Google, когда в программу добавляли выражение «король минус мужчина плюс женщина» и на выходе получали слово «королева» [111]. Этот случай действительно впечатляет, поскольку математическими методами система смогла имитировать смысловые связи, формируемые в человеческом мозге на протяжении всей жизни. Но, как и в любом машинном обучении, успех эксперимента зависит от качества загружаемого набора данных (Dataset), а потому в настоящее время ведутся исследования по обработке различных корпусов текстов и слов и поиску применений наборов данных [112].

Использование векторной алгебры позволяет получать смысловые конструкции, о которых компьютер не может иметь никакого представления. Он может лишь имитировать определение смысла слов по другим, связанным с ним словам. При подборе нужного корпуса слов, а также добавления в алгоритм учёта пунктуации и склонения слов – можно использовать такую технологию при составлении автоматических аннотаций и рефератов текстов, статей и докладов, сокращая объёмное описание и выделяя самое главное.

В настоящее время сведений о применении технологии в семантическом анализе не имеется, однако в будущем, при использовании статистических алгоритмов, как основы, и точных алгоритмов как проверочных инструментов, Word2vec позволит сформировать программное представление семантических связей реального мира, основанное на лингвистических единицах. Задачей такой разработки станет формирование необходимого корпуса текстов, подходящих для реализации такой масштабной проблемы [112].

8.2.5. Основные архитектуры Word2vec

Word2vec, как инструмент для расчёта векторных представлений слов, реализует две основные архитектуры – Continuous Bag of Words (CBOW) и Skip-gram. Принцип работы архитектуры CBOW состоит в предсказывании слова при заданном контексте. Архитектура Skip-gram работает наоборот – предсказывается контекст, при заданном слове. На вход подается корпус текста, а на выходе, в качестве результата, получается набор векторов слов.

Векторное представление работает по принципу нахождения связей между контекстами слов, согласно предположению, что слова, находящиеся в похожих контекстах, означают похожие вещи, т.е. являются семантически близкими.

Более формально задача стоит так: максимизация косинусной близости между векторами слов (скалярное произведение векторов), которые появляются рядом друг с другом, и минимизация косинусной близости между векторами слов, которые не появляются рядом друг с другом, т.е. в близком контексте.

Например, слова «анализ» и «исследование» часто встречаются в похожих контекстах, вроде «Учёные провели анализ алгоритмов» или «Учёные провели исследование алгоритмов». Технология Word2vec анализирует эти контексты и делает вывод, что слова «анализ» и «исследование» являются близкими по смыслу. Так как подобные выводы Word2vec делает на основании большого количества текста, выводы оказываются вполне адекватными [111].

За основу для будущего исследования была взята Skip-gram архитектура, поскольку она даёт более точные результаты при меньшем размере корпуса текста для её обучения. Обучать модель нейронной сети следует, используя архив гуманитарных и технических научных работ из 1000 книг.

По итогу обучения, каждому слову будет соответствовать определенный вектор. Близость значений векторных представлений слов однозначно определяет семантическую близость слов. Пример подобной программной реализации алгоритма Word2vec представлен в программном решении *Serelex*. Визуализация процесса семантического поиска представлена на рис. 8.6.

Поскольку каждому слову будет соответствовать определенный вектор, то все слова будут подчиняться правилам векторной алгебры, что даёт исследуемой модели возможность расширения возможностей векторных представлений, просуммировав вектора всех слов в предложениях и выведя сперва векторное представление предложений, а затем и всего текста.

Полученные результаты будут накапливаться, с целью классификации произведений и нахождения зависимостей в больших объемах информации.

Нельзя сказать, что полученный вектор будет определять семантическое содержание текста или же оно будет в нем зашифровано, но у текстов с различной тематикой или структурой предложений векторы будут отличаться.

8.2.6. Алгоритм автоматической классификации текстов

У полученных векторов различных текстов обученной модели нейронной сети будут различные значения. Значит, для определения однозначного вектора тематики, необходимо произвести сложение этих векторов [112].




Рисунок 8.6 – Визуализация семантического поиска в системе Serelex

И обученная модель, и текст, тематику которого нужно определить, должны пройти NLP конвейер, который исключит из текста неалфавитные символы, и приведет слова в нормальную форму. Следующим шагом станет получение векторных представлений каждого слова и вектора текста целиком [112].

При получении вектора важно, чтобы использовались данные из уже обученной модели. Это делается для того, чтобы слова, которых не существует в первичной модели нейронной сети, пропускались и не препятствовали определению векторного представления всего текста в целом.

Получив вектор искомого произведения, необходимо определить, к какой тематической категории он относится. Это можно сделать путём расчёта среднеквадратичного отклонения. Предположим, что ближайший к вектору искомого текста вектор тематики означает, что текст принадлежит к некой тематике. Для определения верности предположения, следует увеличить число искомых текстов, а для определения эталонной тематики произведения необходимо воспользоваться классификаторами электронной научной библиотеки «CyberLeninka», откуда эти тексты и будут взяты [113].

Все шаги алгоритма отображены на рис. 8.7.

Итак, были рассмотрены алгоритмы семантического анализа текста, используемые в разрабатываемом программном средстве, представлен анализ входных и выходных данных, и принципы работы технологии Word2vec. Также был проведен анализ применимости алгоритма формализации текста. Исследования показали, что выдвинутая гипотеза о том, что предложения, содержащие в себе ключевые слова с самой высокой частотой встречаемости в тексте содержат суть повествования, является верной.

8.3. Программная реализация средства семантического анализа

Ранее была подробно рассмотрена проблема семантического анализа и формализации текстов, а также предложены возможные пути её решения с использованием технологии векторных представлений слов.

На основе предложенной концептуальной модели, было выполнено алгоритмическое построение, и выдвинута гипотеза о применимости данного алгоритма. Все представленные выше алгоритмы необходимо применить и реализовать в интегрированной среде разработки (IDE) PyCharm Community на языке Python, проверить их адекватность и работоспособность в различных условиях работы модели нейронной сети и на различных текстах.



Рисунок 8.7 – Алгоритм определения тематики текста

8.3.1. Обоснование выбора языка программирования

Для реализации поставленных задач были выбраны средства разработки PyCharm Community. В качестве языка программирования для создания программного средства был выбран язык Python 3. Причина выбора данного языка программирования заключается в том, что Python имеет широкий набор библиотек, упрощающих написание кода, а также в нем наиболее удобно представлена работа с матрицами, что дает большие возможности при работе с нейронными сетями. Также в Python реализован тип данных *словарь*, что будет удобно при векторизации токенов и хранении этих данных.

Кроме этого, в Python существует возможность построения программного интерфейса при помощи графической библиотеки *Tkinter* (*Tk interface*), позволяющей создавать программы с оконным интерфейсом. Выполнение цикла отрисовки графического интерфейса не будет мешать работе основных программных функций, поскольку Tkinter позволяет использовать различные потоки для графики и логики программного средства. Язык Python позволяет использовать множество собственных библиотек, значительно упрощающих процесс разработки. Это позволит уменьшить количество строк программного кода и сконцентрировать внимание на реализации собственных алгоритмов.

В качестве инструментов разработки в Python будут использованы: библиотека для работы с матрицами *Numpy*, сборник итераторов *Itertools*, конструктор моделей классификаторов *Sklearn*, NLP-анализатор *Spacy*, библиотека семантического моделирования *Genism* и другие.

Для разработки программного средства была выбрана IDE PyCharm, так как в ней имеется встроенный инструмент простой установки пакетов *pip*, а также удобные механизмы редактирования кода, которые позволят ускорить процесс разработки. Настройки программы Pycharm по типу *PynSource* дают возможность проверить и проанализировать написанный код, сделать его методы логичными, а их использование – обоснованным.

8.3.2. Описание реализуемых классов и их методов

Все программное средство представлено тремя классами. Каждый из них выполняет ограниченный ряд функций и взаимодействует с другими классами. Все классы представлены на рис. 8.8 в виде UML–диаграммы.




Рисунок 8.8. UML–диаграмма классов

Первый класс, который необходимо рассмотреть – это класс *form*. В нём реализован интерфейс разрабатываемого программного средства и методы, обращающиеся к другим классам. Помимо вывода интерфейса, методы этого класса проводят проверку входных данных на соответствие требованиям по загрузке файлов в программу. Так, метод *analyze*, прежде чем обратиться к классу *formalize* и послать выбранный пользователем документ на анализ, проверяет, действительно ли выбранный файл имеет расширение «.txt» и кодировку «utf-8». Этот класс имеет две формы инициализации, выводящие справочную информацию о создании экземпляра класса, а также четыре метода, каждый из которых вызывается при нажатии на одну из четырех кнопок главного окна разрабатываемого приложения.

Как уже упоминалось, во время выполнения алгоритмов из других классов для изменения содержимого окна класса *form* в режиме реального времени используется переключение между потоками приложения. Таким образом, поток, в котором проходит выполнение какого-либо из алгоритмов программы применяет функцию *sleep* библиотеки *time*. В этот момент происходит переключение на поток графического интерфейса, и в специально отведенном текстовом поле отображается информация о прогрессе анализа текста или обучения новой модели нейронной сети. В классе *form* имеется поле *file*. Оно заполняется при открытии текстового файла, и информация о пути к файлу и его названии передаются в методы анализирующего класса.

Второй класс для рассмотрения – это класс *vector*. Он представляет собой набор методов, комплексно использующих средства библиотек *gensim* и *sklearn*. Класс *vector* содержит в себе методы создания словаря на основе входного корпуса текстов, обучения модели нейронной сети на основе этого словаря, вывода графика распределения слов в двумерной проекции. Помимо инструментов для работы с моделями нейронных сетей, в этом классе реализованы функции для оперирования векторами: функции суммирования векторов, получения скалярного произведения, а также модуля вектора.

Третий класс, в котором реализовано выполнение разработанных в данной работе алгоритмов, называется *formalize*. Этот класс имеет 11 методов, и некоторые из них следует рассмотреть подробнее. Метод *readbook* считывает текстовую информацию из документа, который был в него передан, и отправляет текст дальше по конвейеру. Конвейер состоит из 4 функций *nlr4*, *nlr5*, *nlr6* и *nlr7*. В них последовательно производится очистка текста от знаков препинания, удаление предлогов и союзов, удаление сокращений, перевод слов в нормальную форму и получение массива токенов текста, где каждый токен представляет из себя самостоятельное, имеющее смысл слово, представленное в нормальной форме или в инфинитиве. Метод *conveuer* вызывает по очереди каждый из методов конвейера. Метод *make_model* взаимодействует с методами класса *vector* и отвечает за создание модели, а также за возвращение статистической информации о количестве токенов, ключевых словах, номерах предложений, в которых содержится наибольший коэффициент самых часто-встречаемых в исходном тексте слов, а также осуществляет вывод самих этих предложений. Стоит отметить, что все методы, выполнение которых занимает много времени, получают в качестве аргумента элементы графического интерфейса и выводят в них прогресс выполнения операций.

Таким образом, можно заключить, что класс *form* является управляющим классом и вызывает методы других классов *formalize* и *vector*, которые предстают как инструмент реализации алгоритмов конвейера обработки естественных языков и вспомогательный инструмент взаимодействия с векторными представлениями соответственно.

8.3.3. Принцип работы с программным средством

Запуская программное средство, на экране можно увидеть окно, размером 830 на 850 пикселей. Эти размеры можно изменить, при желании пользователя. В окне находится информационная надпись, 3 поля для вывода информации и 4 кнопки. Внешний вид данного окна представлен на рис. 8.9.




Рисунок 8.9. Внешний вид окна программы

Файловая структура проекта такова, что помимо файлов с расширением «.ру» в папке находятся файлы модели нейронной сети текущего анализируемого текстового документа, а в папках «Модели Г» и «Модели Т» расположены более крупные модели нейронной сети, обученные на корпусе текстов технических и гуманитарных наук. При желании эти модели можно переобучить. Для этого необходимо открыть текстовый файл, содержащий корпус соответствующих текстов, нажав на кнопку открыть. После открытия файла можно запустить обучение гуманитарной или технической модели.

Для выполнения анализа текста необходимо открыть файл и нажать кнопку «Начать анализ». Время обработки файла зависит от его размера и числа токенов (в случае лексического анализа, под термином токен понимаются последовательности символов, соответствующие лексеме). Так, файл размером 50 килобайт, содержащий менее 3000 токенов, обрабатывается примерно 10 секунд. Результаты анализа текста продемонстрированы на рис. 8.10.




Рисунок 8.10. Результаты анализа текста

В форме вывода информации есть два логических блока. В *первом блоке* выводится информация о состоянии семантической модели, количество токенов и модули среднеквадратичного отклонения с моделями двух категорий. Ниже указана вероятность, с которой алгоритм отнес искомый текст к той или иной категории. *Во втором логическом блоке* содержится список ключевых предложений текста, расставленный по мере их встречаемости в самом тексте. В выборке содержится один процент от первоначального объёма текста. Такая выборка позволяет проверить работу модели на незнакомых текстах, поскольку даже одного процента текста обычно хватает, чтобы установить, например, что перед нами текст по философии или по квантовой физике.

8.3.4. Описание эксперимента с семантическим анализом группы текстов

Был проведен эксперимент для подтверждения гипотезы о применимости предложенного алгоритма для классификации текстов. Сначала было нужно выбрать корпус текстов технических и гуманитарных направленностей, который должен быть достаточно большим, чтобы точнее определить вектора токенов.

В этом случае корпус технических текстов насчитывал 412 учебников и научных работ по информатике, машиностроению, математическому анализу, системному анализу, квантовой физике и электротехнике, взятых из архивов научных работ и открытых Интернет–библиотек. Корпус гуманитарных текстов состоял из 500 учебников по юриспруденции, философии, литературе и истории.

После обучения модели нейронной сети, размер словарей токенов для технических текстов составлял более 264 тысяч семантических единиц, а для гуманитарных произведений – более 217 тысяч. После обучения моделей категорий были выбраны тексты, которые проанализировала программа. При отборе текстов авторы руководствовались правилом, чтобы они не входили в первоначальную выборку предобученных моделей. Было выбрано 15 текстов, связанных с математическим анализом и 15 – с юриспруденцией.

Проанализировав все произведения, алгоритм указал верную категорию произведений в 26 из 30 случаев. При полученной точности в 80% можно утверждать, что алгоритм готов к применению для определения тематики текста (контента Web–сайта) при дуальности модели, так как на примере обученной модели были представлены тексты из технической и гуманитарной сфер.

Дальнейшие модификации алгоритма возможны в сторону поиска более точного инструмента сравнения векторных представлений текстов, добавления новых инструментов определения векторов (text2vec), и расширения категорий текстов для проверки работоспособности алгоритма вне рамок дуальной модели.

9. ПОИСК ПОТЕНЦИАЛЬНО ОПАСНЫХ КОНСТРУКЦИЙ И УЯЗВИМОСТЕЙ В ИСХОДНЫХ ТЕКСТАХ ПРОГРАММ С ПОМОЩЬЮ ИСКУССТВЕННЫХ НЕЙРОННЫХ СЕТЕЙ

Настоящее время очень сильно отличается от недалекого прошлого: сейчас основным и самым дорогостоящим товаром является информация. XXI век стал веком информационных технологий. Сегодня невозможно представить жизнь без современных гаджетов, на котором хранится много ценных и нужных данных, хотя недавно это казалось за гранью реальности.

Однако, вместе с развитием информационных технологий растёт и преступность в компьютерной сфере. Чем изощреннее становятся способы несанкционированного доступа к защищаемой информации, тем больше средств тратится на предотвращение подобного взлома. Вопрос защиты информации в мире информационных технологий давно стоит на первом месте.

Зачастую злоумышленники используют программные закладки, как способ доступа к конфиденциальной информации. Это участки кода, которые необходимы для выполнения недеklarированных операций, известные разработчикам кода. Кроме того, разработанный код может содержать грубые ошибки, допущенные по невнимательности программиста–разработчика.

Организации, которые работают с конфиденциальной информацией, в целях безопасности обязаны использовать программное обеспечение, которое не содержит недеklarированных возможностей. При этом, для предотвращения неприятных последствий, программисты–тестировщики проверяют уязвимости программного обеспечения до его ввода в эксплуатацию. Однако такие методы не обеспечивают защищённости ПО и имеет ряд существенных недостатков:

- процесс тестирования является довольно трудоемким, и занимает значительное количество времени – от недели до нескольких месяцев;
- такая услуга значительно увеличивает бюджет, выделенный на разработку;
- метод тестирования не гарантирует полного выявления всех уязвимостей, так как всегда существует вероятность ошибки за счёт человеческого фактора.

Для решения проблем тестирования исходных текстов программного обеспечения используются программные анализаторы исходного кода.

Анализаторы исходных текстов программы – это класс программных продуктов, которые были специально созданы для выявления уязвимостей и предотвращения ошибок в исходных текстах программ [114].

Программное обеспечение часто имеет различные дефекты, из-за ошибок в коде программы. Уязвимости, допущенные при разработке программного продукта, являются причиной сбоев, и как следствие, нарушений нормальной работы программы. Ошибки, допущенные при разработке программного обеспечения, могут повлечь за собой очень неприятные последствия, которые могут закончиться искажением или уничтожением данных, и даже остановкой системы. Большинство уязвимостей связано с некорректной обработкой данных, которые получены извне. Сбои часто происходят из-за недостаточно строгой проверки входных данных. Вот почему проверка программного продукта с помощью анализатора исходного кода является необходимым и важным требованием при создании программы до её ввода в эксплуатацию.

Существующие программные анализаторы можно разделить на три типа: 1) предназначенные для кодов Web-приложений; 2) позволяющие обнаружить уязвимости в программных модулях, которые используются для расширения функциональных возможностей ПО; 3) предназначенные для программ, написанных на различных языках программирования.

Объектом исследования являются процессы анализа исходных текстов программ, предметом – алгоритмы анализа исходных текстов программ.

Целью исследования является разработка анализатора исходных текстов программы для нахождения возможных уязвимостей и опасных конструкций, с применением технологии искусственных нейронных сетей. Для достижения поставленной цели были поставлены следующие задачи:

- определить необходимость и значимость прохождения процедуры сертификации для внедрения программного обеспечения на практике;
- исследовать существующие аналоги анализаторов программных кодов, присутствующие на современном мировом и российском рынках;
- оценить преимущества использования искусственного интеллекта и нейронных сетей для поиска опасных конструкций в исходных текстах ПО;
- разработать алгоритм работы анализатора исходных текстов программ, построенного на основе искусственных нейронных сетей;
- создать программную реализацию разработанного алгоритма;
- протестировать программную реализацию анализатора исходных текстов программ и оценить корректность его работы.

9.1. Необходимость сертификации программного обеспечения

Сегодня день рынок информационных технологий настолько развит, что у потребителя нет возможности самостоятельно убедиться в качестве используемого программного продукта. Для безопасного использования программного обеспечения оно должно пройти процедуру сертификации.

Сертификация – процедура, выполняемая третьей стороной, независимо от изготовителя и потребителя продукции или услуг, по подтверждению соответствия этих продуктов или услуг установленным требованиям [114]. Сертификация не является обязательной процедурой и обычно проводится на добровольной основе, чтобы повысить конкурентоспособность программного продукта на рынке, что важно для производителя, а также внедрить свою разработку в ту сферу, где используется только сертифицированная продукция.

При работе с информацией ограниченного доступа, программы должны пройти проверку на наличие в них недеklarированных возможностей.

Недекларированные возможности – это функциональные возможности программы, не описанные, или не соответствующие описанию в документации, при использовании которых возможно нарушение конфиденциальности, доступности или целостности обрабатываемой информации [115].

Классификация программного обеспечения проводится в соответствии с руководящим документом «Защита от несанкционированного доступа к информации. Часть 1. Программное обеспечение средств защиты информации. Классификация по уровню контроля недеklarированных возможностей», и делит все программные продукты на 4 уровня контроля [116]:

- 4 уровень – системы, обрабатывающие конфиденциальную информацию;
- 3 уровень – системы, обрабатывающие информацию с грифом «Секретно»;
- 2 уровень – системы для информации с грифом «Совершенно Секретно»;
- 1 уровень – системы для информации с грифом «Особой Важности».

Распространённым методом обеспечения информационной безопасности программного продукта является поиск опасных конструкций в исходных кодах программы. В табл. 9.1 представлен перечень обязательных требований к уровню контроля. Начиная со второго уровня контроля, необходимо обеспечить «контроль наличия заданных конструкций в исходных текстах». Подобный контроль осуществляется с помощью *сигнатур* [117].

Таблица 9.1. Перечень требований к уровню контроля

№	Наименование требования	Уровень контроля			
		4	3	2	1
	Требования к документации				
1	Контроль состава и содержания документации				
1.1.	Спецификация (ГОСТ 19.202-78)	+	=	=	=
1.2.	Описание программы (ГОСТ 19.402-78)	+	=	=	=
1.3.	Описание применения (ГОСТ 19.502-78)	+	=	=	=
1.4.	Пояснительная записка (ГОСТ 19.404-79)	-	+	=	=
1.5.	Тексты программ, входящих в состав ПО (ГОСТ 19.401-78)	+	=	=	=
	Требования к содержанию испытаний				
2.	Контроль исходного состояния ПО	+	=	=	=
3.	Статический анализ исходных текстов программ				
3.1.	Контроль полноты и отсутствия избыточности исходных текстов	+	+	+	=
3.2.	Контроль соответствия исходных текстов ПО его объектному (загрузочному) коду	+	=	=	+
3.3.	Контроль связей функциональных объектов по управлению	-	+	=	=
3.4.	Контроль связей функциональных объектов по информации	-	+	=	=
3.5.	Контроль информационных объектов	-	+	=	=
3.6.	Контроль наличия заданных конструкций в исходных текстах	-	-	+	+
3.7.	Формирование перечня маршрутов выполнения функциональных объектов	-	+	+	=
3.8.	Анализ критических маршрутов выполнения функциональных объектов	-	-	+	=
3.9.	Анализ алгоритма работы функциональных объектов на основе блок-схем, диаграмм и т.п., построенных по исходным текстам контролируемого ПО	-	-	+	=
4.	Динамический анализ исходных текстов программ				
4.1.	Контроль выполнения функциональных объектов	-	+	+	=
4.2.	Сопоставление фактических маршрутов выполнения функциональных объектов и маршрутов, построенных в процессе проведения статического анализа	-	+	+	=
5.	Отчётность	+	+	+	+

Сигнатура – это характерный признак уязвимости, используемый для её обнаружения. Все известные сигнатуры попадают в специализированную базу данных, исходя из которой и проводится поиск опасных конструкций. Эффективность метода сводится к оперативности пополнения базы сигнатур.

9.2. Обзор программных реализаций текстовых анализаторов

Мировой рынок богат множеством программных средств, позволяющих анализировать исходный код. Согласно исследованию, проведенному в 2017 году консалтинговой компанией *Gartner*, лидерами среди разработчиков современных программ–анализаторов исходного кода являются компании IBM, HP и Checkmarx. Их продукция и представлена на рынке [118].

Российский рынок программ–анализаторов исходных кодов еще молод – первые программные продукты появились менее семи лет назад. Лидерами российского рынка являются Solar Security, Positive Technologies и In-foWatch. На рис. 9.1 представлен основной принцип работы программ–анализаторов.



Рисунок 9.1. Основной принцип работы анализаторов исходных кодов ПО

При проведении анализа исходных кодов используются различные базы данных, в которых содержатся известные на сегодняшний день уязвимости и программные ошибки. При создании анализатора подключают аналитиков, создающих собственные базы уязвимостей, которые в дальнейшем постоянно обновляются. Государственными базами занимаются регуляторы отдельных стран. В США компания MITRE занимается обслуживанием одной из самых крупных баз данных уязвимостей CWE – Common Weakness Enumeration. В России за обновлением аналогичных баз данных следит Федеральная служба по техническому и экспортному контролю (ФСТЭК России) [119].

Статический анализатор исходного текста HP Fortify Static Code Analyzer является статическим анализатором исходного текста, одним из лидеров на мировом рынке. Программа позволяет находить уязвимости с минимальными временными затратами. Поддерживает более 20 языков программирования, различные платформы, а также Web-приложения. В общей сложности, это программное средство было протестировано более чем на 15 тыс. образцах CLOC (*Count number of lines of code in file* – количество строк кода в файле) различного кода, при это число пропущенных ошибок приближается к нулю.

Большим недостатком такого программного средства является высокая стоимость, которая делает данный продукт недоступным для начинающих компаний-разработчиков. Работа с этой программой усложняется за счёт англоязычного интерфейса и отсутствия русскоязычной документации. Интерфейс HP Fortify Static Code Analyzer представлен на рис. 9.2.




Рисунок 9.2. Интерфейс HP Fortify Static Code Analyzer

Преимуществами HP Fortify Static Code Analyzer являются: высокое качество; большое число поддерживаемых сред разработки и языков программирования; низкая вероятность допущения ошибки; возможность модификации правил проверки и поддержка международных стандартов.

Статический анализатор программного кода IBM Security AppScan Source предназначен для статического анализа кода и позволяет обнаружить уязвимости на ранних этапах жизненного цикла программного обеспечения, обладает очень высокой скоростью сканирования программного кода, но поддерживает намного меньше сред разработки и языков программирования, чем анализатор исходного кода HP Fortify Static Code Analyzer.

Этот анализатор предназначен больше для разработчиков программного обеспечения, так как для работы с ним необходимы базовые знания в программировании. В его возможностях есть большое количество функций, предназначенных именно для программистов-разработчиков. Этот анализатор даёт более полную картину всех уязвимостей, с привязкой к исходному коду. На рис. 9.3 представлен интерфейс IBM Security AppScan Source.




Рисунок 9.3. Интерфейс IBM Security AppScan Source

Преимуществами IBM Security AppScan Source являются высокое качество программного продукта; взаимодействие между сотрудниками во время анализа исходного кода; удобство использования на этапе разработки программного продукта; возможность совмещения анализа исходного текста с автоматическим сканированием; высокая скорость работы.

Анализатор программного обеспечения и Web-приложений Checkmarx CxSAST является продуктом американо-израильской компании. Подходит для анализа как обычного программного обеспечения, написанного на различных языках программирования, так и для анализа Web-приложений. Поддерживает языки программирования Python, PHP, Perl и Java Script. Применим на любых этапах жизненного цикла ПО – от разработки до применения. Удобен тем, что все найденные им уязвимости классифицируются по степени риска – от незначительных до критических. Работа с этим анализатором облегчается за счёт функции визуализации анализируемого кода, которая позволяет построить блок-схему программы и увидеть программные переходы от функции к функции. Интерфейс Checkmarx CxSAST представлен на рис. 9.4.




Рисунок 9.4. Интерфейс Checkmarx CxSAST

Преимуществами Checkmarx CxSAST являются: большой перечень поддерживаемых языков программирования; возможность проводить анализ не только всего кода, но и определённых участков кода; высокая скорость работы; функция визуализации анализируемого кода и формирование отчёта.

Российский анализатор программного кода Solar inCode (Ростелеком).

Программный продукт предназначен для поиска недеklarированных возможностей и уязвимостей. Анализатор имеет возможность сканирования исполняемых и бинарных файлов на уязвимости. Поддерживает 20 языков программирования и интегрируется в большое число сред разработки [120].

Одним из главных преимуществ, по сравнению с зарубежными аналогами, является русскоязычная документация и русскоязычный интерфейс. Низкая стоимость позволяет использовать этот программный продукт даже небольшим компаниям. Программный анализатор Solar inCode активно используется российскими компаниями для сертификации кода и поиска недеklarированных возможностей [121]. Интерфейс Solar inCode представлен на рис. 9.5.




Рисунок 9.5. Интерфейс Solar inCode

Преимуществами Solar inCode являются анализ кода без использования исходных текстов программ; формирование рекомендаций по настройке средств защиты и по устранению уязвимостей; наличие русскоязычной документации и интерфейса; поддержка более 20 языков программирования; обеспечение выполнения требований приказа ФСТЭК России от 11.02.2013 №17 «Об утверждении требований по защите информации, не составляющей государственную тайну, содержащейся в государственных информационных системах»; низкая стоимость по сравнению с зарубежными аналогами [122].

Application Inspector (продукт компании Positive Technologies). Этот анализатор отличается тем, что в первую очередь нацелен на поиск уязвимостей тестируемого ПО, а затем выявляет общие ошибки программного обеспечения.

Помимо того, что этот анализатор способен показывать уязвимые участки кода и составлять отчёты, он позволяет создавать эксплойты — небольшие исполняемые модули, которые позволяют демонстрировать последствия найденных уязвимостей. С помощью такой функции становится возможным увидеть на практике, к каким последствиям могут привести найденные уязвимости. Интерфейс Application Inspector представлен на рис. 9.6.




Рисунок 9.6.Интерфейс Application Inspector

Преимущества Application Inspector заключаются в наличии русскоязычной документации и интерфейса; возможности анализа Web-приложений; удобство для разработчиков и для заказчиков; обеспечение выполнения требований приказа ФСТЭК России от 11.02.2013 №17 «Об утверждении требований о защите информации, не составляющей государственную тайну, содержащейся в государственных информационных системах»; низкая стоимости, и в наличии функции визуализации найденных уязвимостей программного кода.

Российский программный продукт *InfoWatch Appercut* предназначен для отечественных заказчиков ПО. Поддерживает практически все языки Web – программирования, обеспечивает все требования безопасного и эффективного программирования. Интерфейс InfoWatch Appercut представлен на рис. 9.7.




Рисунок 9.7. Интерфейс InfoWatch Appercut

Преимущества InfoWatch Appercut заключаются в том факте, что этот программный продукт был сертифицирован ФСТЭК России; написан на русском языке (русскоязычная документация и интерфейс); имеет высокую скорость сканирования программного кода; способен проверять измененные участки сканируемого кода; поддерживает все известные бизнес-платформы.

AppChecker (российский программный продукт ЗАО НПО «Эшелон»). Эта компания является испытательной лабораторией Министерства обороны, ФСБ и ФСТЭК России, и имеет огромный опыт в области динамического и статического анализа исходных кодов программного обеспечения. Анализатор *AppChecker* предназначен для анализа Web-приложений. Этот программный продукт еще молод, но активно развивается за счёт постоянно обновляемой базы данных сигнатур. Он позволяет выполнять требования ГОСТ Р56939 и стандарт Банка России ИББС-2.6-2014. Недостатком программного продукта является отсутствие возможности анализа встраиваемого кода.

Программный интерфейс AppChecker представлен на рис. 9.8.




Рисунок 9.8. Интерфейс AppChecker

Преимуществами «Эшелон» AppChecker являются: возможность поиска более 100 типов ошибок, дефектов кодирования и программных закладок; постоянно пополняемая база сигнатур; проведение аудита одновременно несколькими экспертами; русскоязычный интерфейс и документация.

9.3. Искусственные нейронные сети для поиска уязвимостей и опасных конструкций в исходных текстах программного кода

В рамках исследовательского проекта разрабатывается программное обеспечение, осуществляющее поиск опасных конструкций и уязвимостей в исходных текстах программ, с помощью искусственных нейронных сетей.

Искусственная нейронная сеть (ИНС) – это математическая модель, а также её аппаратная и/или программная реализация, построенная по принципу организации и функционирования биологических нейронных сетей. ИНС состоит из трёх типов слоёв: входного, скрытого и выходного. ИНС с одним скрытым слоем представлена на рис. 9.9. Она представляет собой систему соединенных и взаимодействующих между собой несложных процессов (искусственных нейронов). На вход каждого нейрона подается сигнал, который обрабатывается специальной функцией и передается нейронам скрытого слоя.




Рисунок 9.9. Графическое изображение искусственной нейронной сети

Искусственные нейроны, объединенные в большую сеть, способны решать довольно трудные задачи. Основным отличием ИНС от других алгоритмов является возможность обучения и самостоятельного принятия решений [123].

9.3.1. Алгоритм обучения искусственных нейронных сетей

Возможность обучения нейронной сети – её главное преимущество перед традиционными алгоритмами. С технической точки зрения, процесс обучения заключается в нахождении оптимальных коэффициентов связей (весов) между нейронами. Изначально веса выбираются случайным образом, на интервале от -0.5 до 0.5 . Алгоритм обучения нейронной сети показан на рис. 9.10.




Рисунок 9.10. Процесс обучения нейронной сети

В процессе своего обучения нейронная сеть способна выявить сложные зависимости между входными и выходными данными. Перед обучением ИНС необходимо подготовить данные, на которых будет обучаться нейросеть [124].

Обучающая выборка представляет собой значения, подаваемые на входной слой, и результат – ответ, ожидаемый на выходном слое нейронной сети.

Внутри искусственного нейрона хранятся активационная и сумматорная функции. Сумматорная функция выглядит всегда одинаково и представляет собой сумму всех поступивших на вход сигналов, умноженных на их вес:

$$net = x_1w_1 + x_2w_2 + \dots + x_nw_n = \sum_{i=1}^n x_iw_i \quad (9.1)$$

Результат работы сумматорной функции называется *взвешенной суммой*. Далее, нейрон должен обработать результат сумматорной функции с помощью *функции активации*, чтобы получить адекватный сигнал, с которым сеть будет работать дальше. На рис. 9.11 схематически изображен весь процесс работы активационной и сумматорной функции одного искусственного нейрона.




Рисунок 9.11. Графическое изображение работы искусственного нейрона

Выбор функции активации искусственной нейронной сети является важной задачей, и осуществляется, исходя из типа решаемой задачи [125].

9.3.2. Функция активации выходного сигнала искусственного нейрона

Функция активации обрабатывает результат сумматорной функции, и определяет выходной сигнал искусственного нейрона. Для разных нейронных сетей и типов решаемых задач используют разные функции активации.

Существует много функций активации, но самые известные из них – это: сигмоидальная функция, гиперболический тангенс, ReLU (Rectified Linear Unit – наиболее часто используемая функция активации при глубоком обучении. Она возвращает 0, если принимает отрицательный аргумент, а в случае положительного аргумента функция возвращает само число).

Сигмоидальная функция активации, или сигмоид, выражается формулой:

$$f(x) = \frac{1}{1+e^{-x}} \quad (9.2)$$

Такая функция, монотонно возрастающая, и везде дифференцируемая, является S-образной функцией. На рис. 9.12 показан её график.




Рисунок 9.12. График сигмоидальной функции

Эта функция позволяет усиливать слабые сигналы. Сигмоида нашла широкое применение в нейронных сетях, так как она легко интерпретируется: от отсутствия активации (0), до полной активации (1). Данная функция имеет массу преимуществ: сигмоида – нелинейная аналоговая функция, а это значит, что и комбинация сигмоидальных функций будет также нелинейной аналоговой функцией; она подходит для решения задач классификации, кроме того, сигмоида является дифференцируемой функцией на всём отрезке.

Гиперболический тангенс принимает на вход произвольное число, а на выходе выдаёт вещественное число в интервале от –1 до 1; выражается формулой:

$$f(x) = \tanh(x) = \frac{2}{1+e^{-2x}} - 1 \quad (9.3)$$

Внешне гиперболический тангенс похож на сигмоидальную функцию. На рис. 9.13 представлен график функции гиперболического тангенса.




Рисунок 9.13. График гиперболического тангенса

Функция имеет схожие свойства с сигмодой. Она также является нелинейной, и хорошо подходит для комбинации слоев. Однако значение производной у неё значительно больше, чем у сигмоидальной функции.

Функция *ReLU* (*Rectified Linear Unit* – *выпрямленный линейный блок*) в последнее время используется всё шире. Она выражается формулой:

$$f(x) = \max(0, x) \quad (9.4)$$

Функция ReLU реализует простой переход в нуле, и возвращает значение x в случае, если x положительно. В противном случае, функция возвращает значение 0. На рис. 9.14 представлен график функции ReLU.




Рисунок 9.14. График функции ReLU

Данная функция начинает набирать популярность среди разработчиков нейронных сетей, так как имеет свои преимущества по сравнению другими функциями активации: простоту вычисления; отсутствие подверженности насыщению; повышение скорости сходимости; хорошая аппроксимируемость.

Корректировка весовых коэффициентов при обучении нейронной сети. На вход сети подается обучающая выборка с известным значением *ожидания ответа сети*. Ошибка нейронной сети рассчитывается по формуле:

$$\delta = y_0 - y \quad (9.5)$$

В соответствии с полученным значением ошибки сети, корректируются весовые коэффициенты. Такая операция повторяется много раз, до тех пор, пока ошибка сети не становится ничтожно малой. Результатом многократной корректировки весов становится обученная нейронная сеть [126].

Алгоритмов корректировки весов существует множество, но наиболее известен алгоритм обратного распространения ошибки.

Алгоритм обратного распространения ошибки (backpropagation) подходит для многослойных нейронных сетей. Его суть состоит в отрегулировании каждого веса пропорционально тому, насколько он соответствует общей ошибке. Этот алгоритм определяют два потока в нейронной сети. *Входные сигналы* распространяются в *прямом направлении*, в результате которого можно получить ответ сети, рассчитать её ошибку. В то же время, *величина ошибки* распространяется в *обратном направлении*, корректируя все весовые коэффициенты. Ошибка каждого нейрона сети рассчитывается по формуле:

$$\delta_j = \dot{f}(net_j) * \sum_k \delta_k * w_{jk} \quad (9.6)$$

Алгоритм хорош тем, что обеспечивает корректировку нейронов скрытого слоя, что позволяет ещё качественнее обучить искусственную нейронную сеть.

9.4. Алгоритмическая реализация процесса анализа исходных текстов программного обеспечения

Основные этапы анализа исходных текстов ПО представлены на рис. 9.15.

- обучение искусственной нейронной сети, в результате которого строится и формируется ИНС с определенными весовыми зависимостями;
- анализ исходного текста разработанного программного обеспечения, в целях нахождения в нём всех потенциально опасных конструкций;
- применение искусственных нейронных сетей для анализа найденных в программном обеспечении потенциально опасных конструкций.



Рисунок 9.15. Этапы работы программы – анализатора исходных текстов программы

Главный вопрос, который надо решить задолго до этапа создания программного средства – это разработка структуры модели нейронной сети. Модель ИНС строится, исходя из вида решаемой задачи, и на базе исходных данных подбираются следующие параметры сети: количество скрытых слоев; принцип работы нейронной сети; способы её обучения; функция активации.

9.4.1. Построение искусственной нейронной сети

Решение задачи поиска заданных конструкций относится к классу задач типа «классификация объекта». Задача классификации – это задача, имеющая дело с множеством объектов (ситуаций), разделённых на некие классы.

Для решения таких задач нужно создать конечное множество объектов, для которых известна их принадлежность к определенному классу. Такое множество называется *обучающей выборкой*. Классовая принадлежность остальных объектов неизвестна. Требуется обучить нейронную сеть так, чтобы она могла классифицировать произвольный объект из исходного множества, то есть присвоить ему номер класса, к которому он относится [127].

Наиболее эффективной искусственной нейронной сетью для решения поставленных исследовательских задач данного типа является многослойная нейронная сеть прямого распространения с одним скрытым слоем.

Нейронная сеть *прямого распространения* – это сеть, все связи которой направлены непосредственно от входных нейронов к выходным. В обратном направлении в такой сети сигнал не распространяется. В качестве функции активации используется сигмоидальная функция, представленная на рис. 9.16.




Рисунок 9.16. График сигмоидальной функции

Сигмоидальная функция активации выражается формулой:

$$f(x) = \frac{1}{1+e^{-x}} \quad (9.7)$$

За счёт своего максимального и минимального значения, результаты такой функции могут интерпретироваться как вероятность отношения объекта к определённому классу, где 0 – это 0% вероятность, а 1 – это 100% вероятность, что объект относится к данному классу.

9.4.2. Обучение искусственной нейронной сети

Существует два подхода к обучения нейронной сети: обучение с учителем и обучение без учителя. Обучение *без учителя* применяется тогда, когда правильного ответа нет, и решаются задачи типа *кластеризации* объекта.

Исходя из поставленной задачи, в данном случае для обучения ИНС целесообразно применить подход обучения *с учителем*. Суть этого подхода заключается в том, что на вход подается сигнал, а на выходе полученный ответ сравнивается с уже готовым, правильным ответом. После этого, с помощью выбранного алгоритма, изменяются веса связей нейронной сети.

В качестве метода обучения выбран метод *обратного распространения ошибки*, минимизирующий разницу между реальным и ожидаемым выходами искусственной нейронной сети, за счёт изменения весов синопсисов.

Перед использованием ИНС для решения задач на практике, необходимо собрать *обучающую выборку* задач с готовыми ответами. Выборка должна быть достаточной, но не иметь избыточной информации. Если обучающая выборка слишком мала, то обучение нейронной сети не может привести к качественной корректировке весовых зависимостей. Если же обучающая выборка избыточна, то обучение ИНС займет слишком много времени.

Так как процесс обучения является самым ресурсозатратным этапом работы анализатора, то для того, чтобы качественно скорректировать весовые зависимости и, исходя из мощности средств вычислительной техники, затратить на обучение минимальное количество времени, необходимо соблюдать золотую середину. На рис. 9.17 представлена общая схема обучения нейронной сети.

Обучение будет проходить до тех пор, пока разница между ожидаемым и реальным ответом не будет достаточно мала (не превышать заранее заданной погрешности). В качестве алгоритма *корректировки весов* был выбран метод *градиентного спуска*, алгоритм которого представлен на рис. 9.18.




Рисунок 9.17. Блок–схема алгоритма общей схемы обучения искусственной нейронной сети



Рисунок 9.18. Блок–схема алгоритма метода градиентного спуска

Для успешного применения этого метода необходимо, чтобы функция активации была дифференцируема. Этому условию как раз и удовлетворяет сигмоидальная функция, производная которой рассчитывается по формуле:

$$\dot{f}(x) = f(x) * (1 - f(x)). \quad (9.8)$$

Новое значение весового коэффициента рассчитывается по формуле (9):

$$w_{ij}^l = w_{ij}^l + d_j^l * \dot{f}(x_j^l) * f(x_j^l) * a. \quad (9.9)$$

9.4.3. Процесс анализа исходного текста программного кода

После завершения процесса обучения искусственной нейронной сети, можно приступить к анализу исходного текста программы. Для этого нужно сформировать массив из возможных потенциально опасных конструкций, которые в дальнейшем будет искать и анализировать нейронная сеть.

Этот процесс не занимает много времени, и является подготовительным этапом перед поиском и анализом потенциально опасных конструкций, а также оставлением итогового отчёта. Основной задачей является подготовка нужных данных перед заключительным этапом работы программы–анализатора исходных текстов программы, учитывая, что эта программа сможет анализировать текст, написанный на любом языке программирования.

После формирования массива потенциально опасных конструкций, обучения ИНС и качественного корректирования весовых зависимостей, можно приступать к заключительному этапу работы программы.

На вход нейронной сети, по одной, подаются сигнатуры потенциально опасных конструкций. На выходном нейроне, сеть выдаёт результат – ответ о том, принадлежит ли конкретная сигнатура к классу опасных конструкций. За счёт использования сигмоидальной функции активации – нейрона с удобной процентной интерпретацией, выдаётся вероятность отношения найденной конструкции к тому или иному классу, что позволит тестировщику, в спорных моментах, самому принять окончательное решение о принадлежности.

9.5. Программное конструирование программы–анализатора

9.5.1. Обоснование выбора языка программирования – Python

В качестве языка программирования для реализации программного средства был выбран высокоуровневый кроссплатформенный язык Python. Синтаксис языка минималистичен, за счёт чего повышается читаемость кода и появляются дополнительные удобства при написании программного кода. Стандартные библиотеки Python включает в себя большой объём полезных функций. Язык Python имеет характерные черты, которые выделяют его среди других языков: динамическую типизацию; поддержку многопоточных вычислений; автоматическое управление памятью; полную интроспекцию; механизм обработки исключений; высокоуровневые структуры [128].

Кроме того, Python поддерживает библиотеки, предназначенные для построения искусственных нейронных сетей и анализа больших массивов данных. Это современный и активно развивающийся язык программирования. Его новые версии, с добавлением и изменением языковых свойств, выходят в среднем раз в два года, что позволяет Python долгое время быть одним из самых применяемых языков программирования. В настоящий момент Python занимает третье место в рейтинге популярности языков TIOBE [128].

9.5.2. Выбор интегрированной среды разработки и обучения

В настоящее время для Python существует большой выбор сред разработки, среди которых есть платные и бесплатные. Оптимальной средой, по мнению авторов, является Python IDLE – эта среда разработки является бесплатной, она достаточно удобна и эффективна при разработке и отладке программных средств, написанных на языке Python. Это интегрированная среда разработки и обучения создана на базе библиотеки Tkinter, со встроенным интерпретатором, обеспечивающим работу программ. Благодаря использованию Tkinter, среда IDLE может быть использована на различных платформах, среди которых Windows, Mac OS, Unix подобные операционные системы.

9.5.3. Описание основных модулей программного средства

Опишем используемые библиотеки и основные функции, созданные в процессе реализации программного кода. Функции призваны обеспечивать корректную работу программы, а разработанный графический интерфейс позволяет пользователю использовать весь функционал программного средства, оберегая пользователей от ошибок и от нарушения работы программы.

Графический интерфейс программы–анализатора был создан с помощью Tkinter–стандартной кроссплатформенной библиотеки Python, предназначенной для организации диалогов с помощью оконного графического интерфейса.

Для разработки модели нейронной сети была использована библиотека NumPy, являющаяся модулем с открытым исходным кодом, представляющим собой общие математические и числовые операции в виде скомпилированных быстрых функций. NumPy предоставляет реализации вычислительных алгоритмов и осуществляет поддержку многомерных массивов, а также высокоуровневых математических функций для их обработки.

Библиотеку NumPy часто рассматривают в качестве альтернативы системе компьютерной математики MatLab, из-за схожего функционала.

Опишем основные функции разработанного программного средства – анализатора исходных текстов. Эти функции имеют следующее назначение:

examples_creator – функция принимает на вход обучающую выборку в формате .txt, структурирует её и поэлементно переводит в кодировку ASCII.

save_examples – функция принимает на вход закодированную обучающую выборку и сохраняет её в формате .txt в виде массива NumPy.

insert_text – позволяет выбрать файл, в котором содержится обучающая выборка, за счёт открытия рабочей директории. После того, как пользователь выбрал файл, имя файла вставляется в объекты *Text* и *Entry* и добавляется в отчёт, который будет сформирован в конце работы программы.

layer_creator – на вход функции подается элемент из обучающей выборки, на основании которого строится модель выбранной нейронной сети, с определенным количеством скрытых слоёв и передаточной функцией.

weight_creator – генерирует весовые зависимости между нейронами сети. Весовые зависимости выбираются случайным образом, в промежутке между -0.5 до $+0.5$. Функция добавляет смещение весовых коэффициентов, результат её работы – матрица из весовых коэффициентов и смещений.

learning_first_layer – на вход функции подается вектор из обучающей выборки весовых коэффициентов первого слоя и смещения нейронов первого слоя. Вектор обучающей выборки активирует нейронную сеть и подготавливает входной слой для обучения сети, активирует сумматорную и активационную функции. Результат работы функции – активационный и сумматорный векторы.

learning_hidden_layer – на вход функции подаётся результирующий вектор предыдущего слоя, весовые коэффициенты скрытого слоя и смещения нейронов скрытого слоя. Данная функция вычисляет сумматорную и активационную функции для каждого нейрона скрытого слоя. Результат работы – сумматорная функция и ответ искусственной нейронной сети.

sigmoid – функция предназначена для вычисления активационной функции. Работает как с числами, так и с векторами поэлементно.

summator – функция предназначена для вычисления сумматорной функции. Работает как с числами, так и с векторами поэлементно.

button_learn – активирует процесс обучения нейронной сети, после нажатия кнопки УЧИТЬ. После окончания обучения, в текстовом поле Text добавляется запись о том, что нейронная сеть успешно обучена.

error_net – на вход функции подаётся ожидаемое и реальное значение сети. Функция предназначена для расчёта ошибки нейронной сети.

error_correction – на вход подаётся ошибка сети и весовые коэффициенты. Функция предназначена для расчёта ошибки каждого нейрона, входящего в сеть.

weight_correction – на вход подается вектор из обучающей выборки, весовые коэффициенты всех нейронов, входящих в сеть, смещения весов, коэффициент ошибки всех нейронов, входящих в сеть, вектор сумматорной функции, вектор функции активации, значение ошибки сети. Эта функция предназначена для корректировки всех весовых зависимостей, исходя из полученной ошибки сети. Результат её работы – исправленные весовые коэффициенты и смещения всех весов нейронов, входящих в сеть.

sigmoid_prime – предназначена для расчёта производной функции активации. Функция работает как с числами, так и с векторами поэлементно.

insert_text – позволяет выбрать файл, который в дальнейшем будет анализироваться на содержание опасных конструкций в исходных текстах программы, за счёт открытия рабочей папки с файлами. Можно выбрать исходный текст программы, написанный на любом языке программирования. После выбора файла, его имя вставляется в объекты Text и Entry и добавляется в отчёт, который будет сформирован в конце работы программы.

button_analyze – активирует процесс анализа исходного текста программы. После окончания процесса анализа, запись об успешном завершении добавляется в текстовое поле Text. Эта запись позже будет добавлена в отчёт.

similar_construction – на вход функции подается и анализируется исходный текст программы. В массив добавляются потенциально опасные конструкции.

code_constructions – принимает на вход массив потенциально опасных конструкций, структурирует его и поэлементно переводит в кодировку ASCII.

net_activation – на вход, по одному, подаются векторы из массива потенциально опасных конструкций. Вектор активирует нейронную сеть, сигнал проходит по первому слою, рассчитывается сумматорная и активационная функции и передаются скрытым слоям нейронной сети. Результат работы функции – активационный и сумматорный вектор.

9.6. Тестирование модулей разработанного программного средства

Рассмотрим пример работы разработанной программы–анализатора. На рис. 9.19 продемонстрирован интерфейс программного средства.




Рисунок 9.19. Интерфейс программы–анализатора исходных текстов программ

Разработанный интерфейс минималистичен, чтобы пользователь мог легко разобраться с программным средством и не допустить ошибок, которые могут привести к некорректной работе программы. Интерфейс включает:

- окно для ввода документа, в котором хранится обучающая выборка;
- окно для ввода документа, хранящего в себе код программного средства, который в дальнейшем будет проходить процедуру анализа;
- кнопку «Учить», запускающую процесс обучения ИНС;
- кнопку «Анализ», нажатие которой инициирует процесс анализа исходного текста выбранной программы и поиска в нём опасных конструкций;
- текстовое поле, в котором ведется отчёт о ходе выполнения программы.

Сначала необходимо выбрать документ, в котором хранится обучающая выборка. На рис. 9.20 представлен скриншот программы.




Рисунок 9.20. Загрузка обучающей выборки

После того, как обучающая выборка была загружена, в отчёт заносится информация о ней. Далее необходимо нажать кнопку «Учить», запускающую процесс обучения искусственной нейронной сети. Этот процесс занимает много времени. Скорость обучения нейронной сети зависит от нескольких факторов: от мощности компьютерной техники, на которой работает программное средство; от параметров нейронной сети; и от размера обучающей выборки.

На рис. 9.21 представлен результат работы программы–анализатора:




Рисунок 9.21. Окончание обучения нейронной сети

Когда нейронная сеть полностью обучена, она готова к анализу исходного кода. После окончания процесса обучения, в отчёт добавляется информация: «Искусственная нейронная сеть успешно обучена», которая сигнализирует пользователю, что можно выбирать исходный код программы и переходить к заключительному этапу работы анализатора – поиску опасных конструкций.

На рис. 9.22 представлен результат выбора исходного кода программы.




Рисунок 22 – Выбор исходного кода программы

Информация о выбранном коде также заносится в отчёт.

Далее нужно нажать кнопку «Анализ» и перейти к заключительному этапу работы программы. Сначала анализатор проверяет исходный текст в поисках заданных опасных конструкций. Программа сохраняет найденные конструкции в двумерном массиве. Затем, только что сформированный массив с набором данных проходит через обученную искусственную нейронную сеть. Параллельно формируется отчёт о найденных опасных конструкциях с вероятностью их принадлежности к тому или иному классу. На рис. 9.23 представлен результат работы анализатора исходных текстов программы.




Рисунок 9.23. Поиск заданных опасных конструкций. Пример 1

В этом примере программный анализатор нашёл заданную конструкцию и отнёс ее к классу опасных конструкций с вероятностью 73,86%. На рис. 9.24 представлена найденная конструкция в исходном тексте программы.

```
import MySQLdb

db = MySQLdb.connect(host="194.45.123.165",
                     user="bergenson",
                     passwd="qwerty123",
                     db="data")
cur = db.cursor()
cur.execute("SELECT * FROM SECRET_LIST")
```

Рисунок 9.24. Заданная конструкция в исходном тексте программы

Такая конструкция действительно является опасной, так как в данной переменной хранится пароль, и с её помощью потенциальный злоумышленник может организовать несанкционированный доступ к данным программы.

Протестируем программный анализатор на другом исходном тексте.

На рис. 9.25 представлен результат работы программы.




Рисунок 9.25. Поиск заданных опасных конструкций. Пример 2

Программный анализатор нашел одну заданную конструкцию, и отнес её к классу потенциально опасных конструкций с вероятностью 61,48%. На рис. 9.26 найденная конструкция представлена в исходном тексте программы.

```
login = input()
paroli = input()

class Product(db.Model):
    __tablename__ = 'products'
    id = db.Column(db.Integer, primary_key= True)
    name = db.Column(db.String(255))
```

Рисунок 9.26. Заданная конструкция в исходном тексте программы

Такая конструкция действительно является потенциально опасной, так как в данной переменной хранится пароль, и с её помощью возможный хакер может организовать несанкционированный доступ к данным программы.

Протестируем программный анализатор на другом исходном тексте программы. На рис. 9.27 представлен результат работы программы.




Рисунок 9.27. Поиск заданных конструкций. Пример 3

Анализатор нашел две заданные потенциально опасные конструкции. Конструкция *keyword* возможно является опасной с вероятностью 59,86%, а конструкцию *passport* анализатор опасной не считает, так как её вероятность принадлежности к классу опасных конструкций составляет всего 24,78%.

На рис. 9.28 представлена первая найденная конструкция в исходном тексте программы. Такая конструкция действительно является потенциально опасной, в так как в этой переменной хранится пароль, и с её помощью может быть организован несанкционированный доступ к данным программы. На рис. 9.29 показана вторая найденная конструкция в исходном тексте программы.

```
Keyword = {
    'user1': 'qwerty123',
    'user2': '12345678',
    'user3': 'asdfghjkl',
    'user4': 'AsDfGeSfE',
}
```

Рисунок 9.28. Найденная первая заданная конструкция в исходном тексте программы

```
passport = {
    'number': None,
    'name': None,
    'surname': None,
    'dateOfBirth': None,
}
```

Рисунок 9.29. Найденная вторая заданная конструкция в исходном тексте программы

Найденная переменная не содержит пароль, а значит, конструкция не является потенциально опасной, и хакеры не смогут ею воспользоваться.

Чтобы подвести итоги в вопросе о работоспособности искусственной нейронной сети, а также оценить степень влияния искажения вредоносной последовательности на результаты, необходимо провести обучение ИНС на выявление одной сигнатуры. В ходе проверки моделируются ситуации, в которых заданная потенциально опасная конструкция будет искажаться на 12,5%, 25%, 37,5% и 50%. Для каждой ситуации необходимо провести по 100 проверок. Результаты тестирования приведены в табл. 9.2.

Таблица 9.2. Значения вероятностей ошибок первого и второго рода

Оцениваемая характеристика	Искажение сигнатуры			
	0,125	0,25	0,375	0,5
Количество проверок	100	100	100	100
Вероятность ошибок первого рода	1%	4%	19%	36%
Вероятность ошибок второго рода	0%	0%	1%	3%

Ошибка первого рода состоит в том, что будет отвергнута правильная гипотеза. Ошибка второго рода состоит в том, что будет принята неправильная гипотеза. В случае поиска опасных конструкций важно, чтобы не была отвергнута правильная гипотеза, то есть необходимо следить за вероятностью ошибки первого рода. Результат тестирования показал, что незначительное отклонение от заданной последовательности не оказывает существенного влияния на их выявление. Из этого можно сделать вывод, что использование искусственных нейронных сетей для выявления заданных опасных конструкций является более эффективным решением, чем поиск по базе уязвимостей, так как позволяет выявлять не только те конструкции, которые уже есть в базе данных, но и подозрительные участки программного кода.

Подводя итоги, нужно отметить, что вопрос информационной безопасности является очень важным – необходимо, чтобы информация ограниченного доступа, обрабатываемая программным средством, не попала к третьим лицам, иначе цена утечки данных может варьироваться от ущерба, принесённого одному человеку, до ущерба, принесённого целому государству. Поэтому, при работе с информацией ограниченного доступа так важно использовать только программные средства, прошедшие процесс сертификации.

10. ПОДСИСТЕМА ПОДДЕРЖКИ ПРИНЯТИЯ РЕШЕНИЙ ПРИ ИДЕНТИФИКАЦИИ ОБЪЕКТОВ КРИТИЧЕСКОЙ ИНФОРМАЦИОННОЙ ИНФРАСТРУКТУРЫ

Развитие информационной инфраструктуры Российской Федерации состоит из таких важных этапов, как: улучшение российских центров обработки и хранения данных, развитие сетей связи нового поколения, внедрение цифровых платформ работы с данными. К 2024 году в нашей стране должны быть реализованы следующие задачи: доступ 97% граждан к высокоскоростному Интернету с устойчивым покрытием по всей стране, и устойчивое покрытие во всех крупных городах сетей связи 5G.

С развитием информационных технологий, как во всём мире, так и в нашей стране, остро встала проблема обеспечения информационной безопасности и защиты данных. За последнее десятилетие число и уровень сложности кибератак со стороны, как *прогосударственных хакерских групп*, так и *финансово мотивированных киберпреступников*, значительно возросли. Люди, компании и государственные организации не уверены в безопасности киберпространства, а также в целостности и защищённости своих персональных данных.

Интернет стал кровеносной системой нашей цивилизации. Однако свобода коммуникаций и глобальные возможности, которые даёт Интернет всё чаще оказываются под угрозой: слив и утечка данных, кибератаки со стороны враждебных государств – это реалии, в которых сегодня живёт каждый из нас. Яркий пример: вредоносная программа, сетевой червь, и программа-вымогатель денежных средств – шифровальщик WannaCry. Он оказался способен быстро распространяться по Интернету и локальным сетям. В первый день атаки было заражено более 300 000 персональных компьютеров более чем в 75 странах мира. В результате четырёхдневной эпидемии, шифровальщик полностью вывел из строя более 200 000 персональных компьютеров, в том числе и критическую информационную инфраструктуру Британии.

Ещё один пример вредоносного программного обеспечения, влияющего на функционирование критической информационной инфраструктуры – это Stuxnet, часто называемый *выстрелившим кибероружием*. Этот вредонос в Иране вывел из строя центрифугу для обогащения урана, замедлив, тем самым, иранскую ядерную программу на несколько лет. Червь сумел быстро распространиться через USB флэшки, проникая даже в те компьютеры, которые не были подключены к сети Интернет.

До появления Stuxnet, в сфере промышленной автоматизации не было принято задумываться об активной информационной безопасности – многие специалисты считали, что изоляция программных комплексов от глобальных сетей общего пользования сама по себе является надёжной защитой.

В связи с возникшей проблемой, остро встал вопрос не просто об обеспечении информационной безопасности, а о выделении, как особой категории, отдельной, *критически важной информационной инфраструктуры*. Нарушение или прекращение её работы может серьёзным образом повлиять на функционирование как организации, так и государства в целом [129].

Впервые понятие *критической информационной инфраструктуры* (далее КИИ) было закреплено в «Доктрине информационной безопасности Российской Федерации № 646» утверждённая указом Президента от 5 декабря 2016 года. Так, в рассматриваемом документе одним из национальных интересов в информационной сфере явилось обеспечение устойчивого и бесперебойного функционирования информационной инфраструктуры, и в первую очередь, критической информационной инфраструктуры Российской Федерации. В 2018 вступил в силу Федеральный закон от 26 июля 2017 года №187 «О безопасности критической информационной инфраструктуры Российской Федерации», вскоре стали появляться и подзаконные нормативно–правовые акты, которые более детально описывали процессы обеспечения безопасности КИИ. Например, в Постановлении правительства № 127 от 8 февраля 2018 года «Об утверждении Правил категорирования объектов критической информационной инфраструктуры Российской Федерации, а также перечня показателей критериев значимости объектов критической информационной инфраструктуры Российской Федерации и их значений» говорится о том, что такое категорирование, какие объекты критической информационной инфраструктуры являются значимыми, какие должностные лица субъекта КИИ должны входить в состав комиссии по категорированию, что такое показатели критериев значимости, и другие, не менее важные вопросы.

Проблему безопасности КИИ всё чаще поднимают на конференциях, форумах и семинарах, посвящённых информационной безопасности, о чём свидетельствует «ИнфоФорум 2020», на котором одна из главных тем была посвящена безопасности КИИ [130]. Выделение особой категории критической информационной инфраструктуры, как отдельного раздела информационной безопасности, произошло в 2018 году. В связи с этим, у специалистов по информационной безопасности возникает много вопросов.

Тема безопасности критической информационной инфраструктуры РФ достаточно обширна, поэтому вскоре, после принятия закона, стали появляться программные решения, целью которых является упрощение того или иного этапа в комплексном обеспечении безопасности КИИ. Своё решение предлагает «Лаборатория Касперского» [131], имеющая свои оригинальные программные продукты, направленные на безопасность КИИ и реализацию проектов центров Государственной системы обнаружения, предупреждения и ликвидации последствий компьютерных атак (ГосСОПКА). Компания «Код безопасности» предлагает решение [132], обеспечивающее широкий спектр программных продуктов для выполнения большинства технических мер защиты, направленных на все категории значимости объектов КИИ. Компания предлагает готовые решения на том этапе, когда объекты КИИ получили свои категории.

В настоящее время отсутствует информация о разработке программного продукта, который может уже на начальном этапе проводить идентификацию объектов КИИ с целью присвоения категории значимости. Таким образом, разработка подсистемы поддержки принятия решений идентификации объектов критической информационной инфраструктуры является актуальной.

Объектом исследования являются процессы подготовки и принятия решений должностными лицами субъекта критической информационной инфраструктуры РФ. *Предметом исследования* выступают методы описания и методики обработки данных при подготовке и принятии должностными лицами решений в отношении субъекта КИИ, в ходе построения системы безопасности объекта критической информационной инфраструктуры РФ.

Целью исследования является разработка подсистемы поддержки принятия решений идентификации объектов КИИ. Задачи исследования включают:

1. Изучение нормативно–правовой базы Российской Федерации в области обеспечения безопасности критической информационной инфраструктуры;
2. Исследование основных механизмов и методов теории принятия решений;
3. Формирование методики идентификация объектов КИИ;
4. Разработка структурной схемы и алгоритма работы подсистемы поддержки принятия решений в вопросах идентификации объектов КИИ;
5. Программная реализация подсистемы поддержки принятия решений идентификации объектов критической информационной инфраструктуры.

Для решения задач использованы методы системного анализа, теории принятия решений, теории искусственного интеллекта и экспертных оценок.

10.1. Теоретический анализ проблемы обеспечения безопасности критической инфраструктуры и методологии теории принятия решений

10.1.1. Методология теории принятия решений

Методика принятия оптимального решения, основанная на наблюдении и опыте, является главной частью практически всех сфер действия человека.

Основная задача сводится к рациональному выбору решения. Процесс принятия решений состоит из двух этапов. На первом, подготовительном этапе происходит уточнение, формализация и решение поставленной задачи. На втором, деловом этапе, результат предъявляется лицу, принимающему решение, который одобряет или отвергает его. Так, процесс принятия решений может стать бесконечным, поэтому важно, чтобы человек, принимающий решение, владел методом и мог самостоятельно поставить и решить задачу.

Главный принцип теории принятия решений сводится к тому, что лицо, принимающее решение, должно всегда выбирать альтернативу с предельно ожидаемой целесообразностью. В общем случае, задача теории принятия решений строится следующим образом: устанавливаются все возможные способы действия – альтернативы, последовательность альтернатив и числовое решение, цели участников процесса принятия решений, а также природа влияния на этот процесс различных случайных факторов.

После этого подбирается соответствующая модель и метод решения поставленной задачи. Модели принятия решений представлены на рис. 10.1.

Нормативная (классическая) модель позволяет лицу, принимающему решение (ЛПР) определить действенные пути решения задачи. Такая модель базируется на следующих экономических предположениях: ЛПР стремится к рациональному анализу поставленной задачи и к достижению понятных и согласованных целей, и старается продумать и просчитать все потенциальные варианты решения задачи и их последствия. Значимость нормативной модели сводится к тому, что она подталкивает менеджеров к рациональным решениям. Известность такой модели, во многом, связана с появлением различного рода количественных методов принятий решений с помощью персональных ЭВМ.

Дескриптивная (описательная) модель принятия решений основана на экспериментах, наблюдениях и эмпирических исследованиях, состоит из небольшого количества элементов и поясняет экономические соотношения так, как они существуют в настоящем мире, но в облегчённой форме.



Рисунок 10.1. Модели принятия решений

Такая модель описывает действительный процесс принятия решений в непростых ситуациях, когда менеджеры, даже если очень захотят, не смогут принять оптимальное экономическое решение. Дескриптивная модель принятия решений, в большинстве своём, основывается на интуиции управленцев. При интуитивном принятии решений используется проницательность и личный опыт больше, чем конкретные умозаключения или последовательная закономерность.

10.1.2. Анализ информации нормативно–правовой базы в области обеспечения безопасности критической информационной инфраструктуры

Система нормативно–правовых актов в области обеспечения безопасности критической информационной инфраструктуры включает в себя:

1. Федеральный закон №187 от 26 июля 2017 года «О безопасности критической информационной инфраструктуры Российской Федерации» [129].
2. Нормативные правовые акты Президента Российской Федерации.
3. Нормативные правовые акты Правительства Российской Федерации.
4. Нормативные правовые акты Федеральных органов исполнительной власти Российской Федерации в области критической инфраструктуры.

Основным документом в области обеспечения безопасности КИИ является упомянутый выше Федеральный закон №187, вступивший в силу 1 января 2018 года. В нём раскрываются важные понятия и определения, касающиеся КИИ, а также Государственной системы обнаружения, предупреждения и ликвидации последствий компьютерных атак (ГосСОПКА).

В законе также говорится об обязанностях и правах субъекта КИИ. Федеральным органом исполнительной власти, уполномоченным в области обеспечения безопасности критической информационной инфраструктуры является Федеральная служба по техническому и экспортному контролю РФ (ФСТЭК), являющаяся органом защиты государственной тайны, наделённой полномочиями по распоряжению сведениями, составляющими государственную тайну. Федеральным органом исполнительной власти, уполномоченным для обеспечения функционирования государственной системы обнаружения, предупреждения и ликвидации последствий кибератак на информационные ресурсы Российской Федерации является Федеральная служба безопасности России (ФСБ). Полный список нормативно – правовых актов в области обеспечения безопасности КИИ [133 – 150] представлен на рис. 10.2.

10.1.3. Государственная система предупреждения, обнаружения и ликвидации последствий компьютерных атак на информационные ресурсы Российской Федерации (ГосСОПКА)

При сборе информации для нормативно–правовой документации в области безопасности КИИ выявлен основной документ, в котором раскрывается понятие Государственной системы, отвечающей за обнаружение и ликвидацию последствий компьютерных (кибер–) атак (далее–ГосСОПКА). Такая система представляет собой единый территориально–распределенный комплекс, включающий в себя силы и средства, предназначенные для обнаружения, предупреждения и ликвидации последствий компьютерных атак, а также реагирования на произошедшие компьютерные инциденты [134, 144–146].

Федеральным органом исполнительной власти, отвечающим за надёжное функционирование ГосСОПКА, является ФСБ России. В систему ГосСОПКА входит национальный координационный центр по компьютерным инцидентам РФ (далее–НКЦКИ), в чьи обязанности входит решение следующих задач:

- анализ причин возникновения компьютерного инцидента;
- оказание методической помощи организациям, являющимися субъектами критической информационной инфраструктуры в случае необходимости;
- разработка рекомендаций по обнаружению и нейтрализации актуальных угроз информационной безопасности в отношении КИИ.

Система нормативных правовых актов в области обеспечения безопасности критической информационной инфраструктуры

Федеральный закон от 26 июля 2017 №187
"О безопасности критической информационной
инфраструктуры Российской Федерации"

Нормативные правовые акты Президента Российской Федерации

Указ Президента Российской Федерации от 25 ноября 2017 года №569 «О внесении изменений в Положение о Федеральной службе по техническому и экспортному контролю, утвержденное Указом Президента Российской Федерации от 16 августа 2004 года №1085»

Указ Президента Российской Федерации от 22 декабря 2017 года №620 «О совершенствовании государственной системы обнаружения, предупреждения и ликвидации последствий компьютерных атак на информационные ресурсы Российской Федерации»

Указ Президента Российской Федерации от 2 марта 2018 года №98 «О внесении изменений в Перечень сведений, отнесенных к государственной тайне, утвержденный Указом Президента Российской Федерации от 30 ноября 1995 года №1203»

Нормативные правовые акты Правительства Российской Федерации

Постановление Правительства Российской Федерации от 8 февраля 2018 года №127 «Об утверждении Правил категорирования объектов КИИ Российской Федерации, а также перечня показателей критериев значимости объектов критической информационной инфраструктуры Российской Федерации и их значений»

Постановление Правительства Российской Федерации от 17 февраля 2018 года №162 «Об утверждении Правил осуществления государственного контроля в области обеспечения безопасности значимых объектов КИИ»

Нормативные правовые акты федеральных органов исполнительной власти

Приказ ФСТЭК России от 21 декабря 2017 года №235

Приказ ФСТЭК России от 22 декабря 2017 года №236

Приказ ФСТЭК России от 25 декабря 2017 года №239

Приказ ФСТЭК России от 11 декабря 2017 года №229

Приказ ФСТЭК России от 6 декабря 2017 года №227

Приказ ФСБ России от 24 июля 2018 года №366

Приказ ФСБ России от 24 июля 2018 года №367

Приказ ФСБ России от 19 июня 2019 года №282

Приказ ФСБ России от 19 июня 2019 года №281

Приказ ФСБ России от 24 июля 2018 года №368

Приказ ФСБ России от 6 мая 2019 года №196

Приказ Минкомсвязи России «Об утверждении порядка, технических условий, установки и эксплуатации средств обнаружения, предупреждения и ликвидации компьютерных атак на сети связи»

Рисунок 10.2. Система нормативно–правовых актов в области обеспечения безопасности КИИ

Структура Государственной системы обнаружения, предупреждения и ликвидации последствий компьютерных атак представлена на рис. 10.3.

Структура ГосСОПКА



Рисунок 10.3. Структура системы ГосСОПКА

Субъект может работать с ФСБ напрямую, и направлять в национальный координационный центр по компьютерным инцидентам (НКЦКИ) уведомления и запросы посредством почтовой, телефонной или факсимильной связи.

В ходе исследования определено минимальное количество сотрудников и их режим работы, необходимый для надёжной работы центра ГосСОПКА.

Режим функционирования—график 24×7. Если рабочая смена сотрудников будет двенадцатичасовой, то получается две смены в сутки, по двенадцать часов, и, минимум, по два человека в самой смене. Нельзя забывать, как минимум, об одном «плавающем» сотруднике, для закрытия смены в случае отпусков и болезней. Итого, получается минимум 6–7 человек для режима 24×7, с часовым перекрытием в смене. Кроме того, нужно учитывать физиологию людей.

Исследованиями доказано, что после двенадцати минут непрерывного мониторинга аналитик пропускает 45% активности на мониторе. После 22 минут – не воспринимается уже 95% информации.

Поэтому нужно учитывать необходимость отдыха и ротации смен, а также фактор снижения работоспособности в обеденное время, и катастрофическое снижение активности и внимания сотрудников в ночное время.

В табл. 10.1 представлен количественный расчёт необходимого персонала для надёжного и бесперебойного функционирования центра ГосСОПКА.

Персонал Государственной системы обнаружения, предупреждения и ликвидации последствий компьютерных атак (ГосСОПКА)

Таблица 10.1.

<i>Персонал ГосСОПКА</i>		
<i>Первая линия</i>	<i>Режим работы</i>	<i>Количество</i>
1) Специалист по мониторингу	24×7	6
2) Специалист по обслуживанию средств защиты информации	8×5	1
<i>Вторая линия</i>		
3) Специалист по ликвидации последствий компьютерных атак на КИИ	8×5	2
4) Специалист по оценке защищённости КИИ	8×5	1
5) Специалист по оценке качества	Субподряд	
6) Пентестер (тестирующий безопасности)	Субподряд	
7) Специалист по расследованию инцидентов ИБ	Субподряд	
<i>Третья линия</i>		
8) Технический эксперт	8×5	2
9) Аудитор информационной безопасности	8×5	1
10) Аналитик–архитектор	8×5	1
11) Руководитель	8×5	1
Итого: как минимум, 15 сотрудников		

10.1.4. Система безопасности объекта критической инфраструктуры

Системы безопасности создают субъекты критической информационной инфраструктуры. Они включают правовые, организационные, технические и иные меры, направленные на обеспечение информационной безопасности (защиты данных) субъектов КИИ. Системы безопасности включают силы обеспечения безопасности значимых объектов КИИ (людей–специалистов) и используемые ими средства (программные и программно–аппаратные) обеспечения безопасности значимых объектов КИИ (рис. 10.4). Система безопасности объекта КИИ включает в себя также организационно–распорядительные документы, (ОРД) и инструкции, которыми должен руководствоваться персонал в процессе работы.

К силам обеспечения безопасности значимых объектов КИИ относятся:

1. Подразделения (работники) субъекта КИИ, ответственные за обеспечение безопасности значимых объектов критической информационной инфраструктуры.

Выделенное подразделение (специалисты), ядро обеспечения безопасности, может заниматься только обеспечением безопасности объектов КИИ.



Рисунок 10.4. Жизненный цикл СБО КИИ

Выделенное подразделение выполняет свои функции во взаимодействии с другими подразделениями, координирует их деятельность. Подразделения и специалисты, ответственные за обеспечение безопасности значимых объектов КИИ, выделяются в каждом филиале, обособленном структурном подразделении или дочернем предприятии.

Функции выделенного подразделения КИИ:

- разрабатывать предложения о выполнении требований нормативной базы;
- заниматься расследованием инцидентов информационной безопасности;
- заниматься обнаружением и детектированием компьютерных атак;
- координировать деятельность персонала выделенного подразделения КИИ при ликвидации последствий произошедших компьютерных атак.

2. *Подразделения (работники), эксплуатирующие значимые объекты КИИ* непосредственно обеспечивают безопасность объекта КИИ. Не принимают самостоятельных решений, а действуют либо по инструкциям и нормативным документам, либо по указаниям от руководства выделенного подразделения.

3. *Подразделения (работники), обеспечивающие функционирование (ремонт, обслуживание, сопровождение) значимых объектов КИИ.*

4. *Иные подразделения, участвующие в обеспечении информационной безопасности и защиты данных значимых объектов КИИ.*

К средствам, необходимым для обеспечения безопасности значимых объектов КИИ, относятся программные и программно–аппаратные средства. Анализ существующих решений для безопасности КИИ показан в табл. 10.2.

Анализ существующих решений для безопасности КИИ

Таблица 10.2.

<i>Организационные и технические меры</i>	<i>Обозначение программного продукта</i>	<i>Организация, предоставляющая услуги</i>
1. Идентификация и аутентификация (ИАФ)	Средства криптографической защиты информации,	НПО «Эшелон», «ИнфоТеКС», «КриптоПро», «InfoWatch», «Код Безопасности»
2. Управление доступом (УПД)	Средства доверенной загрузки	НПО «Эшелон», «InfoWatch», «Код Безопасности»,
3. Ограничение среды программирования (ОПС)	Средства доверенной загрузки	НПО «Эшелон», «InfoWatch», «Код Безопасности»
4. Защита машинных носителей информации (ЗНИ);	Системы информационной защиты от НСД и DLP; Средства доверенной загрузки	НПО «Эшелон», «InfoWatch», «Код Безопасности»
5. Аудит безопасности (АУД);	Система сбора и анализа событий ИБ	«Лаборатория Касперского», «ИнфоТеКС»,
6. Антивирусная защита (АВЗ);	Антивирусы	«Лаборатория Касперского», «Doctor Web»
7. Обеспечение (ОЦД) целостности данных;	Системы информационной защиты (СЗИ) от НСД и DLP	НПО «Эшелон», «Infowatch», «Код Безопасности»,

Продолжение табл. 10.2.

<i>Организационные и технические меры</i>	<i>Обозначение программного продукта</i>	<i>Организация, предоставляющая услуги</i>
8. Система обнаружения вторжений (СОВ); Система предотвращения вторжений (СПВ) (компьютерных атак)	Межсетевые экраны, Средства обнаружения и предотвращения атак	НПО «Эшелон», «ИнфоТеКС», «Код Безопасности», «Fortinet»
9. Обеспечение доступности данных; (ОДД)	Средства резервного копирования	«Acronis»
10. Защита технических средств и систем (ЗТС);	Средства доверенной загрузки	НПО «Эшелон», «Infowatch», «Код Безопасности»,
11. Защита программного кода информационной (автоматизированной) системы и её компонентов	Межсетевые экраны, Средства защиты виртуализации	«Лаборатория Касперского», НПО «Эшелон», «Fortinet», «Код Безопасности», «ИнфоТеКС»
12. Планирование мероприятий по обеспечению систем безопасности (ПМОБ);	Сервисы автоматизации документооборота ИБ	«АльфаДок», «DocShell»
13. Управление системной конфигурацией; (УКФ);	Средства доверенной загрузки	НПО «Эшелон», «InfoWatch» «Код Безопасности»
14. Управление обновлениями (ОПО);	Антивирусы	«Лаборатория Касперского», «Doctor Web»
15. Реагирование на обнаруженные инциденты информационной безопасности (ИНЦ);	Система сбора и анализа событий инцидентов информационной безопасности	НПО «Эшелон», «ИнфоТеКС»
16. Обеспечение действий в нештатных ситуациях (ДНС);	Сервисы автоматизации документооборота ИБ	«АльфаДок», «DocShell»
17. Информирование и обучение персонала (ИПО)	Системы повышения осведомлённости по ИБ	«Лаборатория Касперского»

В значимых объектах КИИ, в зависимости от их категории значимости и степени опасности угроз безопасности информации, должны быть реализованы определённые организационные и технические меры [136–140, 142, 145, 146].

Таким образом, в ходе анализа приказа ФСТЭК России от 25 декабря 2017 года № 239 «Об утверждении требований по обеспечению безопасности значимых объектов КИИ» [140] и продуктов компаний, предоставляющих свои услуги и программные средства в области защиты данных и информационной безопасности, была сформирована наглядная таблица всех организационно–технических мер, необходимых для обеспечения информационной безопасности значимого объекта КИИ, а также компаний, разработавших свои программные продукты, необходимые для соблюдения требований регуляторов в области обеспечения безопасности критической информационной инфраструктуры.

10.2. Подсистема поддержки принятия решений идентификации объектов критической информационной инфраструктуры

10.2.1. Методика идентификации объектов критической информационной инфраструктуры

Идентификация объектов критической информационной инфраструктуры основывается на Постановлении Правительства Российской Федерации от 8 февраля 2018 года № 127 «Об утверждении Правил категорирования объектов КИИ РФ, а также перечня показателей критериев значимости объектов критической информационной инфраструктуры РФ и их значений».

Категорирование – это установление соответствия каждого объекта КИИ критериям значимости и их показателям [136]. Установлено 3 категории значимости. Самая высокая категория–первая, самая низкая–третья.

Существуют пять основных показателей критериев значимости: *социальная, политическая, экономическая, экологическая, и значимость для обеспечения обороны страны и безопасности государства и правопорядка.*

Порядок категорирования в соответствии с Постановлением Правительства от 08.02.2018 №127 (далее – ПП №127) включает следующие этапы:

1. Создание комиссии по категорированию.
2. Определение процессов в рамках видов деятельности (с учётом всех видов деятельности: основной и дополнительных) субъекта КИИ.

3. Выявление процессов, нарушение или прекращение которых может привести к негативным последствиям: формирование перечня *критических процессов* (в соответствии с показателями, установленными ПП №127).

4. Определение объектов (ИС/ИТКС/АСУ), обрабатывающих данные, необходимые для обеспечения критических процессов, и (или) осуществляющих управление, контроль или мониторинг критических процессов.

5. В случае наличия таких объектов, формирование перечня объектов КИИ, подлежащих категорированию, и передача этого перечня во ФСТЭК РФ. При отсутствии объектов КИИ, на этом этапе работа комиссии заканчивается.

6. Проведение категорирования выявленных объектов КИИ: оценка, в соответствии с перечнем показателей критериев значимости, масштаба возможных последствий, в случае возникновения компьютерных инцидентов на объектах КИИ (показатели установлены ПП №127) и присвоение каждому из объектов соответствующей категории значимости, или принятие решения об отсутствии необходимости присвоения категории. Такое решение комиссии оформляется *актом категорирования* [136]. Список объектов формируется и утверждается субъектом критической информационной инфраструктуры.

В соответствии с п. 15 Правил категорирования объектов КИИ РФ № 127, перечень объектов подлежит согласованию с государственным органом или юридическим лицом, выполняющим функции разработки или осуществления государственной политики, и (или) нормативно–правового урегулирования в определённой сфере, в части подчинённых им субъектов КИИ. Государственные органы, выполняющие функции разработки, проведения и реализации государственной политики и нормативно–правового регулирования:

- министерство энергетики РФ, в области топливно–энергетического комплекса, газовой и нефтехимической промышленности; федеральная служба экологического, технологического и атомного надзору, по атомной энергетике;
- министерство здравоохранения РФ – в области здравоохранения;
- министерство транспорта Российской Федерации – в области транспорта;
- министерство цифрового развития, связи и массовых коммуникаций РФ, в области информационно–коммуникационных технологий и связи;
- министерство финансов РФ – в банковской сфере и финансовом рынке;
- министерство науки и высшего образования РФ, в науке и образовании;
- министерство промышленности и внешней торговли РФ, в оборонной промышленности и в области международной торговли.

Российские юридические лица, выполняющие функции по разработке, проведению и реализации государственной политики и (или) нормативно-правовому регулированию: государственная корпорация «РосАтом» – в области атомной энергии; государственная корпорация по космической деятельности «РосКосмос» – в ракетно–космической промышленности.

Максимальный срок категорирования не должен превышать одного года со дня утверждения субъектом КИИ перечня объектов (внесения дополнений, изменений). Список объектов в течение 10 рабочих дней после утверждения направляется в печатном и электронном виде во ФСТЭК России. В список включаются объекты КИИ филиалов и представительств субъекта КИИ.

Для проведения категорирования решением руководителя субъекта КИИ создаётся постоянно действующая комиссия, в состав которой включаются:

1. Руководитель субъекта КИИ или уполномоченное им лицо [136].
2. Работники субъекта КИИ, являющиеся специалистами в области выполняемых функций или осуществляемых видов деятельности, и в области информационно–коммуникационных технологий и связи, а также специалисты по эксплуатации основного технологического оборудования, технологической (промышленной) безопасности, контролю за опасными (отравляющими и взрывчатыми) веществами и материалами, а также их учёту.
3. Работники субъекта КИИ, на которых возложены функции обеспечения информационной безопасности объектов критической инфраструктуры.
4. Работники подразделения по защите государственной тайны субъекта КИИ (в случае, если объект критической информационной инфраструктуры обрабатывает информацию, составляющую государственную тайну).
5. Работники структурного подразделения по гражданской обороне и защите от чрезвычайных ситуаций, или работники, уполномоченные для решения задач в области гражданской обороны и защиты от ЧС.

Структурная схема подсистемы поддержки принятия решений идентификации объектов КИИ представлена на рис. 10.5. Входными данными являются данные, введённые пользователем, промежуточными данными – 5 показателей критериев значимости, а результатом является категория значимости объекта критической информационной инфраструктуры.

10.2.2. Алгоритмическое конструирование. Выбор платформы и языка программирования для разрабатываемой подсистемы

Разработка структурной схемы алгоритма работы подсистемы поддержки принятия решений является первым этапом создания программного продукта. Она демонстрирует процесс обработки данных (рис. 10.6)

При разработке программного приложения и дальнейшей его поддержке, важнейшую роль играет выбор языка программирования. По оценке компании Net Applications, занимающейся сбором данных о применении операционных систем во всём мире, за 2021 год наибольшая доля десктопных операционных систем приходится на Microsoft Windows и составляет 88,81%. Исходя из этого, программное будет создано на платформе Windows 10. Оптимальными языками программирования для этих целей являются Java, C#, Python и C++.

Выбор языка программирования для создания подсистемы поддержки принятия решений идентификации объекта критической информационной инфраструктуры, складывается из рассмотрения достоинств и недостатков этих языков. Самым востребованным языком у профессиональных программистов – разработчиков, на начало 2021 года считался язык *Java*. Это вызвано его полной кроссплатформенностью, обеспечивающейся процессом трансляции программ, написанных на Java, в промежуточный байт-код, исполняемый виртуальной машиной Java (JVM) на любой платформе, поддерживающей JVM. Все версии Java *обратно совместимы*, вплоть до версии 1.0.2, что позволяет не менять программное обеспечение, написанное на более старых версиях Java. Однако Java считается громоздким языком, из-за своего синтаксиса, а также имеет проблемы со *сборщиком мусора*, которые могут вызывать утечки данных из памяти, вследствие чего производительность работы программы падает.

Язык программирования C#, разрабатываемый корпорацией Microsoft, обладает собственной средой разработки Visual Studio с удобными средствами разработки графического интерфейса и встроенным менеджером пакетов NuGet. Язык C# является объектно-ориентированным. Так же, как и в Java, код на C# переводится в байт-код CIL на основе стека (Common Intermediate Language), общий для платформы .NET, а затем выполняется виртуальной машиной CLR (Common Language Runtime) – исполняющей средой для байт-кода CIL. C# обладает «*синтаксическим сахаром*», упрощающим написание и понимание кода. Недостатком его является большой *порог вхождения*, если разработчик изначально не был знаком с синтаксисом таких языков как C++ или Java.




Рисунок 10.5. Структурная схема подсистемы поддержки принятия решений идентификации объектов КИИ




Рисунок 10.6. Структурная схема программы

Язык программирования *Python* сегодня очень востребован. Главным его достоинством является простота разработки для начинающих программистов. Код на языке Python легко читаем, а стандартные библиотеки поддерживают большинство нужных функций. Поддерживает масштабируемость приложений и кроссплатформенность, так как существуют интерпретаторы под разные виды платформ. Недостатком является медленность его работы. Кроме того, замечена проблема с совместимостью различных версий языка Python.

Принимая во внимание все достоинства и недостатки современных языков программирования, сделан вывод, что подходящим языком программирования для создания больших проектов является язык C++. Он универсален, часто применяется в задачах системного программирования, при разработке трансляторов и структурировании операционных систем. Язык C++ славится своей эффективностью и логической стройностью программ. Программы, написанные на C++, можно сравнить, по скорости работы, с программами, написанными на Ассемблере. Однако, при всём этом, языки C++ и Ассемблер представляют собой разные уровни программирования.

Для решения задачи построения подсистемы поддержки принятия решения, являющейся целью данного исследования, был выбран язык C++. Его выбор основан на наличии большого количества библиотек, необходимых для разработки подсистемы поддержки принятия решений, упрощённого кода, в отличие от других языков, а также опыта программирования на этом языке.

10.3. Программная реализация подсистемы поддержки принятия решений по идентификации объектов критической инфраструктуры

Подсистема поддержки принятия решений представляет собой систему анализа и обработки данных для оказания помощи лицам, принимающим решения в непростых условиях, при недостаточном количестве информации. Принятие ответственным лицом более объективного и правильного решения происходит за счёт анализа всех входных параметров, а также дальнейшей оценки их информативности в *признаковой структуре*.

Для разработки программного модуля системы поддержки принятия решений в области идентификации объектов критической информационной инфраструктуры используется Постановление Правительства РФ от 8 февраля 2018 г. № 127. Пользователю не нужно тратить много времени на вычитку документа. Программа всё сделает сама, нужно только следовать инструкциям.

Описание функций и ключевых слов, используемых в программе:

1. *int main()* – основная функция. Именно с неё начинается работа всей программы. Из этой функции возможно обратиться к любой другой функции, используемой в программе. Например, вызвать функцию *minimut()*, которая загружает шаблон, отвечающий за присвоение первой категории значимости.

2. *bezopas()* – функция, отвечающая за вызов шаблона, который выводит на экран информацию о необходимых мерах, принимаемых для обеспечения безопасности объекта критической информационной инфраструктуры.

3. *exit(0)* – вызывает немедленное окончание работы программы.

4. *cout* – стандартный *выходной поток*. Ключевое слово позволяет вывести текст на экран. Для корректной работы нужно подключить библиотеку *<iostream>*. Команда используется вместе с операцией поразрядного сдвига *<<*.

5. *cin* – стандартный *входной поток*. Используется для ввода информации. Команда используется вместе с операцией поразрядного сдвига *>>*.

6. *endl* – переход на новую строку при выводе результатов.

Начало любой программы на языке C++ сопровождается подключением библиотек, для возможности более гибкого использования преимуществ языка. При разработке программного средства использовались языковые библиотеки: *#include <iostream>; #include <string>; #include <sstream>; #include <functional>; #include <Windows.h>; using namespace std*. Их параметры означают следующее:

<iostream> – заголовочный файл. Предоставляет средства ввода–вывода. Его возможности размещены в пространстве имен *std*, поэтому для того, чтобы применить этот заголовочный файл, нужно или указывать префикс *std*, или объявлять пространство имен, используя инструкцию *using namespace*;

<string> – определение и ввод / вывод данных строковых типов;

<sstream> – заголовочный файл, который также отвечает за корректное отображение и ввод / вывод строковых данных;

<functional> – заголовочный файл, отвечающий за работу шаблонов классов, и помогающий работать с функциональными объектами.

<Windows.h> – заголовочный файл, отвечающий за использование элементов графического интерфейса. Например, в программе можно поменять цвет фона консоли с чёрного на белый, для лучшего восприятия пользователем.

Программа реализована таким образом: пользователю предлагается ввести свои данные; ответы сравниваются с эталонными значениями, и исходя из этого, присваивается категория значимости, или выносится решение об отсутствии необходимости присвоения категории значимости.

Существует 3 категории, из которых самой высокой является первая, а самой низкой – третья. Окно запроса входных данных показано на рис. 10.7.

Рисунок 10.7. Окно запроса входных данных

В зависимости от предлагаемого вопроса, входные данные могут быть как числовыми, так и с возможностью выбора ответа. Например, можно ввести 1, 2 или 3, и в том случае, если описание объекта не подходит для конкретного объекта критической информационной инфраструктуры пользователя, то ему предлагается ввести или отрицательное число, или 0. Окно запроса входных данных с вариантами ответа представлено на рис. 10.8.

Рисунок 10.8. Окно запроса входных данных с вариантами ответа

Обязательным условием для работы разрабатываемой подсистемы является присвоение первой категории значимости объекту КИИ на любом из этапов. Согласно Постановлению Правительства №127, в результате категорирования объекту КИИ присваивается категория значимости с наивысшим значением. Окно с присвоением первой категории значимости представлено на рис. 10.9.

Рисунок 10.9 – Присвоение первой категории значимости

Если пользователь вводит неверное число, например, в вопросе с выбором ответа (от одного до трёх), пользователь ввёл число пять, то программа выдаёт ошибку и приостанавливает свою работу, до нажатия клавиши.

Окно вывода ошибки представлено на рис. 10.10. Подобный функционал проверки правильности ввода входных данных реализован на всех этапах.




Рисунок 10.10. Неверный ввод входных данных

На этапе присвоения категории значимости, пользователю предлагается получить информацию о требованиях к организационным и техническим мерам, принимаемым для обеспечения безопасности значимых объектов КИИ. Для этого нужно нажать 1. Если пользователь вводит не 1, то программа выдаёт ошибку и завершает свою работу. Вывод подробной информации для обеспечения безопасности КИИ представлен на рис. 10.11.




Рисунок 10.11. Вывод подробной информации для обеспечения безопасности КИИ

Некоторые вопросы разделены на пункты «а» и «б», как вопрос № 3. При подсчёте итоговой категории значимости, этот вопрос должен быть разделён, и учитываться как два отдельных, 3(а) и 3(б). Пример показан на рис. 10.12.




Рисунок 10.12. Разделение вопроса на два пункта.

По окончанию работы, программа показывает, какая категория значимости присвоена объекту, по каждому из 18 вопросов. Далее происходит присвоение общей категории значимости всему объекту. Общая категория значимости присваивается по наибольшей из категорий значимости. К примеру, если в первом вопросе объекту присваивается вторая категория значимости, но при этом во всех остальных вопросах категория оказывается третьей, то всему объекту присваивается большая, вторая категория значимости (рис. 10.13).

СОЦИАЛЬНАЯ ЗНАЧИМОСТЬ	
1.	3 категория
2(a).	3 категория
2(б).	2 категория
3(a).	3 категория
3(б).	2 категория
4.	3 категория
5.	2 категория
ПОЛИТИЧЕСКАЯ ЗНАЧИМОСТЬ	
6.	3 категория
7.	2 категория
ЭКОНОМИЧЕСКАЯ ЗНАЧИМОСТЬ	
8.	3 категория
9.	3 категория
10.	3 категория
ЭКОЛОГИЧЕСКАЯ ЗНАЧИМОСТЬ	
11(a).	3 категория
11(б).	3 категория
ЗНАЧИМОСТЬ ДЛЯ ОБЕСПЕЧЕНИЯ ОБОРОНЫ СТРАНЫ, БЕЗОПАСНОСТИ ГОСУДАРСТВА И ПРАВОПОРЯДКА	
12.	3 категория
13(a).	3 категория
13(б).	3 категория
14.	2 категория
КАТЕГОРИЯ ЗНАЧИМОСТИ ОБЪЕКТА - 2	
Для получения информации о требованиях к организационным и техническим мерам, применимым объектов КИИ - нажмите 1	

Рисунок 10.13. Присвоение категории значимости по каждому пункту

Итак, поставленные авторами цели и задачи исследования были успешно решены. В процессе работы был проведён анализ нормативно – правовой базы обеспечения безопасности критической информационной инфраструктуры. Проведён анализ Постановления Правительства № 127 «Об утверждении Правил категорирования объектов критической информационной инфраструктуры Российской Федерации, а также перечня показателей значимости объектов КИИ РФ и их значений» с целью получения информации об этом процессе.

Разработана программная реализация подсистемы поддержки принятия решений, позволяющая быстро идентифицировать объекты КИИ, с помощью присвоения итоговой категории значимости всему объекту. Программа подсказывает, какие организационные и технические мероприятия должны быть реализованы на объектах КИИ, вне зависимости от их категории значимости. Разработанная подсистема позволяет специалистам в области информационной безопасности получать информацию о категории значимости конкретного объекта КИИ вне зависимости от рода деятельности организации.

11. СИСТЕМА ПОДДЕРЖКИ ПРИНЯТИЯ РЕШЕНИЙ ПРИ ИДЕНТИФИКАЦИИ МНОЖЕСТВА ДЕМАСКИРУЮЩИХ ПРИЗНАКОВ ЗАЩИЩАЕМОГО ОБЪЕКТА ОРГАНИЗАЦИИ

Конкуренция – это важный фактор рыночной экономики, обеспечивающий соперников всей полнотой необходимой им информации о деятельности интересующей их организации. В ходе конкурентной борьбы используются современные *технические средства разведки* (ТСР), и применяются различные *способы промышленного шпионажа*, которые совмещают использование традиционных противоправных шпионских средств, таких как подкуп, шантаж и кража, с постоянно совершенствующимися электронными устройствами, средствами скрытого наблюдения и подслушивания, взломом компьютерных сетей, и др., позволяющими несанкционированно, безопасно для хакера или злоумышленника, получать большой объем информации, ничем не рискуя и находясь на безопасном расстоянии от источников конфиденциальных данных.

Достижения микроэлектроники и нанoeлектроники, способствующие созданию технической базы для массового изготовления средств нелегального добывания информации, подрывает информационную безопасность компаний, обладающих информацией ограниченного распространения, что в итоге приводит к нежелательным для них последствиям. Чтобы иметь возможность противостоять постоянно развивающимся средствам перехвата, организациям необходимо постоянно модернизировать систему защиты информации.

Без проведения специальных исследований и аттестации объекта информатизации (ОИ) нельзя с большой точностью утверждать, что система защиты информации достаточно совершенна. Мероприятия, проводимые в ходе аттестация ОИ, позволяют выявить информативные демаскирующие признаки (ДП) объектов защиты и наиболее полно оценить возможности перехвата злоумышленником защищаемой информации. Такие мероприятия включают в себя испытания как отдельных средств ОИ, так и систем защиты информации на аттестуемом объекте с помощью специальной контрольной аппаратуры и тестовых средств, а также проведение комплексных аттестационных испытаний объекта в реальных условиях его эксплуатации с наличием угроз.

Выполнение этих процедур требует привлечения значительных ресурсов компании (временных, материальных, людских, финансовых), и как следствие, негативным образом сказывается на работе компаний и организаций.

В целях снижения ресурсных затрат компании при оценке используемых средств и систем защиты информации, актуальным является вопрос о создании программного продукта, который позволяет выявлять демаскирующие признаки объекта защиты и давать рекомендации по снижению угроз информативности обнаруженных демаскирующих признаков объекта защиты на предварительном этапе оценки, т.е. до проведения мероприятий по аттестации объекта информатизации. В качестве указанного программного продукта может выступать подсистема поддержки принятия решений идентификации множества демаскирующих признаков (ПППР ИМДП).

Проблемы идентификации различных демаскирующих признаков ОИ затрагиваются во многих работах российских авторов. При этом методики, наиболее полно учитывающие демаскирующие признаки и предполагаемую угрозу их информативности, остаются недостаточно разработанными.

Среди отечественных авторов, работы которых посвящены инженерно-технической защите информации и проблемам идентификации демаскирующих признаков, особенно выделяются В.П. Гуляев, А.А. Торокин, А.А. Хорев, Ю.К. Меньшаков, А.П. Зайцев, А.А. Шелупанов. Необходимо также отметить авторов, непосредственно не занимающихся технической защитой информации, но описывающих в своих работах все демаскирующие признаки и проблемы их идентификации. Большой вклад в классификацию демаскирующих акустических признаков внес В.Н. Носуленко в своей статье «Психология слухового восприятия» [151]. Свойства проводников и диэлектриков описал Привалов Е.Е. в работе «Электротехническое материаловедение» [152].

Несмотря на достаточное количество исследований в области идентификации демаскирующих признаков объектов защиты, вопросы оценки угроз информативности различных демаскирующих признаков, и практической реализации подсистемы поддержки принятия решений по идентификации множества демаскирующих признаков объектов защиты организаций, в настоящее время изучены и проработаны недостаточно.

Таким образом, дальнейшее исследование вопросов идентификации демаскирующих признаков объектов защиты организаций, разработки методов автоматизации процессов выявления информативных ДП, и выработки рекомендаций по снижению информативности выявленных ДП в интересах получения наиболее адекватного результата, является весьма актуальным.

Объектом исследования являются процессы подготовки и принятия решений по идентификации множества демаскирующих признаков объектов защиты организации. *Предметом исследования* этого проекта выступают методы идентификации (классификации), и методики обработки множества демаскирующих признаков объектов защиты организации. *Цель исследования*: разработка методики построения подсистемы поддержки принятия решений идентификации множества демаскирующих признаков объектов защиты организации. Для достижения цели необходимо решить *следующие задачи*:

- 1) систематизация методов классификации демаскирующих признаков, исследование проблемы классификации с позиции системного анализа;
- 2) исследование методов мониторинга и особенностей обнаружения и распознавания объектов на основе их демаскирующих признаков;
- 3) анализ экспертной оценки угроз и возможной информативности демаскирующих признаков объекта защиты организации;
- 4) разработка структурной схемы алгоритма (модели) расчёта угроз и информативности признаковой структуры объекта защиты организации;
- 5) разработка подсистемы поддержки принятия решений идентификации множества демаскирующих признаков объекта защиты организации на основе системного подхода и методов системного анализа.

Методы исследования: Для решения поставленных задач использованы положения теории системного анализа, теории принятия решений, методы, основанные на применении коэффициентных методик и экспертных оценок.

11.1. Анализ демаскирующих признаков объектов защиты

Техническая разведка представляет собой деятельность по добыванию какой-либо организацией необходимых сведений о сопернике, или конкуренте, с помощью технических средств в процессе конкурентной борьбы [153].

Разведывательный процесс с помощью технических средств состоит из последовательно сменяющих друг друга этапов: наблюдение (мониторинг), обнаружение, распознавание, идентификация объекта. Суть этапа *наблюдения* и *обнаружения* заключается в выявлении различного рода сигналов, имеющих характеристики, которые выделяют их из множества других сигналов. Наличие таких сигналов означает, что в зоне *мониторинга* разведки может находиться выделяющийся чужеродный объект, который контрастирует с фоном [154].

Под *распознаванием* понимается классификация – процесс приписывания найденного объекта к одному из классов. При этом все существующие объекты группируются в классы, согласно определенным признакам [155].

На этапе *идентификации* происходит однозначное определение конкретного объекта внутри класса по его индивидуальным характеристикам.

Задача *защиты объекта* состоит в предотвращении факта его обнаружения и распознавания признаков, на основе которых производится идентификация защищаемого объекта организации. *Свойство объекта*, которое возможно обнаружить средствами разведывательной аппаратуры, позволяющее выделить и распознать объект, которому принадлежит данный признак, среди других объектов, называется *демаскирующим признаком объекта*. Из этого следует, что не все свойства объекта являются его демаскирующими признаками. Они являются таковыми лишь в том случае, когда выделяют объект относительно других, и когда орган разведки может заметить такие демаскирующие признаки. На основе их анализа можно определить принадлежность, состав, деятельность и расположение объектов и их составных частей, выявить их назначение, цели и задачи их деятельности, а также планируемый характер их выполнения.

Анализ технических демаскирующих признаков конкретного объекта разведки сводится к выявлению определенной совокупности демаскирующих признаков и их параметров, которые могут быть использованы средствами технической разведки для извлечения защищаемой информации [156].

В настоящий момент существует несколько различных классификаций демаскирующих признаков. Классификация Д.Б. Халяпина, представленная на рис. 11.1, отражает большинство демаскирующих признаков [157].

По Д.Б. Халяпину, все демаскирующие признаки можно разделить на опознавательные признаки, признаки деятельности и дополнительные признаки. Отдельно выделяются количественные / качественные и прямые / косвенные группы демаскирующих признаков защищаемых объектов.

Опознавательные признаки отражают состояние объекта, не зависящее от течения времени. К ним относятся видовые ДП, физические поля и среды, сопутствующие работе объекта или отраженные от него, следы деятельности объекта и его вещественные характеристики. Наиболее информативными из них являются визуальные ДП, в связи с физиологическим развитием органов чувств человека. Обнаружение опознавательных признаков помогает определить специфику объекта (провести распознавание и идентификацию объекта).




Рисунок 11.1. Классификация демаскирующих признаков объектов защиты

Визуальные демаскирующие признаки – это все ДП, которые можно обнаружить в видимом спектре электромагнитного излучения, а также визуализировать в радиотепловом, радиолокационном и инфракрасном диапазонах. К ним относятся размеры объекта, форма, тень, пыль, дым и многие другие. Они выявляются в результате анализа внешнего вида объекта, наиболее эффективным способом выявления которых является комплексное использование различных разведывательных устройств, направленных на получение визуальных ДП в различных частях спектра. Сочетание характеристик дает возможность защиты наиболее приемлемым методом распознать объект.

Согласно понятийно–терминологического словаря «Гражданская защита», «физические поля – это пространство, в котором проявляются физические свойства материального объекта в результате его взаимодействия с окружающей средой» [154]. Таким образом, поле любой физической природы представляет собой носитель информации, распространяющийся в пространстве. Из всех существующих физических полей в качестве носителей информации используют электрические, магнитные, электромагнитные и акустические поля.

При рассмотрении физического поля, как носителя информации, можно называть его сигналом (сигналом являются любые зарегистрированные данные). Информация, передающаяся посредством сигнала, содержится в значениях его параметров. Классификация сигналов [158] представлена на рис. 11.2:




Рисунок 11.2. Классификация различных видов сигналов

Аналоговый сигнал представляет собой любой непрерывный сигнал, у которого каждый из представляющих его параметров описывается временной функцией и непрерывным множеством возможных значений [159]. Это отличает его от *дискретного сигнала*, в котором непрерывная величина является последовательностью дискретных значений, которая может принимать только одно фиксированное значение из конечного числа значений.

В зависимости от вида информации, содержащейся в сигнале, изменяются его демаскирующие признаки, которые возможно распознать с помощью аппаратуры: форма, ширина спектра, частотный и динамический диапазон.

К *материально–вещественным* демаскирующим признакам относятся признаки вещества (демаскирующее вещество) и различные предметы, которые могут вскрыть объект. Источниками такой информации могут стать образцы объекта, макеты, составные части и комплектующие. Кража составных частей объекта может дать конкурентам информацию, как о материалах, используемых для создания объекта и внешнем виде, так и о функционировании объекта.

Полную информацию об объекте можно получить из должным образом не уничтоженной документации или ее черновиков, откуда можно узнать о функционировании объекта и его технические характеристики. Документация может быть представлена на бумажном или электронном носителе.

Опознавательные признаки также включают в себя характеристики, влияющие на окружающую среду и следы антропогенной деятельности. Заборы проб воздуха, почвы и жидкостей, измерение радиоактивного фона и дальнейший их анализ позволяют получить данные о профиле предприятия. Также демаскирующими признаками объекта являются следы при перемещении объекта. Следы могут остаться на грунте, песке, снеге. Перемещение массивных объектов определяются по примятости травяного покрова. Демаскирующими признаками деятельности являются тени, дым и следы от кострищ.

Опознавательные признаки позволяют, на основе анализа оперативно–технических характеристик объекта, определить класс или тип объекта, его принадлежность и возможности, отличить его от других объектов путём сравнения его технических характеристик. Признаки деятельности представляют собой изменяющиеся во времени характеристики объекта и описывают этапы работы объекта, такие, как изменение режима работы объекта, состава или количества поставок, качественная замена персонала и пр. Обычно такие признаки обнаруживаются при анализе организационно–производственной деятельности объекта. Изменение признаков деятельности служит сигналом изменения выпускаемой продукции или перепрофилирования производства.

Дополнительные признаки, демаскирующие объект, являются наиболее статичными и более независимыми в проявлении. Они могут определяться, например, расположением объектов в пространстве и между собой, а также взаимодействием со средой и свойствами самих объектов.

Дополнительные демаскирующие признаки, по длительности сохранения, делятся на постоянные, периодические и эпизодические.

Постоянные *признаки* объектов не изменяются, или медленно изменяются в течение долгого времени. К ним относятся такие демаскирующие признаки, как материал изготовления, размеры, форма, очертание, контуры, цвет, и др.

Периодическими признаками являются детали и фрагменты объекта, его тень при различном освещении, внешняя окраска и др.

Эпизодические признаки могут проявляться не больше одного раза за все время существования объекта, и в большинстве случаев непреднамеренно. Например, сколы или пятна краски на объекте, или следы от ударов.

Способность перемещаться в пространстве определяет еще одну группу дополнительных демаскирующих признаков. Если объект может перемещаться в пространстве, то он называется *подвижным*, иначе он является неподвижным. Примером подвижных объектов могут стать поезда с вагонами, автомобили, бронетехника, а неподвижных – постройки, памятники, тяжёлые станки.

По линейным размерам объекты можно разделить на три вида: точечные; линейные и плоскостные объекты, в зависимости от своих габаритов.

Точечными (компактными) объектами являются объекты с примерно одинаковой длиной и шириной, при этом имеющие малые размеры. Чаще всего точечные объекты являются компонентом более сложных объектов.

Линейные (протяженные) объекты – это объекты, длина которых больше ширины более, чем в три раза. К этому виду относятся железнодорожные составы, мосты, дороги, здания, трубопроводы, стадионы и др.

Плоскостные (площадные) объекты, обладают большими размерами. К ним можно отнести города, посёлки, сельскохозяйственные поля или порты.

Объекты также делятся на простые и сложные. *Простыми* чаще всего являются самостоятельные объекты, которые можно представить, как часть сложного объекта. *Сложные* объекты представляют собой упорядоченные группы более простых объектов, как, например, испытательный полигон.

По статистическим свойствам, дополнительные демаскирующие признаки могут быть вероятностными и детерминированными. *Детерминированными* являются такие демаскирующие признаки, время проявления которых может быть задано в виде некоторой определенной функции. Проявление *вероятностных* случайных демаскирующих признаков непредсказуемо, и представляет собой хаотические функции времени.

Местоположение объекта определяет его координаты в пространстве, и близость его к связанным или не связанным с ним другим объектам. Местоположение является демаскирующим признаком, так как существует логическая взаимосвязь объектов между собой. Так, можно предположить наличие порта в населенном пункте, расположенном у крупного водоема.

Все демаскирующие признаки делятся на две группы: количественные и качественные. *Количественные* ДП описываются числовым значением и поддаются прямому измерению. *Качественные* ДП подразумевают какие-либо сравнительные характеристики. Примером таких ДП может служить правильная геометрическая, или, наоборот, неправильная форма объекта.

Основным показателем демаскирующего признака является его информативность, которая оценивает степень уникальности данного ДП среди других объектов. Значение информативности принадлежит интервалу $[0, 1]$ и означает, что чем меньше объектов обладают этим демаскирующим признаком, тем больше его информативность (ближе к значению 1).

Величина информативности определяется по формуле:

$$I_k = \frac{(N - N_k)}{N} \quad (11.1)$$

где N_k – количество объектов, обладающих признаком k из N рассматриваемых.

Именной демаскирующий признак, информативность которого равна 1, является самым информативным признаком из всех возможных, так как из формулы (11.1) видно, что этот демаскирующий признак является уникальным, и принадлежит только этому объекту. К именовым ДП относится папиллярный рисунок пальцев человека или MAC–адрес оборудования в сети Ethernet.

Прямые демаскирующие признаки непосредственно принадлежат объекту, и могут быть напрямую восприняты наблюдателем. Их информативность колеблется в интервале $[0,1]$. Чем больше прямых ДП обнаружено, тем с большей вероятностью можно провести распознавание объекта.

Косвенные демаскирующие признаки, хотя они могут и не принадлежать самим объектам, также влияют на их распознавание. Они отражают состояние и свойства объекта технической разведки, и, чаще всего, являются результатом взаимодействия такого объекта с внешней средой. К косвенным демаскирующим признакам относятся, например, следы, оставленные объектом.

Итак, демаскирующие признаки разделяются на опознавательные признаки деятельности, дополнительные, количественные и качественные, а также прямые и косвенные группы демаскирующих признаков.

11.2. Обоснование выбора и описание основных демаскирующих признаков

Перед проектированием подсистемы поддержки принятия решений (ПППР) было отобрано конечное количество демаскирующих признаков, которые являются наименее специфическими и присутствуют у большинства объектов. Такое упрощение необходимо для построения конечной структуры демаскирующих признаков и позволяет пользователю применять меньшее количество аппаратуры для замеров демаскирующих признаков объекта. Так как к таким признакам в большинстве своем относятся *опознавательные признаки*, именно они и составили основу классификации, используемой в ПППР.

В разрабатываемой подсистеме поддержки принятия решений, отобранные демаскирующие признаки образуют структуру [160], показанную на рис. 11.3:



Рисунок 11.3. Структура демаскирующих признаков внутри ПППР

Необходимо более подробно остановиться на указанных демаскирующих признаках, чтобы понять, насколько каждый из них может способствовать обнаружению и распознаванию объекта защиты организации.

11.2.1. Визуальные демаскирующие признаки

Габаритные размеры – это предельное расстояние между внутренней или внешней стороной объекта. Вероятность обнаружения зависит от его угловых размеров и контраста. Чем они больше, тем быстрее будет обнаружен объект.

При поиске объекта решающим фактором является не его форма, а именно размер объекта, в пределах соотношения сторон 1:1 – 1:10. Увеличение углового размера в 2 раза увеличивает скорость распознавания в 8 раз [158]. Из этого следует, что размер объекта является одним из решающих демаскирующих признаков при визуальном обнаружении объекта [160].

Дым представляет собой *дисперсную систему* с размером частиц 0,1 – 0,001 мкм, и образуется при горении или возгонке летучих веществ. Дым, при сгорании горючих веществ, может содержать частицы несгоревшего топлива, сажи, золы и других веществ [161]. Дым может демаскировать объект, так как его видно и с земли, и с воздуха. При сгорании горючих веществ, дым держится до тех пор, пока не будет ликвидирован очаг возгорания, или пока не выгорит весь объем горючих веществ. Дым от выстрелов держится 1–2 секунды в сухую погоду. При большой влажности воздуха дым заметен лучше, держится дольше и принимает правильную овальную форму. Локализовать объект по наличию дыма не составляет труда, так как он является демаскирующим признаком [162].

Контраст является одной из оптических характеристик объекта. В видимом диапазоне электромагнитных волн видимость объектов определяется яркостным контрастом, возникающим в результате разницы между отражательными световыми способностями фона и объекта. По яркости K он определяется как:

$$K = \frac{B_{\max} - B_{\min}}{B_{\max}} = 1 - \frac{B_{\min}}{B_{\max}}, \quad (11.2)$$

где $B_{\max}$ и $B_{\min}$ – минимальная и максимальная яркости объекта и фона. Яркость, как максимальная, так и минимальная, может принадлежать и объекту, и фону.

Наименьшее значение контраста, при котором искомый объект ещё можно обнаружить и распознать, называется *пороговым контрастом* (ϵ). На рис. 11.4 изображено пороговое соответствие между яркостью фона и контрастом, для разных угловых размеров объекта, например, в виде круглого диска [163].

Характер зависимости для светлых объектов примерно тот же, что и для тёмных, хотя хорошо видно, что при равных угловых размерах объекта абсолютные значения пороговых контрастов для объектов темнее фона будет ниже, чем для объектов светлее фона. Значение порогового контраста зависит от знания наблюдателем расположения объекта. Если наблюдатель точно знает местоположение объекта, и он смотрит непосредственно на объект разведки, то пороговый контраст будет меньше, чем в том случае, если местоположение объекта неизвестно и его приходится искать в некотором пространстве.




Рисунок 11.4. Соответствие между яркостью фона и контрастом для разных угловых размеров объекта

Приняты следующие значения коэффициентов контраста по яркости:

- 1) $K < 0,2$ (незаметный контраст);
- 2) $K = 0,2-0,3$ (малозаметный контраст);
- 3) $K = 0,3-0,6$ (заметный контраст);
- 4) $K > 0,5$ (резко заметный контраст).

При проведении маскировки объектов необходимо стремиться, чтобы яркости фона и объекта были максимально близки друг к другу. При этом численно контраст будет уменьшен, что приведет к визуальному «сливанию» объекта с фоном и увеличит время поиска и распознавания объекта [164].

Местоположение, как демаскирующий признак, позволяет определить, насколько объект будет замечен на фоне окружающей среды, и есть ли у него возможность затеряться среди находящихся рядом объектов. В зависимости от проявления маскировочного эффекта, свойства местности можно разделить на *скрывающие*, которые обладают естественными маскировками, позволяющими скрывать объекты без применения средств искусственных маскировок, и *видовые*, уменьшающие заметность объектов, благодаря наличию контраста между отдельными участками местности (лесом, рекой, лугом, пашней, полевыми культурами, огородами и т. д.), и снижающие контраст между объектами, имеющимися на изучаемой местности, и окружающим фоном.

При рассмотрении вариантов местоположения, выделяются следующие варианты расположения объектов: внутри помещения; в зелёных насаждениях; в городской застройке; на открытой местности, например, на морском побережье.

Если говорить о таком варианте местоположения, как *«внутри помещения»*, то необходимо отметить почти полную невозможность наблюдения объекта воздушной разведкой. Но расположение внутри помещения не исключает возможности утечки информации об объекте через окна и двери.

Наблюдение за объектом *«снаружи помещения»*, через окна, может обеспечить противника немалым количеством видовой информации, в видимом диапазоне электромагнитных волн. Но количество информации, получаемое при наблюдении снаружи, уменьшается пропорционально ухудшению условий наблюдения, таких как появление дождя, тумана, смога, снега и пр. Меньшее, но не менее важное количество информации злоумышленник может получить, используя средства разведки в инфракрасном (ИК) диапазоне. Демаскирующие признаки этого диапазона электромагнитных волн практически не зависят от погодных условий, как и от времени суток – возможно наблюдение ночью.

Наблюдение за объектом внутри помещения может дать противнику полную информацию об объекте в видимом диапазоне. Однако необходимо учесть, что попасть на охраняемый объект ему будет гораздо сложнее, чем наблюдать за объектом снаружи, хотя это даст намного меньше информации.

Зеленые насаждения, являясь одним из видов естественной маскировки, больше скрывают объекты наблюдения, чем демаскируют их. Лесопосадки хорошо маскируют объекты от воздушной и наземной разведки. Основными характеристиками, влияющими на возможность сокрытия объекта, являются: густота и ярусность леса, состав древесных пород и высота деревьев.

Густота леса определяется средним расстоянием между деревьями. По этому признаку лесопосадки можно разделить на следующие категории: очень густой лес (среднее расстояние между деревьями до 4 м); густой лес (до 10 м), и редколесье (с расстоянием между деревьями более 10 м). По *ярусности* леса бывают одноярусные и многоярусные. *Многоярусные* леса затрудняют не только воздушное, но и наземное наблюдение, из-за наличия подлеска (иногда до пяти ярусов). Они скрывают объекты на расстоянии 100 и более метров от опушки. Состав древесных пород леса также влияет на его свойства сокрытия. Лиственный лес теряет свои маскирующие свойства с приходом зимы, а хвойный лес обладает неизменными свойствами маскировки и зимой.

Густой кустарник, сады и парки, придорожные посадки также являются хорошими средствами маскировки. Они обладают значительной *пятнистостью*, которая создается тенями и меняющейся высотой, а также густотой деревьев.

Городская застройка хорошо маскирует объект [164], так как обладает значительной пятнистостью фона от домов. В солнечную погоду пятнистость усиливается тенями, падающими от деревьев, зданий и архитектурных строений.

Открытая местность очень сильно демаскирует объект любого размера. Демаскировка объекта является более эффективной, если она производится утром или вечером, так как тени от объекта наиболее сильно выделяют его [165].

Пыль является крупнодисперсной системой, с размером частиц дисперсной фазы более 10 мкм. Она состоит из твердых частиц, образованных в результате высыхания жидкости с растворенными веществами или тонкого измельчения твердых тел, которые осаждаются на различных поверхностях. Воздействие какой-либо внешней силы вызывает переход осевшей пыли (аэрогеля) во взвешенное состояние аэрозоля и наоборот [166]. Пыль в виде аэрозоля является демаскирующим признаком движущихся объектов. В связи с этим, следует избегать движения по пыльным грунтовым дорогам, и стараться передвигаться или по обочине, или по травяному покрову.

Следы от объекта являются значительным косвенным демаскирующим признаком. Изучение следов позволяет определять вид объекта, направление движения, давность следа, а также количество движущихся объектов. Также следы могут способствовать определению объекта к какой-либо группе. Анализ следов начинается с определения вида объекта, оставившего следы. Например, можно определить вид гусеничной техники, зная особенности рисунка отпечатков гусениц и ширину колеи. Направление движения следов человека можно определить по следующим характерным признакам [165]:

- наибольшей глубиной следа обладает та его часть, которая обращена в сторону движения, так как носком человек отталкивается, двигаясь вперед;
- сдвиг грунта происходит в сторону, обратную направлению движения;
- отдельные комки грунта выбрасываются вперед, в сторону движения, а у следов на песке и на снегу, если нога погружается глубоко, образуется валик грунта на стороне, противоположной направлению движения [164].

Наиболее просто определить давность следа, оставленного на влажной почве, так как он медленно подвергается изменениям. Такой след долго остается темнее окружающего его грунта, из-за особенности спрессованной почвы сохранять в себе влагу. Через 3–4 часа после появления следа начинают светлеть и сильно выделяться комочки грунта, попавшие на дно следа. При вязкой почве, на дне следа через 2–3 часа образуется корка на почве, через 4–5 часов появляются трещины, затем, через 1–2 суток частицы грунта отделяются от дна следа и «набухают», спустя 2–3 суток контуры следа сначала рассыпаются, а затем вовсе исчезают. Сложнее определить давность следов на песке или мягком грунте, так как в сухую безветренную погоду такие следы бывают очень чёткими и хорошо заметными, но даже при небольшом ветре они быстро разрушаются, и через несколько часов становятся еле заметными, а затем вообще исчезают. Сильный ветер может снести следы за несколько минут. Следы техники в этих условиях сохраняются около 3–4 часов, однако рисунок следов от колёсных или гусеничных машин стирается так же быстро.

Температура является демаскирующим признаком, лежащим в основе тепловой разведки, ведь любое тело излучает электромагнитные волны в инфракрасном диапазоне. В ближней (0.75–1.3 мкм) и средней (1.2–3.0 мкм) зонах инфракрасного излучения мощность собственного излучения объектов значительно меньше, чем отраженного объектом потока солнечной энергии. Мощность собственного излучения объектов, нагретых солнцем, становится соизмеримой с мощностью отраженной ими солнечной энергии в длинноволновой области. Максимум энергии инфракрасного излучения тел, при температуре воздуха летом до 30 – 35 градусов, находится в диапазонах 3–5 мкм и 8–14 мкм. Чем выше температура нагретого тела, тем больше излучаемая энергия, а её максимум при этом смещается в сторону более коротких волн.

Тепловая разведка позволяет обнаружить объекты, используя разность температур между ним и фоном. Разность температур возникает за счёт работы отопительных систем зданий, либо в процессе продолжительной работы двигателя транспорта. Тепловая разведка более эффективна ночью, так как снижение температуры фона происходит быстрее снижения температуры объекта, которые могут сохранять высокую температуру в течение 4 – 5 часов летом и 1,5 – 2 часов зимой после отключения источника тепла.

Тень. Тени объектов возникают в условиях прямого освещения и могут нести информацию о местоположении, размере и форме объекта. Они являются наиболее информативными при наблюдении сверху. Тени разделяются на *собственную*, которая падает на сам объект, и *падающую*, которая покрывает поверхность фона. Линейные объекты, такие как линии электропередач, чаще всего можно обнаружить только с помощью падающей на поверхность тени. По форме тени, падающей от наблюдаемого объекта на поверхность, можно определить форму объекта. В этом случае следует учитывать искажения тени, если поверхность, на которую падает тень, обладает неровным рельефом.

Необходимо учитывать, что, в зависимости от градуса высоты солнца над горизонтом, интенсивность тени и степень её темноты может варьироваться, в большей или меньшей степени. При небольшой высоте солнца над горизонтом (высота = 10°), освещенность внутри тени будет в два раза меньше, чем у соседнего незатененного места. При высоте солнца в 20° , интенсивность тени будет больше уже в 4 раза, а при высоте солнца в 40° – больше уже в 6 раз, чем освещенность соседних незатененных мест. Чем темнее и интенсивнее тень, тем более она заметна наблюдателю и демаскирует объект наблюдения [164].

Форма наблюдаемого объекта является более информативным признаком для искусственных объектов, чем для естественных. *Естественные* объекты обладают неправильными формами без ровных линий. *Искусственные* объекты обычно обладают правильными геометрическими формами, которые выделяют их на местности, особенно при наблюдении с высоты.

Удельная электропроводность. Электропроводность объекта – это его способность проводить электрический ток. На рис. 11.5 представлена схема расположения энергетических зон для различных видов материалов.




Рисунок 11.5. Схема расположения энергетических зон в проводнике – металле, полупроводнике и диэлектрике

Проводники и полупроводники, обладающие собственной проводимостью, становятся заметными при *радиоэлектронной разведке* в связи с наличием токов на поверхности объекта. Необходимо отметить, что диэлектрики, по своей сути, не обладающие проводимостью, в некоторых случаях также могут быть замечены *радиолокатором* [166]. Электропроводность твердых диэлектриков обусловлена наличием влаги на его поверхности, дефектами и различными загрязнениями. Вода, находящаяся на поверхности диэлектрика, обладает значительной электропроводимостью. Уже при тонком слое влаги на поверхности диэлектрика можно обнаружить заметную проводимость [167], определяющуюся толщиной слоя воды. *Загрязнение* поверхности почти не влияет на удельную поверхностную проводимость *гидрофобных* диэлектриков (не смачиваемых водой), но сильно влияет на проводимость гидрофильных твердых тел (смачиваемых водой). Высокой проводимостью также обладают и *объемно-пористые* вещества [168], так как процесс поглощения влаги вглубь материала стимулирует образование её плёнки на поверхности диэлектрика.

11.2.2. Сигнальные демаскирующие признаки

Частота сигнала – это физическая величина, определяющая количество колебаний сигнала в единицу времени. Для стандартизации, за единицу времени принята 1 секунда. Единицей измерения частоты является Герц (Гц). Значение в 1 Гц определяет один последовательный переход сигнала из максимального в минимальное значение, и в обратном направлении, за 1 секунду. Частота является одной из основных характеристик, описывающих любой сигнал.

При рассмотрении акустического сигнала, частотный диапазон разделяют на *инфразвук* с частотами ниже 16 – 20 Гц, *слышимый человеком звук*, частоты которого составляют 20 – 2000 Гц, и *ультразвук*, превышающий по частоте звуки слышимого человеком диапазона. В табл. 11.1 представлена подробная классификация частотных диапазонов акустического сигнала [169].

На рис. 11.6 представлена классификация частот радиосигнала. Каждый из диапазонов частот обладает особенностями распространения в среде. На очень низких частотных (ОНЧ) и низких частотных (НЧ) диапазонах во всех странах осуществляется *круглосуточная внутриконтинентальная связь*.

Классификация частот акустического диапазона

Таблица 11.1

Частота	Наименование диапазона	Пример
0,001 – 20	Инфразвуковой диапазон	Тоны сердца человека
20 – $2 \cdot 10^4$	Звуковой диапазон	Человеческий голос
$2 \cdot 10^4$ – $2 \cdot 10^5$	Низкочастотный ультразвуковой диапазон	Звуки, издаваемые дельфинами и летучими мышами
10^5 – 10^7	Среднечастотный ультразвуковой диапазон	Колебания магнитострикционных излучателей
10^7 – 10^9	Высокочастотный ультразвуковой диапазон	Колебания пьезоэлектрических излучателей
10^9 – 10^{13}	Гиперзвуковой диапазон	Тепловые колебания молекул

На средних частотах (СЧ) связь происходит днём – до 1500 км, ночью – до 4000 км. На высоких частотах (ВЧ) дальность связи увеличивается с ростом частоты, и днём, и ночью, а с ростом частоты увеличивается зависимость качества связи от солнечной активности. На ультравысоких частотах (УВЧ), сверхвысоких частотах (СВЧ) и крайне высоких частотах (КВЧ) связь уже является квазиоптической, и осуществляется в пределах прямой видимости.




Рисунок 11.6. Классификация частот радиосигнала

Ширина спектра сигнала. Сложный сигнал можно разложить на простые составляющие, результатом чего является *спектр* сигнала – функция частоты. Так как спектр сигнала может быть неограниченным, то область частот, в котором находится основная часть энергии (90%) сигнала называется шириной спектра сигнала [170]. Ширина спектра является важной характеристикой сигнала, т.к. она определяет полосу пропускания канала, по которому передается сигнал.

Разного рода сигналы обладают различной шириной спектра. Например, для телефонного сигнала, ширина спектра сигнала составляет 3100 Гц, звуковой многотональный сигнал, воспринимаемый человеком, имеет полосу частот от 16 Гц до 20 кГц и считается *узкополосным*, телевизионный сигнал имеет частоту от 10 Гц до 4 – 5 МГц, и является *широкополосным* [169].

По ширине спектра сигналы делятся на узкополосные и широкополосные [169]. *Узкополосным* является сигнал, ширина спектра которого намного меньше средней частоты ($\Delta f \ll f_{cp}$). К такому виду сигналов относятся модулированные радиосигналы. *Широкополосным* считается сигнал, у которого произведение активной ширины спектра на его длительность, намного больше единицы. Данное произведение называют *базой сигнала* B . Ширина спектра широкополосного сигнала намного превосходит минимальную полосу частот, которая на самом деле необходима для передачи конкретной информации [170]. Широкополосные сигналы используются для передачи цифровой информации, так как они являются *помехоустойчивыми*. При синтезе широкополосного сигнала может быть применена модуляция с использованием случайной, псевдослучайной последовательности. Такая модуляция делает сигнал похожим на случайный шум, и трудным для демодуляции, производимой противником. Широкополосный сигнал может обеспечить скрытность сигнала, так как его передача происходит с малой мощностью, что усложняет его обнаружение и распознавание противником (злоумышленником) [171, 172].

Мощность сигнала является его энергетической характеристикой, которая выражается полной энергией электромагнитного излучения, переносимого через данную поверхность, в единицу времени. По величине мощности, источники сигнала делятся на следующие категории: *маломощные* (до 100 Вт); *средней мощности* (до 10 кВт); *мощные* (до 1000 кВт); и *сверхмощные* (более 1000 кВт). Мощность, которая генерируется источником сигнала, определяет качество приёма сигнала и предполагаемую дальность его распространения.

Мощность сигнала может варьироваться, в зависимости от назначения радиоприёмного устройства, принимающего сигнал, от нескольких тысячных долей ватт до тысяч ватт. Если говорить о дальности передачи сигнала, то увеличение мощности не даёт пропорционального её увеличения. Было замечено, что для увеличения дальности передачи в два раза, необходимо увеличить мощности источника в четыре раза, при наличии прямой видимости, а при отсутствии такой видимости – уже в восемь раз [170 – 172].

Вид сигнала. Любые сигналы возможно разделить на два вида: аналоговый и цифровой сигнал, функции от времени которых представлены на рис. 11.7:




Рисунок 11.7. Виды сигналов

В ГОСТ 17657–79 «Передача данных. Термины и определения» дано определение аналогового сигнала как «сигнала данных, у которого каждый из представляющих параметров описывается функцией времени и непрерывным множеством возможных значений» [159]. Аналоговый сигнал непрерывно изменяется во времени, а амплитуда простого гармонического сигнала изменяется по синусоидальному закону, представленного в формуле:

$$s(t) = A \cdot \sin(\omega t + \varphi) \quad (11.3)$$

где A – амплитуда; $\omega = 2 \cdot \pi \cdot f$ – круговая частота колебаний; φ – фаза колебаний.

К *аналоговым* сигналам относятся звуки *струнных инструментов, речевой* сигнал и все окружающие естественные природные звуки. *Цифровой* сигнал – это «сигнал данных, у которого каждый из представляющих параметров описывается функцией дискретного времени и конечным множеством возможных значений» [172]. Наибольшее распространение получил бинарный дискретный сигнал, который имеет только два уровня амплитуды – высокий (5 В) и низкий (0 В), и применяется повсеместно в ЭВМ.

Спектр дискретного сигнала, представленный на рис. 11.8, является бесконечным количеством гармоник, убывающих по амплитуде.




Рисунок 11.8. Спектр дискретного сигнала

Необходимо отметить преимущества передачи цифрового сигнала над аналоговым при передаче данных по каналам связи. К ним относятся: большая степень защиты передаваемой информации в результате её шифрования; простота приёма цифрового сигнала; большая защищенность от искажений.

Характер спектра сигнала. Непрерывные сигналы можно разделить, по характеру спектра сигнала, на гармонические и негармонические сигналы.

Гармоническим называется сигнал, в линейчатом спектре которого можно чётко выделить ряд гармоник. Если в этом ряде имеется одна основная гармоника, то такой сигнал называют *тональным*. Если в спектре выделяются не связанные по частоте гармоники, то сигнал является *созвучием* [172].

Негармонический сигнал по характеристикам более приближен к шуму. В спектре такого сигнала зачастую тяжело выявить закономерную связь между отдельными гармониками. Необходимо отметить, что существенным отличием такого сигнала от шума является различие в спектре этого сигнала, который для негармонического сигнала является линейчатым, а спектр шума – сплошным.

Коэффициент заполнения. Одним из признаков импульсных систем является коэффициент заполнения D – безразмерная физическая величина, определяющая отношение длительности импульса к периоду его следования. Коэффициент заполнения указывают в процентах и рассчитывают по формуле:

$$D = \frac{\tau}{T} \cdot 100\%, \quad (11.4)$$

где τ – длительность импульса; T – период следования импульсов.

Если коэффициент заполнения равен 75%, то это означает, что 75% какого-либо промежутка времени напряжение было, а остальные 25% его не было. Вид сигнала, в зависимости коэффициента заполнения, представлен на рис. 11.9.




Рисунок 11.9. Различные коэффициенты заполнения сигнала

Обратной величиной коэффициента заполнения является *скважность*. Необходимо отметить, что коэффициент заполнения и скважность описывают одну и ту же величину, но в ряде случаев проще оперировать интервалом $[0,1]$, в котором изменяется коэффициент заполнения, нежели значениями от 1 до бесконечности, в котором изменяется величина скважности.

Уровень звукового давления. Одной из характеристик акустического сигнала является звуковое давление, представляющее собой переменное избыточное давление, возникающее в упругой среде при прохождении акустической волны. Оно определяется как разность между мгновенным значением давления в упругой среде, возникающим при распространении звуковой волны, и атмосферным давлением (т.е. давлением, дополнительно возникающим в этой же среде при распространении звуковой волны – положительным в местах сжатия, и отрицательным в местах разрежения воздуха). Измеряется в паскалях (Па) и рассчитывается по формуле:

$$P_a = P_{cp} - P_{атм}, \quad (11.5)$$

где P_{cp} представляет собой давление в среде; а $P_{атм}$ – атмосферное давление.

Наименьшее звуковое давление, воспринимаемое человеческим ухом, равно $2 \cdot 10^{-5}$ Па, называется *порогом слышимости*. В свою очередь, наибольшее значение звукового давления, переносимое слуховым анализатором, равно 20 Па и является верхней границей слышимости. Оно называется *болевым порогом*.

Большой числовой разброс между порогом слышимости и болевым порогом приводит к неудобствам при расчётах. Из-за этого повсеместно используется логарифмическая шкала, основанная на отношении действительного уровня звукового давления к порогу слышимости. Данная величина называется *уровнем звукового давления*, измеряется в децибелах (дБ) и рассчитывается по формуле:

$$L_p = 20 \cdot \lg \frac{P}{P_0} \quad (11.6)$$

где P —измеренное звуковое давление; P_0 —звуковое давление порога слышимости.

При этом 0 дБ соответствует порогу слышимости, а 120 дБ – болевому порогу. На рис. 11.10 представлены описания уровней звукового давления.




Рисунок 11.10. Уровни звукового давления

Звуковое давление увеличивается при уменьшении расстояния от источника звука (обратно пропорционально), а также зависит от места нахождения источника звука и акустических характеристик помещения.

Интенсивность звукового сигнала. Звуковая волна является носителем энергии в направлении своего распространения. *Интенсивностью звука* называется количество энергии, переносимое звуковой волной за единицу времени через единицу поверхности, перпендикулярной направлению распространения звуковой волны, она рассчитывается по формуле:

$$I = \frac{P_a^2}{R_a} \quad (11.7)$$

где R_a – акустическое сопротивление среды, измеряемое в $\frac{\text{кг}}{\text{м}^2 \cdot \text{с}}$.

11.2.3. Материально–вещественные демаскирующие признаки

Макет объекта. Существование макета объекта ставит под угрозу безопасность информации об объекте, ведь макет, в зависимости от своего вида, обладает той или иной информацией об объекте. Это может быть его геометрия, форма, соотношение сторон, цвет, применяемые материалы, взаимодействие с внешним миром, и другие демаскирующие признаки.

Отходы объекта включают в себя различные элементы его деятельности, из которых возможно получить информацию о используемых в производстве материалах, виде производимой продукции, типе производства, а также конфиденциальную информацию, содержащуюся на бумажных или магнитных носителях. Отходы производства являются демаскирующим признаком в достаточной степени, если не соблюдаются правила их утилизации. Если отходы относятся к классу медицинских, их демаскирующим признаком будет цвет контейнеров для сбора отходов. Так, класс А (малоопасные отходы) хранятся в белых упаковках или контейнерах, класс Б (опасные отходы) – в контейнерах желтого цвета, чрезвычайно опасные вещества класса В хранятся в контейнерах красного цвета, а отходы, близкие по составу к промышленным отходам – утилизируются в чёрных мешках [173].

Ионизирующее излучение. Это излучение, создаваемое при радиоактивном распаде, торможении заряженных частиц в веществе, ядерных превращениях и образует ионы различных типов при взаимодействии со средой. Оно бывает различных типов, к основным из которых относятся: α –излучение, β –излучение, γ –излучение, нейтронное излучение. Очевидно, что при рассмотрении, например, ионизирующего излучения, как демаскирующего признака, можно отбросить несущественные по ионизирующему действию излучения, как, например, излучение Черенкова–Вавилова (свечение, вызываемой заряженной частицей в прозрачной среде), которое не может повлиять на ионизирующее излучение.

α –излучение – это распад атомных ядер, сопровождаемый испусканием потока α –частиц (ядер атомов гелия ${}^4_2\text{He}^{2+}$). Пробег α –частиц в воздухе составляет не более 10,6 см при нормальных условиях и энергии α –частицы, равной 10 МэВ. Вследствие малого пробега α –частиц, их детектирование на расстоянии более 10 см в воздушной среде невозможно. Тем не менее, наличие ${}^4_2\text{He}^{2+}$ ядер гелия *He* в воздушной среде является демаскирующим признаком α –распада, так как ${}^4_2\text{He}^{2+}$ является устойчивым изотопом, который может распространяться на большие расстояния от источника распада [174].

β –излучение является потоком электронов, испускаемых в результате β –распада. Оно обладает намного большей проникающей способностью, чем α –излучение. Пробег β –частицы может составлять до двух метров в воздухе, но легко поглощается слоем металла или пластика, составляющим несколько сантиметров. Регистрация β –частиц может осуществляться только при малых расстояниях от источника излучения, и почти невозможна при нахождении источника излучения в какой–либо таре и упаковке [174].

γ -излучение является потоком γ -квантов электромагнитного излучения, излучаемых ядрами, которые находятся в возбужденном состоянии. Этот вид излучения обладает большой проникающей способностью, пробег γ -квантов может достигать 2 км в зависимости от энергии источника и задерживается значительной толщиной бетона или металла. Это делает γ -излучение наиболее доступным для детектирования с помощью технических средств и наиболее выявляемым материально-вещественным демаскирующим признаком [174].

Нейтронное излучение представляет собой поток нейтральных частиц ядра. Из-за нейтрального заряда данный вид излучения обладает большой проникающей способностью, а дальность обнаружения источника нейтронного излучения составляет около 1,5 километров. Ослабление нейтронного излучения происходит с помощью водорода или материалов, содержащих атомы водорода, таких как вода, полиэтилен, парафин [174].

Минимально значимая активность (МЗА)—это величина, характеризующая активность источника ионизирующего излучения. Она измеряется в беккерелях; один беккерель определяется как активность источника излучения, в котором один радиоактивный распад происходит в среднем за одну секунду.

Радионуклиды делятся на 4 группы, по степени радиационной опасности, в зависимости от минимально значимой активности.

Класс А ($1 \cdot 10^3$) Бк;

Класс Б ($1 \cdot 10^4 - 1 \cdot 10^5$) Бк;

Класс В ($1 \cdot 10^6 - 1 \cdot 10^7$) Бк;

Класс Г ($1 \cdot 10^8 - 1 \cdot 10^9$) Бк.

Чем ниже класс опасности, тем менее активен радионуклид.

Энергия элементарных частиц измеряется в электрон-вольтах (эВ) и кратных единицах. Определено, что 1 эВ – это энергия, которую приобретет электрон в электрическом поле, при прохождении разности потенциалов в 1В. Например, энергия бета-превращения заключена между 13,4 МэВ и 18,61 МэВ.

Химические выбросы, как демаскирующий признак, позволяют определить специализацию производства и тип выпускаемой продукции. Для обнаружения химических выбросов производятся проверки проб воздуха, грунта, воды, жидкости, флоры и фауны в районах предполагаемого расположения объекта.

Класс опасности опасных веществ. Под вредным веществом понимается вещество, которое, при контакте с организмом человека, может вызывать отклонения в состоянии его здоровья, в случае нарушения требований безопасности. В таблице 2 представлена классификация опасности веществ по значению его предельно допустимой концентрации (ПДК) [175].

Классы опасности загрязняющих веществ

Таблица 11.2

Класс опасности	Название класса	Основные показатели
Первый класс	Чрезвычайно опасные, особо опасные вещества	Ксенобиотики $\text{ПДК} < 10^{-5} \frac{\text{мг}}{\text{л}}$; $\text{КАК} > 200$; $t_{95} > 180$ суток
Второй класс	Высоко опасные вещества	Ксенобиотики, Pb, As, CCl_4 , CHCl_3 $\text{ПДК} = 10^{-4} - 10^{-5} \frac{\text{мг}}{\text{л}}$; $\text{КАК} > 50 - 200$; $t_{95} = 60 - 180$ суток
Третий класс	Опасные вещества	Ксенобиотики и природные вещества (H_2S , S^2). $\text{ПДК} = 10^{-3} - 10^{-4} \frac{\text{мг}}{\text{л}}$; $\text{КАК} > 1,1 - 50$; $t_{95} = 10 - 59$ суток
Четвертый класс	Умеренно опасные вещества	В основном природные вещества $\text{ПДК} > 0,01 \frac{\text{мг}}{\text{л}}$; $\text{КАК} < 1,1$; $t_{95} < 10$ суток

В таблице 11.2 приняты следующие обозначения: КАК – коэффициент аккумуляции, а t_{95} – время снижения концентрации вещества в 20 раз.

Чем опаснее загрязняющее химическое вещество, тем устойчивее оно к распаду, и тем дольше по времени его можно обнаружить.

Таким образом, в этом пункте рассмотрены возможные демаскирующие признаки объекта и проведён их анализ, на основе которого были отобраны самые актуальные из них, которые легли в основу разрабатываемой подсистемы поддержки принятия решений по идентификации множества демаскирующих признаков объекта, а также описаны их характеристики.

11.3. Разработка подсистемы поддержки принятия решений идентификации множества демаскирующих признаков

Выбор языка программирования играет решающую роль при создании программного приложения и дальнейшей его поддержке. По оценке компании Net Applications, занимающейся сбором статистических данных мирового рынка об использовании операционных систем, за 2021 год наибольшая доля десктопных операционных систем приходится на Microsoft Windows и составляет 88,81% от общего количества [176]. Опираясь на эти данные, было принято решение создания программного обеспечения для платформы Windows. Подходящими языками программирования являются Java, C# и Python.

Необходимо рассмотреть достоинства и недостатки как существующих языков программирования, так и возможностей среды разработки (IDE).

Самым востребованным языком программирования, по статистике ТЮВЕ, в 2021 году [177] является *язык Java*. Это вызвано его кроссплатформенностью, обеспеченной процессом трансляции Java–программы в байт–код, исполняемый виртуальной машиной Java на любой платформе, поддерживающей JVM. Это повышает безопасность, так как выполнение кода и доступ к ресурсам контролируется Java машиной. Это объектно–ориентированный язык, исключая элементарные типы данных. Все версии Java обратно совместимы, вплоть до версии 1.0.2, что позволяет не менять код, написанный на более старых версиях Java. Однако нужно учитывать, что Java является громоздким языком с точки зрения синтаксиса, и испытывает проблемы со *сборщиком мусора*, которые могут вызывать утечки данных из памяти. Востребованность этого языка вызывает необходимость в разработке разнообразных новых сред разработки, направленных на упрощение работы с языком Java, а также новых языков на его базе–Kotlin. Среди IDE языка Java известны NetBeans, IntelliJ IDEA и Eclipse.

Язык программирования C# (разработанной корпорацией Microsoft), обладает собственной средой разработки Visual Studio, с удобными средствами разработки графического интерфейса и встроенным менеджером пакетов NuGet. Он является объектно–ориентированным языком. Так же, как и в Java, программный код на C# переводится в байт–код CIL, общий для платформы .NET, и выполняется виртуальной машиной CLR. Обладает *синтаксическим сахаром*, упрощающим написание и понимание кода. C# не является вполне кроссплатформенным языком, но, учитывая условие разработки под Windows, это не существенно. Недостатком языка является *большой порог вхождения*, если разработчик изначально не знаком с синтаксисом C++ или Java. Также C# немного проигрывает Java в производительности [177].

Язык программирования Python обладает многими достоинствами, среди которых – простота вхождения для начинающих. Код на Python легко читаем, а стандартная библиотека поддерживают большинство необходимых функций. Поддерживает масштабируемость и кроссплатформенность приложений, так как интерпретаторы Python существуют под разные виды платформ. Главным его недостатком является медленность работы. Есть проблема с совместимостью версий языка. Существует ряд интегрированных сред разработки для языка Python, например, Komodo IDE, Eric, PyDev и другие.

Для решения задачи построения ПППР был выбран язык С#, в связи с отсутствием специфических требований к языку. Его выбор основывался на удобстве проектирования графического интерфейса (GUI) с помощью Visual Studio, а также наличием опыта в программировании на данном языке.

11.3.1. Формальное описание подсистемы поддержки принятия решений с использованием коэффициентной методики

Метод оценки входных параметров с использованием коэффициентов является эффективным способом оценить *информативность признаковой структуры объекта защиты объекта*, которая, в этом случае, складывается из признаков групп, которые ее составляют, и рассчитывается по формуле:

$$X = \sum_{i=1}^g W_i \cdot X_i, \quad (11.8)$$

где X – выходной показатель; g – общее количество входных показателей; $W_i \geq 0$ – весовой коэффициент i -го входного показателя; X_i – нормированный i -й входной показатель ($i = 1, \dots, g$). Условие нормирования для W_i таково:

$$\sum_{i=0}^g W_i = 1. \quad (11.9)$$

Значение $W_i = 0$ указывает на отсутствие информативности признака, или группы признаков. Чем больше W_i приближается к единице, тем более информативным является данный демаскирующий признак [178].

Условие нормирования для X_i представлено в формуле:

$$X_i \in [0,1] \quad (11.10)$$

Значение информативности X_i описывает возможность обнаружения демаскирующего признака при заданном его значении. При этом, значение X_i , равное 0, означает полное отсутствие демаскирующего признака.

Однако в действительности оказывается, что обойтись только общим случаем подсчёта информативности нельзя [179]. Структура усложняется до иерархического вида с несколькими подуровнями, на каждом из которых нужно рассчитать частные показатели информативности, вносящие вклад в общую информативность признаковой структуры. Общая схема подсистемы поддержки принятия решений, разработанная для идентификации множества демаскирующих признаков объекта, графически представлена на рис. 11.11:




Рис. 11.11. Структура подсистемы поддержки принятия решений идентификации множества демаскирующих признаков

Условные обозначения входных значений, а также частных показателей структуры подсистемы поддержки принятия решений [179] идентификации множества демаскирующих признаков перечислены ниже:

- В частный показатель информативности визуальных демаскирующих признаков;
- V^1 значение X_i демаскирующего признака «Местоположение»;
- V^2 значение X_i демаскирующего признака «Форма объекта»;
- V^3 значение X_i демаскирующего признака «Контраст с фоном»;
- V^4 значение X_i демаскирующего признака «Пыль»;
- V^5 значение X_i демаскирующего признака «Дым»;
- V^6 значение X_i демаскирующего признака «Тень»;
- V^7 значение X_i демаскирующего признака «Следы от объекта»;
- V^8 значение X_i демаскирующего признака «Температура объекта»;
- V^9 значение X_i демаскирующего признака «Удельная электропроводность»;
- V^{10} значение X_i демаскирующего признака «Габаритные размеры»;
- С частный показатель информативности сигнальных демаскирующих признаков;
- C_1 частный показатель информативности радиосигнальных демаскирующих признаков;
- C_1^1 значение X_i демаскирующего признака «Однородность сигнала»;
- C_1^2 значение X_i демаскирующего признака «Частота»;
- C_1^3 значение X_i демаскирующего признака «Ширина спектра сигнала»;
- C_1^4 значение X_i демаскирующего признака «Мощность»;
- C_1^5 значение X_i демаскирующего признака «Вид сигнала»;
- C_1^6 значение X_i демаскирующего признака «Продолжительность излучения/импульса»;
- C_1^7 значение X_i демаскирующего признака «Коэффициент заполнения»;
- C_2 частный показатель информативности, связанной с акустическими сигнальными демаскирующими признаками;
- C_2^1 значение X_i демаскирующего признака «Вид сигнала»;
- C_2^2 значение X_i демаскирующего признака «Частота»;
- C_2^3 значение X_i демаскирующего признака «Характер спектра сигнала»;

- C_2^4 значение X_i демаскирующего признака «Продолжительность сигнала / импульса»;
- C_2^5 значение X_i демаскирующего признака «Уровень звукового давления»;
- C_2^6 значение X_i демаскирующего признака «Интенсивность сигнала»;
- D частный показатель информативности, связанной с материально–вещественными демаскирующими признаками;
- D^1 значение X_i демаскирующего признака «Макет объекта»;
- D^2 значение X_i демаскирующего признака «Отходы от объекта»;
- D_3 частный показатель информативности, связанной с демаскирующими признаками химических выбросов;
- D_3^1 значение X_i демаскирующего признака «Класс опасности вещества»;
- D_3^2 значение X_i демаскирующего признака «Концентрация вещества»;
- D_4 частный показатель информативности демаскирующих признаков ионизирующего излучения;
- D_4^1 значение X_i демаскирующего признака «Вид ионизирующего излучения»;
- D_4^2 значение X_i демаскирующего признака «Минимально значимая активность»;
- D_4^3 значение X_i демаскирующего признака «Энергия».

Верхним уровнем и итоговым результатом является X – интегральный показатель информативности признаковой структуры [179], рассчитываемый суммированием частных показателей и их информативности по формуле (11.8). Частные показатели информативности также рассчитываются по той же формуле, условные обозначения которых представлены выше.

Однако данный подход не учитывает влияния входных параметров друг на друга, что реализуется с помощью дополнительных повышающих коэффициентов $X_{don\ i}$. Тогда, для подсчёта информативности признаковой структуры объекта защиты, формула (11.8) примет следующий вид:

$$X = \sum_{i=1}^g W_i \cdot (X_i + X_{don.i}) \quad (11.11)$$

Так, существует влияние местоположения объекта на информативность демаскирующего признака «Тень». Если объект находится на открытом пространстве, (рис. 11.12, а), то, очевидно, что тень портового крана обладает большей информативностью, чем тень телевизионной вышки (рис. 11.2, б).




Рисунок 11.12. Тень портового крана на водной глади (а)
и тень телевизионной вышки на городской застройке (б)

Входными параметрами, для подсчёта информативности признаковой структуры, являются нормированные значения X_i каждого демаскирующего признака. Источниками этой информации могут быть: инструментальные измерения демаскирующих признаков, а также проектная документация. Источником информации о значениях W_i является экспертная оценка.

11.3.2. Формирование экспертных оценок при реализации подсистемы поддержки принятия решений

Экспертное оценивание остается одним из востребованных направлений в теории поддержки принятия решений, если использование других объективных методов невозможно, или сложно осуществимо.

Экспертная оценка, проводимая группой высоко квалифицированных специалистов, позволяет дать относительно точную и многостороннюю оценку предметной области на основе опыта и интуиции экспертов. Нельзя забывать, что зачастую опыт и интуиция эксперта играет решающую роль в принятии решения в сложных условиях и условиях нехватки времени.

Одним из наиболее важных этапов проведения экспертного оценивания является подбор экспертов для формирования экспертной комиссии (ЭК). От выбора членов ЭК зависит результат всего исследования, а далее – и результат принятия решения с дальнейшими последствиями. По возможности, нужно отобрать наиболее компетентных экспертов, которые будут отвечать на вопросы менее предвзято. После опроса важно провести оценку согласованности их мнений. После этого можно оценивать возможность доверия результатам опроса.

При формировании экспертной оценки демаскирующих признаков, было отобрано 5 специалистов по техническим средствам защиты информации. Главной задачей было провести ранжирование (заранее подготовленных организатором исследования) демаскирующих признаков.

Ранжирование проводилось по правилу: наиболее информативный демаскирующий признак помещается вверх и имеет порядковый номер 1, а наименее информативный демаскирующий признак ставится последним в списке и имеет порядковый номер M , где M – количество сравниваемых демаскирующих признаков в группе. Групповой опрос специалистов – экспертов проводился с помощью платформы онлайн-опросов *SurveyMonkey* в индивидуальном порядке. На рис.11.13 представлен внешний вид страницы опроса по группе визуальных демаскирующих признаков.

После проведения анкетирования экспертов, обрабатываются результаты и устанавливается, какие визуальные демаскирующие признаки эксперты признали наиболее информативными, а какие нет. На рис. 11.14 графически отображены результаты опроса экспертов по визуальной группе демаскирующих признаков.

Итогом обработки этих результатов является весовой коэффициент каждого демаскирующего признака, рассчитываемый по формуле:

$$W_i = \frac{\sum_{k=1}^N W_{ik}}{N}, \quad (11.12)$$

где W_i – весовой коэффициент i -го показателя; W_{ik} – численная величина весомости i -го показателя, данная экспертом с порядковым номером k ; N – количество участвующих в экспертизе экспертов.

1 Визуальные демаскирующие признаки	
1	Габаритные размеры
2	Пыль
3	Местоположение
4	Температура объекта
5	Форма объекта
6	Следы от объекта
7	Дым
8	Тепло
9	Контраст с фоном
10	Удельная электропроводность

1 из 7 вопросов

Рисунок 11.13. Страница опроса экспертного мнения

Визуальные демаскирующие признаки

Ответили: 5 Пропустили: 0




Рисунок 11.14. Результаты опроса специалистов–экспертов по визуальной группе демаскирующих признаков

Эта же формула позволяет оценить вклад каждой группы признаков в общую признаковую структуру. Нужно отметить, что не всегда имеет смысл проводить оценку согласованности мнений экспертов, так как отобранные эксперты не всегда обладают достаточной компетентностью в данной сфере.

11.3.3. Программная реализация подсистемы поддержки принятия решений идентификации множества демаскирующих признаков

Подсистема поддержки принятия решений представляет собой систему обработки данных для оказания помощи должностным лицам, принимающим решения в сложных условиях, при недостаточном количестве информации. Принятие ответственным лицом более продуманного и объективного решения происходит за счёт анализа всех входных параметров, и дальнейшей оценки их информативности в признаковой структуре объекта.

Для разработки программного модуля системы поддержки принятия решений применяется коэффициентный метод. При использовании этого метода возможно оценить, как количественные, так и качественные параметры. Именно это, а также простота реализации обусловили выбор данного метода [178].

Начиная работу с системой поддержки принятия решений, пользователю предлагается ввести входные данные – сначала данные, описывающие визуальные демаскирующие признаки, затем последовательно – акустические, радиосигнальные, материально–вещественные и другие данные, описывающие соответствующие демаскирующие признаки. Окно запроса входных данных визуальных демаскирующих признаков [179] представлено на рис. 11.15.

Необходимые пояснения для входных параметров даются с помощью подсказок возле полей ввода. Например, подсказка к демаскирующему признаку «*Контраст с фоном*» имеет вид, представленный на рис. 11.16:

Обязательным условием для разрабатываемой подсистемы является возможность не запрашивать лишние данные, если пользователь определил, что группа демаскирующих признаков отсутствует. Это упрощает работу с системой и позволяет пользователю не проводить избыточные измерения. При этом поля с избыточными данными становятся неактивными для изменения пользователем, что показано на рис. 11.17.

Идентификация местожительства демаскирующих признаков

Видовые демаскирующие признаки

Местоположение	Пыль	Следы от объекта
Зеленые насаждения	Да	Нет
Форма объекта	Дым	Температура объекта
Неправильная	Нет	0-50°C
Контраст с фоном	Тень	Удельная электропроводность
20% - 50%	Да	10 ⁻³ - 10 ⁻⁴ См/м
Габаритные размеры		
5 x 3 x 0,7 м		

Далее

Рисунок 11.15. Окно запроса входных данных визуальных демаскирующих признаков




Рисунок 11.16. Всплывающая подсказка

Идентификация множества демаскирующих признаков

Материально-вещественные демаскирующие признаки

Макет объекта:

Отходы от объекта:

Ионизирующее излучение:

Ионизирующее излучение:

Вид ионизирующего излучения:

МЗА:

Энергия:

Наличие химических выбросов:

Химические выбросы:

Класс опасности вещества:


Концентрация вещества:

Назад Далее

Рисунок 11.17. Форма с неактивными полями

После ввода всех необходимых данных происходит оценка всех демаскирующих признаков. Нормирование входных данных обеспечивает систему коэффициентами X_i демаскирующих признаков. При наличии связей между рядом демаскирующих признаков запрашиваются коэффициенты $X_{доп}$, которые суммируются с X_i . Далее запрашиваются коэффициенты W_i из текстового файла factor.txt, содержание которого представлено на рис. 11.18. Это позволяет легко изменять их в любой момент времени, без перекомпиляции приложения. На базе X_i и W_i рассчитывается информативность демаскирующих признаков, а затем информативность групп демаскирующих признаков.

После расчета всех коэффициентов, пользователю выводится результат. Вкладка “Общая информация” отображает информативность признаковой структуры; наиболее информативную группу признаков, а также наиболее информативные признаки во всей признаковой структуре. Содержание вкладки “Общая информация” представлено на рис. 11.19.



```
1 # файл factor.txt содержит весовые коэффициенты демаскирующих признаков,  
2 # сумма которых не может превышать 1 внутри каждой группы. Обычно  
3 # значения коэффициентов устанавливаются экспертами  
4  
5 =====  
6 #          Визуальные демаскирующие признаки          #  
7 =====  
8  
9 contrast 0.1382  
10 shape 0.1127  
11 shadow 0.0657  
12 smoke 0.1091  
13 dust 0.047  
14 location 0.1491  
15 conductivity 0.0691  
16 track 0.0691  
17 temperature 0.08  
18 dimensions 0.16  
19
```

Рисунок 11.18. Содержание файла factor.txt




Рисунок 11.19. Вкладка «Общая информация»

Вкладка «Рекомендации», содержание которой представлено на рис. 11.20, обеспечивает пользователя информацией, которая может помочь скрыть наиболее информативные демаскирующие признаки, если это возможно.

Если присутствуют акустические демаскирующие признаки, то будет рассчитана дальность распространения акустического сигнала — сквозь выбранную среду [179]. Здесь можно найти много информации о проявлениях демаскирующих признаков, появляющихся при определенных условиях.




Рисунок 11.20. Вкладка «Рекомендации»

Анализ коэффициента каждого признака позволит более полно понять ситуацию и при необходимости скорректировать систему защиты объекта.

Вкладка «Коэффициенты» даёт пользователю возможность посмотреть рассчитанные коэффициенты для всех демаскирующих признаков, по отношению к интегральному показателю информативности признаковой структуры A , а не к группе демаскирующих признаков, в которую включен рассматриваемый признак. На рис. 11.21 видно, что демаскирующие признаки ранжированы по группам, а внутри – по убыванию информативности.




Рисунок 11.21. Вкладка «Коэффициенты»

Пользователю доступно сохранение информации из всех вкладок в текстовый файл формата RTF, пример которого представлен на рис. 11.22.




Рисунок 11.22. Пример текстового файла с сохраненными данными

На этом цикл оценки информативности демаскирующих признаков объекта завершен, и полученные результаты окажут своё влияние на процесс правильного принятия решения должностным лицом, при идентификации множества демаскирующих признаков защищаемого объекта организации.

Разработана программная реализация подсистемы поддержки принятия решений, позволяющая: оценить информативность возможных демаскирующих признаков объекта; а также информативность признаковой структуры объекта; получить рекомендации по снижению информативности выявленных демаскирующих признаков объекта; сохранить результаты проведения исследования в целях использования при дальнейшем анализе результатов.

Разработанная подсистема поддержки принятия решений позволяет специалистам в области защиты информации оперативно формировать список информативных демаскирующих признаков объектов защиты, во время предварительного обследования нового объекта информатизации, сохранять результаты проведенных исследований и обосновывать выбор тех или иных средств защиты информации. Созданная подсистема создаёт условия для проектирования и модернизации всей системы защиты, т.е. такого управления частными показателями, когда интегральный показатель информативности признаковой структуры объекта примет желаемое значение.

12. РАЗРАБОТКА FUZZY–СИСТЕМЫ ИДЕНТИФИКАЦИИ ДЕМАСКИРУЮЩИХ ПРИЗНАКОВ ОБЪЕКТА ЗАЩИТЫ

Основоположником теории адаптивных нейро–нечётких систем является R. Yang, публикации которого положены в основу многих исследований, связанных с адаптивной сетью на основе нечёткого вывода (Adaptive Neuro–Fuzzy Interference System, ANFIS). Это искусственная нейронная сеть, основанная на нечёткой системе вывода *Такаги–Сугено*. По этой теме выдающимися зарубежными авторами являются: C.J. Harris, R. Kruse и S.V. Kartalopoulos. По теме *нейро–нечёткой логики* также известны работы L.A. Zadeh, J. Yen, R. Langari, M. Sugeno, R. Hecht–Nielsen и S. Haykin. Таким образом, нейронные сети с нечёткой (fuzzy) логикой сегодня являются весьма актуальной темой.

Несмотря на большое количество исследований в области технической защиты информации, оценка информативности различных демаскирующих признаков, а также разработка методики построения системы идентификации множества демаскирующих признаков объектов защиты различных организаций на базе fuzzy–логики, в настоящее время разработана недостаточно [180].

Дальнейшее исследование вопросов идентификации демаскирующих признаков объектов защиты, для получения наиболее адекватного результата с учётом современной геополитической обстановки, является весьма актуальным.

Объектом исследования проекта являются процессы принятия решений по идентификации множества демаскирующих признаков объектов защиты. *Предметом исследования* выступают методы идентификации (классификации) и методики обработки множества демаскирующих признаков объектов защиты организации. *Целью исследования* является разработка методики построения fuzzy–системы идентификации множества демаскирующих признаков объектов защиты. Для достижения цели нужно решить следующие *задачи исследования*:

- систематизация методов классификации демаскирующих признаков, исследование проблемы классификации с позиции системного анализа;
- исследование особенностей обнаружения и распознавания объектов в условиях неполных данных по их демаскирующим признакам;
- разработка fuzzy–системы идентификации множества демаскирующих признаков объекта защиты на основе системного подхода.

Методы исследования для решения поставленных задач – известные положения теории систем и системного анализа, теории нечётких множеств (fuzzy – логики), теории принятия решений и теории нейронных сетей.

12.1. Теоретические сведения о построении системы идентификации демаскирующих признаков

12.1.1. Особенности использования нейронных сетей в проекте

Нейронная сеть – это математическая модель, представляющая собой параллельный распределённый процессор, состоящий из искусственных нейронов – простых обрабатывающих единиц, которые имеют естественную склонность к накоплению эмпирических знаний и делают их доступными для использования. Она напоминает головной мозг по двум параметрам:

1. Знания приобретаются нейронной сетью из её среды, в процессе обучения.
2. Сильные связи между нейронами, известные как синаптические веса, используются для хранения полученных знаний [180].

Искусственный нейрон – это единица обработки информации, являющаяся основным элементом нейронной сети. На рис. 12.1 показана модель нейрона. Основными элементами модели искусственного нейрона являются:

1. *Множество синапсов*, характеризующиеся синаптическими весами. В отличие от веса синапса в мозге, синаптические веса искусственного нейрона находятся в диапазоне как отрицательных, так и положительных значений.
2. *Сумматор* для объединения входных сигналов, взвешенный по соответствующим синаптическим весам искусственного нейрона.
3. *Функции активации* — это функции, используемые в нейронных сетях для вычисления взвешенной суммы входных данных и смещений, которые используются, чтобы решить, можно ли активировать нейрон, или нет. Они манипулируют исходными данными с помощью метода градиентной обработки, с помощью *градиентного спуска*, а затем производит вывод для нейронной сети.




Рисунок 12.1. Модель искусственного нейрона

Обычно, нормализованный диапазон значений выхода нейрона лежит в пределах $[0, 1]$. В отдельных случаях он равен $[-1, 1]$. Модель нейрона на рис.12.1 также включает *внешнее смещение*, обозначенное буквой b_k . Смещение b_k вызывает увеличение или уменьшение входного значения функции активации, в зависимости от того, является ли внешнее смещение положительным или отрицательным. Можно описать модель нейрона в математической форме:

$$\begin{cases} u^k = \sum_{j=1}^m w_{kj} x_j \\ a^k = f(u^k + b^k) \end{cases}, \quad (12.1)$$





где $x_1, x_2, \dots, x_m$ – входные сигналы; $w_{k1}, w_{k2}, \dots, w_{km}$ – синаптические веса нейрона; u^k – выход линейного сумматора; b^k – смещение; $f(\dots)$ – функция активации нейрона; a^k – выходное значение нейрона.

Функция активации, обозначаемая как $f(\dots)$, имеет разновидности [181], представленные в табл. 12.1, и имеющие различные формы:

Различные виды функций активации

Таблица 12.1

Название	Отношение вход /выход	Графическая зависимость
Функция активации жёсткого периода (ступенчатая)	$a=0; \quad n<0;$ $a=1; \quad n\geq 0.$	
Симметричная функция активации, жесткого предела	$a=-1; \quad n<0;$ $a=+1; \quad n\geq 0.$	
Линейная функция активации	$a=n$	
Линейная с насыщением функция активации	$a=0, \quad n<0,$ $a=n, \quad 0\leq n\leq 1,$ $a=1, \quad n>1$	
Симметричная линейная, с насыщением, функция активации	$a=-1, \quad n<-1,$ $a=n, \quad 0\leq n\leq 1,$ $a=1, \quad n>1$	

Название	Отношение вход /выход	Графическая зависимость
Сигмоидальная (логистическая) функция активации	$a = \frac{1}{1 + e^{-n}}$	
Функция активации – гиперболический тангенс	$a = \frac{e^n - e^{-n}}{e^n + e^{-n}}$	
Полулинейная функция активации	$a=0; n<0;$ $a=n; n\geq 0.$	
Конкурирующая функция активации	$a=1$ – нейрон с максимальным значением n $a=0$ – остальные нейроны	

Нейронные сети, как правило, состоят из нейронных слоёв. Рассмотрим нейронную сеть, состоящую из трёх слоев нейронов. У каждого слоя есть собственные параметры: матрица весов W , вектор смещения b , входной вектор n и выходной вектор a . Слой, выходной вектор a которого является выходом нейронной сети, называется *выходным слоем*. Остальные слои называются *скрытыми*. На рис. 12.2 показана структура трёхслойной нейронной сети, где слои 1 и 2 являются скрытыми слоями, а слой 3 – выходным слоем.




Рисунок 12.2. Трёхслойная нейронная сеть

Основываясь на формуле (12.1), можно найти выход нейронной сети:

$$a^3 = f^3 \left(w^3 f^2 \left(w^2 f^1 \left(w^1 p + b^1 \right) + b^2 \right) + b^3 \right) \quad (12.2)$$

Многослойные нейронные сети являются более мощным инструментом, чем однослойные. Так, двухслойная нейронная сеть, имеющая в первом слое сигмоидную функцию активации и линейную функцию активации во втором слое, способна к приближению большинства функций. При этом однослойные нейронные сети на это не способны, что говорит о недостатках их архитектуры.

Существуют три основных правила, которыми нужно руководствоваться при выборе архитектуры искусственной нейронной сети [181]:

1. Число входных значений нейронной сети равно количеству значений, необходимых для решения поставленных задач. Не стоит передавать урезанные данные, которых будет недостаточно для решения задачи. Передача избыточного количества данных также негативно сказывается на конечном результате.

2. Количество выходных нейронов сети также должно быть равно количеству ожидаемых результатов при решении поставленной задачи.

3. Желаемые характеристики выходного сигнала помогают выбрать функцию активации для выходного слоя. Например, если выходное значение лежит в диапазоне $[-1, 1]$, то целесообразно использовать симметричную функцию активации жёсткого предела, в других случаях – выбор функции активации зависит от того, какие результаты требуются на выходе.

Таким образом, архитектура искусственной нейронной сети практически полностью определяется спецификацией проблемы, включая конкретное количество входов и выходов, а также функцию активации выходного сигнала.

12.1.2. Представление нейронной сети в качестве ориентированного графа

Модель нейрона, представленная на рис. 12.1, функционально описывает различные элементы, составляющие модель искусственного нейрона. Можно упростить описание модели, используя идею *графов потока сигнала*, при этом не пренебрегая какими-либо функциональными деталями модели.

Граф передачи сигнала — это сеть направленных связей (ветвей), которые связаны в определенных точках, называемых узлами. Типичный узел j имеет связанный с ним сигнал узла x_j . Типичная направленная связь начинается в узле j и заканчивается в узле k . Узел k имеет связанную передаточную функцию или коэффициент пропускания, который определяет способ, которым сигнал u_k в узле k зависит от сигнала x_j в узле j .

Поток сигналов в разных частях графика определяется тремя правилами:

Правило 1. Сигнал должен проходить по связи только в том направлении, которое определено стрелками, указанными на схеме этой связи.

Существуют два различных типа связей:

– *синаптические связи*, чье поведение задаётся линейным отношением вход / выход. В частности, сигнал узла x_j умножается на *синаптический вес* w_{kj} , чтобы сформировать сигнал узла y_k , как показано на рис. 12.3, а;

– *связь активации*, чье поведение в общем случае задается нелинейным отношением вход / выход. Такая связь представлена на рис. 12.3 б, где обозначение $\varphi(\dots)$ является нелинейной функцией активации.




Рисунок 12.3. Базовые правила для графа передачи сигнала: а) синаптические связи; б) связь активации; в) синаптическая конвергенция; г) синаптическая дивергенция.

Правило 2. Сигнал узла равен алгебраической сумме всех сигналов, входящих в узел (рис. 12.3, в). Это правило *синаптической конвергенции*.

Правило 3. Сигнал узла передаётся каждой выходящей из узла связи, при этом передача сигнала узла полностью независима от функции передачи выходной связи (рис. 12.3 г). Это правило *синаптической дивергенции*.

По этим правилам можно построить граф передачи сигнала (рис. 12.4), в основе которого лежит модель нейрона. Схема на рис. 12.4 очевидно проще, чем на рис. 12.1, хотя она содержит те же самые функциональные детали. Здесь смещение представлено фиксированным входным сигналом $x_0 = +1$.

Основываясь на графе передачи сигналов (рис. 12.4) в качестве модели нейрона, можно предложить математическое определение нейронной сети:

Нейронная сеть представляет собой *ориентированный граф*, состоящий из узлов с взаимосвязанными синаптическими связями и функциями активации, которые характеризуются четырьмя базовыми свойствами:




Рисунок 12.4. Нейрон графа передачи данных

- каждый нейрон представлен множеством линейных синаптических связей, приложенным извне смещением, и нелинейной функцией активации. Смещение – это синаптическая связь с фиксированным входным значением $+1$;
- синаптические связи нейрона оценивают их входные сигналы;
- взвешенная сумма входных сигналов нейрона определяет индуцированное локальное поле этого рассматриваемого нейрона;
- связь активации подавляет индуцированное локальное поле конкретного нейрона для получения выходного сигнала этого нейрона.

Ориентированный граф, обладающий этими свойствами, является полным, в том смысле, что он описывает не только поток сигнала от нейрона к нейрону, но также и поток сигнала внутри каждого нейрона. Однако, когда необходимо описать только поток сигнала между нейронами, можно использовать сокращенную форму этого графа, опуская детали потока сигнала внутри отдельных нейронов. Такой сокращённый ориентированный граф является *частично полным*, и характеризуется следующими свойствами [182]:

- исходные узлы подают входные сигналы в ориентированный граф;
- каждый нейрон представлен одним узлом – *вычислительным узлом*;
- связи, соединяющие исходные и вычислительные узлы графа, не имеют веса. Они просто определяют направления потока сигнала в графе.

Определенный, таким образом, *частично полный ориентированный граф* называется архитектурным графом, описывающим слой нейронной сети, что проиллюстрировано на рис. 12.5 для простого случая одиночного нейрона с t исходными узлами и одним фиксированным узлом $+1$, определяющим смещение. Здесь вычислительный узел, представляющий нейрон, показан серым кругом, а исходные узлы показаны в виде небольших квадратов.




Рисунок 12.5. Архитектурный граф нейрона

Так, существует три вида графического представления нейронной сети:

- модель нейрона, дающая функциональное описание элемента сети;
- архитектурный граф, описывающий каждый слой нейронной сети;
- граф потока сигнала, предоставляющий полное описание потока сигнала, действующего в искусственной нейронной сети.

12.1.3. Виды обучения нейронной сети

Процессы обучения, с помощью которых функционируют нейронные сети, можно классифицировать следующим образом: обучение *с учителем* и обучение *без учителя*, которое может быть подразделено на обучение *без контроля* и обучение *с подкреплением*. Эти формы обучения, присущие искусственным нейронным сетям, в широком смысле, аналогичны обучению человека.

Обучение с учителем, также называемое контролируемым обучением, представлено на рис. 12.6. В концептуальном плане, можно представить, что учитель обладает знаниями об окружающей среде, и эти знания представлены в виде множества примеров, представленных в виде пар вход / выход.




Рисунок 12.6. Схема обучения с учителем

Окружающая среда, при этом, неизвестна нейронной сети. Предположим теперь, что учитель и нейронная сеть подвергаются воздействию обучающего вектора (то есть, конкретного примера), взятого из одной и той же среды. Благодаря встроенным знаниям, учитель может предоставить нейронной сети желаемый ответ для этого вектора обучения. Действительно, желаемый ответ представляет собой *оптимальное действие*, которое должно быть выполнено нейронной сетью. Параметры нейронной сети настраиваются при совместном воздействии обучающего вектора и сигнала ошибки, который представляет собой разницу между ожидаемым и действительным ответом нейронной сети. Такая настройка выполняется итеративно, с целью, в конечном итоге, заставить нейронную сеть подражать учителю. Таким образом, знания об окружающей среде, доступные учителю, передаются в нейронную сеть посредством обучения, и сохраняются в форме фиксированных синаптических весов, представляющих собой долговременную память нейронной сети. При достижении этого условия можно отказаться от учителя и предоставить нейронной сети возможность самостоятельно обрабатывать сигналы, поступающие из окружающей среды.

Описанная форма контролируемого обучения является основой обучения с коррекцией ошибок. Из рис. 12.6 очевидно, что процесс контролируемого обучения представляет собой замкнутую *систему обратной связи*, а неизвестная окружающая среда находится вне цикла. Показателем производительности системы можно считать среднеквадратическую ошибку или сумму квадратов ошибок по обучающей выборке, что определяется как функция свободных параметров (то есть синаптических весов) системы. Эта функция может быть визуализирована как *многомерная поверхность ошибки* производительности, или просто *поверхность ошибки*, со свободными параметрами в качестве координат. Поверхность действительной ошибки должна усредняться по всем обучающим примерам. Любая операция, выполняемая системой обратной связи под наблюдением учителя, может быть представлена точкой на поверхности ошибки. Чтобы система могла улучшить производительность с течением времени и, следовательно, обучаться у учителя, эта точка должна постепенно смещаться к минимальной точке поверхности ошибки. Такая минимальная точка может быть локальным или глобальным минимумом.

Искусственная нейронная сеть, обучаемая с учителем, способна изменять и корректировать своё поведение с помощью информации о градиенте поверхности ошибки, соответствующей её текущему поведению.

Градиент поверхности ошибки в любой точке — это вектор, который указывает направление скорейшего спуска к минимальному значению функции (локальному и/или глобальному). С использованием алгоритмов минимизации значения функции, полного набора обучающих примеров и времени, достаточного для проведения обучения, контролируемая нейронная сеть может хорошо аппроксимировать неизвестное отображение ввода–вывода.

Обучение без учителя. В неконтролируемом обучении нет внешнего учителя или критика, который бы контролировал процесс обучения, как показано на рис. 12.7. Скорее, предусматривается независимая от задачи мера качества, определяющая, что должна изучить нейронная сеть. Свободные параметры сети оптимизируются с учётом этой меры. Для конкретной, независимой от задачи меры качества, когда нейронная сеть настроена на статистические закономерности входных данных, она развивает способность формировать внутренние представления для кодирования функций ввода, и, таким образом, автоматически создавать новые классы.




Рисунок 12.7. Схема обучения без учителя

Для проведения обучения без учителя можно использовать правило *конкурентного обучения*. Например, можно использовать нейронную сеть, которая состоит из двух уровней – входного и конкурентного уровня. Входной слой получает доступные данные. Конкурентный слой состоит из нейронов, которые конкурируют друг с другом (в соответствии с правилом обучения) за *возможность реагировать на функции*, содержащиеся во входных данных. В своей простейшей форме, при конкурентном обучении нейронная сеть работает по стратегии «*победитель получает все*». При такой стратегии нейрон с наибольшим суммарным входом «*выигрывает*» у конкурентов и включается. При этом все остальные нейроны в сети выключаются.

12.1.4. Нечёткая логика

Нечёткая логика — это математический метод, предназначенный для моделирования логических рассуждений с помощью расплывчатых или неточных утверждений и позволяющий, при этом, получить точный вывод.

Нечёткая логика основывается на теории нечётких множеств. В отличие от чётких множеств, принадлежность к которым определяется бинарно – принадлежит или не принадлежит (1 или 0), принадлежность к нечёткому множеству описывается обычно действительным числом из интервала $[0,1]$. Нечёткость возникает в результате присвоения суждениям различных степеней принадлежности, где 0 представляет значение «не принадлежит», 1 – «полностью принадлежит», а другие значения относятся к *частичной принадлежности*, то есть – к промежуточным степеням принадлежности.

Степень принадлежности основывается на функции принадлежности к нечёткому множеству. На рис. 12.8 показан пример функции принадлежности. Горизонтальная ось представляет входную переменную x , вертикальная ось представляет степень принадлежности $\mu(x)$ к нечеткому множеству. Кривая опоры (support) функции принадлежности определяет диапазон, в котором входная переменная будет иметь ненулевое значение принадлежности к нечёткому множеству. На этом рисунке $\mu(x) \neq 0$, когда x – любая точка, расположенная между точкой a и точкой d . В то время, как кривая ядра (core) функции принадлежности определяет диапазон, в котором входная переменная x будет иметь полную степень принадлежности ($\mu(x) = 1$), другими словами, произвольная точка в интервале $[b, c]$ полностью принадлежит нечёткому множеству, которое определяется этой функцией принадлежности.




Рисунок 12.8. Функция принадлежности к нечёткому множеству

Существует несколько видов функций принадлежности, представленных в табл. 12.2. Независимо от формы, одна функция принадлежности может определять только один нечёткий набор. Обычно, для описания одной входной переменной используется более одной функции принадлежности [182].

Так, если взять потребление топлива автомобилем, то для представления всей ситуации применима трёхуровневая нечёткая система с нечёткими наборами «Низкий», «Средний» и «Высокий».

Разновидности функций принадлежности

Таблица 12.2

Название	Функция принадлежности $\mu(x)$	График функции
Треугольная	$\mu(x) = \begin{cases} 0, \text{ если } x \leq a; \\ \frac{x-a}{b-a}, a \leq x \leq b; \\ \frac{c-x}{c-b}, b \leq x \leq c; \\ 0, x \geq c. \end{cases}$	
Трапецеидальная	$\mu(x) = \begin{cases} 0, \text{ если } x \leq a; \\ \frac{x-a}{b-a}, a \leq x \leq b; \\ 1, b \leq x \leq c; \\ \frac{d-x}{d-c}, c \leq x \leq d; \\ 0, x \geq d. \end{cases}$	
Экспоненциальная я (Гауссова)	$\mu(x) = e^{-\frac{(x-a)^2}{2b^2}}$	
Колоколообразная	$\mu(x) = \frac{1}{1 + \left \frac{x-c}{a} \right ^{2b}}$	
Сплайн	$\mu(x) = \begin{cases} 1, \text{ если } x \leq a; \\ \frac{1}{2} + \frac{1}{2} \cos\left(\frac{x-a}{b-a} \cdot \pi\right), a \leq x \leq b; \\ 0, x \geq d. \end{cases}$	

В процессе обработки данных правила *If–Then* составляют механизм вывода, который определяет, как проецировать входные переменные в выходное пространство. Обычно, нечёткое правило If–Then имеет вид:

$$\text{If } x \text{ is } A, \text{ Then } y \text{ is } B.$$

Первая часть правила является *посылкой*, где x является входной переменной. Остальная часть – это следствие, а y – выходная переменная. Причина, по которой условные утверждения If–Then универсально применимы, состоит в том, что и A , и B являются лингвистическими переменными, и эта форма условного утверждения согласуется с обычным человеческим суждением. Например, подходящим правилом If–Then может быть утверждение типа: «Если твердость материала жёсткая, то скорость резания низкая». A может рассматриваться как нечёткое множество, и определяться конкретной функцией принадлежности, а B может быть либо нечетким множеством, либо полиномом относительно входа x в зависимости от конкретного метода нечёткого вывода.

В результате активации различных If–Then правил, система даёт нечёткий результат, который необходимо привести к чёткому виду. Подобный процесс называется *дефаззификацией*. Существует несколько методов дефаззификации для одной нечёткой области – т.е. приведения её к чёткому утверждению:

1. *Метод центра тяжести* (centroid), представленный на рис. 12.9, возвращает центр области под кривой. Если представить область кривой как пластину одинаковой плотности, центр тяжести – это точка вдоль оси x , вокруг которой будет уравниваться эта форма.




Рисунок 12.9. Функция принадлежности к нечёткому множеству

2. *Метод медианы* (bisector) – это вертикальная линия, которая делит область на две подобласти равной площади. Иногда, но не всегда совпадает с линией центра тяжести. Метод медианы проиллюстрирован на рис. 12.10




Рисунок 12.10. Метод медианы

3. Наименьший из максимумов (smallest of maxima, SOM), наибольший из максимумов (largest of maxima, LOM), центр максимумов (middle of maxima, MOM). Эти три метода выбирают ответ из области с максимальным значением. Поскольку в данном примере есть отрезок (*плато*) максимума, то значения SOM, LOM и MOM различны. Это показано на рис. 12.11.




Рисунок 12.11. Методы SOM, LOM, MOM

Если в области имеется только точка максимума, то тогда величины SOM, LOM и MOM принимают одно и то же значение [183].

Таким образом, использование различных методов *дефаззификации* предполагает получение различных выходных результатов.

12.1.5. Адаптивная нейро–нечёткая система (ANFIS)

Адаптивная нейро–нечёткая система (Adaptive Neuro–Fuzzy Inference System, ANFIS) является гибридной системой, которая объединяет методы нечёткой логики и нейронных сетей для использования основных преимуществ этих методов: нечёткая логика учитывает неточность и неопределённость моделируемой системы, в то время как нейронная сеть позволяет системе адаптировать начальные правила нейро–нечёткой системы для получения окончательной модели ANFIS, соответствующей поставленной задаче [184].

Структура адаптивной нейро–нечёткой системы состоит из 5 блоков:

- база правил, содержащая в себе нечёткие правила If–Then;
- база знаний, хранящая функции принадлежности нечётких множеств, используемых в правилах If–Then нейро–нечёткой системы;
- блок принятия решений, производящий вывод на основе правил If–Then;
- интерфейс *фаззификации*, преобразующий нечёткие данные в степени принадлежности лингвистическим термам для последующего преобразования;
- интерфейс *дефаззификации*, преобразующий полученный нечёткий результат вычислений в чёткий выход нейро–нечёткой системы [185–190].

В разрабатываемой адаптивной нейро–нечёткой системе используются нечёткие правила *Такаги–Сугено*. Адаптивная нейро–нечёткая модель обычно представляется как *шестислойная нейронная сеть прямого распространения* (Feed Forward Neural Network), структура которой показана на рис. 12.12.




Рисунок 12.12. Структура адаптивной нейро–нечёткой системы

Первый слой адаптивной нейро–нечёткой системы называется *входным* слоем. Нейроны этого слоя передают чёткие входные данные на второй слой без преобразования. *Второй* слой, *слой фаззификации*, определяет степени принадлежности входного значения к нечётким множествам $A^1, A^2, \dots, A^n$.

Этот слой является адаптивным, и каждый узел имеет функцию активации. Каждый нейрон *третьего* слоя (называемого слоем *правил*) рассчитывает степень принадлежности w_k , которая определяет, насколько каждое нечёткое правило соответствует входному значению. Выход каждого нейрона является произведением всех поступающих к нему сигналов. *Четвёртый* слой называется слоем *нормализации*. Каждый нейрон в этом слое получает входные данные из всех нейронов в слое правил и рассчитывает нормализованную степень принадлежности данного правила, которая определяет вклад конкретного нечёткого правила в конечный результат. *Пятый* слой называется слоем *дефаззификации*. Каждый нейрон в этом слое связан с соответствующим нейроном нормализации четвертого слоя, а также получает начальные входы: $x_1, x_2, \dots, x_n$. Шестой слой представлен одним нейроном, вычисляющим сумму выходов всех нейронов *дефаззификации* и выдаёт общий выход ANFIS.

Таким образом, регулируемые искусственной нейронной сетью параметры нейро–нечёткой системы включают в себя следующие параметры:

- параметры *предпосылок* системы, являющиеся нелинейными параметрами функций принадлежности для второго слоя – слоя фаззификации;
- параметры *следствий* системы – коэффициенты полинома первой степени для пятого слоя нейронной сети прямого распространения – *дефаззификации*.

12.1.6. Сравнение методов обучения нейронных сетей

Хотя адаптивные нейро–нечёткие системы являются комбинацией методов нейронных сетей и нечёткой логики, между всеми этими методами существуют различия. В табл. 12.3 представлена их сравнительная характеристика.

Сравнение методов нечёткой логики, нейронных сетей
и адаптивных нейро–нечётких сетей [183–190]

Таблица 12.3

Параметр	Нечёткая логика	Нейронные сети	ANFIS
Переменная	Лингвистическая переменная	Взвешенное число	Лингвистическая переменная и взвешенное число
Использование внешних знаний	Нет	Да	Да, из-за их использования в нейронной сети

Продолжение таблицы 12.3

<i>Параметр</i>	<i>Нечёткая логика</i>	<i>Нейронные сети</i>	<i>ANFIS</i>
Возможность принятия решений	Да, используется для принятия точного решения в случае неопределённости	Нет, но нейронная сеть способна действовать как человек, который принимает решение в сложной ситуации	Да, на основе модуля нечёткой логики
Точность результата	Даёт точный результат	Даёт приближенный результат	Даёт точный результат
Обработка неопределённости	Разработана для обработки неопределённости	Не может справиться с неопределённостью	Обрабатывает неопределённости
Извлечение знаний	Да	Нет	Да
Взаимодействие	Через нечёткую систему вывода	Нет, полностью чёрный ящик	Через правила If–Then–Else
Возможность обучения	Не может обучиться, используя знания лингвистики	Да, может обучаться на наборах данных	Может обучаться через нейронную сеть
Возможность использования априорных знаний	Могут быть использованы	Нет	Могут
Подход к решению проблемы	Нелинейный	Нелинейный	Линейный

В результате анализа табл. 12.3 становится очевидно, что ANFIS обладает существенными преимуществами, относительно методов нечёткой логики и искусственных нейронных сетей, составляющих его основу:

- использование нечётких правил If–Then для описания сложной системы;
- не требуются (но могут быть использованы) априорные знания, которые необходимы для нечетких систем, но не всегда могут быть доступными [183];
- недостатки метода нейронных сетей покрываются и компенсируются преимуществами метода нечёткой логики и наоборот [184 – 190].

Итак, были рассмотрены теоретические сведения построения нейро–нечёткой системы идентификации демаскирующих признаков. Было выполнено сравнение интеллектуальных методов обработки данных, таких как: нейронные сети, нечёткая логика и адаптивные нейро–нечёткие системы, используемые при создании Fuzzy–системы идентификации демаскирующих признаков объекта.

12.2. Программная реализация адаптивной нейро–нечеткой системы идентификации демаскирующих признаков

12.2.1. Апробирование построения ANFIS с помощью средств MatLAB

Перед построением нейро–нечёткой системы было принято решение опробовать метод в упрощённом виде, используя усреднённые данные и инструмент *Neuro–Fuzzy Designer* из *MatLAB Fuzzy Logic Toolbox* [191].

На вход алгоритма нужно ввести четыре переменные, описывающие информативность каждой группы демаскирующих признаков. Общая схема нейро–нечеткой сети в *Neuro-Fuzzy Designer* представлена на рис. 12.13.




Рисунок 12.13. Общая схема нейро–нечёткой сети

Процесс обучения нейронной сети представляет собой изменение внутренних параметров сети для более точного соответствия поставленной задаче. Обновление параметров нейронной сети происходит с помощью метода оптимизации, который объединяет в себе метод *обратного распространения ошибки* для параметров предпосылок и метод *наименьших квадратов* для параметров следствий системы [192]. Необходимые параметры для обучения нейро–нечёткой системы, количество эпох и погрешность задается в окне редактора ANFIS, панель которого представлена на рис. 12.14.




Рисунок 12.14. Панель окна редактирования ANFIS

Здесь можно загрузить тестовые, тренировочные и проверочные данные, сгенерировать нейро–нечеткую систему и протестировать полученную систему. Пример отображения тренировочных данных представлен на рис. 12.15.




Рисунок 12.15. Тренировочные данные, переданные системе

Нейро–нечёткая система имеет ошибку обучения около 3,5% после 100 эпох обучения. Из рис. 12.16 видно, что достаточно 30–40 эпох для обучения, так как после этого значение ошибки практически не изменяется. Далее, начинается тестирование системы: для этого используется тестовый файл, содержащий данные, которые не использовались в процессе обучения системы. Нейро–нечёткая система, обученная с помощью метода ANFIS (Adaptive Neuro–Fuzzy Interference System), имеет ошибку обобщения примерно в 10%.




Рисунок 12.16. Зависимость ошибки обучения нейронной сети (Error) от количества эпох (Epochs)

В процессе обучения нейро–нечёткой системы, в консоль Neuro–Fuzzy Designer выводится основная информация о состоянии системы, показанная на рис. 12.17. В неё входит: минимальное значение среднеквадратичной ошибки (RMSE) обучения, количество узлов в системе, число линейных и нелинейных параметров, общее число параметров, значения тренировочных и проверочных пар данных, количество нечётких правил в системе и значение функции потерь для предыдущей и текущей эпохи обучения [193].

```

Minimal training RMSE = 0.052789

ANFIS info:
  Number of nodes: 193
  Number of linear parameters: 405
  Number of nonlinear parameters: 36
  Total number of parameters: 441
  Number of training data pairs: 900
  Number of checking data pairs: 0
  Number of fuzzy rules: 81

Start training ANFIS ...

1      0.0527706
2      0.0527514

```

Рисунок 12.17. Основная информация о нейро–нечеткой системе

На рис. 12.18 представлены функции принадлежности входных данных, полученные после обучения нейронной сети [194].




Рисунок 12.18. Функции принадлежности входных данных после обучения

В данном случае полученные функции принадлежности представляют собой колоколообразную функцию [182], но этот параметр можно изменить в окне генерации FIS, которое представлено на рис. 12.19.

Сгенерированная структура нейро–нечёткой системы представлена на рис. 12.20. Здесь показаны четыре входных узла (input), представляющие собой значения информативности каждой группы демаскирующих признаков, по три узла *inputmf* для каждого узла input, которые являются функциями принадлежности к группам демаскирующих признаков объектов защиты («Низкий», «Средний», «Высокий»), 198 узлов правил и столько же узлов дефаззификации, а также выходной узел output.




Рисунок 12.19. Окно генерации FIS




Рисунок 12.20. Подробная структура нейро-нечёткой сети

Программное средство Neuro-Fuzzy Designer предоставляет возможность визуализации поверхности сопоставлений двух входных значений и одного выходного. Когда на вход передаются четыре значения групп демаскирующих признаков, можно посмотреть шесть поверхностей зависимости каждого входа от другого. Данные поверхности представлены на рис. 12.21.




Рисунок 12.21. Поверхности сопоставлений входных значений нейро–нечёткой сети и ее выходного значения

Система способна рассчитывать результат для всего диапазона входных значений. На рис. 12.22 показано графическое изображение нечёткого вывода системы на базе сгенерированных нечётких правил для входных значений: {визуальные=0.59; акустические=0; радиосигнальные=0; материальные=0.33}.

Система приняла решение, что информативность признаковой структуры для этих входных значений равна 0.406, в то время как действительный результат равен 0.42. Ошибка данного решения не превышает заявленных 10%.

12.2.2. Подготовка обучающих данных для нейро–нечеткой системы

При подготовке данных для обучения нейро–нечёткой системы использовались результаты предыдущего исследования (глава 11), результатом которого являлось создание подсистемы поддержки принятия решений идентификации множества демаскирующих признаков объекта [195, 196].




Рисунок 12.22. Графическое представление нейро–нечёткого вывода

Нормированные входные данные, которые описывают информативность тридцати общих демаскирующих признаков, и результаты работы подсистемы на основе их анализа, взяты в качестве начальных сведений. На рис. 12.23 показана имитация выбора пользователем значения параметра «контраст».

```
Random x = new Random(); // объявление переменной для генерации
чисел
for (int q = 0; q < 100000; q++){
    int n = x.Next(0, 4); //получаем случайное число в
интервале [0,4]
    ElemList.Add(new ComboElement("contrast", Element.
Unmask.visual, n));}
```

Рисунок 12.23. Автоматический выбор значений характеристик системы

Таким же образом имитируется выбор и всех параметров системы. После сохранения всех выбранных значений в список экземпляров класса *ElemList*, производится получение весов для выбранных значений параметров, расчёт результатов для каждой группы демаскирующих признаков, рассчитывается общий результат системы (*commonResult*). Фрагмент кода показан на рис. 12.24.

```

ElemList.ForEach(delegate (Element item) {
    item.TakeWeight();
    item.TakeFactor();});
Results.MaterialResult.CountMaterialR(ElemList);
Results.MaterialResult.CountMaterialCh(ElemList);
Results.MaterialResult.CountMaterial(ElemList);
Results.SignalResult.CountSignalA(ElemList);
Results.SignalResult.CountSignal(ElemList);
Results.SignalResult.CountSignalR(ElemList);
Results.VisualResult.CountVisual(ElemList);
Results.commonResult = Results.MaterialResult.resultMaterial
* Results.MaterialResult.w_material + Results.ResultSignal *
Results.SignalResult.w_signal + Results.ResultVisual * Results.
VisualResult.w_visual;

```

Рисунок 12.24. Расчёт результатов по всем группам демаскирующих признаков и получение общего результатов

Далее, все необходимые данные объединяются в общий список *records* и записываются в файл .csv. Запись данных в файл представлен на рис. 12.25

```

using (var writer = new StreamWriter("C:\\Data\\Traning_data.csv"))

using (var csv = new CsvWriter(writer))
{
    csv.WriteRecords(records);
}

```

Рисунок 12.25. Запись данных в файл с расширением .CSV

На рис. 12.26 представлен фрагмент обучающих данных для нейро–нечеткой системы, хранящийся в файле с расширением .csv.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V
1	Contrast	Shape	Dimensions	Shadow	Smoke	Dust	Location	Conductivity	Track	Temperature	Rad_frequency	Rad_power	Rad_type	Rad_Sp	Rad_duration	Rad_RES	Rad_duty	Ac_Intensity	Ac_duration	Ac_pressure	Ac_frequ	Ac_Type
2	0	0,728	0,5311741	0	1	1	0	1	1	1	0,65	0,75	0,7	0,91	0,7	1	0	0,8	1	0,63	0,22	1
3	1	1	0,8542848	0	1	0	0,466	0,576	1	0,784	0	0	0	0	0	0	0	0	0	0	0	0
4	0	0,728	0,8639213	0	1	1	1	0,576	1	1	0	0	0	0	0	0	0	0	0	0	0	0
5	0,15	0,728	0,8639213	1	0	1	0	1	0	0	0	0	0	0	0	0	0	0,7	0,8	0	0,34	0,86
6	0,596	0	0,5311798	0	1	0	0,8	1	1	1	0,1	0,75	0,7	0,21	0,94	1	0	0	0	0	0	0
7	1	1	0,5311241	0	0	0	0,8	0	0	0,4375	0,65	0,5	1	0,51	0,7	1	0	0	0	0	0	0
8	0,596	0	0,8639213	1	0	1	0,466	0,398	1	0,199	0,85	1	0,7	0,3	1	0,8	1	0	0	0	0	0
9	0	0,728	0,5311682	0	0	1	0,8	1	1	1	0,45	0	1	0,91	1	1	0	0,3	0,8	0,75	0,56	1
10	0	0,728	0,8595912	1	0	0	0	0,398	1	1	0	0	0	0	0	0	0	0	0	0	0	0
11	1	0,728	0,8612018	1	1	0	0,466	0,576	1	1	0	0	0	0	0	0	0	0	0	0	0	0
12	1	0	0,8552589	0	1	1	0,066	0,398	1	0,784	0,25	0,5	1	0,51	0,94	1	0	0,3	1	0,63	0,45	1
13	1	1	0,8639213	1	1	1	0,066	1	0	0,784	0	0	0	0	0	0	0	0	0	0	0	0
14	0	0,728	0,8509978	0	0	1	0	0,398	1	0,784	0	0	0	0	0	0	0	0,3	0,8	1	0,56	0,86
15	1	0	0,8639213	0	1	0	0	0,576	1	1	0	0	0	0	0	0	0	0	0	0	0	0
16	0	0	0,5312055	0	0	0	0,466	0	0	1	0,45	1	0,7	0,91	0,86	1	0	0	0	0	0	0
17	0,15	1	0,5311687	0	1	0	0	0	1	1	0,75	0,75	1	0,21	0	0,8	0,4	0,8	1	0,5	0,1	0,86

Рисунок 12.26. Обучающие данные для нейро–нечёткой системы

Далее полученные данные делятся на тренировочные и тестовые наборы данных. Тренировочный набор используется в процессе обучения нейро–нечёткой системы, а тестовый набор применяется для оценки правильности обучения системы [197]. Размер тренировочного набора составляет более 20000 записей, набор тестового набора составляет более 1000 записей.

12.2.3. Выбор средств для реализации нейро –нечёткой системы

Выбор языка программирования для реализации нейро–нечёткой системы при создании приложения играет решающую роль. В 2021 году [198] наиболее востребованными языками для глубокого машинного обучения являются:

1. *Python* – простой в использовании язык программирования высокого уровня, являющийся интерпретатором. Он стал одним из самых широко применяемых языков программирования для Data Science благодаря полезным библиотекам и простоте читаемости кода. Python облегчает пользователю реализацию решений, следуя стандартам требуемых алгоритмов [199]. Язык поддерживает большое количество библиотек. Решение проблем в области машинного обучения включают в себя предварительную обработку данных, их анализ, визуализацию, прогнозирование и сохранение данных [200]. Для выполнения этих проблем в Python есть специальные библиотеки, такие, как *Pandas*, *Numpy*, *Matplotlib*, *SciPy*, *Scikit-Learn* и т.д. Расширенные библиотеки Python, такие как *Tensorflow*, *Keras* и *Pytorch*, предоставляют инструменты глубокого обучения для специалистов по большим данным [201] (*Big Data*). Существенным преимуществом этого языка является «*минимализм*», то есть разработка приложений с меньшим количеством строк кода по сравнению с другими языками программирования (например, громоздким языком Java).

2. *R* – идеальный язык для статистически ориентированных задач. Но порог вхождения в язык более высок по сравнению с Python. Недостаток языка R состоит в том, что он не является языком программирования общего назначения, т.е. он не используется для задач, не относящихся к статистическому программированию. Сильная сторона R – способность справляться со сложной линейной алгеброй. Это делает R идеальным для не только статистического анализа, но и для работы с нейронными сетями. Недостаток данного языка – в его низкой скорости. Программы выполняются медленнее, чем на Python.

3. *C++* работает гораздо быстрее, чем другие языки программирования – его способность общаться на аппаратном уровне позволяет сократить время выполнения кода, что полезно для проектов искусственного интеллекта, которые чувствительны ко времени. Язык может использоваться для статистического подхода к искусственному интеллекту, подобного тем, которые встречаются в нейронных сетях. С высокой скоростью выполнения программ и объектно – ориентированным подходом к программированию, язык *C++* является хорошим кандидатом для программ искусственного интеллекта [202].

Фактически, большая часть библиотек глубокого машинного обучения написана на языках C и C++, и предлагает интерфейсу программного приложения API оболочку для других языков программирования. Если нужно контролировать время выполнения программы и её производительность, то язык C++ является хорошим выбором. Но этот язык не совсем подходит для многозадачных проектов, и используется только для реализации ядра – базы конкретных систем или алгоритмов. Этот подход затрудняет новичкам его использование для написания программ искусственного интеллекта [203].

На основе анализа преимуществ и недостатков, а также специфики разрабатываемого приложения, был выбран язык программирования Python. Для упрощения разработки программного обеспечения следует использовать различные библиотеки и фреймворки. Для машинного обучения и нейронных сетей на языке Python основными фреймворками являются [204]:

1. *Keras* – минималистическая библиотека на основе Python, которую можно запускать поверх библиотек TensorFlow, Theano или CNTK. Она была разработана, чтобы облегчить быстрые эксперименты. Поддерживает широкий спектр слоев нейронных сетей, таких как свёрточные, рекуррентные или плотные слои. Её можно эффективно использовать в областях машинного перевода, распознавания изображений, распознавания речи и др. *Преимущества:*

- библиотека Keras является понятной и легкой в освоении для построения моделей глубокого обучения (Deep Learning) с большим количеством слоев;
- библиотека Keras имеет полностью настраиваемые модули;
- она обладает упрощенным и интуитивно понятным для неподготовленных пользователей интерфейсом, что обеспечивает низкий порог вхождения;
- Keras имеет встроенную поддержку (справочную систему с примерами), для обучения новичков на нескольких графических процессорах одновременно;
- его легко настроить, так как Keras является высокоуровневой библиотекой;
- ограничен программно–аппаратной частью сервиса, отвечающего за работу его внутренней части (back–end) библиотек Tensorflow, CNTK, Theano и др.

2. *Tensorflow* – это созданная Google и написанная на языках C++ и Python расширенная библиотека. Она считается одной из лучших в мире библиотек с открытым исходным кодом, предназначенных для численных расчётов. Библиотека TensorFlow хорошо показала себя для интеллектуальных проектов, таких, как создание многослойных нейронных сетей. Она используется в распознавании голоса / изображения и в текстовых приложениях [205].

Преимуществами библиотеки TensorFlow являются [206]:

- существование многочисленной документации и гайдлайнов (инструкций, рекомендаций, или сводов правил для формирования внешнего вида продукта, созданных дизайнерами для непосредственных разработчиков) для Tensorflow;
- мониторинг процессов обучения моделей и визуализации (*Tensorboard*);
- поддержка всего сообщества разработчиков и технологических компаний;
- возможность распределенного обучения.

Обнаруженные недостатки:

- библиотека TensorFlow показывает плохие результаты по скорости в тестах производительности, по сравнению, например, с библиотеками *CNTK* и *MXNet*;
- имеет более высокий порог входа для начинающих, чем *PyTorch* или *Keras*.

3. *PyTorch* является адаптированной под язык Python библиотекой *Torch*, написанной на *Lua*, и большим конкурентом для *TensorFlow*. Библиотека была разработана компанией *Facebook*, и используется социальными сетями *Twitter* и *Salesforce*, Оксфордским университетом и многими другими. *PyTorch*, в основном, используется для быстрого и эффективного обучения моделей глубокого обучения, поэтому она является основой выбора для большого числа исследователей. *Преимущества* библиотеки *PyTorch* [206, 207]:

- процесс моделирования и обучения нейронных сетей является простым и прозрачным, благодаря архитектурному стилю фреймворка;
- возможно использование общих средств отладки, таких, как отладчик *pdb*, *ipdb* или *PyCharm*, также предназначенных для языка Python;
- обладает декларативным параллелизмом данных;
- имеет модульные части, которые можно легко объединить.

Некоторые *недостатки*, конечно, неизбежны и для *PyTorch* [206, 207]:

- отсутствие интерфейсов для мониторинга и визуализации, таких, как *Tensorboard*, хотя к интерфейсу *Tensorboard* можно подключиться к извне;
- необходимость написания своего кода для обучения нейронной сети.

Так как при разработке нейро–нечётких систем основным требованием является гибкость и низкоуровневость, то для небольшого проекта однозначным выбором является *Pytorch*. Далее, для реализации графического интерфейса программного средства, написанного на языке программирования Python, существует несколько программных платформ – фреймворков [206, 207].

1. *Tkinter*. Это стандартное средство разработки графического интерфейса для Python. Его главным преимуществом является возможность использования фреймворка без установки – Tkinter встроен в стандартную библиотеку Python.

Преимуществами Tkinter также являются: его кроссплатформенность; отображение визуальных элементов с использованием естественно присущих им *нативных* элементов операционной системы (таким образом, приложение, написанное на Tkinter, подстраивается под операционную систему, на которой оно запущено); интуитивно понятный интерфейс – Tkinter обладает простым программным интерфейсом приложения (API), который легко изучить.

Обнаруженные *недостатки* Tkinter:

- при использовании этой программной платформы (фреймворка) создать хорошо выглядящий интерфейс не получится;
- создать графический интерфейс для сложных и больших приложений тяжело;
- из-за того, что виджеты Tkinter не являются объектами Python, тяжело проводить их отладку и устранение ошибок в Debug – приложениях.

2. *PyQt*. Это фреймворк Qt для языка Python, один из наиболее известных кроссплатформенных фреймворков для графического интерфейса, написанного на языке C++. Существуют две версии PyQt: PyQt 4.x и PyQt 5.x, которые соответствуют версиям Qt 4 и 5. Обе версии PyQt совместимы с Python 2 и 3.

Преимуществами PyQt являются его следующие достоинства [208]:

- графический интерфейс выглядит естественно на любой платформе;
- существует большая пользовательская база, что позволяет легко получить ответ на свой вопрос, и обмениваться материалами с коллегами во всём мире;
- поддержка программных платформ Windows, OS X, Linux, iOS и Android;
- возможность использования графического редактора интерфейса *Qt Designer*.

Выявленные *недостатки* PyQt [208]:

- существуют пробелы в документации для языка Python, хотя нужные страницы имеются в соответствующей документации для языка C++;
- достаточно крутая кривая траектории обучения;
- большой размер конечного разработанного приложения.

3. *Kivy* является открытым ресурсом (Open Source), кроссплатформенным фреймворком языка Python, предназначенным для разработки графического интерфейса. Его целью является быстрая разработка дизайна программных средств, а также их быстрого прототипирования, что делает написанный код развертываемым и готовым к взаимодействию и повторному использованию.

Преимуществами фреймворка Kivy является поддержка функции *Multitouch* (для сенсорных систем ввода – сенсорного экрана, сенсорной панели и др.) что полезно при построении мобильных приложений; а также простота и интуитивная понятность в использовании [206, 207].

Недостатками являются отсутствие собственных (нативных) графических элементов, а также собственного графического дизайнера для интерфейсов.

4. *WxPython* – это кроссплатформенный фреймворк. Он реализует множество расширенных модулей – оболочек для графических элементов известной кроссплатформенной библиотеки *wxWidgets*, написанной на C++. Поддерживает такие платформы, как: Microsoft Windows, Mac OS X и MacOS, Linux и другие Unix-подобные системы с библиотеками GTK2 / GTK3 [208].

Преимуществами WxPython является большая библиотека виджетов; гибкий и настраиваемый интерфейс; естественность и нативность приложений.

Недостатки: из-за активной разработки *WxPython*, в приложениях часто встречаются программные и/или системные ошибки (баги), из-за которых программа может демонстрировать неожиданное поведение и результаты.

При выборе фреймворка, основными требованиями для создания графического интерфейса были: наличие качественной документации и существование собственного графического дизайнера интерфейса. Поэтому для реализации нейро-нечёткой системы идентификации демаскирующих признаков [209] объекта защиты был выбран фреймворк PyQt.

12.2.4. Программная реализация алгоритма fuzzy – системы идентификации демаскирующих признаков объекта защиты

Рассмотрим подробно алгоритм расчёта результата нейро-нечёткой системой. Для реализации алгоритма использовался фреймворк PyTorch.

В основе работы Pytorch лежит понятие *тензора* – многомерной матрицы, содержащей элементы одного типа данных, над которой проводятся различные операции преобразования. Структурная схема разрабатываемой fuzzy-системы идентификации демаскирующих признаков представлена на рис. 12.27.

Нейро-нечёткая (fuzzy) система идентификации демаскирующих признаков состоит из семи слоёв, схема которых представлена на рис. 12.28 [209]. Входные данные нейро-нечёткой системы, получаемые от пользователя, передаются на вход первого слоя в виде тензора размерностью 1×30 .




Рисунок 12.27. Структурная схема нейро–нечёткой fuzzy–системы идентификации множества демаскирующих признаков




Рисунок 12.28. Схема адаптивной нейро–нечёткой сети

Входные данные нейро–нечёткой системы, получаемые от пользователя, передаются на вход первого слоя, в виде тензора размерностью 1×30 . Для примера, рассмотрим работу нейро–нечёткой системы [210] со следующим входным тензором t , представленным на рис. 12.29.

```
INFO:root:input layer
INFO:root:tensor([[1.0000, 0.0000, 0.8639, 1.0000, 0.0000, 0.0000, 0.0660, 1.0000, 1.0000,
0.4375, 0.4500, 1.0000, 0.7000, 0.9100, 1.0000, 1.0000, 0.0000, 1.0000,
0.4000, 0.8700, 0.5600, 0.8600, 0.0000, 0.9100, 1.0000, 1.0000, 0.0000,
0.7300, 0.4700, 1.0000]])
```

Рисунок 12.29. Входной тензор нейро–нечёткой сети

Первый слой сети передаёт входные данные на следующий слой без изменений, что выражено следующей формулой: [211].

$$Q_k^1 = x_k, \quad (12.2)$$

где x_k – k –й входной элемент.

На рис. 12.30 представлен код первого слоя нейро–нечеткой системы.

```
class InputLayer(nn.Module):
    """
    Класс, описывающий поведение входного слоя ANFIS
    Передает тензор слою компрессии
    """
    def __init__(self):
        super(InputLayer, self).__init__()

    def forward(self, tensor: torch.Tensor):
        return tensor
```

Рисунок 12.30. Входной слой нейро–нечёткой системы

Второй слой – слой компрессии. Здесь происходит процесс преобразования входного тензора к меньшей размерности. Такие преобразования необходимы, чтобы сделать возможной дальнейшее построение базы правил нейро–нечёткой системы [212]. Количество правил можно вычислить по соотношению:

$$e = r^s, \quad (12.3)$$

где s – количество входов разрабатываемой нейро–нечёткой системы; r – количество лингвистических термов для входной переменной.

В разработанной системе нечёткое множество лингвистических термов состоит из следующих элементов: {‘Низкий’, ‘Средний’, ‘Высокий’}.

Производя простые математические вычисления, можно заключить, что построение базы нечётких правил с количеством правил равным 330 не является возможным. Использование слоя компрессии позволяет построить систему с базой нечётких правил, состоящих из 81 правила.

Слой компрессии является разреженным слоем, в котором нейроны связаны между собой по принадлежности к различным группам демаскирующих признаков. Здесь производится преобразование входного тензора, содержащего 30 элементов, в новые четыре элемента, представляющие собой результат сложения элементов по группам демаскирующих признаков (визуальная, акустическая, радиосигнальная и материально–вещественная группы). В математическом виде эти преобразования представлены следующей формулой:

$$Q_k^2 = \sum_{k_1}^{k_2} x_k, \quad (12.4)$$

где k_1 и k_2 – первый и последний элементы, относящиеся к одной и той же группе демаскирующих признаков объекта защиты.

Выходное значение O_k^2 для тензора t представлено на рис. 12.31:

```
INFO:root:compression layer
INFO:root:tensor([[5.3674, 5.0600, 3.6900, 5.1100]])
```

Рисунок 12.31. Выходное значение слоя компрессии

Третий слой является слоем *фаззификации*. Он является адаптивным, и каждый узел имеет функцию активации, что отражено в формуле:

$$O_k^3 = \mu_{A^i}(x), \quad (12.5)$$

где x – входное значение узла k ; A^i – нечёткое множество, описывающее лингвистические переменные; μ^{A^i} – функция принадлежности к A^i .

На этом этапе производятся преобразования чётких данных в значения степеней соотношения к функциям принадлежности лингвистических термов нечёткого множества. Каждый входной элемент порождает три новых, проходя через функции принадлежности к термам {‘Низкий’, ‘Средний’, ‘Высокий’}.

Функции принадлежности μ_{A^i} в разрабатываемой нейро–нечёткой системе определяются как колоколообразные функции, представленные формулой:

$$\mu(x; a, b, c) = \frac{1}{1 + \left| \frac{x - c}{a} \right|^{2b}}, \quad (12.6)$$

где a – коэффициент концентрации функции принадлежности; b – коэффициент крутизны функции принадлежности; c – координата максимума той же функции.

Коэффициенты функций принадлежности для нейро–нечёткой системы подбираются в процессе обучения, чтобы лучше соответствовать обучающим данным. Так, например, на рис. 12.32 показаны все функции принадлежности для первого узла слоя компрессии, после обучения нейро–нечёткой системы:




Рисунок 12.32. Функции принадлежности к нечётким множествам

Выходной тензор слоя имеет размерность 12 и для тензора t имеет вид, представленный на рис. 33.

```
INFO:root:fuzzy layer
INFO:root:tensor([[[0.0034],[0.0083],[0.0024],[0.0038],[0.0095],[0.0028],[0.0074],[0.0200],
[0.0063],[0.0037],[0.0093],[0.0027]], grad_fn=<CatBackward>)
```

Рисунок 12.33. Выходной тензор слоя фаззификации

В слое фаззификации используются два класса [211]:

1. Класс *FuzzyVariable* представляет нечёткую переменную и содержит в себе три параметра колоколообразной функции принадлежности, обучаемых нейронной сетью. Метод *bell_mf* возвращает степень принадлежности нечёткой переменной к заданным колоколообразным функциям принадлежности.

2. Класс *FuzzyLayer* представляет нечёткий слой, состоящий из 4 узлов класса *FuzzyVariable*, и возвращает тензор со значениями принадлежности нечёткой переменной к заданным колоколообразным функциям принадлежности.

Четвёртый слой представляет собой *базу правил* нейро–нечёткой системы и состоит из 81 нейрона. В этой системе используются нечёткие правила *Такаги–Сугено* [213], представленные соотношением:

$$\begin{aligned} R: & \text{IF } X_1 \text{ is } A_e^1 \text{ AND } X_2 \text{ is } A_g^2 \text{ AND } X_3 \text{ is } A_h^3 \text{ AND } X_4 \text{ is } A_j^4 \\ & \text{THEN } z \text{ is } f(X_1, X_2, X_3, X_4), \end{aligned} \quad (12.7)$$

где A_1, A_2, A_3, A_4 – нечёткие множества, описывающие лингвистические переменные; X_1, X_2, X_3, X_4 – посылки нечётких правил; z – следствие этих правил.

Количество посылок нечётких правил зависит от количества нейронов слоя *компрессии*, и подразумевает, что в одном правиле не будут фигурировать одинаковые элементы, к которым применяются различные функции принадлежности. Поэтому нужно использовать *разреженный слой нейронной сети*, в котором каждый элемент предыдущего слоя не связан с каждым нейроном последующего слоя. Для реализации такой архитектуры можно использовать бинарную матрицу, описывающую каждую связь нейрона.

В процессе обучения нейро–нечёткой системы требуется перемножить существующую матрицу весов слоя на бинарную матрицу связей, с целью поддержания связей, существующих в ней, и отсечения лишних связей, не предусмотренных в нейро–нечёткой системе [214]. Фрагмент бинарной матрицы связей для четвёртого слоя, слоя правил, представлен на рис. 12.34:

Выход каждого нейрона, принадлежащего слою правил, – произведение всех поступающих к нему сигналов [215], которое определяется по формуле:

$$w_k = \mu A_e^1(x_1) \times \mu A_g^2(x_2) \times \mu A_h^3(x_3) \times \mu A_j^4(x_4). \quad (12.8)$$

Рисунок 12.34. Бинарная матрица связей

```
INFO:root:rules layer
INFO:root:tensor([3.5408e-10, 8.8685e-10, 2.5680e-10, 8.7512e-10, 2.1919e-09, 6.3469e-10,
2.4995e-10, 6.2604e-10, 1.8128e-10, 9.6015e-10, 2.4048e-09, 6.9636e-10,
2.3730e-09, 5.9436e-09, 1.7211e-09, 6.7778e-10, 1.6976e-09, 4.9157e-10,
3.0316e-10, 7.5931e-10, 2.1987e-10, 7.4927e-10, 1.8767e-09, 5.4342e-10,
2.1401e-10, 5.3601e-10, 1.5521e-10, 8.8486e-10, 2.2162e-09, 6.4175e-10,
2.1869e-09, 5.4775e-09, 1.5861e-09, 6.2463e-10, 1.5645e-09, 4.5302e-10,
2.3994e-09, 6.0097e-09, 1.7402e-09, 5.9302e-09, 1.4853e-08, 4.3009e-09,
1.6938e-09, 4.2423e-09, 1.2284e-09, 7.5760e-10, 1.8975e-09, 5.4946e-10,
1.8724e-09, 4.6898e-09, 1.3580e-09, 5.3480e-10, 1.3395e-09, 3.8787e-10,
2.5563e-10, 6.4026e-10, 1.8540e-10, 6.3179e-10, 1.5824e-09, 4.5821e-10,
1.8045e-10, 4.5197e-10, 1.3087e-10, 6.9317e-10, 1.7361e-09, 5.0273e-10,
1.7132e-09, 4.2909e-09, 1.2425e-09, 4.8932e-10, 1.2256e-09, 3.5488e-10,
2.1887e-10, 5.4818e-10, 1.5873e-10, 5.4093e-10, 1.3548e-09, 3.9232e-10,
1.5450e-10, 3.8697e-10, 1.1205e-10])
```

На основе выходного тензора слоя правил разработан соответствующий код, описывающий слой правил нейро–нечёткой системы [216].

На следующем этапе нужно оценить вклад каждого нечёткого правила в конечный результат вывода системы. Это задача *пятого слоя – нормализации*.

Каждый нейрон в этом слое получает входные данные из всех нейронов в слое правил и рассчитывает нормализованную степень принадлежности этого правила. Выход k -го нейрона пятого слоя определяется по формуле:

$$\overline{w_k} = \frac{w_k}{\sum_{i=0}^n w_i}, \quad (12.9)$$

где n – общее число нечётких правил в нейро–нечёткой системе [217].

В результате получится тензор, значения которого лежат в пределах $[0, 1]$. Выходной тензор слоя имеет такую же размерность, что и предыдущий слой и для тензора t имеет вид, представленный на рис. 12.36.

```
INFO:root:normalization layer
INFO:root:tensor([0.0029, 0.0074, 0.0021, 0.0073, 0.0182, 0.0053, 0.0021, 0.0052, 0.0015,
0.0080, 0.0199, 0.0058, 0.0197, 0.0493, 0.0143, 0.0056, 0.0141, 0.0041,
0.0025, 0.0063, 0.0018, 0.0062, 0.0156, 0.0045, 0.0018, 0.0044, 0.0013,
0.0073, 0.0184, 0.0053, 0.0181, 0.0454, 0.0131, 0.0052, 0.0130, 0.0038,
0.0199, 0.0498, 0.0144, 0.0492, 0.1231, 0.0357, 0.0140, 0.0352, 0.0102,
0.0063, 0.0157, 0.0046, 0.0155, 0.0389, 0.0113, 0.0044, 0.0111, 0.0032,
0.0021, 0.0053, 0.0015, 0.0052, 0.0131, 0.0038, 0.0015, 0.0037, 0.0011,
0.0057, 0.0144, 0.0042, 0.0142, 0.0356, 0.0103, 0.0041, 0.0102, 0.0029,
0.0018, 0.0045, 0.0013, 0.0045, 0.0112, 0.0033, 0.0013, 0.0032, 0.0009])
```

Рисунок 12.36. Выходной тензор слоя нормализации

Для пятого слоя нейро–нечёткой сети также разработан программный код, в котором представлен класс, описывающий слой нормализации. В этом слое производится суммирование всех элементов тензора, а затем выполняется деление каждого элемента тензора на полученную сумму.

Шестой слой является слоем дефаззификации, в котором происходит преобразование нормализованных нечётких данных в чёткие. Каждый нейрон в этом слое связан с соответствующим нейроном нормализации пятого слоя, а также получает выходной тензор второго слоя *компрессии*: O_k^2 . Нейрон дефаззификации вычисляет взвешенное значение выхода каждого правила:

$$\overline{w}_k f_k = \overline{w}_k (p_k x_1 + q_k x_2 + r_k x_3 + s_k x_4 + t_k). \quad (12.10)$$

Слой является адаптивным и содержит пять параметров, обучаемых нейро–нечёткой системой, а именно: p, q, r, s, t . Характеристики параметра p представлены на рис. 12.37. Выходной тензор, представленный на рис. 12.38, имеет такую же размерность, что и входной слой нейро–нечёткой сети.

```
INFO:root:defuzzification_layer.p
INFO:root:tensor([[ 0.9863],[ 1.0009],[ 1.0015],[ 0.9833],[ 0.9365],[ 1.0217],[ 0.9926],
[ 1.0032],[ 1.0007],[ 1.0482],[ 1.0306],[ 0.9979],[ 1.0003],[ 0.8383],
[ 1.0099],[ 1.0047],[ 0.9832],[ 0.9969],[ 0.9966],[ 1.0038],[ 0.9969],
[ 0.9882],[ 1.0050],[ 0.9969],[ 1.0024],[ 1.0025],[ 0.9998],[ 0.9746],
[ 0.9117],[ 0.9963],[ 0.7207],[ 0.3179],[ 1.0324],[ 0.9701],[ 0.9136],
[ 0.9977],[ 0.9416],[ 0.9318],[ 1.0015],[ 0.4003],[ -0.0358],[ 0.9214],
[ 0.9488],[ 0.8680],[ 0.9823],[ 0.9911],[ 1.0141],[ 1.0038],[ 0.9801],
[ 0.8460],[ 0.9922],[ 0.9928],[ 0.9801],[ 1.0002],[ 0.9967],[ 1.0062],
[ 0.9956],[ 0.9656],[ 0.9115],[ 0.9989],[ 1.0032],[ 0.9870],[ 1.0001],
[ 0.9700],[ 0.9957],[ 1.0019],[ 0.9141],[ 0.8031],[ 0.9914],[ 1.0023],
[ 0.9786],[ 0.9976],[ 1.0050],[ 0.9971],[ 1.0013],[ 1.0097],[ 0.9781],
[ 1.0006],[ 0.9949],[ 0.9963],[ 0.9998]])
```

Рисунок 12.37. Характеристики обученного параметра p слоя дефаззификации

```
INFO:root:defuzzification layer
INFO:root:tensor([[0.0591, 0.1475, 0.0430, 0.1446, 0.3481, 0.1063, 0.0418, 0.1046, 0.0304,
0.1615, 0.3973, 0.1165, 0.3837, 0.8828, 0.2867, 0.1134, 0.2818, 0.0823,
0.0508, 0.1271, 0.0368, 0.1249, 0.3111, 0.0910, 0.0359, 0.0898, 0.0260,
0.1445, 0.3466, 0.1069, 0.3114, 0.6059, 0.2583, 0.1035, 0.2526, 0.0758,
0.3802, 0.8631, 0.2882, 0.6853, 0.9690, 0.6684, 0.2756, 0.6583, 0.2042,
0.1261, 0.3130, 0.0920, 0.3036, 0.7100, 0.2258, 0.0893, 0.2224, 0.0650,
0.0427, 0.1066, 0.0311, 0.1037, 0.2516, 0.0765, 0.0303, 0.0754, 0.0219,
0.1151, 0.2860, 0.0842, 0.2730, 0.6416, 0.2064, 0.0818, 0.2036, 0.0594,
0.0367, 0.0918, 0.0266, 0.0905, 0.2243, 0.0657, 0.0259, 0.0648, 0.0188]],
grad_fn=<MulBackward0>)
```

Рисунок 12.38. Выходной тензор слоя дефаззификации

Для реализации шестого адаптивного слоя *дефаззификации* [211] нейро–нечёткой сети, в котором вычисляется взвешенное значение выхода каждого правила, был представлен программный код, в котором представлен класс.

Седьмой слой является выходным слоем и представлен одним нейроном, который вычисляет сумму выходов всех нейронов *дефаззификации* и выдаёт общий выход адаптивной нейро–нечёткой системы ANFIS [205, 207, 218].

Результат, выданный этим слоем, показан на рис. 12.39. Он является конечным результатом, и при обучении, сравнивается с обучающим результатом.

```
INFO:root:output layer
INFO:root:tensor([[0.5962]], grad_fn=<AddmmBackward>)
```

Рисунок 12.39. Конечный результат системы

В случае тензора t выходной слой выдал результат 0.5962, при этом обучающий результат равен 0,59. На рис. 12.40 представлено различие между ожидаемым значением и результатом, полученным системой.




Рисунок 12.40. Конечный результат системы

Код основной модели ANFIS–системы работает так: на вход системы подаётся 4 значения групп демаскирующих признаков, а на выходе система делает предположение об информативности признаковой структуры объекта.

При разработке нейро–нечёткой системы идентификации демаскирующих признаков были использован Python версии 3.6, а также следующие библиотеки и фреймворки: PyQt5, Os, Math, Logging, Torch, Numpy, CustomizedLinear [206].

12.3. Обучение нейро–нечёткой (fuzzy) системы

Обучение нейро-нечёткой системы используется для изменения весов и связей между нейронами. Целью алгоритмов обучения является уменьшение ошибки между полученными результатами и их действительными значениями.

Обучение системы происходит по алгоритму *обратного распространения ошибки*, являющемуся оптимальным для нейронных сетей с прямой связью. В основе алгоритма лежит передача рассчитанной разницы между полученным и желаемым значением от выхода нейронной сети к её входу. В результате подбора весов, в скрытых слоях нейронной сети устанавливаются нужные веса для представления важных особенностей решаемой задачи [206].

Алгоритм обратного распространения ошибки состоит из 4 этапов.

Этап 1. Прямое распространение. На этом этапе вычисляется результат нейро–нечёткой системы, который зависит от её входных значений. Для такого расчёта каждый скрытый и выходной нейрон рассчитывают свою степень активации, которая зависит от значений нейронов предыдущего слоя; значений весов между текущим и предыдущим слоями; а также пороговых значений функции активации для каждого нейрона. Функции активации могут быть различными, но они должны быть непрерывны и дифференцируемы.

Этап 2. Обратное распространение ошибки. На этом этапе считается ошибка, которая является разницей между требуемым и полученным выходным результатом системы. Эта ошибка передается предыдущему слою нейронной сети. Таким образом считается ошибка для каждого скрытого слоя.

Этап 3. Обновление весов нейронной сети. Полученные ошибки для каждого слоя используются для коррекции весов нейронной сети, вследствие чего количество ошибок в каждом слое нейро–нечёткой сети уменьшается.

Эти три этапа повторяются до тех пор, пока ошибка обучения не снизится до ожидаемого, приемлемого уровня, когда она окажется несущественной.

Следующим, *четвёртым этапом является определение корректности значения интегрального показателя*, рассчитанного с использованием нейро–нечёткой модели. В процессе обучения [206], система определяет количество верных ответов в эпохе, основываясь не просто на равенство обучающего результата и результата, выданного системой, а используя следующее условие:

if $|preds-label| < |label \times pct_close|$ then результат верен,

где *preds* – результат, выданный системой, *label* – обучающий результат. Значение *pct_close* выбирается пользователем из интервала [0, 1].

После обучения системы сохраняется её состояние, которое обеспечивает наилучший результат с большим значением точности предположений. Функция обучения нейро–нечеткой системы, при необходимости, корректируется.

Таким образом, происходит процесс обучения нейронной сети на основе обучающих данных. Точность предположений увеличивается при настройке функций активации и оптимизатора. *Функция потерь* используется в качестве характеристики, показывающей, насколько точно разработанная модель может предсказать ожидаемый результат. После 50 эпох обучения, *функция потерь* имеет вид, представленный на рис.12.41.




Рисунок 12.41. Поведение функции потерь

12.3.1. Контрольный пример работы системы

Система для идентификации демаскирующих признаков защищаемого объекта построена на основе адаптивной сети с системой нечёткого вывода. В связи с наличием нейронной сети, требуется провести её обучение перед тем, как приступать к идентификации демаскирующих признаков [219].

Работа программы начинается с окна меню, из которого можно перейти к обучению нейро–нечёткой системы и идентификации демаскирующих признаков [220]. На рисунке 12.42 представлено меню системы.




Рисунок 12.42. Меню системы

При переходе к обучению нейро–нечёткой системы открывается окно, в котором отображается непосредственная информация об её обучении. Вкладка «Обучение» хранит данные об ошибках обучения и точности системы на каждой итерации обучения (эпохе). Внешний вид вкладки «Обучение» после процесса обучения системы представлена на рис. 12.43.

Во вкладке «Параметры системы» окна программы отображается дополнительная информация о параметрах обученной системы, таких как: веса нейронов, смещения и размер выходного тензора каждого слоя нейро – нечёткой системы и др., представленных на рис. 12.44.




Рисунок 12.43. Вкладка обучения нейро-нечёткой системы




Рисунок 12.44. Вкладка параметров обученной системы

После обучения нейро–нечёткой системы можно приступить к процессу идентификации демаскирующих признаков объекта защиты [220]. Для этого пользователю необходимо ввести известные данные об исследуемом объекте. Требуемые данные разделяются по группам демаскирующих признаков. Каждая группа демаскирующих признаков расположена в отдельном окне, для удобства ввода данных. На рис. 12.45 представлены окна для идентификации акустической группы демаскирующих признаков объекта защиты.

Рисунок 12.45. Окно ввода данных об исследуемом объекте

Необходимым условием для работы нейро–нечёткой системы является возможность не запрашивать лишние данные, если пользователь определил, что группа демаскирующих признаков отсутствует. Это упрощает работу с системой и позволяет не проводить пользователю избыточные измерения. При этом поля с избыточными данными становятся неактивными для изменения пользователем, что представлено на рис. 12.46.

В разработанном программном приложении присутствует *контекстная помощь*, содержащая в себе дополнительные материалы и пояснения к определению демаскирующих признаков, а также необходимую справочную информацию для лучшего понимания процессов в нейро–нечёткой сети.

Материально-вещественные демаскирующие признаки

Наличие ионизирующего излучения ☐ Есть ☒ Нет

Наличие химических выбросов ☒ Есть ☐ Нет

Ионизирующее излучение

Вид излучения	МЗА	Энергия
α - излучение	Не определено	Не определено

Химические выбросы

Класс опасности вещества	Вид излучения
III (ПДК = 10<sup>-3</sup> - 10<sup>-4</sup> мг/)	Превышает ПДК

Макет объекта

Отходы от объекта

Рисунок 12.46. Окно ввода материально–вещественных данных

Пример контекстной помощи – подсказки к пониманию демаскирующего признака «Контраст с фоном» представлен на рис. 12.47.

Визуальные демаскирующие признаки

Местоположение

Пыль

Следы от объекта

Форма объекта

Дым

Температура объекта

Контраст с фоном

Тень

Удельная электропроводность

Определяется отношением абсолютной величины разности между яркостью объекта L_o и яркостью фона L_f к яркости фона

$$k = \frac{L_o - L_f}{L_f}$$

Рисунок 12.47. Контекстная помощь к демаскирующему признаку

В программе предусмотрена обработка возникающих ошибок. При вводе некорректных данных приложение не завершает работу экстренно. Вместо этого пользователю отображается окно с понятным описанием причины ошибки в программе. Работа программы не продолжается до тех пор, пока ошибка не будет устранена. Это обеспечивает корректный результат выполнения программы на всех её этапах. На рис. 12.48 представлено окно ошибки «Значения габаритных размеров объекта должны быть числами больше нуля», отображаемое в случае ввода нечисловых символов, значений габаритных размеров меньше нуля или пустой последовательности.




Рисунок 12.48. Сообщение об ошибке

После ввода необходимых данных открывается окно с рекомендациями. Во вкладке «Общая информация», показанной на рис. 12.49, отображается информативность признаковой структуры объекта, наиболее информативная группа демаскирующих признаков, и 5 самых информативных признаков объекта.




Рисунок 12.49. Вкладка «Общая информация»

На рис. 12.50 представлена вкладка с рекомендациями по снижению информативности признаков структуры. Здесь предложены различные варианты по предотвращению распространения защищаемой информации посредством наиболее информативных демаскирующих признаков.




Рисунок 12.50. Вкладка «Рекомендации», содержащая инструкции по снижению информативности демаскирующих признаков

При необходимости можно получить информацию по абсолютному вкладу каждого демаскирующего признака в признаковую структуру объекта во вкладке «Коэффициенты», представленную на рис. 12.51. Это позволит пользователю наиболее гибко построить систему защиты информации, учитывая абсолютную информативность демаскирующих признаков.

В результате работы программы формируется отчёт по информативности признаков структуры объекта защиты и рекомендациям по снижению её информативности. Предусмотрено сохранение отчёта, для дальнейшей работы с ним и возможности сравнения результатов различных исследований. Отчёт сохраняется в формате .html, который открывается в любом браузере без подключения к сети Интернет. Такой формат был выбран из-за возможности запуска даже на «пустой» операционной системе, без заранее установленных программ для просмотра и редактирования текстовых файлов.




Рисунок 12.51. Вкладка «Коэффициенты»

В отчёте, по результатам работы программы, содержится вся информация из вкладок «Общая информация», «Рекомендации» и «Коэффициенты».

Пример отчёта представлен на рис. 12.52.




Рисунок 12.52. Отчёт по проведенному исследованию

Таким образом, в данной исследовательской работе был проведен анализ совокупности демаскирующих признаков объекта защиты, и проведена их подробная классификация. Основными группами, на которые можно разбить демаскирующие признаки, являются визуальные, сигнальные и материально–вещественные демаскирующие признаки объекта защиты [220].

На основе выбранных в предыдущем исследовании демаскирующих признаков была построена система идентификации демаскирующих признаков. Такая система использует адаптивную сеть на основе системы нечёткого вывода для оценки информативности признаковой структуры защищаемого объекта, что с одной стороны позволяет учитывать нечёткость и неопределенность входных данных, а с другой стороны делает возможным подстраивать систему для более точных предположений с помощью обучения нейронной сети.

Разработанная нейро–нечёткая (fuzzy) система позволяет:

- оценить информативность признаковой структуры объекта;
- определить информативность возможных демаскирующих признаков объекта защиты в их признаковой структуре;
- оценить наиболее информативную группу демаскирующих признаков;
- узнать дальность распространения акустического сигнала в выбранной среде при присутствии акустической группы демаскирующих признаков;
- получить рекомендации по снижению информативности демаскирующих признаков объекта защиты, и тем самым повысить безопасность этого объекта;
- сохранить отчёт с результатами проведенного исследования.

Цель исследования, заключающаяся в разработке методики построения fuzzy–системы идентификации множества демаскирующих признаков объектов защиты, полностью достигнута. Для её достижения были решены задачи:

- систематизации методов идентификации и классификации демаскирующих признаков защищаемого объекта с позиции системного анализа;
- исследования особенностей обнаружения и распознавания объектов в условиях неполных данных по их демаскирующим признакам;
- программной реализации нейро–нечёткой fuzzy–системы идентификации множества демаскирующих признаков объекта защиты на языке Python.

Реализованная нейро–нечёткая fuzzy–подсистема поддержки принятия решений позволяет специалистам в области защиты информации оперативно сформировать список информативных демаскирующих признаков, и может помочь при предварительном обследовании объекта информатизации.

13. ПОДСИСТЕМА ПОДДЕРЖКИ ПРИНЯТИЯ РЕШЕНИЙ ИДЕНТИФИКАЦИИ ТЕХНИЧЕСКИХ КАНАЛОВ УТЕЧКИ ИНФОРМАЦИИ В КОМПЛЕКСНОЙ СИСТЕМЕ ЗАЩИТЫ

В настоящее время информационные системы очень сложны по своей структуре, а это значит, что специалистам по защите информации необходимо рассматривать всю совокупность возможных угроз и принимать меры для предотвращения их возникновения. Один из способов локализации и устранения угроз информационной безопасности является организация *технической защиты информации* (ТЗИ) – обеспечение информационной безопасности и защиты данных некриптографическими методами. Техническая защита информации, содержащей сведения, составляющие государственную тайну, секретной или конфиденциальной информации с ограниченным доступом, предотвращение её утечек по техническим каналам связи, несанкционированного доступа к ней, специальных воздействий на информацию и её носители, в целях добывания, передачи, уничтожения, искажения и блокирования доступа к ней на территории Российской Федерации, является одной из основных задач, стоящих перед специалистами по информационной безопасности и защите данных [221].

При организации технической защиты информации практического значения не имеет ни форма представления защищаемой информации, ни способы или каналы её передачи. Применение методов и способов ТЗИ должно осуществляться на всех этапах рассматриваемого процесса. Создание системы технической защиты информации, а также реализация на практике мероприятий по обеспечению безопасности защищаемых ресурсов осуществляется после всестороннего исследования и определения требуемых мер по обеспечению сохранности информации. Результатом проведения подобных мероприятий является локализация всех возможных технических каналов утечки данных (информации); выявление способов несанкционированного доступа и неосторожных (непреднамеренных) действий персонала компании [222].

Разработка и внедрение технической системы защиты информации требует привлечения значительных ресурсов компании (временных, финансовых, материальных, человеческих,), и как следствие, сказывается негативным образом на работе компаний и организаций. В целях снижения ресурсных затрат организации, при проведении подобных мероприятий, актуальным является вопрос создания программного продукта, который позволяет выявить возможные технические каналы утечки информации в защищаемой информационной системе, и представить рекомендации по локализации

выявленных *технических каналов утечки информации* (ТКУИ) ещё на предварительном этапе оценки, т.е. до проведения мероприятий по аттестации объекта информатизации (ОИ). В качестве такого программного продукта может выступать подсистема поддержки принятия решений (ПППР) идентификации ТКУИ в защищаемой информационной системе.

Проблемы идентификации технических каналов утечки информации рассматриваются во многих работах российских авторов. При этом методики, наиболее полно учитывающие ТКУИ и их предполагаемую информативность, в настоящее время разработаны недостаточно. Среди отечественных авторов, работы которых посвящены инженерно–технической защите информации и проблемам идентификации ТКУИ, выделяются А.А. Торокин [223], А.П. Зайцев [224], А.А. Хорее [225], А.И. Долгов [226, 227] и Д.Б. Халяпин [228–230]. Несмотря на большое количество исследований в области идентификации, вопросы оценки их информативности и практической разработки систем ПППР в области идентификации ТКУИ объектов защиты организаций изучены мало.

Таким образом, дальнейшее исследование вопросов идентификации технических каналов утечки информации, разработки методов автоматизации процессов выявления информативных ТКУИ и выработки рекомендаций по снижению информативности выявленных ТКУИ в интересах получения наиболее адекватного результата является весьма актуальным.

Объектом исследования являются процессы подготовки и принятия решения при построении системы защиты информации в организации. *Предметом* исследования выступают методы идентификации (классификации) и методики обработки данных, характеризующих технические каналы утечки информации в защищаемой информационной системе организации.

Цель исследования: разработка подсистемы поддержки принятия решений по идентификации ТКУИ в защищаемой информационной системе организации. *Задачи* исследования: систематизация методов идентификации/классификации ТКУИ с позиций системного анализа; анализ особенностей применения технических средств защиты для локализации каналов утечки информации; разработка структурной схемы модели идентификации технических каналов утечки информации; разработка подсистемы поддержки принятия решений по идентификации технических каналов утечки информации в защищаемой информационной системе организации на основе системного подхода.

Методы исследования: положения системного анализа, теории принятия решений, применение коэффициентных методик и экспертных оценок.

13.1. Технические каналы утечки информации

13.1.1. Классификация технических каналов утечки информации

Технический канал утечки информации—это совокупность объекта разведки (источник информации), технического средства разведки (средство перехвата информации), с помощью которых добывается информация об этом объекте, и физической среды, в котором распространяется информационный сигнал (канал связи). Другими словами, это взаимодействие источника данных, физической среды (линии связи), в которой функционирует информационный носитель данных; шумов, препятствующих передаче сведений в линии связи, и технических средств перехвата данных, которыми пользуется противник [232].

Любой канал представлен в виде трёх компонентов [233], рис. 13.1.




Рисунок 13.1. Главные компоненты каналов утечки

Любой из возможных методов и путей утечки информации (МПУИ) из информационной системы содержит свои особенности и характерные черты, которые необходимо знать и принимать во внимание, для обеспечения эффективного сокрытия данных от передачи в таких каналах утечки. Классификация каналов утечки информации (КУИ) показана на рис. 13.2.

Технические каналы утечки информации по структуре можно разделить на простые (одноканальные) и составные (многоканальные).




Рисунок 13.2. Классификация каналов утечки информации

Методы и пути утечки информации из информационной системы за счёт технических средств характеризуется показателями, которые дают возможность оценить риск неконтролируемого распространения защищаемых данных. Этими показателями являются: *пропускная способность* технического канала утечки данных, его *длина* и условная *информативность*.

Все эти показатели характеризуют составляющие части канала утечки: *источника* носителя данных, *среды передачи* и *приёма сигнала*.

Источник носителя данных характеризуется следующими показателями: диаграммой направленности излучения носителя данных (света, а также акустической и электромагнитной волн); мощностью источника носителя данных; его параметрами спектра; его динамическим диапазоном.

Среда передачи характеризуется набором физических характеристик, которые определяют условия передачи носителя с данными. Ведущими из них считаются: скорость передачи носителя в среде; коэффициент ослабления, либо передачи энергии носителя на единицу длины; амплитудно–частотная характеристика (если коэффициент передачи зависит от частоты сигнала); мощность сигнала и вид помех, воздействующих на сигнал.

Параметры методов и путей утечки информации из информационной системы за счёт технических средств, зависят от характеристик приёмника сигналов, основными из которых являются: область принимаемых частот; чувствительность; пространственная селективность приёмной антенны; динамический диапазон носителя данных; а также степень и вид его искажений.

Комплексирование методов и путей утечки данных из информационной системы обеспечивает: увеличение вероятности выявления и определения объектов за счёт расширения характеристик их признаков структур; повышение достоверности семантических сведений и точности измерения; признаков, в случае добывания сведений из не очень достоверных источников.

На рис. 13.3 изображены два ключевых вида комплексирования.




Рисунок 13.3. Виды комплексирования

13.1.2. Акустический канал утечки информации

Человеческая речь является древнейшим, простым и естественным способом общения и передачи сведений между людьми. Заинтересованность к перехвату акустических данных существовала всегда, и она не исчезает и не уменьшается, невзирая на появление, за последние десятилетия, большого числа различных *технических* методов и *средств приёма*, обработки, хранения и передачи *информации* (ТСПИ). Наоборот, она только возрастает [234].

Это связано с рядом своеобразных отличительных черт перемещения акустических колебаний, таких, как ограниченная дальность перемещения и ограниченное время существования. Речевые сведения обладают наиболее высокой оперативностью, вследствие того, что они могут быть перехвачены еще до документирования информации (если оно предполагается), в период её озвучивания. Приведенные характерные черты делают акустические сведения более значимыми, и поясняют большое внимание к ним иностранных разведок, а также различного рода злоумышленников, заинтересованных в перехвате секретной или конфиденциальной информации. Структура акустического канала утечки информации (АКУИ) [235] приведена на рис. 13.4.



Рисунок 13.4. Структура акустического канала утечки информации

Подробная классификация акустических каналов утечки информации приведена на рис. 13.5. Выделяются: воздушный, вибрационный, оптико–электронный, акустоэлектрический и параметрический каналы.




Рисунок 13.5. Классификация АКУИ

Все устройства акустической разведки в своей основе применяют микрофоны разных типов и назначения (рис. 13.6). К основным характерным чертам микрофонов относятся: чувствительность, частотная характеристика, характеристика направленности и уровень собственного шума [236].



Рисунок 13.6. Классификация микрофонов

При перемещении механических колебаний разного рода из твердой среды в воздушную среду, и при возбуждении акустических колебаний, в воздушной среде образуется *виброакустический* канал утечки данных. Средой распространения акустических сигналов в *вибрационном* (структурном) канале утечки данных являются твердые тела, ограждающие конструкции зданий и сооружений. Для перехвата акустических колебаний в этой среде используются контактные микрофоны (стетоскопы). Акустическая волна в значительной степени поглощается в среде распространения, в отличие от электромагнитной.

Преобразование акустических колебаний в электрические, и обратно, а также перемещение этих колебаний в различных присущих им средах образует акустоэлектрический канал утечки информации (рис. 13.7).

Определенные элементы *вспомогательных технических средств и систем* (ВТСС) могут обладать эффектом преобразования акустических колебаний в электрические. Такой эффект зачастую именуют «микрофонным эффектом».

Под ВТСС [236] подразумевают такие технические средства и системы, устанавливаемые вместе с *основными техническими средствами и системами* (ОТСС), которые не предназначены для передачи, обработки и хранения сведений ограниченного доступа. Громкоговорители, электрические звонки (в том числе и вызывные звонки телефонных аппаратов), электрорадио-измерительное оборудование относятся к электромагнитным преобразователям.



Рисунок 13.7. Структура акустоэлектрического и акустоэлектромагнитного каналов утечки информации

Прослушать разговор, который проводится в защищаемом помещении, возможно с помощью закладных устройств. На рис. 13.8 представлена подробная классификация закладных устройств, применяемых злоумышленниками:



Рисунок 13.8. Классификация закладных устройств [237]

Акустооптический КУИ обусловлен зондированием вибрирующих тонких отражающих поверхностей (стекла окон, зеркала и т.п.), приёмом отраженного луча оптических (лазерным) приемником для дальнейшей модуляции лазерного луча. Из лазера в инфракрасном диапазоне и оптического приемника состоит система лазерного подслушивания («лазерные микрофоны») [238].

Луч лазера падает на стекло окна под определенным углом. Модуляция луча происходит на границе стекло–воздух с помощью звуковых колебаний.

Фотодетектором улавливается отраженный луч, расположенный на оси, и происходит амплитудная демодуляция отраженного излучения (рис. 13.9).




Рисунок 13.9. Лазерное прослушивание

Параметрическим каналом утечки информации называется канал утечки, обусловленный изменением характеристик отдельных элементов устройства при воздействии на них акустического давления, которое приводит к утечке сведений при определенных условиях. Одним из условий может являться воздействие высокочастотным сигналом (диапазона радиочастот) на вспомогательные технические средства и системы (ВТСС), включающие подобные элементы. Такое воздействие, приводящее к утечке информации, называется «высокочастотным (ВЧ) навязыванием» [239].

13.1.3. Оптический канал утечки информации

Структура оптического канала утечки информации (ОКУИ) представлена на рис. 13.10. Если в атмосфере присутствуют взвешенные частицы пыли и влаги, то они могут формировать мглу и туман. Капли и кристаллы воды, в виде дождя и снега, в том числе – аэрозолей и дымов, включающие в себя твердые частицы, влияют на метеорологическую видимость. Она может вызвать замутнение и ухудшить видимость атмосферы. Максимально большое расстояние, начиная с которого, при фиксированной прозрачности атмосферы, в светлое время суток совершенно черный объект с угловыми размерами $20' \times 20'$ сливается с фоном у горизонта и становится невидимым, называется метеорологической дальностью видимости.



Рисунок 13.10. Структура оптического канала утечки информации

Кривизна Земли так же, как и состояние атмосферы, могут повлиять на протяженность каналов утечки информации, если наблюдатель и сам предмет его наблюдения находятся на Земле. Для расчёта дальности прямой видимости $D_{ПВ}$ необходимо учитывать кривизну Земли, для чего используется формула:

$$D_{ПВ} = 3,57(\sqrt{h_0} + \sqrt{h_H}) \quad (13.1)$$

где h_0 – расстояние до объекта, находящегося над поверхностью Земли, м;
 h_H – расстояние до наблюдателя, находящегося над поверхностью Земли, м.

Всё, что может создать препятствие для распространения света: неровности поверхности земли, всевозможные сооружения (горы, овраги, башни, высотные здания, и т.д.) или растительность, текущая формула не учитывает. По мнению учёных [238], потенциальные оптические каналы утечки информации, в общем случае, обладают достаточно устойчивыми повторяющимися признаками.

Единственной средой распространения световых волн, вплоть до недавнего времени, были безвоздушное пространство и атмосфера. С разработкой волоконно–оптических технологий появились направляющие линии связи оптического диапазона. Они обладают многими преимуществами [238], если сравнивать их с электрическими проводниками. Они рассматриваются в качестве наиболее совершенной физической среды для передачи больших объёмов данных. Линии связи, использующие оптоволокно, являются волоконно– оптическими линиями связи (ВОЛС). Они устойчивы к внешним помехам, имеют малое затухание, обеспечивают значительно большую безопасность передаваемых по волокну данных, и считаются долговечными.

Наибольший угол абсолютного отражения света (а при равенстве и превышении угла падения света на границу раздела среды наблюдается полное отражение от неё) определяется по формуле:

$$a = \arcsin\left(\frac{n_1}{n_2}\right) \quad (13.2)$$

где n_1 и n_2 – преломление сердцевины и оболочки среды (рис. 13.11).




Рисунок 13.11. Движение света в волоконно–оптической линии связи

Волоконно–оптическая линия связи может быть *ступенчатой* (при постоянном показателе преломления света) и *градиентной* (при показателе преломления жилы, изменяющем своё значение). Для передачи оптических сигналов используются 2 вида ВОЛС: *одномодовые* и *многомодовые* волоконно–оптические линии связи (рис. 13.12).




Рисунок 13.12. Одномодовые и многомодовые ВОЛС

Возможность утечки информации (УИ) из электрического кабеля значительно выше, чем из волоконно – оптической линии связи. Такая утечка возможна [239], но при конкретных условиях (рис. 13.13).




Рисунок 13.13. Несанкционированное получение данных из ВОЛС

На характеристики оптических каналов утечки информации значительное влияние оказывают характеристики оптического приёмника [240]. Наиболее существенные для добывания сведений из них следующие:

- диапазон длин волн, воспринимаемый оптическим приёмником;
- чувствительность, определяемая минимальным уровнем светового потока на входе оптического приёмника, при котором на его выходе складывается изображение объекта с приемлемым качеством;
- разрешающая способность, определяющая наименьшие размеры пиксела;
- угол (поле) зрения, определяющий наблюдаемую часть пространства;
- величина геометрических и цветовых искажений изображения объекта наблюдения, что особенно зависит от характеристик оптического приёмника.

13.1.4. Радиоэлектронный канал утечки информации

Носителем данных в радиоэлектронном канале утечки информации (РЭКУИ) является *электромагнитное поле* и *электрический ток*, с частотами от акустического звукового диапазона до десятков гигагерц. У этого канала утечки информации имеются особенности, которые отличают его от других:

- наименьшая зависимость функционирования канала утечки информации от метеорологических условий, года и времени суток;
- высокая достоверность таких, полученных несанкционированным путём добываемых сведений, (за исключением случаев дезинформации);
- большое количество добываемой информации и нужных сведений;
- оперативность получения данных, вплоть до реального масштаба времени;
- скрытность перехвата сигналов, о котором жертва не может догадаться.

На рис. 13.14 представлена развёрнутая структура РЭКУИ [241].




Рисунок 13.14. Структура радиоэлектронного канала утечки информации

Существует два вида РЭКУИ, зависящие от способа перехвата данных. В канале утечки *первого вида*, изображенного на рис. 13.15, производится *перехват данных*, которые передаются по функциональному каналу связи.

Для этого приёмник сигнала канала утечки информации подключается, контактно или дистанционно, к проводам соответствующего функционального канала, или настраивается на параметры сигнала функционального радиоканала.




Рисунок 13.15. Радиоэлектронный канал утечки информации первого вида

При перехвате передаваемых сведений по проводным линиям связи применяются специальные электронные устройства перехвата, имеющие возможность подключаться к линиям последовательно (рис. 13.16, б) или параллельно, одновременно к двум проводам (рис. 16, а).




Рис. 13.16. Подключение к линиям связи: а) параллельное; б) последовательное.

Контактное подключение, считающееся простым способом, довольно легко находится специальной аппаратурой контроля проводных линий, из-за большого падения напряжения в линии. Поэтому существует такое большое разнообразие устройств перехвата данных, способных изменять силу тока в линии и компенсировать падение напряжения их при подключении.

Контактное и бесконтактное подключение может быть и к волоконно-оптическим линиям связи. Для того, чтобы *контактно* подсоединиться к линии, убирают защитный слой кабеля, стравливают светотражающую оболочку и выгибают оптический кабель на определенный угол (рис. 13.17, а).

Обнаружить утечку данных, при таком контактном подсоединении к ВОЛС, за счёт уменьшения мощности излучения довольно сложно, так как отбирается всего 0,001% передаваемой мощности, что сложно заметить.

В качестве элемента съёма светового сигнала при *бесконтактном* подсоединении к волоконно–оптической линии связи (рис. 13.17, б) используется стеклянная трубка с выгнутым концом, наполненная жидкостью с высоким показателем преломления, жёстко фиксированная на оптическом кабеле, с которого заранее снята экранная оболочка. Устанавливается объектив на выгнутом конце трубки, который фокусирует световой поток на фотодиод, который является оптико–электрическим преобразователем.




Рис. 13.17. Съём информации с волоконно–оптической линии связи:
а) контактный съём; б) бесконтактный съём

Перехват данных, которые передаются по радиоканалу, осуществляется с использованием приёмника, который настроен на соответствующую частоту, а также который поддерживает вид модуляции и протокол передачи, который использует передатчик. Выявить приёмник, который осуществляет перехват невозможно. Это считается отличительной особенностью перехвата радиосигнала. Для перехвата применяют сканирующие приёмники, обычные (серийно выпускаемые) приёмники, а также специализированные комплексы (например, для перехвата данных передаваемой по сетям сотовой связи).

Радиоэлектронный канал утечки информации *второго вида* (рис. 13.18) содержит: передатчик сигналов, среду распространения и приёмник сигналов. Передатчик этого канала утечки информации может образоваться без участия источника или получателя данных (произвольно), или специально размещается в помещении злоумышленником. В качестве такого передатчика могут применяться специальные *закладные устройства*, а также источники *побочных электромагнитных излучений и наводок* (ПЭМИН).

Высокочастотные генераторы могут входить в состав *технических средств приёма, обработки, хранения и передачи информации* (ТСПИ).




Рисунок 13.18. Радиоэлектронный канал утечки информации второго вида

Вызывать непреднамеренную модуляцию собственных высокочастотных колебаний генераторов, излучаемых в окружающее пространство, могут *наведенные* электрические сигналы – наводки. Для перехвата подобных *побочных электромагнитных излучений* (ПЭМИ) технических средств приёма и передачи информации злоумышленник может использовать как обычные средства радио– или радиотехнической разведки, так и *технические средства разведки* (ТСР) *побочных электромагнитных излучений и наводок* (ПЭМИН). Как правило, предполагается, что ТСР ПЭМИН размещаются за пределами *контролируемой зоны* (КЗ) объекта защиты [241].

Наводки (токи и напряжения) в токопроводящих элементах обусловлены электромагнитным излучением технических средств приёма, обработки, хранения и передачи сигнала (в том числе, и их соединительными линиями), а также ёмкостными и индуктивными связями между ними. Случайная антенна (посторонние проводники) либо соединительные линии *вспомогательных технических средств и систем* (ВТСС), при гальваническом подсоединении к которым имеется возможность перехвата информационных сигналов, которые наведены в них, средствами разведки ПЭМИН.

Просачивание информационных сигналов в цепи электропитания может произойти при наличии внутренних паразитных индуктивных и/или ёмкостных связей в блоке питания ТСПИ, а также за счёт неравномерности потребления тока, которые обусловлены обработкой информационного сигнала.

Электрические сигналы, как носители данных, являются дискретными или аналоговыми, а их спектр содержит частоты от десятков Гц до десятков ГГц.

Более широко используются сигналы, у которых ширина спектра соответствует ширине спектра *стандартного телефонного канала*. Такого рода сигналы передают *речевые данные* с помощью телефонных аппаратов.

Подобные сигналы распространяются по направляющим линиям связи, соединяющим абонентов, как внутри организации, так и внутри населенного пункта, города, государства, и даже земного шара в целом.

Направляющие линии связи, в основном, строятся для передачи сигналов в заданном направлении. Они создаются с высокой надёжностью, а также передают данные с должным качеством. *Проводная связь* – это прикладная область электросвязи, которая рассматривает методы и средства передачи электрических сигналов по проводам. Линии связи бывают двух видов: кабельные и воздушные. *Воздушные* линии связи относятся к симметричным цепям. Их характерной чертой является наличие двух проводников с одними и теми же электрическими свойствами. В *безвоздушном* пространстве и в *атмосфере* радиоэлектронного канала утечки информации, её носителями являются физические поля: в дальней зоне – электромагнитное поле, в ближней зоне источника поля – электрическое и магнитное поля.

При протекании *по проводам* источника радиосигнала электрического тока переменной частоты появляется электромагнитное поле, которое может распространяться в окружающем пространстве с конечной скоростью. Векторы напряжённости как электрического, так и магнитного полей являются перпендикулярными направлению перемещения электромагнитной волны, и взаимно перпендикулярны. Электромагнитная волна обладает такими параметрами, как мощность, поляризация и частота колебаний.


Поляризация электромагнитной волны определяет направление вектора напряжённости электрического поля. В случае, если вектор электрического поля лежит в горизонтальной плоскости, то поляризация *горизонтальная*, а в случае, если он располагается в вертикальной плоскости, то – вертикальная.

Ретрансляторы применяются с целью передачи сигнала на большие расстояния в диапазоне УКВ (ультракороткие волны – диапазон радиоволн с частотами от 30 до 300 МГц, с соответствующими длинами волн от 10 метров до одного метра). *Радиорелейные линии* (РРЛ), представляют собой цепочку приёмо–передающих станций, каждая из которых устанавливается в пределах прямой видимости соседних станций, проводятся с помощью наземных ретрансляторов. Все станции РРЛ разделяются на *промежуточные*, *оконечные* и *узловые*. Оконечные радиорелейные станции размещаются в конце и начале линии. На этих станциях выделяются и вводятся данные, обеспечивается распределение информации и сведений среди потребителей. Промежуточные станции предусмотрены для ретрансляции сигналов.

В табл. 13.1 продемонстрированы результаты сравнительного анализа характеристик радиоволн различных диапазонов.

Анализ характеристик радиоволн различных диапазонов

Таблица 13.1

Диапазон волн	Дальность распространения	Антенны	Уровень помех	Поглощение в атмосфере
Длинноволновые (ДВ)	Поверхностной волной – до 3 тыс. км			
Средневолновые (СВ)	Поверхностной волной – до 1500 км, пространственной – до 4000 км			
Коротковолновые (КВ)	Пространственной – на любое расстояние			
Ультракоротковолновые (УКВ)	Прямая видимость			
		Компактные	Низкий	Сильное

При распространении радиоволн в городе, характер их распространения значительно искажается, по сравнению с распространением на открытых пространствах, как результат множественных переотражений от помещений, стен зданий и затухания в них. Подобные условия необходимо принимать во внимание при оценке пространственной ориентации и возможностей радиоэлектронных каналов утечки информации.

Проблему электромагнитной совместимости радиосигналов с конкретными сведениями и с другими радиосигналами – помехами с совпадающими частотами, порождает разнообразие естественного и искусственного происхождения источников излучений в радиодиапазоне. На рис. 13.19 представлена классификация возможных помех.

13.1.5. Материально–вещественный канал утечки информации

Отличительная черта этого канала (МВКУИ), в сравнении с другими каналами утечки информации, вызвана особенностью источников и носителей данных, которыми в нём считаются либо материальные объекты (макротела и микрочастицы), либо субъекты (люди) (рис. 13.20).




Рисунок 13.19. Классификация помех в технических каналах утечки




Рисунок 13.20. Структура материально–вещественного канала утечки информации

Утечка информации в этом канале сопровождается физическим движением материальных тел со сведениями, и людей за пределами контролируемой зоны. Для того, чтобы отобразить рассматриваемый канал более отчётливо, необходимо определить состав источников и носителей данных.

Главными источниками данных материально–вещественного канала утечки информации (МВКУИ) являются следующие:

- разрабатываемые в процессе научно–исследовательских и опытно–конструкторских исследований, проводящихся в организации, макеты узлов, устройств, конструкций, блоков, а также черновики различных документов;
- листы документов, чертежей, плакатов, испорченные в ходе оформления и дальнейшем их размножении, использованная копировальная бумага, а также остатки печатной деятельности и делопроизводства организации;
- флэш–карты и жёсткие диски персональных компьютеров, которые содержат защищаемые сведения, нечитаемые из–за их физических дефектов и искажений загрузочных либо других секторов;
- остатки индустриального производства (мусор) квалифицированного и массового выпуска продукции, содержащие в себе признаки защищаемых сведений в газообразном, жидком или твёрдом виде;
- бракованная продукция, а также её компоненты;
- остатки радиоактивных материалов, остаточная радиоактивность.

Следующие объекты и субъекты имеют возможность перемещать сведения в рассматриваемом материально–вещественном канале утечки информации за пределы контролируемой зоны (они требуют особого внимания):

- человек (работник компании, посетитель, представитель вторсырья и др.) и управляемые им транспортные и технические средства;
- воздушные массы атмосферы (ветер);
- жидкая среда (вода и другие жидкости);
- излучения радиоактивных элементов.

Эти носители могут переносить все возможные виды защищаемой информации: признаковую, семантическую, а также демаскирующие вещества.

Семантические сведения находятся в черновиках документов, схем, чертежей; сведения о видовых и сигнальных демаскирующих признаках – в бракованных узлах и деталях, в свойствах радиоактивных излучений и т.д.; демаскирующие вещества – в газообразных, жидких и твердых отходах производства, которые могут разноситься ветром, водой и излучением.

13.2. Анализ методов защиты от утечки по техническим каналам

13.2.1. Защита от утечки по акустическому каналу

Совокупность мер, направленных на исключение возможности утечки конфиденциальных данных за счёт воздействия акустических полей, называется *акустической защитой*. Её структура представлена на рис. 13.21.




Рисунок 13.21. Структура акустической защиты

Чтобы определить степень эффективности защит [241], используются измерительные приборы, преобразующие колебания звукового давления в показания, соответствующие уровню звукового давления – *шумомеры*. Существуют четыре класса точности шумомеров [242]:

- 0 класс предназначен для лабораторных измерений уровня шума;
- 1 класс – для натурных измерений (вне помещения) уровня шума;
- 2 класс – для общих целей, при которых нужны измерительные работы;
- 3 класс – для ориентировочных (оценочных) измерений уровня шума.

Для обеспечения защиты используют *пассивные* и *активные* методы. Пассивные методы включают в себя звукопоглощение и звукоизоляцию. *Звукопоглощение* обеспечивается использованием особых герметических панелей, выполненных из стекловаты высокой плотности, различной толщины. *Звукоизоляция* обеспечивается особыми звукоизолирующими покрытиями стен. Звукоизоляцию целесообразно использовать только в небольших помещениях, т.к. в больших помещениях звуковая энергия максимально поглощается, не достигнув стен. Если пассивными мерами не удаётся обеспечить необходимого уровня безопасности, то следует применять активные методы [242].

Техническое средство, генерирующее *шумоподобные электронные сигналы*, называется *генератором шума* и считается одним из активных средств защиты. Сигналы подаются на датчики вибрационного (акустического) преобразования.

Для создания акустического шума в помещениях или вне их предназначены акустические датчики, а для маскирующего шума в ограждающих конструкциях применяются вибрационные датчики (приклеиваются к ним, создавая в них звуковые колебания) [243]. Примером такого генератора шума является система *виброакустического зашумления «Заслон»*. Характеристики современных систем зашумления – генераторов шума, приведены в табл. 13.2.

Характеристики современных систем зашумления

Таблица 13.2

Тип	Шумовая полоса (Гц)	Вибрационные излучатели	Акустические излучатели	Количество подключаемых датчиков
«Заслон»	100–6000	6	2	До 10
ANG–2000	250–5000	–	–	–
WNG–033	100–12000	–	–	До 18
«Кабинет»	100–6000	–	–	До 30

13.2.2. Защита от утечки по оптическому каналу

Комплекс мероприятий, который уменьшает или исключает возможность выхода конфиденциальной сведений за пределы контролируемой зоны за счёт распространения световой энергии называется *защитой от утечки информации по оптическому каналу*. Для сохранения данных от такой утечки рекомендуется:

- располагать объекты охраны, исключая отражение света в стороны, где может находиться злоумышленник (создавая пространственные ограждения);
- довести до минимума отражательные свойства объекта охраны;
- уменьшить освещённость объекта охраны (энергетические ограничения);
- использовать средства преграждения или значительного ослабления отраженного света: устанавливать экраны, ставни, ширмы, шторы, тёмные стекла и иные преграждающие объекты или промежуточные среды;
- применять средства маскирования, имитации объектов и людей (манекены, муляжи, фотографии и др.) для защиты и введения противника в заблуждение;
- использовать от неконтролируемого распространения средства пассивной и активной защиты источника излучения или отражательного света;
- осуществлять маскировку объектов охраны, варьируя контрастом фона и отражательными свойствами объектов защиты;
- применять *маскирующие средства* сокрытия объектов, в виде маскирующих сеток, защитных укрытий, красок и аэрозольных завес.

*Аэрозольные завесы находят широкое применение в качестве оперативных средств сокрытия. Это мельчайшие частицы различных веществ, взвешенные в газообразной среде, которые, в зависимости от агрегатного сочетания и размеров, образуют туман, дым, копоть. Такие завесы способны преградить распространение отраженного (от объекта защиты) света. Дымообразующие вещества имеют хорошие свойства *светопоглощения*. Аэрозольные образования в виде маскирующих завес гарантируют групповую или индивидуальную защиту техники и объектов, включая и выпускаемую продукцию [244].*

13.2.3. Защита от утечки данных по радиоэлектронному каналу

Организационно–технические и организационные меры защиты [245] от утечки информации по электромагнитному каналу представлены на рис. 13.22.




Рисунок 13.22. Организационные и организационно–технические меры защиты информации от утечек по радиоэлектронному каналу [245]

Более эффективным для защиты информации и широко передаваемым по активным каналам связи считается применение информационных методов сокрытия информации, а именно—*шифрования*. Из технических методов защиты именно информационные методы единственно приемлемы для защиты данных, передаваемой по радиоканалу. Проблема состоит в том, что носитель информации (электромагнитная волна) в пространстве не содержит точных пределов, и локализовать ее какими-либо техническими средствами невозможно.

Методы *энергетического сокрытия* используются для защиты данных, передаваемых по *проводным линиям связи*. Это возможно, так как любой проводник имеет чёткие границы в пространстве. Для защиты от бесконтактного съёма данных применяется линейное зашумление (как активный способ), и экранирование кабелей с заземлением экрана (как пассивный способ).

Из пассивных способов, для защиты данных от утечки по электрическому каналу, используется ограничение небезопасных сигналов, фильтрация, защитное отключение, а также экранирование линий, выходящих за пределы контролируемой зоны с заземлением экранирующей оболочки [244]. В этом случае экранируются участки проводника, проходящие рядом с техническими средствами и другими проводниками, несущими данные ограниченного доступа, для исключения взаимного наведения и влияния в проводнике, который выходит за пределы контролируемой зоны информационного сигнала, в отличие от защиты проводного функционального канала связи [245].

Электронное устройство, пропускающее сигналы одного диапазона (или диапазонов) частот, и не пропускающее сигналы другого (других) диапазона частот, называется *фильтром*. Если фильтр не пропускает сигналы высоких частот, но пропускает низкочастотные сигналы, то это *фильтр низких частот* (ФНЧ). Если, наоборот, фильтр не пропускает низкочастотные сигналы, но пропускает высокочастотные, то это *фильтр высоких частот* (ВФЧ).

Для исключения (ослабления) просачивания информационных сигналов от технических средств приёма–передачи информации (ТСПИ), которые работают на более высоких частотах, в заземление, в цепи электропитания или в линии, выходящие за пределы контролируемой зоны, используют ФНЧ.

Ограничитель — это электронное устройство, не пропускающее слабые сигналы, которые могут возникнуть в результате наводок или на выходе элементов, обладающих «*микрофонным эффектом*», но пропускающее сигналы высокого уровня. В этом и заключатся ограничение небезопасных сигналов.

Некоторые типы сетевых фильтров представлены на рис. 13.23 и рис. 13.24.



Рисунок 13.23. Сетевой фильтр ФАЗА-1-10 Рисунок 13.24. Сетевой фильтр ЛФС-40-1Ф

Сетевой фильтр ФАЗА-1-10 является специализированным устройством для предотвращения утечки данных от компьютеров и иных технических средств передачи данных по линиям питающей сети, которые выходят за границы контролируемой зоны или за пределы выделенного помещения, за счёт подавления наводок небезопасных (информативных) сигналов.

Однофазный помехоподавляющий сетевой фильтр ЛФС-40-4Ф создан для защиты вычислительной техники и радиоэлектронных устройств от утечки информации по цепям электропитания с частотой $50 \pm 0,5$ Гц, с предельным рабочим током 40 А и напряжением до 250 В, а также – от высокочастотных помех в полосе частот 0,1...1000 МГц. Линейное зашумление является активным способом защиты, и для зашумления информационных сигналов в кабелях и проводах, которые выходят за пределы контролируемой зоны, используются *системы линейного зашумления (СЛЗ)*. Это необходимо в случаях:

- недостаточных уровней переходных затуханий между подверженными влиянию и влияющими кабелями, и соединительными линиями;
- воздействия на провода, цепи и устройства вспомогательной аппаратуры низкочастотных электромагнитных полей основной аппаратуры;
- электроакустических преобразований во вспомогательной аппаратуре.

Генераторы линейного зашумления показаны на рис. 13. 25 и рис. 13.26.



Рисунок 13.25. Генератор линейного зашумления СОНАТА-РК1



Рисунок 13.26. Генератор линейного зашумления ЛГШ-503

Для активной защиты объектов информатизации от возможных утечек, в форме информативных электрических сигналов и наводок, по системе заземления, по сети электропитания, по инженерным коммуникациям, а также за счёт паразитных электромагнитных излучений, используется генератор линейного зашумления «Соната–РК1». Его аналог, «ЛГШ–503», предназначен для активной защиты от утечки информации по сети электропитания («ноль», «фаза» и «защитное заземление»), и для противодействия съёму информации средствами несанкционированного доступа, по каналам побочного электромагнитного излучения, объектов информатизации путём создания широкополосной шумовой помехи в диапазоне частот от 0,01 МГц до 2000 МГц.

Специализированными устройствами, контролирующими *характеристики линии* (индуктивность, напряжение, сопротивление, ёмкость) обеспечивается контроль, а при их отклонении от нормированных – выдаётся сигнал тревоги.

Локализация излучений путём заземления и экранирования технических средств, а также экранирования целых помещений, относится к мероприятиям защиты данных от утечки по электромагнитному каналу, с помощью *пассивных средств*. Так, например, сверхлегкое *радиоэкранное укрытие* разборного типа на основе металлизированных тканей «Шатер» представлено на рис. 13.27.




Рисунок 13.27. Радиоэкранное укрытие разборного типа «Шатер»

«Шатер» предназначен для экранирования помещений и рабочих мест для обработки режимной информации, и проведения испытаний (мониторинга) различной радиоэлектронной аппаратуры на наличие побочных электромагнитных излучений и наводок (ПЭМИН), и гарантирует снижение значений ПЭМИН от устанавливаемых технических средств в широком диапазоне частот. Укрепляемая на сборно–разборном каркасе цельная экранирующая оболочка из металлизированной ткани, представляет собой радиоэкранное укрытие. Изделие имеет внешний или внутренний, по отношению к рабочему пространству, входной тамбур с двумя дверями, обеспечивающими *радиогерметичность* при входе–выходе персонала из внутреннего помещения.

Радиоэкранное укрытие оперативно подключается к сети электропитания, и устанавливается внутри или вне помещения, на месте эксплуатации, для временного или постоянного использования. Это средство пассивной защиты, тогда как *пространственное зашумление* – мероприятие активной защиты.

13.2.4. Защита от утечки по материально–вещественному каналу

Методы предотвращения утечки данных по материально–вещественным каналам можно разделить на две группы (рис. 13. 28) [246]:

- методы избавления от данных в отходах деятельности компании;
- методы избавления от демаскирующих веществ объекта защиты.




Рис. 13.28. Способы предотвращения утечки информации по материально–вещественному каналу

Методы избавления от данных, оставшихся на бумажных или машинных носителях, и содержащейся информации в отходах и бракованных изделиях, оставшейся в процессе научной и производственной деятельности организации, формируют первую группу. Она предусматривает следующие меры:

- необходимо производить учёт испорченной копировальной бумаги, отдельных листов с записями, бракованных узлов, деталей и макетов;
- собирать черновики документов, а также всевозможные записи на отдельных неучтённых листках, в специальные опечатанные ящики;
- проводить ликвидацию (уничтожение) машинных и бумажных носителей;
- производить плановую разборку конструкций и макетов, разрушение механических элементов изделий, содержащий охраняемую информацию.

Сегодня применяются всевозможные *размельчители бумаги (шредеры)*, вместо сжигания подлежащих уничтожению бумажных носителей. Они удобны в работе, экологически безопасны и занимают сравнительно мало пространства.

Простые шредеры продольного разреза превращают листы бумаги в продольные полосы. Бумажные ленты режутся последовательно, и в этом случае существует возможность восстановления текста на бумаге.

Наиболее надёжную защиту могут гарантировать ленточно–поперечные размельчители. Они не только режут ленту поперек, но и секут её вдоль, превращая лист бумаги в небольшие прямоугольники либо квадраты. Таким способом порезанную бумагу восстановить практически невозможно, а также по объёму она занимает значительно меньше места, чем при резке полосами.

Ещё надёжнее *дробители (гриндеры)*, измельчающие бумагу в клочки. В них можно регулировать скорость и менять размеры клочков. *Гребенчатый* гриндер обладает двумя вращающимися гребнями, которые ворошат бумагу, обеспечивая непрерывность процесса, в то время как искромсанная до нужных размеров бумага проваливается через сетку в нижнюю часть машины.

В *дезинтеграторах* достигается максимальное измельчение бумаги. Такое устройство способно порезать бумагу на кусочки размером до 1 мм, т.е. вплоть до мельчайшего фрагмента, в котором невозможно разобрать отдельную букву.

Следует учитывать бракованную продукцию, которая может содержаться в макетах, в узлах, а также в элементах конструкций. Для защиты данных, необходимо после использования разбирать и уничтожать неразборные узлы и части, которые могут обладать демаскирующими признаками.

13.3. Разработка подсистемы поддержки принятия решений в процессе идентификации технических каналов утечки информации

13.3.1. Выбор языка программирования для реализации подсистемы

Выбор языка программирования играет существенную роль при создании программного обеспечения. Ресурс *Stackoverflow* считается основой анализа, так как в нём формируется отчёт о востребованности языков программирования. Сведения, собранные за последние 3 года, с использованием данных Google Trends [247] показывают динамику языков программирования (рис. 13.29). Для реализации подсистемы принятия решений (ПППР) существует выбор из таких языков, как Java; C# и Python. Рассмотрим их достоинства и недостатки.

Язык *JavaScript*, как правило, применяется как встраиваемый язык для программного доступа к объектам приложений. Он широко используется в качестве языка сценариев, чтобы придать веб–страницам интерактивность. Он находит применение в браузерах, но не подходит для реализации ПППР идентификации технических каналов утечки информации [248].




Рисунок 13.29. Статистика популярности языков программирования за последние годы

SQL—декларативный язык программирования, который используется для создания, изменения и управления данными в реляционной базе данных. Следовательно, для написания ПППР он не подходит.

Выполняемые виртуальной машиной Java (JVM) программы, написанные на языке *Java*, транслируются в байт-код Java. JVM-программа обрабатывает код и передает инструкции аппаратной части ПК как интерпретатор. Полная независимость байт-кода от операционной системы и оборудования считаются плюсом языка. Это позволяет запускать Java-приложения на любом устройстве, для которого существует соответствующая виртуальная машина. Значимой чертой технологии Java считается гибкая система безопасности, позволяющая полностью контролировать исполнение программы JVM.

Язык программирования *C#* на сегодня является одним из стремительно развивающихся, мощных и востребованных языков в ИТ-отрасли. На нём пишется наибольшее количество приложений. Это молодой, по сравнению с другими языками, однако прошедший большой путь язык программирования. С интегрированной средой программирования Microsoft Visual Studio .NET, в 2002 году вышла первая версия языка. Когда упоминают *C#*, то зачастую имеют в виду технологии платформы .NET (WPF, ASP.NET). Мощную платформу для создания приложений представляет фреймворк .NET. Его черты: возможность поддержки нескольких языков; кроссплатформенность; мощная библиотека классов; большое разнообразие технологий [249].

C# обладает такой отличительной чертой языка и фреймворка .NET, как автоматическая сборка мусора – в большинстве случаев программисту не приходится заботиться об освобождении памяти, в отличие от языка C++.

Высокоуровневый язык программирования общего назначения *Python* ориентирован на увеличение производительности разработчика и читаемости программного кода. Python поддерживает ряд парадигм программирования: структурное, объектно–ориентированное, функциональное, императивное и аспектно–ориентированное. Автоматическое управление памятью, механизм обработки исключений, динамическая типизация, полная интроспекция, поддержка многопоточных вычислений и удобные высокоуровневые структуры данных считаются его основными архитектурными чертами. Код в Python организован в функции и классы, которые имеют возможность объединяться в модули (они в свою очередь могут быть объединены в пакеты). Однако Python обладает и недостатками: низкое быстродействие, так как он является интерпретатором; в нём невозможна модификация встроенных классов; возможна глобальная блокировка интерпретатора (GIL) [250].

Изучив все возможные варианты, для написания ПППР был выбран язык C#, в том числе, из–за наличия удобного и простого графического интерфейса в Visual Studio, а также имеющегося опыта программирования на этом языке.

13.3.2. Формальное описание подсистемы поддержки принятия решений с использованием коэффициентной методики

Под *коэффициентной методикой* подсистемы ПППР понимается методика вычисления того или иного множества выходных показателей, значения каждого из которых определяются путём суммирования значений некоторого подмножества входных и (или) промежуточных показателей, учитываемых при суммировании, вместе с соответствующими весовыми коэффициентами.

Коэффициентная методика может быть описана следующей формулой:

$$X = \sum_{i=1}^g W_i \cdot X_i, \quad (13.3)$$

где X – выходной показатель, X_i – i -й входной показатель ($i = 1, \dots, g$), g – общее количество входных показателей, $W_i \geq 0$ – весовой коэффициент i -го входного показателя. Условие нормирования для W_i представлено в формуле:

$$\sum_{i=1}^g W_i = 1. \quad (13.4)$$

Значение $W_i = 0$ указывает на полное отсутствие информативности канала утечки информации. Чем больше суммарное значение W_i стремится к единице, тем более информативным является этот канал.

Условие нормирования для X_i представлено в формуле:

$$X_i \in [0,1]. \quad (13.5)$$

Значение X_i описывает возможность обнаружения канала утечки информации. При этом, X_i равное 0, означает полное отсутствие такого канала.

Обойтись только общим случаем подсчёта информативности нельзя, так как структура расчёта усложняется до иерархического вида, со многими подуровнями, на каждом из которых нужно рассчитывать частные показатели информативности, вносящие свой вклад в общую информативность канала утечки информации. Структура такого расчёта канала УИ показана на рис. 13.30.

Итоговым результатом является значение A – интегральный показатель информативности КУИ, который рассчитывается суммированием частных показателей и их информативности по формуле (13.4). Частные показатели информативности также рассчитываются по формуле (13.4), где:

- B – частный показатель информативности акустического канала УИ;
- B_1 – значение X_i канала УИ «телефон и телефонные линии связи»;
- B_2 – значение X_i канала УИ «охранная сигнализация»;
- B_3 – значение X_i канала УИ «пожарная сигнализация»;
- B_4 – значение X_i канала УИ «звукоусилительная аппаратура»;
- B_5 – значение X_i канала УИ «звуковоспроизводящая аппаратура»;
- B_6 – значение X_i канала утечки информации «система воздухообмена»;
- B_7 – значение X_i канала утечки информации «трубы отопления»;
- B_8 – значение X_i канала утечки информации «трубы водоснабжения»;
- BC_1 – значение X_i акустического КУИ и оптического КУИ «окна»;
- BC_2 – значение X_i акустического КУИ и оптического КУИ «двери»;
- BC_3 – значение X_i АКУИ и ОКУИ «контролируемая зона»;
- BC_4 – значение X_i акустического КУИ и оптического КУИ «этаж»;
- BC_5 – значение X_i акустического КУИ и оптического КУИ «стены»;
- BC_6 – значение X_i акустического КУИ и оптического КУИ «потолок и пол»;
- BC_7 – значение X_i акустического КУИ и оптического КУИ «зеркала»;
- BC_1^1 – значение X_j BC_1 «шторы и жалюзи»;
- BC_1^2 – значение X_j BC_1 «расположение соседних зданий»;




Рисунок 13.30. Структура расчета информативности канала утечки информации

BC_1^3 – значение X_j BC_1 «резиновые прокладки»;
 BC_1^4 – значение X_j BC_1 «количество стеклопакета»;
 $BC_{1,2}$ – значение X_j BC_1 и BC_2 «высота»;
 $BC_{2,1}$ – значение X_j BC_1 и BC_2 «ширина»;
 BC_2^1 – значение X_j BC_2 «толщина»;
 BC_2^2 – значение X_j BC_2 «материал»;
 BC_2^3 – значение X_j BC_2 «тип»;
 BC_2^4 – значение X_j BC_2 «резиновый уплотнитель»;
 BC_2^5 – значение X_j BC_2 «стекла»;
 C – частный показатель информативности оптического КУИ;
 C_1 – значение X_i канала УИ «оптико–волоконные линии связи»;
 C_2 – значение X_i канала утечки информации «доска»;
 C_3 – значение X_i канала утечки информации «интерактивная доска»;
 C_4 – значение X_i канала утечки информации «проектор»;
 C_1^1 – значение X_j BC_7 и C_2 «высота»;
 C_1^2 – значение X_j BC_7 и C_2 «ширина»;
 C_1^3 – значение X_j BC_7 , C_2 и C_3 «размещение»;
 C_1^4 – значение X_j C_3 «размер»;
 C_1^5 – значение X_j C_3 «угол»;
 C_1^6 – значение X_j C_4 «яркость»;
 C_1^7 – значение X_j C_4 «разрешение»;
 C_1^8 – значение X_j C_4 «расстояние от экрана»;
 D – частный показатель информативности РКУИ;
 D_1 – значение X_i КУИ «телефон и телефонные линии связи»;
 D_2 – значение X_i канала утечки информации «розетка»;
 D_3 – значение X_i канала утечки информации «сетевой коммутатор»;
 D_4 – значение X_i канала утечки информации «ЭВМ»;
 D_5 – значение X_i канала утечки информации «охранная сигнализация»;
 D_6 – значение X_i канала утечки информации «звукоусилительная аппаратура»;
 D_7 – значение X_i канала утечки информации «пожарная сигнализация»;
 D_8 – значение X_i канала утечки информации «заземление»;

Из рис. 13.30 видно, что некоторые значения X_i рассчитываются по показателям X_j , следовательно, для них расчет X_i будет показан формулой:

$$X_i = \sum_{j=1}^n X_j. \quad (13.6)$$

Входными параметрами для подсчёта информативности канала утечки информации являются нормированные значения X_i каждого канала (КУИ). Источником информации о значениях W_i является экспертная оценка.

13.3.3. Программная реализация подсистемы поддержки принятия решений при идентификации технических каналов утечки информации

Подсистема поддержки принятия решений в процессе идентификации технических каналов утечки информации включает в себя пять функций: поиск каналов утечки информации; функции первичного исследования; просмотра отчётов; анализатора данных; архивирования и отправки по почте.

При поиске каналов утечки информации в помещении, нужно ввести атрибуты объекта, включающие исходные данные: адрес, наименование объекта, размещение объекта, этаж расположения и расстояние до контролируемой зоны (рис. 13.31).

The screenshot shows a software window titled 'Подсистема поддержки принятия решения' with a sub-header 'Укажите атрибуты объекта'. It contains several input fields and buttons. On the left, there are three text input fields labeled 'Полный адрес', 'Наименование объекта', and 'Размещение', each followed by an 'Очистить поле' (Clear field) button. Below these is a button 'Очистить все поля' (Clear all fields). On the right, there are two numeric input fields: 'Этаж расположения помещения' (Floor of the room) and 'Расстояние до контролируемой зоны' (Distance to the controlled zone), both with '0' entered and a '0-9' spinner. At the bottom left is a 'Назад' (Back) button, and at the bottom right is a 'Далее' (Next) button.

Рисунок 13.31. Атрибуты объекта – исходные данные

Расчёт коэффициентов происходит с помощью нейро–нечёткой логики. Далее выбираются каналы для проведения первичных исследований, присутствующие в помещении. На завершающем этапе происходит расчёт общего коэффициента возможной утечки информации (рис. 13.32).

The screenshot shows a software window titled 'Завершение' (Completion). It displays the results of a search: 'Количество каналов утечки: 3 из 3' (Number of leakage channels: 3 out of 3). Below this, it says 'Выберите каналы для проведения первичных исследований' (Select channels for primary research). There is a list of three channels with checkboxes and numerical values: 'Акустический канал' (Acoustic channel) with value 0,12, 'Оптический канал' (Optical channel) with value 0,1881, and 'Радиоэлектронный канал' (Radioelectronic channel) with value 0,0396. Below the list is a button 'Провести расчеты(рекомендуется)' (Perform calculations (recommended)). At the bottom, it shows 'Общий коэффициент возможной утечки информации: 0,3477' (Overall coefficient of possible information leakage: 0,3477) with a note '[Ниже среднего]' (Below average). At the bottom left is a 'Назад' (Back) button, and at the bottom right is a 'Завершить' (Finish) button.

Рисунок 13.32. Завершающая форма поиска каналов утечки информации

При завершении вычислений происходит запись отчёта в файл, который можно посмотреть в функции просмотра отчётов, и, при необходимости, заархивировать папку с отчётами, выбирая одну из двух функций (рис. 13.33).




Рисунок 13.33. Функции архивирования отчётов

В файл отчёта входит информация о том, какие каналы утечки найдены и существуют; какие из выбранных компонентов входят в тот или иной канал утечки; а также рекомендации по защите от присутствующих каналов утечки информации. Отчёт можно просмотреть и отредактировать (рис. 13.34).




Рисунок 13.34. Окно просмотра файлов

На рис. 13.35 изображено окно отправки файлов отчётов и сообщений по электронной почте. Для отправки необходимо выбрать почту, с которой будет отправлен файл, и ввести свои данные (логин и пароль), а также указать почту, на которую необходимо отправить сообщение с файлами. Существует окно выбора, в котором можно указать тему и набрать текст сообщения, а также прикрепить пересылаемый файл. Если тема и текст сообщения не указаны, то файлы отчётов будут отправлены по умолчанию.

Рисунок 13.35. Окно отправки отчетов и сообщений по почте

Функция анализатора данных позволяет, по готовому описанию помещения, произвести поиск каналов утечки информации и составить отчёт (рис. 13.36). Также в функцию анализатора можно загрузить файл описания помещения. База знаний расположена в XML файле, что позволяет сократить время считывания и повышает количество записей в сравнении с txt файлом.

Первичные исследования проводятся, в основном, по двум каналам утечки данных: *оптическому* (рис. 13.36) и *акустическому* (рис. 13.37). При этом в первичных исследованиях акустического канала утечки информации можно провести предварительные расчеты звукоизоляции/виброизоляции (рис. 13.38) или расчёты на наличие акустоэлектрических преобразований. После проведения расчётов выводы сохраняются в файле отчёта.

Рисунок 13.36. Первичные исследования оптического канала утечки информации

Рисунок 13.37. Изучение акустоэлектрических преобразований при первичном исследовании акустического канала утечки информации

Рисунок 13.38. Изучение виброизоляции / звукоизоляции при первичном исследовании акустического канала утечки информации

Таким образом, цели исследования проекта достигнуты. Разработанная подсистема поддержки принятия решений идентификации технических каналов утечки информации позволяет специалистам в области защиты информации оперативно формировать список информативных технических каналов утечки данных при предварительном обследовании защищаемой автоматизированной системы организации, а также сохранять результаты проведенных исследований. Разработанное программное средство создаёт условия для проектирования и модернизации системы защиты организации, т.е. такого управления частными показателями, при котором интегральный показатель информативности признаковой структуры объекта будет принимать желаемое значение.

14. РАЗРАБОТКА АДАПТИВНОГО FUZZY–АЛГОРИТМА ИДЕНТИФИКАЦИИ ТЕХНИЧЕСКИХ КАНАЛОВ УТЕЧКИ ЗАЩИЩАЕМОЙ ИНФОРМАЦИИ УЧРЕЖДЕНИЯ

14.1. Применение нейронных сетей в поиске технических каналов утечки информации

14.1.1. Использование нейро–нечёткой логики в нейронной сети при поиске технических каналов утечки информации

Нечётким набором данных могут обладать все рассмотренные ранее характеристики. Если представленные начальные данные являются слабо формализованными и не совсем надёжными, то для решения поставленной задачи необходимо применять аппарат нечёткой логики и нечётких множеств. У такого подхода есть сильные стороны [251]: эффективность, тесно связанная с универсальностью, что подтверждается рядом теорем, аналогичных теоремам о полноте для искусственных нейронных сетей. Согласно знаменитой теореме FAT (Fuzzy Approximation Theorem), которую доказал Барт Коско в 1993 году: «любая математическая система может быть аппроксимирована системой, основанной на нечёткой логике» [252]. Метод решения и описание условий задачи на языке, близком к естественному, также является сильной стороной.

Но для управляющих нечётких экспертных систем имеются недостатки. Считается, что при разработке человеком первичного набора постулируемых нечётких правил, этот набор может оказаться неверным, противоречивым или неполным [253]. Существенным недостатком также считается тот факт, что параметры и вид функций принадлежности, описывающих выходные и входные переменные системы, выбираются человеком субъективно, и могут оказаться не вполне отражающими реальную действительность.

Чтобы исключить эти недостатки, учёные предложили сделать нечёткое управление и экспертные системы *адаптивно–корректирующими системами*. Это обусловлено тем фактом, что нейро–нечёткая система работает как по параметрам, так и по правилам функций принадлежности [254]. Исходя из многих вариантов такой адаптации, можно сделать вывод, что использование метода гибридных нейронных сетей является наиболее успешным [255].

Как писал Ю.А. Заргарян: «Гибридная нейронная сеть, формально, по структуре, напоминает многослойную нейронную сеть с обучением, например, по алгоритму обратного распространения ошибки, но скрытые слои в ней соответствуют этапам функционирования нечёткой системы» [256].

Первый слой нейронов выполняет функцию введения нечёткости на основе заданных функций принадлежности входов. Совокупность нечётких правил отображает *второй слой*. В то время как *третий слой* выполняет функцию приведения к чёткости. Каждый слой характеризуется параметрами функций принадлежности, нечётких решающих правил, активационных функций, весами связей, что является набором параметров. Как и для обычных нейронных сетей, необходимо производить *настройку слоев*.

14.1.2. Принципы создания и работы обучаемой нейронной сети

Семён Хайкин дал определение нейронным сетям: «под нейронными сетями подразумеваются вычислительные структуры, моделирующие простые биологические процессы, которые ассоциируются с процессами человеческого мозга [257]. Адаптируемые и обучаемые, нейронные сети представляют собой распараллеленные системы, которые способны к обучению путём анализа положительных и отрицательных воздействий извне. Искусственный нейрон (или просто нейрон) в таких сетях является простым преобразователем, который назван так по аналогии со своим биологическим прототипом».

Одним из составляющих частей искусственной нейронной сети является искусственный нейрон, структура которого изображена на рис. 14.1.




Рисунок 14.1. Структура искусственного нейрона

Нейрон состоит из синапсов (умножителей), осуществляющих связь между нейронами, нелинейного преобразователя и сумматора, который выполняет суммирование сигналов. Связь между двумя нейронами называется *синапсом*.

Для осуществления связи между нейронами, синапсы умножают входной сигнал на число, обозначающее силу связи, – на *вес синапса*, который является важным параметром, в силу того, что из-за веса синапса входная информация изменяется, когда передается от одного нейрона к другому [258].

Сумматор принимает сигналы по синаптическим связям от других нейронов, а также по внешним входным сигналам. Кроме того, сумматор выполняет и сложение сигналов, поступивших по синаптическим связям от других нейронов, и внешних входных сигналов. Нелинейная функция одного аргумента – выход сумматора – реализуется *нелинейным преобразователем*.

Каждый нейрон имеет свое выходное значение, которое определяется в зависимости от функции активации, или *передаточной функции нейрона*. Сам же нейрон в целом реализует скалярную функцию векторного аргумента. Математическая модель нейрона описывается формулой [259]:

$$H = \sum_{j=1}^t e_j b_j + q, \quad (14.1)$$

где e_j – вес синапса ($j = 1, \dots, t$); q – значение смещения; H – результат суммирования; b_j – компонента входного вектора (входной сигнал).

Вид функции активации обуславливает, что весовые коэффициенты, значения смещения и входной сигнал могут принимать действительные значения. Их выход может быть, как действительным, так и целым.

Во многих практических задачах входы, веса и смещения могут принимать лишь фиксированные значения. Синаптические связи с отрицательными весами являются *тормозящими*, а с положительными весами – *возбуждающими* [260]. Сам нейрон e_j описывается своими весами и передаточной функцией $f(H)$, которая полностью описывает нейрон. Получив набор чисел (вектор) b_j в качестве входов, нейрон выдает определенное число y на выходе.

Если предположить, что нейронную сеть необходимо создать с нуля, то сначала нужно выбрать архитектуру и тип создаваемой сети. После этого необходимо решить вопрос с подбором весов – то есть с обучением сети.

Сначала нужно провести анализ создаваемой сети, выбрать нейроны (число входов и передаточные функции), способ соединения нейронов между собой, и данные, которые будут являться входами и выходами сети.

Следующий этап создания нейронной сети предполагает её обучение с помощью подбора весов, то есть, чтобы сеть работала нужным образом, необходимо подобрать правильные значения её весов.

Тип искусственного нейрона зависит от функций, которые он выполняет. Существует три типа нейронов: *входные*, *выходные* и *промежуточные*.

К *первому типу* относятся входные нейроны. На каждый входной нейрон подаётся *входной вектор*, кодирующий входное воздействие, или образ внешней среды. Он может воспринимать сигналы только от внешней для этой системы среды. Во входных нейронах не осуществляются вычислительные процедуры, информация передаётся со входа на выход, путём изменения его активации.

Ко *второму типу* относятся выходные нейроны, предоставляющие выходные значения нейронной сети, т.е. представляют результат её работы.

К *третьему типу* относятся нейроны, составляющие основу нейронных сетей (каждого слоя). Они называются *промежуточными* нейронами.

Исходя из того, что нейрон, имеющий только выходные связи, относится к входному нейрону, а нейрон, имеющий только входные связи, относится к выходному нейрону, то тип нейрона тесно связан с его расположением в сети.

Использование функций активации, перечисленных в табл. 14.1, является составной частью *метода нормализации входных данных*.

Перечень функций активации нейронов

Таблица 14.1

Название функции активации	Формула	Область значений
Пороговая	$f(N) = \begin{cases} 0, & N < 0 \\ 1, & N \geq 0 \end{cases}$	0, 1
Знаковая (сигнатурная)	$f(N) = \begin{cases} 0, & N > 0 \\ -1, & N \leq 0 \end{cases}$	-1, 1
Сигмоидальная (логистическая)	$f(N) = \frac{1}{1 + e^{-N}}$	(0, 1)
Полулинейная	$f(N) = \begin{cases} N, & N > 0 \\ 0, & N \leq 0 \end{cases}$	$(0, +\infty)$
Линейная	$f(N) = N$	$(-\infty, +\infty)$
Радиальная базисная (гауссова)	$f(N) = e^{-N^2}$	(0, 1)
Полулинейная с насыщением	$f(N) = \begin{cases} 0, & N \leq 0 \\ N, & 0 < N < 1 \\ 1, & N \geq 1 \end{cases}$	(0, 1)
Линейная с насыщением	$f(N) = \begin{cases} -1, & N \leq -1 \\ N, & -1 < N < 1 \\ 1, & N \geq 1 \end{cases}$	$(-1, 1)$

Название функции активации	Формула	Область значений
Гиперболический тангенс (сигмоидальная)		$(-1, 1)$
Треугольная	$f(N) = \begin{cases} 1 - N , & N \leq 1 \\ 0, & N > 1 \end{cases}$	$(0, 1)$

Введя большое количество входных данных в нейронную сеть, пропустив их через функцию активации, можно получить выходные данные в нужном диапазоне. Диапазон значений – главное отличие функций активаций. В общем случае, принимать действительные значения могут: входной сигнал, весовые коэффициенты и значения смещения. Тип функции активации определяет выходные результирующие данные, которые могут принимать либо действительные, либо целочисленные значения. Во многих практических задачах входные данные, веса и смещения и результирующие выходные данные могут принимать лишь некоторые фиксированные значения.

14.1.3. Выбор топологии нейронных сетей для задачи поиска технических каналов утечки информации

Для выбора топологии следует рассмотреть основные типы нейронных сетей, которые формируются на основе нейроподобных элементов [261]:

- полносвязные сети, продемонстрированные на рис. 14.2, а;
- многослойные или слоистые сети, изображенные на рис. 14.2, б;
- слабосвязные нейронные сети (с локальными связями), рис. 14.3, в.

Первый тип – это *полносвязные* нейронные сети, изображённые на рис. 14.2, а, где каждый нейрон передает свой выходной сигнал всем остальным нейронам, в том числе и самому себе. Выходными сигналами всей сети могут быть как все, так и некоторые выходные результирующие сигналы нейронов, сформировавшиеся после нескольких тактов (эпох) функционирования сети.

Второй тип нейронной сети, изображенный на рис. 14.2, б, представляет собой *многослойные сети*. В таких сетях нейроны объединяются в слои, причём каждый слой содержит набор нейронов, которые имеют один входной сигнал. Каждый слой может иметь любое число нейронов, которое заранее никак не связано с количеством нейронов в других слоях.




Рисунок 14.2. Архитектуры нейронных сетей: а) полносвязная сеть; б) многослойная сеть с последовательными связями; в) слабосвязные сети

В многослойной сети слои нумеруются слева направо, а сама сеть состоит из Q слоев. Выходы сети являются выходными сигналами последнего слоя, а внешние входные сигналы подаются на входы нейронов первого слоя (входной слой часто нумеруется как ноль). Вход нейронной сети можно рассматривать как выход *нулевого слоя* вырожденных нейронов, в которых суммирование и преобразование сигналов не производится. Нулевой слой служит в качестве распределительных точек. Кроме этого, многослойная нейронная сеть имеет один или несколько скрытых (промежуточных) слоев. Связи от выходов нейронов некоторого слоя q к входам нейронов следующего слоя $(q + 1)$ являются последовательными связями. Многослойные (слоистые) нейронные сети также классифицируются на следующие типы [262]:

1. *Монотонные*. Это специальный частный случай слоистых сетей, которые имеют дополнительные условия на связи и элементы. Каждый слой разбит на два блока, кроме последнего (выходного) слоя: это *тормозящий* и *возбуждающий* блоки. Связи между блоками также разделяются на два вида: тормозящие и возбуждающие. Если от одного блока к другому блоку ведут только возбуждающие связи, то это означает, что любой выходной сигнал блока является монотонной неубывающей функцией любого выходного сигнала первого блока. Если же эти связи только тормозящие, то любой выходной сигнал первого блока является невозрастающей функцией любого выходного сигнала второго блока. Для такого типа нейронных сетей необходима монотонная зависимость выходного сигнала элемента. Такая зависимость является функцией от параметров входных сигналов.

2. *Сети без обратных связей.* В этих нейронных сетях нейроны входного слоя получают входные сигналы. Входной слой преобразует входные сигналы и передаёт их нейронам первого скрытого слоя. После этого срабатывает первый скрытый слой и передаёт сигналы далее, и т.д. до Q -го слоя, который выдает выходные сигналы, для интерпретации их пользователем. Если не оговорено другое, то каждый выходной сигнал i -го слоя подается на вход всех нейронов $(q+1)$ -го слоя, но также существует и другой вариант соединения q -го слоя с произвольным $(q+p)$ -м слоем. На рис. 14.3 показаны сети прямого распространения. Они являются классическим вариантом слоистых сетей.




Рисунок 14.3. Двухслойная сеть прямого распространения без обратных связей

3. *Сети с обратными связями.* В этих сетях данные с последующих слоев передается на предыдущие слои (рис. 14.4). Примерами сетей с обратными связями являются частично-рекуррентные сети Элмана и Жордана.




Рисунок 14.4. Частично-рекуррентные сети: а) Элмана; б) Жордана

На практике, чаще других используются многослойные нейронные сети. По принципу структуры нейрона их можно разделить на два вида: *гомогенные* (однородные) и *гетерогенные*. Очевидно, что в гомогенную нейронную сеть входят нейроны одного типа, с единой функцией активации, а в гетерогенную нейронную сеть – нейроны, обладающие различными функциями активации.

По другой классификации, нейронные сети можно классифицировать на *аналоговые* и *бинарные*. Особенностью бинарных сетей является способность оперировать двоичными сигналами. Вход каждого нейрона принимает только два значения: логическую единицу («возбужденное» состояние) и логический ноль («заторможенное» состояние). Выходы также дают бинарные результаты.

По третьей классификации нейронные сети разделяются на *асинхронные* и *синхронные*. Если рассмотреть асинхронные сети более подробно, то можно увидеть, что в них только один нейрон меняет свое состояние. В синхронной сети состояние изменяется сразу, у всего слоя (у целой группы нейронов). Алгоритмически, ход времени в нейронной сети задается итерационным выполнением однотипных действий над нейроном или группой нейронов.

Существует классификация нейронных сетей по количеству слоёв. Теоретически, число нейронов в каждом слое может быть произвольным, так же, как и число слоёв, однако фактически это число ограничено ресурсами компьютера, на котором реализуется искусственная нейронная сеть.

При создании искусственной нейронной сети сначала нужно выбрать её структуру. Она выбирается в зависимости от сложности и особенности поставленной задачи. Если структура искусственной нейронной сети очень большая и масштабная, то контролировать её работу очень сложно.

Для решения многих типов задач оптимальные конфигурации нейронных сетей уже созданы. В настоящее время специалисты тратят много времени на решение сложной задачи синтеза новой конфигурации сети только в том случае, если задача не может быть сведена ни к одному из известных типов.

Если все же приходится решать задачу синтеза новой конфигурации, то специалистам нужно руководствоваться несколькими основополагающими принципами, среди которых – требование усилить мощность искусственной нейронной сети. Для этого нужно увеличивать *сложность алгоритмов* функционирования ИНС, которая включают в себя введение в нейронные сети нескольких типов синапсов: тормозящих, возбуждающих и других.

Важным принципом является *увеличение возможностей* нейронной сети. Это предполагает добавление большего количества слоёв в многослойной сети, а также числа нейронов в них. Значимым принципом является введение *обратных связей* вместе с увеличением возможностей искусственной нейронной сети, что поднимает вопрос о её динамической устойчивости.

14.1.4. Обучение искусственной нейронной сети для решения задачи идентификации технических каналов утечки информации

Обучение нейронной сети – это процесс настройки её весов (рис. 14.5). При обучении человека происходят аналогичные действия. Основной принцип обучения ИНС: «пусть имеется некоторая база данных, содержащая примеры (например, коэффициенты зависимости защищаемого помещения от выбранных параметров). Алгоритм обучения – это набор формул, который позволяет, по вектору ошибки, вычислить требуемые поправки для весов нейронной сети».




Рисунок 14.5. Процесс обучения нейронной сети

Установлено, что весовые коэффициенты искусственной нейронной сети обладают способностью к стабилизации. После многократного представления примеров, сеть способна предоставить правильные решения для всех примеров из базы данных. Тогда можно утверждать, что «сеть натренирована», «сеть обучена» или «сеть выучила все примеры». Набор примеров должен содержать всю максимально возможную информацию, которую сеть должна знать о задаче. От количества примеров в обучающей выборке и от того, насколько полно эти примеры описывают задачу, зависит качество обучения сети.

Во время обучения искусственной нейронной сети, при её программной реализации, можно наблюдать, что функция ошибки (например, сумма квадратов ошибок для всех выходных значений) со временем уменьшается.

Если функция ошибки достигает приемлемого низкого уровня или близка к нулю, то в этом случае обучение нейронной сети следует остановить. Сама сеть при этом считается обученной и готовой к применению на новых данных.

Один из самых наиболее известных алгоритмов обучения – алгоритм *обратного распространения ошибки*, принцип действия которого показан на рис. 14.6, а, б и в. Он относится к итеративному градиентному алгоритму обучения и используется для минимизации среднеквадратичного отклонения желаемого выхода и текущего выхода многослойных нейронных сетей [263].




Рисунок 14.6. Принцип работы алгоритма обратного распространения ошибки:

- а) движение от первого слоя к последнему; б) движение от последнего слоя к скрытому; в) движение от скрытого слоя к первому

Нейроны в многослойных сетях делятся на группы с общим входным сигналом – слои, при этом на каждый нейрон первого слоя подаются все элементы внешнего входного сигнала. Для обучения многослойных нейронных сетей с последовательными связями используется алгоритм обратного распространения ошибки. Нейроны осуществляют взвешенное суммирование (с синаптическими весами) элементов входных сигналов, и к полученной сумме прибавляется смещение нейрона. Далее, полученный результат умножается на функцию активации нейрона, а затем происходит нелинейное преобразование. Значение функции активации – это выходное значение нейрона.

В многослойных нейронных сетях подходящие выходные значения нейронов всех слоёв, кроме последнего, неизвестны. Трёх- или более многослойный персептрон обучить нет возможности, если руководствоваться только величинами ошибок, расположенных на выходах нейронной сети. Более подходящим вариантом обучения нейронной сети в этих условиях оказался *метод градиентного поиска минимума функции ошибки* с рассмотрением сигналов ошибки от выходов нейронной сети к её входам, в направлении, обратном прямому распространению сигналов в нормальном режиме работы.

В этом алгоритме функция ошибки представляет собой сумму квадратов рассогласования (ошибки) ожидаемого и реального выхода сети. При вычислении элементов вектора–градиента применен особый вид производных функций активации сигмоидального типа. Этот алгоритм функционирует циклически, путём повторяющихся итераций. Циклы этого алгоритма принято называть эпохами. На любой эпохе на вход сети поочередно подаются все обучающие наблюдения, затем выходные значения сети сравниваются с целевыми значениями и вычисляется ошибка. Значение ошибки, а также градиента поверхности ошибок применяется для корректировки весов, после чего все действия повторяются. Начальная конфигурация сети выбирается случайным образом, и процесс обучения останавливается или тогда, когда пройдено определенное количество эпох, или тогда, когда ошибка достигнет некоторого определенного уровня малости, или тогда, когда ошибка перестанет уменьшаться (пользователь сам выбирает условие остановки).

Описание алгоритма состоит из следующих шагов [263]:

Шаг 1. Присвоение весам сети небольших начальных значений.

Шаг 2. Выбор очередной обучающей пары (X, Y) из всего обучающего множества, после чего вектор X подается на вход сети.

Шаг 3. Вычисление выходного результирующего значения ИНС.

Шаг 4. Вычисление разности между требуемым (целевым значением Y) и реальным (вычисленным) выходным результатом нейронной сети.

Шаг 5. Веса нейронной сети корректируются, для минимизации ошибки.

Шаг 6. Шаги, *со второго по пятый*, повторяются в виде итерации для каждой пары обучающего множества, до тех пор, пока ошибка на всём множестве не достигнет приемлемой низкой величины, близкой к нулю.

Шаг 7. Шаги, *второй и третий*, подобны тем вычислениям, которые выполняются в уже обученной искусственной нейронной сети.

Все вычисления в сети выполняются послойно. На *третьем шаге* каждый из выходов сети вычитается из соответствующего компонента целевого вектора, с целью получения ошибки. Эта ошибка используется на *пятом шаге* для коррекции весов сети. *Второй и третий* шаги можно рассматривать как *проход вперед*, так как сигнал распространяется по сети от входа к выходу. *Четвертый и пятый* шаги составляют *обратный проход*, так как здесь вычисляемый сигнал ошибки распространяется обратно по нейронной сети и используется для подстройки и корректирования весов.

14.1.5. Выбор топологии ИНС для создания адаптивного fuzzy-алгоритма идентификации технических каналов утечки информации

По результатам уже рассмотренных топологий искусственной нейронной сети, функций активации и алгоритмов обучения можно выбрать наиболее подходящие из них для решения поставленной исследовательской задачи – разработка адаптивного нейро-нечёткого fuzzy-алгоритма идентификации технических каналов утечки информации. Для реализации проекта выбраны:

1. *Топология* – многослойная искусственная нейронная сеть. Такой выбор обоснован тем, что в многослойной нейронной сети, в отличие от других видов ИНС, есть единый входной сигнал, причём количество нейронов в каждом слое никак заранее не связано с количеством нейронов в других слоях.

2. *Вид сети* – многослойная нейронная сеть без обратной связи. Такой вид сети является классическим видом искусственной нейронной сети, где каждый слой передает следующему слою свои выходные сигналы.

3. *Функция активации* – сигмоидальная. Достоинством использования такой функции активации является тот факт, что производная сигмоиды может быть легко выражена через саму функцию, что позволяет существенно сократить вычислительную сложность метода обратного распространения ошибки, сделав его применимым на практике, а нейрон с сигмоидальной функцией активации, в большинстве случаев, обучается с учителем.

4. *Алгоритм обучения* – алгоритм обратного распространения ошибки. Достоинством использования этого алгоритма для обучения выбранной сети является тот факт, что такой вид обучения часто используется в многослойных нейронных сетях, алгоритм обучения сети проходит с учителем, где на каждой эпохе на вход поочередно подаются все обучающие наблюдения, выходные значения сети сравниваются с целевыми значениями и вычисляется ошибка.

Общая схема искусственной нейронной сети показана на рис. 14.7.




Рисунок 14.7. Общая схема искусственной нейронной сети разрабатываемого проекта

Общая схема работы программы представлена на рис. 14.8.



Рисунок 14.8. Общая схема работы программы

14.2. Реализация программного обеспечения и сравнение работы нейронной сети и подсистемы поддержки принятия решений

14.2.1. Выбор языка программирования и практическая реализация программного обеспечения согласно цели исследования

Для реализации многослойной искусственной нейронной сети можно использовать следующие современные языки программирования:

Julia – разработанный Джеффом Безансоном с коллегами в 2009 году высокоуровневый язык программирования общего назначения. Он разработан для целей вычислительной математики и высокопроизводительного численного анализа, поэтому не включает необходимости отдельной компиляции по скорости. *Julia* имеет простой синтаксис и глубокие математические корни, что делает его дружественным языком программирования для системных аналитиков. Он также включает Flux, основу для машинного обучения и искусственного интеллекта. *Julia* помимо сочетания с математическим синтаксисом, предлагает идеальный способ выражения алгоритмов. Язык поддерживает платформы машинного обучения TensorFlow и MXNet.

Python – широко применяемый язык программирования и может быть использован для реализации искусственного интеллекта из-за бесшовной и простой структуры, которую он предлагает. Легко реализовать различные алгоритмы искусственного интеллекта позволяет синтаксис *Python*, что также позволяет сократить время разработки по сравнению с другими доступными языками программирования. Применение этого языка позволяет пользователям создавать нейронные сети с набором полезных библиотек, которые могут использоваться для разработки искусственного интеллекта. Другие функции включают возможность тестирования алгоритмов без необходимости их реализации. Язык *Python* также поддерживает процедурно-ориентированные, функциональные и объектно-ориентированные стили программирования. *Python* обладает и недостатками: глобальной блокировкой интерпретатора; низким быстродействием; невозможностью модификации встроенных классов.

Java, сегодня наиболее известный язык программирования, также может рассматриваться как хороший выбор для программирования искусственного интеллекта, поскольку он обеспечивает алгоритмы нейронные сети и поиска. *Java* является простым для понимания языком, предлагающим графическое представление, масштабируемость и отладку. Портативность *Java* делает его предпочтительным для реализации интеллектуальных приложений.

Язык *C++* был разработан с учётом требований гибкости, эффективности и производительности, что сделало его оптимальным выбором для многих интеллектуальных проектов, требующих высокоскоростных вычислений. *C++* позволяет широко использовать интеллектуальные алгоритмы и является эффективным средством реализации статистических методов искусственного интеллекта, таких как многослойные искусственные нейронные сети.

К семье языков с *C*-подобным синтаксисом относится язык *C#*. Этот язык программирования имеет перегрузку операторов, в том числе операторов явного и неявного приведения типа, статическую типизацию, обработку событий, атрибуты, поддерживает анонимные функции с поддержкой замыканий, полиморфизм, делегаты, свойства, обобщённые типы и методы, итераторы, LINQ, исключения, комментарии в формате XML. Его синтаксис наиболее близок к *Java* и *C++*. *C#* обладает такой отличительной чертой языка и фреймворка *.NET*, как автоматическая сборка мусора. В большинстве случаев не приходится заботиться об освобождении памяти, в отличие от *C++*.

Для реализации проекта был выбран язык программирования C#. Его преимущества: высокая востребованность (согласно статистике популярности языков программирования, по данным Google Trends, он занимает четвёртое место среди самых используемых языков программирования, рис. 13.29); близость к языкам C++ и Java; поддержка объектно–ориентированного стиля программирования; возможность использования конструкторов форм для реализации интерфейса пользователя; наличие множества открытых библиотек для реализации нейронной сети; а также кроссплатформенность [264].

Программа для расчётов использует искусственную нейронную сеть, состоящую из трех слоёв, представленных ранее на рис. 14.7: входной нейрон, три скрытых нейрона и выходной нейрон. В *первый скрытый нейрон* попадают данные по параметрам, формирующие акустический канал утечки информации. Во *второй скрытый нейрон* подаются данные по параметрам, формирующие оптический канал утечки информации. В *третий скрытый нейрон* передаются данные по параметрам, формирующие радиоэлектронный канал утечки информации. Выходной нейрон – сумма трёх скрытых нейронов. Система активно взаимодействует с базой данных из СУБД Access (рис. 14.9).

```
class ConnectClass
{
    string strConName = @"Provider=Microsoft.ACE.OLEDB.12.0;Data Source=Teach.accdb;Persist Security Info=false";

    public double Connect(string strNameTable, string strParam, string strChannel)
    {
        String connect = strConName;
        string strResult;
        double dblResult;
        try
        {
            OleDbConnection con = new OleDbConnection();
            con.ConnectionString = connect;
            con.Open();
            SetLog("Connect", strParam, "Подключение выполнено успешно!, Класс: ConnectClass");

            string query = "SELECT coefficient FROM " + strNameTable + " WHERE NameData='" + strParam + "' AND Channel='" + strChannel + "'";

            OleDbCommand command = new OleDbCommand(query, con);

            strResult = command.ExecuteScalar().ToString();
            dblResult = Convert.ToDouble(strResult);
            SetLog("Connect", strParam, "Данные по параметру получены успешно и равны:" + strResult);
            con.Close();
        }
        catch { }
    }
}
```

Рисунок 14.9. Функция для получения данных из таблицы СУБД Access

В базе данных, хранящейся в СУБД Access, находятся: коэффициенты синапсов; коэффициенты компонентов помещения, изображённые на рис. 14.10; логирование; данные для обучения нейронной сети.

SourceCoefficient				
id	NameData	Coefficient	Channel	Present
1	Пожарная сигнализация	0,2	Акустический	☐
2	Сетевой коммутатор	0,14	Радиоэлектронный	☐
3	ЭВМ	0,14	Радиоэлектронный	☐
4	Оптоволокно	0,14	Радиоэлектронный	☐
5	Система воздухообмена	0,2	Акустический	☐
6	Телефон	0,14	Радиоэлектронный	☐
7	Розетка	0,14	Радиоэлектронный	☐
8	Охранный сигнализация	0,2	Акустический	☐
9	Звукоусилительная аппаратура	0,14	Радиоэлектронный	☐
10	Звуковоспроизводящая аппаратура	0,14	Радиоэлектронный	☐
11	Трубы водоснабжения	0,2	Акустический	☐
12	Заземление	0,14	Радиоэлектронный	☐
13	Трубы отопления	0,2	Акустический	☐
14	Кирпич (стена)	0,15	Акустический	☒
15	Керамические блоки (стена)	0,2	Акустический	☐
16	Газоблоки (стена)	0,25	Акустический	☐
17	Дерево (стена)	0,3	Акустический	☐
18	Звукопоглощающие материалы (стена)	0,1	Акустический	☐
19	Дерево (потолок/пол)	0,5	Акустический	☒
20	Железобетон (потолок/пол)	0,2	Акустический	☐
21	Металл (потолок/пол)	0,3	Акустический	☐

Рисунок 14.10. Коэффициенты компонентов помещения

Для работы программного средства необходимо обучить искусственную нейронную сеть. Для этого нужно перейти в режим «Настройки» и нажать кнопку «Обучить». кнопка изображена на рис. 14.10.




Рисунок 14.10. Настройка для обучения нейронной сети

Обучение нейронной сети происходит следующим образом [263, 265]:

Этап 1. Рандомно определяется количество компонентов помещения:

$$N = \text{Random}(P) \quad (14.2)$$

где P обозначает количество компонентов помещения; Random – функция, которая случайным образом определяет число из диапазона от 1 до P .

Этап 2. На данном этапе определяется конкретный компонент помещения, который помещается в массив, состоящий из N элементов.

$$\text{mas}(i) = \text{Random}(N), \quad (14.3)$$

где $\text{mas}(i)$ обозначает массив, который содержит компоненты помещения; N показывает общее отобранное число компонентов помещения.

Этап 3. Происходит расчёт коэффициентов по каждому каналу утечки информации, затем находится общий коэффициент. Результаты сравниваются с тестовыми данными, хранящимися в базе данных СУБД Access (рис. 14.11), и выполняется поиск похожих или приблизительных данных. Значения синапсов установлены стандартно по 0.33 для каждого канала утечки информации.

$$K = \text{Sum}(\text{mas}(i)), \quad (14.4)$$

где K обозначает коэффициент информативности, который рассчитывается отдельно для каждого из каналов утечки информации.

$$M = K_1 + K_2 + K_3, \quad (14.5)$$

где M – это общий коэффициент, определяемый суммой всех коэффициентов.

$$K(i) = Kt(i), \quad (14.6)$$

$$M = Mt,$$

где Kt – тестовый коэффициент информативности по техническим каналам утечки информации; Mt – тестовая сумма коэффициентов информативности, общая по всем каналам утечки информации защищаемой организации.

id	Акустический	Оптический	Радиоэлектронный	Выходной	Ц
76	0,23	0,14	0,25	0,62	
77	0,24	0,15	0,24	0,63	
78	0,25	0,16	0,23	0,64	
79	0,26	0,17	0,22	0,65	
80	0,27	0,18	0,21	0,66	
81	0,28	0,19	0,2	0,67	
82	0,29	0,2	0,19	0,68	
83	0,3	0,21	0,18	0,69	
84	0,31	0,22	0,17	0,7	
85	0,32	0,23	0,16	0,71	
86	0,33	0,24	0,15	0,72	
87	0,14	0,25	0,14	0,53	
88	0,13	0,26	0,13	0,52	
89	0,12	0,27	0,12	0,51	
90	0,11	0,28	0,11	0,5	
91	0,1	0,29	0,1	0,49	
92	0,09	0,3	0,09	0,48	
93	0,08	0,31	0,08	0,47	
94	0,07	0,32	0,07	0,46	
95	0,06	0,33	0,06	0,45	
96	0,05	0,05	0,05	0,15	
97	0,04	0,04	0,04	0,12	
98	0,03	0,03	0,03	0,09	
99	0,02	0,02	0,02	0,06	
100	0,01	0,01	0,01	0,03	

Рисунок 14.11. Тестовые данные для обучения

Этап 4. Определение ошибки (разницы между тестовым и рассчитанным коэффициентом) и снижение коэффициента синапсов на разницу определения ошибки. Чтобы определить величину ошибки в процессе обучения, нужно применить классический алгоритм обратного распространения ошибки. Этот алгоритм хорошо работает на двухслойных и трёхслойных нейронных сетях:

$$E_p = \frac{1}{2} \sum_{j=1}^N (t_{pj} - y_{pj})^2, \quad (14.7)$$

где E_p представляет собой величину функции ошибки; t_{pj} – желаемое выходное значение нейрона; y_{pj} – это активированное выходное значение нейрона.

После обучения искусственной нейронной сети можно перейти к работе с программным средством. Первое что необходимо сделать – указать различные данные о местоположении помещения: этаж расположения, расстояние до контролируемой зоны. Эти данные в дальнейшем влияют на нахождение акустических и оптических каналов утечки информации (АКУИ и ОКУИ). Форма для ввода данных изображена на рис. 14.12.

Рисунок 14.12. Параметры местоположения помещения

Далее, выбираем компоненты помещения из списка (рис. 14.13).

Рисунок 14.13. Основные компоненты помещения

Некоторые внутренние компоненты помещений невозможно описать без использования нечёткой логики, например, у окна указываются его размеры. Работа программы с нечёткими данными изображена на рис. 14.14.

```
LinguisticVariable height = new LinguisticVariable("Height");
var big = height.MembershipFunctions.AddTrapezoid("big", 1169, 1320, 1470, 1469);
var medium = height.MembershipFunctions.AddTrapezoid("medium", 869, 870, 1170, 1170);
var little = height.MembershipFunctions.AddTrapezoid("little", 469, 570, 870, 870);

LinguisticVariable width = new LinguisticVariable("Width");
var Big = width.MembershipFunctions.AddTrapezoid("Big", 1319, 1470, 1770, 2069);
var Medium = width.MembershipFunctions.AddTrapezoid("Medium", 969, 1170, 1170, 1320);
var Little = width.MembershipFunctions.AddTrapezoid("Little", 469, 570, 870, 970);

LinguisticVariable glassunit = new LinguisticVariable("Glassunit");
var Bigs = glassunit.MembershipFunctions.AddTrapezoid("Big", 3, 4, 5, 6);
var Mediums = glassunit.MembershipFunctions.AddTrapezoid("Medium", 1, 3, 3, 4);
var Littles = glassunit.MembershipFunctions.AddTrapezoid("Little", 0, 1, 2, 2);

LinguisticVariable mode = new LinguisticVariable("Leak");
var BIG = mode.MembershipFunctions.AddRectangle("BIG", optic1/4, optic1/2);
var MEDIUM = mode.MembershipFunctions.AddRectangle("MEDIUM", optic1/7, optic1/4);
var LITTLE = mode.MembershipFunctions.AddRectangle("LITTLE", 0, optic1/7);

IFuzzyEngine fuzzy = new FuzzyEngineFactory().Default();
var res1 = Rule.If(height.Is(big).And(width.Is(Big)).And(glassunit.Is(Bigs))).Then(mode.Is(LITTLE));
var res2 = Rule.If(height.Is(big).And(width.Is(Big)).And(glassunit.Is(Mediums))).Then(mode.Is(MEDIUM));
var res3 = Rule.If(height.Is(big).And(width.Is(Big)).And(glassunit.Is(Littles))).Then(mode.Is(BIG));
var res4 = Rule.If(height.Is(big).And(width.Is(Medium)).And(glassunit.Is(Bigs))).Then(mode.Is(LITTLE));
```

Рисунок 14.14. Алгоритм преобразования нечёткой логики в точный коэффициент

Для понимания работы алгоритма и обучения нейронной сети, следует рассмотреть преобразования, выполняющиеся в программе для расчёта параметра «Окно». При обучении выполняются действия, показанные на рис. 14.15.




Рисунок 14.15. Процесс обучения на примере параметра «Окно»

Рассмотрим каждый переход подробно:

Шаг 1. входной нейрон обозначен номером 1, в который поступают входные коэффициенты $coef_1$ и $coef_2$. Поступление на вход двух коэффициентов обусловлено тем, что параметр «Окно» может относиться как к акустическому, так и к оптическому каналу утечки информации.

Шаг 2. Веса синапсов обозначены как $Weight_1$, $Weight_2$, $Weight_3$ и $Weight_4$. Это веса, заданные по умолчанию, и имеющие значения 0.33, сформированные для акустического и оптического канала утечки информации.

Шаг 3. При переходе от входного нейрона на скрытый нейрон созданной искусственной нейронной сети, расчёт происходит по формуле:

$$Coef_3 = Coef_1 * Weight_1, \quad (14.8)$$

где $Coef_3$ – коэффициент, который поступает на вход скрытого нейрона; $Coef_1$ – коэффициент для параметра «Окно», относящегося к оптическому каналу утечки информации; $Weight_1$ – вес синапса. Подобные расчёты производятся и для акустического канала утечки информации.

Шаг 4. При поступлении коэффициента на вход скрытого нейрона, он проходит через функцию активации «Сигмоид». Расчёты идут по формуле:

$$Coef_3 = \frac{1}{1 + e^{-Coef_3}}, \quad (14.9)$$

где $Coef_3$ – коэффициент, прошедший через функцию активации «Сигмоид» в скрытом нейроне созданной искусственной нейронной сети.

Шаг 5. После получения всех коэффициентов, связанных со всеми остальными параметрами (не только «Окно»), происходит суммирование коэффициентов по всему каналу утечки информации, по следующей формуле:

$$Coef_3 = Sum(Coef_3), \quad (14.10)$$

где $Sum(Coef_3)$ – сумма всех полученных коэффициентов по каналу утечки.

Шаг 6. Далее полученный коэффициент из скрытого нейрона передается на выходной нейрон (номер 5), при переходе расчёт идет по формуле:

$$Total_Weight_1 = Coef_3 * Weight_3, \quad (14.11)$$

где $Total_Weight_1$ – коэффициент, поступающий на вход выходного нейрона; $Coef_3$ – выходной коэффициент скрытого нейрона; $Weight_3$ – вес синапса.

Шаг 7. При поступлении коэффициента на вход выходного нейрона, он проходит через функцию активации «Сигмоид». Расчёт производится так:

$$Total_Weight_1 = \frac{1}{1 + e^{-Total_Weight_1}}, \quad (14.12)$$

где $Total_Weight_1$ – выходной коэффициент скрытого нейрона, прошедший через функцию активации «Сигмоид», в выходном нейроне.

Шаг 8. После получения всех коэффициентов, идёт суммирование коэффициентов по всем существующим каналам утечки информации.

Шаг 9. Далее проводится сравнение полученных результатов с тестовыми данными (параметры 6 и 7 на рис.14.15). Если полученный результат имеет значительные отличия от коэффициента тестовых данных, то от пункта 6 следует вернуться к пункту 1, меняя при этом веса синапсов только для тех нейронов, которые дали ошибку при сравнении с тестовыми данными. Веса изменяются по формуле (14.7). Если полученный результат приближенно равен тестовым данным, то следует возвратиться к пункту 8, рис. 14.15 и записать результат весов синапса созданной искусственной нейронной сети.

Закончив обучение нейронной сети, можно запустить работу программного средства. После выбора компонента «Окно» и указания параметров окна, показанных на рис. 14.16, параметр преобразуется из нечёткости в конкретный коэффициент, который поступает на входной нейрон. Этот процесс показан на рис. 14.17, откуда коэффициент сразу переходит в один из скрытых нейронов.

Рисунок 14.16. Параметры окон, влияющие на оптический канал утечки информации

```
public void inputNeuron1 (double dblInput, string NameParam, bool blnAkustic = false, bool blnOptic = false, bool blnRadio = false)
{
    ConnectClass con = new ConnectClass();
    double dblKcoeff = 0, dblOutput=0;
    string strParam="";

    if(blnAkustic==true)
    {
        strParam = "Акустический";
    }
    if(blnOptic==true)
    {
        strParam = "Оптический";
    }
    if(blnRadio==true)
    {
        strParam = "Радиоэлектронный";
    }
    dblKcoeff= con.GetCoefficientSinaps("ChannelCoefficient", strParam, "1");
    dblOutput = dblInput * dblKcoeff;
    dblOutput = ActiveFunction(dblOutput);

    InNeuronInput(dblOutput, blnAkustic, blnOptic, blnRadio);
}
```

Рис. 14.17. Программный код алгоритма работы входного нейрона

При переходе из входного нейрона в скрытый нейрон, значение параметра проходит через функцию активации «Сигмоид». В графическом виде, и в виде программного кода она изображена на рис. 14.18 и 14.19. Такая функция активации выбрана потому, что производная у традиционной сигмоидной функции активации всегда меньше единицы, на всей области определения. Поэтому, после нескольких циклов обучения, ошибка станет близкой к нулю.

```
public double ActiveFunction (double dblSum)
{
    dblActive = (1 / (1 + Math.Exp(-dblSum)));
    return dblActive;
}
```

Рисунок 14.18. Функция активации «Сигмоид»




Рисунок 14.19. График функции активации «Сигмоид»

После всех проведенных расчётов, можно получить величину общего коэффициента, включающего коэффициенты по каждому из каналов утечки информации, и количество каналов утечки информации, присутствующих в исследуемом помещении, которые изображены на рис. 14.20.

Скриншот завершающей формы программы. Вверху заголовок «Завершение». Основной текст: «Количество каналов утечки: 3 из 3». Ниже: «Выберите каналы для проведения первичных исследований». Список каналов с коэффициентами:

- ☐ Акустический канал 0,31
- ☐ Оптический канал 0,2838
- ☒ Радиоэлектронный канал 0,1716

 Кнопка «Провести расчеты(рекомендуется)». Внизу: «Общий коэффициент возможной утечки информации: 0,7654 [Выше среднего]». Три кнопки: «Назад», «Логин», «Завершить».

Рисунок 14.20. Завершающая форма

Схема преобразований параметра «Окна» при расчётах оптического канала утечки информации разработанной программы изображена на рис. 14.21.




Рисунок 14.21. Схема преобразований параметра «Окно» при работе программы

Для выявления ошибок во время работы программы в нейронной сети проводится *логирование*. Общая схема работы НС показана на рис. 14.22.




Рисунок 14.22. Общая схема нейро–нечёткой fuzzy–системы идентификации технических каналов утечки информации

На рисунке 14.22 можно увидеть два варианта расчёта идентификации технических канала утечки информации: в виде подсистемы поддержки принятия решений; в виде адаптивного нейро–нечёткого fuzzy–алгоритма.

После всех проведенных расчётов, пользователь увидит данные по каждому выявленному каналу утечки информации и получит общий коэффициент. Программное средство запишет в отдельный файл и предоставит пользователю рекомендации по защите данных от утечки информации по каждому выявленному в результате проверки техническому каналу. Можно будет ознакомиться с данным файлом, форма которого изображена на рис. 14.23.




Рисунок 14.23. Форма работы с документом

14.2.2. Обработка ошибок и итоги работы программы нейронной сети

Обработка ошибок является важной составляющей любой при разработке новых программных средств. Бывают случаи, когда дальнейшие вычисления программы, в соответствии с базовым алгоритмом, просто бессмысленны или невозможны. Такая ситуация может возникнуть по многим причинам, в том числе – из-за устройств ввода–вывода, состояния системы или внешних данных.

Одной из причин, делающих вычисления бессмысленными, является нехватка доступной памяти. Если в компьютере не хватает свободной памяти, то программа не сможет функционировать нормально. Это означает, что в какой-то момент времени операционная система будет не в состоянии выделить нужный для прикладной программы объём оперативной памяти.

Одной из часто встречающихся причин является целочисленное деление на ноль. Поэтому попытка дальнейшего использования результатов деления невозможна, и дальнейшие вычисления не приведут к решению задачи.

Еще одной из распространённых причин возникновения ситуации, когда дальнейшие вычисления в соответствии с базовым алгоритмом становятся бессмысленными или невозможными, является ошибка, которая возникает при попытке считать какие-либо данные с внешнего устройства.

Это может случиться из-за повреждения внешнего устройства. В случае, если данные с внешнего устройства получить не удастся, то любые дальнейшие вычисления, в соответствии с базовым алгоритмом, становятся бессмысленными.

При работе программы могут возникнуть исключительные ситуации. Они являются механизмом обработки ошибок, пришедшим на смену возврату кода ошибки функциями. На практике встречаются такие типы исключений, которые могут быть отнесены как к асинхронным, так и к синхронным [265].

К первому типу относятся *асинхронные* исключения, которые не зависят от того, какую инструкцию программы конкретно выполняет вычислительная система. Поступление новых данных или аварийный отказ питания – это одни из часто встречающихся асинхронных исключений [266].

Ко второму типу относятся типичные *синхронные* исключения. Они вызваны нехваткой памяти компьютера, ошибкой чтения файла или коммуникационного канала. Исходя из этого, они появляются только в операции выделения памяти, или в операции чтения–записи.

Исходя из сказанного выше, синхронные исключения могут появиться в определённых и заранее известных точках программы, тогда как асинхронные исключения могут возникнуть в любой момент времени.

В подобных случаях, главным и единственным обработчиком исключений становится операционная система. Так, в ОС Windows встроена утилита «Dr. Watson», которая занимается сбором информации о необработанном исключении, и её отправкой на специальный сервер компании Microsoft. В том случае, если в программном обеспечении отсутствует собственный механизм обработки исключений, то для программ – общей реакцией на любую исключительную ситуацию будет немедленное прекращение её выполнения и выдача пользователю информации о характере исключения.

Обработка ошибок представляет собой процесс обнаружения и перехвата ошибок, вызванных работой программы, а затем – принятия соответствующих мер для их устранения. Сама работающая программа также может обрабатывать исключительные ситуации. При возникновении такой ситуации, управление переходит к определенному, заранее известному обработчику – функции, процедуре или блоку кода, которые будут осуществлять необходимые действия.

Существует два механизма функционирования обработчиков исключений. Это обнаружение, перехват и обработка ошибок с возвратом, и без возврата.

При обработке ошибок *с возвратом* предполагается, что обработчик исключения ликвидирует образовавшуюся ошибку и приведет программу в такое состояние, когда она способна работать дальше, по своему основному алгоритму. При такой обработке, после того, как выполнится код обработчика, работа программы переходит обратно в ту точку, где возникла исключительная ситуация, или на команду, вызвавшую исключение, или на следующую за ней, как это было в некоторых старых диалектах языка BASIC. После этого работа программы продолжится в обычном режиме. Для обработчиков *асинхронных* исключений характерна обработка *с возвратом*. Для обработки *синхронных* исключений она непригодна, и нужно проводить обработку *без возврата*.

После выполнения кода обработчика исключения, управление переходит в определенное, заранее заданное место программы, и с него продолжается исполнение – это происходит при обработке без возврата. То есть, фактически, при возникновении исключения, команда, во время работы которой оно возникло, заменяется на безусловный переход к заданному оператору.

Такие языки программирования как C++, Java, Objective-C, Delphi, JavaScript, Ada, Eiffel, D, Python, Common Lisp, OCaml, все языки платформы .NET, Ruby, PHP, SML, и др., имеют встроенную поддержку структурной обработки исключений. При возникновении исключения, поддерживаемого языком, происходит раскрутка стека вызовов до первого обработчика исключений подходящего типа, и управление передаётся обработчику.

В программе используется обработчик исключений (ошибок) с названием «*try...catch...finally*» [267]. При использовании этого блока «*try...catch...finally*» вначале выполняются все инструкции в блоке «*try*». Если в этом блоке не возникло исключений, то после его выполнения начинает выполняться блок «*finally*». И затем конструкция «*try...catch...finally*» завершает свою работу.

В случае, если в блоке «*try*» возникнет исключение, порядок выполнения остановится, и среда CLR начнёт искать блок «*catch*», который сможет обработать возникшее исключение. Если необходимый блок «*catch*» найден, то он будет выполняться, а после его завершения выполнится блок «*finally*». Если нужный блок «*catch*» не найден, то при возникновении исключения программа завершит своё выполнение аварийно [268]. Примеры использования обработок исключений (ошибок) в программе показаны на рис. 14.24 и 14.25.

```

public OleDbConnection ConnectDb()
{
    OleDbConnection con = new OleDbConnection();
    try
    {
        if (con != null)
        {
            con.Close();
        }
        con.ConnectionString = strConName;
        con.Open();
    }
    catch (Exception ex)
    {
        Console.WriteLine(" \n Ошибка " + ex.Message + "\n Метод:" + ex.TargetSite);
    }
    return con;
}

```

Рисунок 14.24. Обработчик ошибок при подключении к базе данных

```

public void SetLog(string strFunction, string strParam, string strText)
{
    String connect = strConName;
    try
    {
        OleDbConnection con = new OleDbConnection();
        OleDbCommand cmd = new OleDbCommand();
        cmd.CommandType = CommandType.Text;
        con.ConnectionString = connect;
        cmd.Connection = con;
        con.Open();
        string strInsert = "INSERT INTO tblLog(DateLog,Function,Param,TextLog) VALUES(now, '" + strFunction + "', '" + strParam + "'";
        cmd.CommandText = strInsert;
        cmd.ExecuteNonQuery();
        con.Close();
    }
    catch (Exception ex)
    {
        Console.WriteLine(" \n Ошибка " + ex.Message + "\n Метод:" + ex.TargetSite);
    }
}

```

Рисунок 14.25. Обработка ошибок при записи логирования

При возникновении ошибки программа не прекратит свою работу, а все возникшие ошибки записывает в таблицу логирования, из которой понятно, какой параметр в какой функции привел к ошибке, рис. 14.26.

tblLog					
id	DateLog	Function	Param	TextLog	
1166	08.02.2020 23:00:09	UpdateSinapsAccess	All	Данные обновлены	
1177	08.02.2020 23:00:09	UpdateSinapsAccess	All	Подключение выполнено успешно! Класс ConnectClass	
1150	08.02.2020 22:59:53	UpdateSinapsAccess	All	Данные обновлены	
1149	08.02.2020 22:59:51	UpdateSinapsAccess	All	Подключение выполнено успешно! Класс ConnectClass	
1148	08.02.2020 22:58:54	TeachProgramm	teach	Ошибка В позиции 0 строка отсутствует.Метод:NodePath GetNodeByIndex(Int3	
1147	08.02.2020 22:58:54	ConnectTeach	teach	Подключение выполнено успешно!, Класс: ConnectClass	
1146	08.02.2020 22:58:53	TeachProgramm	teach	Обучение прошло успешно, класс: ConnectClass	
1145	08.02.2020 22:58:53	ConnectTeach	teach	Подключение выполнено успешно!, Класс: ConnectClass	
1144	08.02.2020 22:58:53	TeachProgramm	teach	Обучение прошло успешно, класс: ConnectClass	
1143	08.02.2020 22:58:53	ConnectTeach	teach	Подключение выполнено успешно!, Класс: ConnectClass	
1142	08.02.2020 22:58:53	TeachProgramm	teach	Подключение выполнено успешно!, Класс: teach	
1141	08.02.2020 22:57:04	UpdateStart	All	Данные для старта обновлены	
1140	08.02.2020 22:57:04	UpdateStart	All	Подключение выполнено успешно! Класс ConnectClass	
1139	08.02.2020 22:57:04	UpdateStart	Start	-----	

Рисунок 14.26. Таблица логирования

14.3. Достоинства и недостатки подсистемы поддержки принятия решений в сравнении с нейро–нечёткой сетью

Так как программное средство, помимо нейро–нечёткой Fuzzy–системы, использует *подсистему поддержки принятия решений*, описанную ранее, (в 13 главе), то можно сравнить, использование какой системы будет более эффективно для решения поставленной цели исследования идентификации технических каналов утечки информации защищаемой организации [269].

Для начала нужно привести определения и перечислить основные характеристики подсистемы поддержки принятия решений [270]:

Подсистема поддержки принятия решений – это:

- помогающая руководителю организации в принятии ответственных решений совокупность суждений и процедур обработки данных, основанная на использовании моделей прогнозирования развития событий [271];
- интерактивная автоматизированная система, оказывающая помощь лицу, принимающему ответственные решения, в использовании прогностических моделей и данных для решения слабоструктурированных задач [272];
- система, обеспечивающая пользователям доступ к данным и / или моделям, так, что пользователи могут принимать более обоснованные решения» [273].

Дать точную формулировку общепринятому определению подсистемы поддержки принятия решений довольно трудно. Это вызвано тем, что её конструкция существенно зависит от вида задач, для решения которых она разрабатывается, возможностей программного обеспечения и видов данных.

Подсистема поддержки принятия решений обладает четырьмя признаками: использует как модели, так и данные; предназначена для помощи в принятии решений для неструктурированных и слабоструктурированных задач [274]; поддерживает, но не заменяет принятие решения ответственным лицом; повышает эффективность принимаемых решений, что является её целью.

Подсистема поддержки принятия решений: предназначена для лиц, которые принимают решения различных уровней. Она может быть адаптирована как для индивидуального, так и для группового использования [275]; оперирует слабоструктурированными задачами; является гибкой и может быть легко приспособлена к изменениям как внутренней среды организации, так и её окружения. Кроме того, такая система удобна в модификации и использовании; поддерживает как последовательные, так и взаимозависимые решения [276].

Такая система поддерживает три фазы процесса решения: выбор, интеллектуальную часть и проектирование; обладает различными методами решения, что повышает качество процесса принятия решений и может быть полезно при решении задачи коллективом, принимающим общее решение. Человек может самостоятельно управлять процессом принятия решений с помощью компьютера, а не наоборот. Система адаптируется к изменяющимся требованиям и поддерживает принцип эволюционного развития; может быть легко смоделирована, если определена логика её конструкции; поддерживает процесс моделирования и позволяет применять полученные знания [274].

Подсистема поддержки принятия решений состоит из двух основных подсистем – информационной системы и лица, принимающего решения [275]. Функция человека, который принимает решение, как компонента подсистемы поддержки принятия решений, состоит в вводе исходных данных и принятии ответственного решения, на основе своих знаний и интуиции [276].

Структура подсистемы поддержки принятия решений идентификации технических каналов утечки информации подробно описана в п. 13.3.2.

Одним из ключевых преимуществ искусственной нейронной сети считается обучаемость. Появление новых данных в традиционных алгоритмах вызывает потребность в их пересчёте, что не свойственно нейронным сетям. Они адаптируются к различным изменениям, и каждый раз применяют новую информацию для поиска решения с помощью системы обучения [271].

Обучение нейронной сети носит итерационный характер. Любой шаг обучения называют эпохой или циклом. Во время одного цикла проводится расчёт синаптических коэффициентов, которые признают за основу уже имеющиеся примеры, из обучающей выборки. Различные данные, имеющие собственные значения и обладающие выходными параметрами, которые хотелось бы получить в результате, входят в структуру обучающей выборки.

Достоинства нейронных систем включают обучаемость; универсальность; высокое быстродействие; простоту применения, отказоустойчивость.

Под универсальностью подразумевается то, что нейронные сети, являются мощным и гибким инструментом, способным решить широкий круг задач обработки и анализа данных, таких как: классификация, распознавание образов, идентификация изображений, перевод, автоматизация управления процессами, прогнозирование финансовых рынков и многое другое.

Под быстродействием нейронной сети предполагается, что входные данные должны преобразоваться в распределенную сеть параллельных вычислений, и подаваться на выход нейронов. Сверхбыстродействие нейронной сети гарантируется именно благодаря системе параллельной обработки данных.

Простота использования нейронной сети состоит в том, что она обучается на подготовленных специалистами примерах. Подборка определенного набора входных параметров и запуск алгоритма обучения в сети, который преобразует полученные данные в особую структуру, является основной деятельностью специалиста, и именно от него требуются знания о том, какие данные необходимы для обучения, в каком количестве и виде, как их настроить для передачи в нейронную сеть, и как, в итоге, объяснить полученные результаты.

Коэффициент полезного действия нейронной сети, выполненный на аппаратном уровне, при не очень хороших условиях, может упасть лишь незначительно, благодаря тому, что она обладает отказоустойчивостью.

Если существует отдельный элемент сети, у которого нарушена или повреждена связь с другими элементами, то это может затруднить процесс извлечения информации из элемента. Однако, в силу распределенного характера хранения информации в нейронной сети, сильно снизить работоспособность системы можно только при серьёзном повреждении её структуры.

В случае, если для анализа были взяты какие-либо лишние параметры, которые не имеют отношения к решению поставленной задачи, то нейронная сеть может самостоятельно отфильтровать ненужные данные. нейронные сети обладают высокой устойчивостью к *шумам* во входных данных.

Сравнив реализацию одной и той же задачи в виде подсистемы поддержки принятия решений, и в виде нейронной сети, можно утверждать следующее:

- нейронная сеть более изменчива, чем подсистема поддержки принятий решений, так как веса синапсов можно изменять, изменяя тестовые данные;
- для реализации нейронной сети требуется меньше программного кода, чем для реализации подсистемы поддержки принятия решений;
- результаты, которые выводит нейронная сеть, более обоснованы и точны, чем результаты подсистемы поддержки принятия решений;
- для решаемой задачи: все коэффициенты параметров помещения для подсистемы поддержки принятия решений расположены в программном коде, а для нейронной сети – в базе данных, что позволяет править коэффициенты более удобно, без использования программного кода.

Из сказанного выше можно сделать вывод, что наличие в программе нейронной сети позволило улучшить результат. Однако можно утверждать, что нейронные сети не могут быть рассмотрены как универсальное средство решения всех интеллектуальных задач: Их применение оправдано в тех областях, в которых существует значительное число однотипных примеров, отражающих скрытые взаимосвязи, на которых обучается нейронная сеть.

Таким образом, при реализации поставленной исследовательской задачи был проведён анализ совокупности технических каналов утечки информации в защищаемой организации, и приведена их подробная классификация.

Выяснено, что основными техническими каналами утечки информации в организации являются: акустический, оптический, радиоэлектронный и материально–вещественный каналы утечки информации [277].

На основе установленных технических каналов утечки информации построена система их идентификации, использующая адаптивную сеть на основе системы нечёткого вывода, для оценки информативности признаковой структуры защищаемого объекта, что, с одной стороны, позволяет учитывать нечёткость и неопределённость входных данных, а с другой стороны делает возможным подстраивать и адаптировать систему для построения более точных предположений с помощью обучения нейронной сети [278].

С помощью разработанного программного средства можно провести оценку информативности технических каналов утечки информации, оценить возможности наиболее информативного из технических каналов утечки информации, и получить рекомендации по снижению его информативности.

Можно провести первичные исследования информативности технических каналов в случае присутствия акустического, оптического, радиоэлектронного или материально–вещественного канала утечки информации [279].

Реализованное программное средство позволяет специалистам в области информационной безопасности и защиты данных оперативно сформировать список существующих в исследуемом помещении организации технических каналов утечки информации, получить подробный отчёт и рекомендации по их предотвращению. Это может значительно ускорить предварительное обследование объекта информатизации и предотвратить утечку данных, которую мог бы использовать противник или злоумышленник [280, 281].

15. ИНТЕЛЛЕКТУАЛЬНЫЙ АНАЛИЗ ДАННЫХ С УЧЁТОМ СВОЙСТВ ДИНАМИЧЕСКИХ ПРОЦЕССОВ. РАЗРАБОТКА АЛГОРИТМА ОЦЕНКИ ПАРАМЕТРОВ ДВИЖЕНИЯ В ЗАДАЧАХ СОПРОВОЖДЕНИЯ

В современном мире стремительно развивается процесс накопления данных, полученных в электронном виде, от текстов и изображений, видео и аудио до всевозможных баз данных, применяющихся в различных областях деятельности современного общества. При этом огромная, если не большая часть информации остаётся недоступной для отдельного пользователя, так как человек не может переработать такое количество данных. В связи с этим встаёт проблема извлечения нужной пользователю информации из большого объёма данных.

Справиться с этой проблемой может *интеллектуальный анализ данных* – процесс нахождения и извлечения нужных сведений в масштабных наборах данных. Для выявления закономерностей и тенденций, присутствующих в них, используется математический анализ. Если собрать воедино закономерности и тренды, то они и составят искомую математическую модель анализа данных.

Технологии интеллектуального анализа данных представляют собой одно из стремительно развивающихся направлений информационных технологий, предназначенных для нахождения нужных сведений из различных баз данных.

Актуальность данной проблемы особо ощущается, например, в задачах навигации и сопровождения беспилотных летательных аппаратов (БПЛА), а также в ситуациях, возникающих при контроле радиоэлектронной обстановки, задач разделения цифровых потоков и т.д. Это связано с тем, что научно-технический прогресс в сфере, связанной с летательными аппаратами и другими объектами, обладающими возможностью манёвра, постоянно движется вперёд и совершенствуется. Поэтому на сегодняшний день так актуальны разработки, которые решают задачу разрешения неопределённости траектории движения объектов, при отсутствии точной модели динамики цели [282].

Исследования на эту тему, освещающие те или иные аспекты этой задачи, за последнее время, периодически появляются в печати. Среди них необходимо особо отметить те, которые посвящены построению фильтров сопровождения. В таких условиях особую значимость и актуальность приобретают проблемы построения математических моделей движения маневрирующих целей [283] как системообразующих элементов проектирования эффективных систем различного назначения. Синтез современных цифровых систем требует построения дискретных моделей экстраполяторов движения.

Необходимость решения задач с помощью методов интеллектуального анализа возникает всё чаще, поэтому они приобретают такое важное значение. Эти методы могут применяться в различных областях деятельности человека, например, для прогнозирования рыночных показателей, в банковской сфере, товарообороте различного назначения и т.д. С помощью этих же методов становится возможным описать этапы изменения в химическом производстве, и даже делать прогнозы по отказам оборудования различного назначения. Существует и множество других областей их применения. Особо стоит отметить их применение при обработке больших данных (Big Data). Так, тема исследования является актуальной и востребованной во многих областях.

Научная новизна заключается в применении нового подхода к синтезу экстраполяторов для широкого класса объектов, движение которых подчинено вариационному принципу Гамильтона – Остроградского.

Объект исследования – алгоритмы оценки параметров движения. *Предмет исследования* – математические методы оценки параметров динамических процессов. *Целью работы* является разработка алгоритма оценки параметров движения в задачах сопровождения, обеспечивающего повышение точности и снижение затрат на его реализацию. Для этого нужно решить *следующие задачи*:

- провести анализ существующих методов и моделей динамической оценки данных и разработанных на их основе алгоритмов оценки параметров движения;
- привести математическое обоснование процесса синтеза алгоритмов на основе объединенного принципа максимума Понтрягина;
- разработать динамический экстраполятор функций в форме, пригодной для реализации в современных системах контроля радиоэлектронной обстановки;
- выполнить анализ эффективности функционирования предлагаемого алгоритма на основе числового моделирования.

15.1. Анализ методов и моделей динамической оценки данных

15.1.1. Построение модели интеллектуального анализа данных

Модель интеллектуального анализа данных создается путём применения алгоритма к данным, однако она представляет собой нечто большее, чем просто контейнер алгоритма и метаданных. Она является набором данных, статистики и закономерностей, который может применяться к существующим, новым или будущим данным, для формирования прогнозов и вывода взаимосвязей [284].

Модель получает данные из структуры интеллектуального анализа данных и обрабатывает их, применяя алгоритм анализа. При этом, структура и модель интеллектуального анализа являются отдельными объектами [284].

В структуре интеллектуального анализа данных хранятся сведения, определяющие их источник. Модель содержит сведения, полученные по итогам статистической обработки данных – закономерности, обнаруженные в результате анализа. Модель интеллектуального анализа данных не будет наполнена до тех пор, пока не будут обработаны и проанализированы все данные, переданные структурой. После обработки модель будет содержать метаданные, результаты, и их привязки к структуре интеллектуального анализа данных. Одни и те же данные можно использовать для создания нескольких моделей, которые могут использовать либо алгоритм кластеризации, либо алгоритм дерева принятия решений, либо какой-то другой алгоритм. В каждом из типов моделей создаются различные наборы шаблонов, наборов элементов, формул и правил, которые могут применяться при прогнозировании.

Каждый из алгоритмов анализирует данные своими методами, поэтому содержимое получаемой модели также организуется в различные структуры. В одном из типов моделей данные и шаблоны могут группироваться в кластеры, а в модели другого типа данные могут быть упорядочены с помощью деревьев, ветвей и правил, разделяющих и определяющих данные.

Модель также зависит от данных, на которых проводилось ее обучение: даже те модели, обучение которых производилось на одной и той же структуре интеллектуального анализа данных, могут выдавать различные результаты, если во время анализа фильтрация данных выполнялась по-разному, или использовались различные начальные значения. Но фактические данные не хранятся в модели: она содержит только сводную статистическую информацию, а настоящие данные находятся в структуре интеллектуального анализа данных. Если при обучении модели были созданы фильтры данных, то определения фильтров также сохраняются в объекте модели [285].

Модель интеллектуального анализа данных до обработки представляет собой пустой объект. Во время обработки модели, данные передаются через фильтр, если он был определен в модели, и анализируются в соответствии с заданным алгоритмом. Алгоритм вычисляет набор сводных статистических показателей, описывающих данные, выявляет заложенные в них правила и закономерности, а затем, на их основе, производит заполнение модели.

После обработки, модель интеллектуального анализа данных содержит нужные сведения о данных и обнаруженных при анализе закономерностях, включая статистические показатели, правила и формулы такой регрессии. Просмотреть эти сведения можно с помощью пользовательских средств просмотра или создав запросы интеллектуального анализа данных, которые будут извлекать эти сведения и использовать их для анализа и представления.

В работе [284] целиком рассматривается весь процесс, в который входят задачи, от формулировки вопроса до развертывания модели в рабочей среде. Так, построение модели интеллектуального анализа данных – это элемент более глобального процесса, состоящего из нескольких этапов. Эти этапы и взаимосвязи между всеми шагами процесса представлены на рис. 15.1.




Рисунок 15.1. Построение модели интеллектуального анализа

Создание аналитической модели данных представляет собой мобильный и повторяющийся процесс. Может оказаться, что уже построенные модели не дают нужный ответ на поставленную задачу, и в этом случае потребуются переформулировать задачу. Иногда требуется обновлять уже построенные модели, так как поступают новые данные. Так, для создания лучшей модели иногда нужно многократно повторить каждый из перечисленных шагов.

15.1.2. Основные методы интеллектуального анализа данных

Разработка данных и установление связей между ними представляет собой общность большого числа различных методов обнаружения знаний. Их можно условно разбить на ряд следующих методов: классификация, кластеризация, последовательные модели и деревья решений.

Ассоциация (отношение) является наиболее известным и простым методом [285]. Согласно ему, чтобы построить модель, необходимо провести сравнение пары, но иногда и большего числа однотипных элементов. Например, в магазинах стараются отследить сопутствующие товары, и поместить их рядом.

На основе ассоциаций можно создать инструменты для обработки данных на компьютере. Образец такого информационного потока, например, созданного в InfoSphere Warehouse, продемонстрирован на рис. 15.2.




Рисунок 15.2. Информационный поток, используемый в методе ассоциации

Если нужно получить сведения о типе исследуемых данных, для чего применяются несколько параметров, на основе которых делается вывод о принадлежности к той или иной группе, то применяется метод *классификации*. Часто её применяют в качестве входных данных для других методов.

Для выявления кластеров используются похожие параметры разных классификаций. Такой метод является *кластеризацией*. Если изучить несколько классов, то их можно объединить в общий кластер, что бывает очень полезно при работе с информацией различной природы. Кластеризацию можно применять и в обратном направлении, для чего нужно, используя входные данные, установить на их основе различные взаимосвязи.

Например, на рис. 15.3 изображён график, на котором возраст покупателя сравнивается со стоимостью покупки. На графике отчётливо выражена пара кластеров: первый кластер находится в возрастной группе от двадцати до тридцати лет, второй – в группе, относящейся к от пятидесяти до шестидесяти лет. Такое построение – один из примеров образа *ближайшего соседа* [285].




Рисунок 15.3. Процесс кластеризации

Среди всех рассматриваемых методов самым широким диапазоном применения отличается *прогнозирование*. В сочетании с другими методами интеллектуального анализа данных, прогнозирование предполагает анализ тенденций, классификацию, сопоставление с моделью и отношения. Проводя анализ прошлых событий или образцов, можно предсказывать будущее.

Ещё один полезный метод для нахождения повторяющихся событий, или установления связей между ними, – это *последовательные модели*. Чаще всего их применяют для долгосрочного анализа. Например, используя данные о покупателях, можно предположить, в какое время дня, месяца или года, и какие именно наименования товаров будут наиболее востребованными.

Интересен метод, называемый «*деревом решений*», обычно используемый в совокупности с другими методами – *классификацией* и *прогнозированием*, где всевозможные мониторинги данных имеют все шансы основываться на предыдущем эксперименте. Пример дерева решений приведён на рис. 15.4.

Все эти методы предполагают сохранение и переработку полученных данных. На практике они, в большинстве случаев, работают в комплексе.



Рисунок 15.4. Классификация неисправных состояний

15.1.3. Адаптивные методы прогнозирования на основе временных рядов

В тех ситуациях, где прогнозирование основывается на данных, полученных с использованием временных рядов, применяются *адаптивные* методы прогнозирования. Рассматриваемые методы применимы для широкого круга задач. Адаптивное прогнозирование не требует большого объема информации, оно базируется на интенсивном анализе данных, содержащихся в отдельных временных рядах. Модель, описывающая структуру показателя и его динамику, отличается корректностью математической формулировки. Неоднородность временных рядов и их связей находит отражение в адаптивной эволюции параметров, или даже самой структуры моделей [285].

Адаптивные методы и модели не заменяют остальные виды методов и моделей. Они применяются только для работы с рядами, обладающими небольшими временными изменениями. Когда нужно делать более дальний прогноз, то их лучше не использовать. Однако теория адаптивных методов прогнозирования на основе временных рядов стремительно развивается.

Развитие методов адаптивного прогнозирования началось с работы Ч. Хольта, вышедшей в 1957 г. «О проблеме экспоненциального сглаживания». В дальнейшем эта проблема более детально изучалась Р.Г. Брауном.

Основным средством анализа и прогноза временного ряда является модель. Само понятие модели применяется в двух значениях: как модель временного ряда, выражающая закон генерирования членов ряда, и как прогнозная модель, или *предиктор*. Отличие этих двух типов моделей состоит в том, что на выходе модели временного ряда появляются фактические члены ряда, а на выходе прогнозной модели – оценка будущих членов ряда.

Теоретически, свойства предиктора исследуются в предположении, что он применяется для получения прогноза для некоего процесса, генерируемого моделью, заданной аналитически. На временной ряд в разное время влияют различные факторы. Одни из них, по тем или иным причинам, ослабляют своё влияние, другие воздействуют активнее. Таким образом, реальный процесс протекает в изменяющихся условиях, составляющих его внешнюю среду, к которой он приспособливается – адаптируется. А модель, в свою очередь, адаптируется к ряду, представляющему этот процесс [285].

Если говорить о практическом применении, то здесь более ценными считаются изменяющиеся ряды. Они называются *нестационарными*, и у них все основные параметры, описывающие такие ряды, изменчивы во времени, а значит, и модель, их описывающая, всегда находится в движении. Сложно провести границу, отделяющую неадаптивные и адаптивные методы. Даже простейшее прогнозирование, методом экстраполяции обычных регрессионных кривых, содержит элемент адаптации, когда с каждым новым получением фактических данных параметры регрессионных кривых пересчитываются и уточняются. Иногда, через большой отрезок времени, может быть изменён даже сам тип этой кривой. Степень адаптации очень мала, и по прошествии времени она падает, вместе с ростом общего количества наблюдаемых точек и с уменьшением удельного веса в выборке каждой новой точки.

Одной из модификации этого метода является метод *кусочно–линейной аппроксимации* (метод взвешенной регрессии), использование которого ведёт к уменьшению *памяти* модели, к *забыванию* старых данных и построению линий регрессии на искусственно ограниченном количестве информации. Этот метод лучше учитывает новые тенденции, быстрее приспособливается к изменившимся характеристикам процесса, но при этом больше реагирует на помехи, случайные отклонения и искажения, что связано с уменьшением доли «наследственности». В кусочно–линейном варианте регрессионного анализа соотношение между «наследственностью» и «изменчивостью» определяется субъективным выбором интервалов аппроксимации. Недостаток этого метода – то, что ценность полученной информации в пределах интервала аппроксимации считается одинаковой, независимо от возраста, а вне его пределов – скачком падает до нуля. Ценность информации, в зависимости от возраста, можно учитывать с помощью геометрически убывающих весовых коэффициентов.

В начале направления лежит *экспоненциальное сглаживание*. На его базе, путём различных модификаций модели, были созданы новые адаптивные модели, обладающие различными отличительными параметрами.

Нужно отметить, что даже если система является механической, то всё равно у неё иногда возможно присутствие элементов свойств адаптации [286]. В этих случаях, процесс адаптации происходит на небольших по размеру шагах. Чтобы *научить модели новому поведению*, применяется *эмпирический метод*, находящий ценную информацию. Он и составляет саму суть адаптации.

Пусть модель находится в некотором исходном состоянии, известны текущие значения её коэффициентов, и по ней делается прогноз. Подождав, пока истечёт одна единица времени, называемая *шагом моделирования*, нужно проанализировать, насколько результат, полученный с помощью модели, далёк от фактического значения ряда. Ошибка прогнозирования, через обратную связь, поступает на вход системы и используется моделью, в соответствии с её логикой, для перехода из одного состояния в другое, с целью лучшего согласования своего поведения с общей динамикой ряда.

На изменения ряда модель отвечает *компенсирующими изменениями*. Затем делается прогноз для следующего момента времени, и весь процесс повторяется. Так, адаптация осуществляется последовательно, с помощью итераций, методом получения каждой новой фактической точки ряда [286].

Правила, которые позволяют осуществить переход от одного состояния, присущего системе, к её новому состоянию (иными словами, сущность самого механизма адаптации) разработчик решает сам. Механизм адаптации находится и проверяется экспериментальным путём, причём совокупность различных применяемых инструментов, методов и приёмов и составляет адаптацию.

Важной характеристикой является скорость отклика модели на ошибки в происходящем процессе—*параметр адаптации*. Используя данные, полученные раньше, и подбирая подход с помощью экспериментов, проводится *обучение модели*. Это делается для нахождения оптимальных параметров адаптации. Каждая модель, взятая отдельно, слишком проста, а данные на её входе ограничены, поэтому для прогноза любого из рядов она применяться не может.

Адаптивные модели, являются более гибкими, чем неадаптивные, хотя их нельзя считать универсальными. На практике, при создании адаптивной модели, в качестве гипотезы принимаются возможные варианты развития событий, и учитывается обученность модели и активные свойства ряда.

В модель должны закладываться те адаптивные свойства, которые необходимы и достаточны для слежения модели за реальным процессом, с заданной точностью [285]. Не стоит надеяться на успешную самоадаптацию модели, более общей по отношению к той, которая необходима для наблюдения за рассматриваемым процессом, так как увеличение числа параметров придаёт системе излишнюю чувствительность, что приводит к её *раскачке*, а, следовательно, и к ухудшению получаемых по ней прогнозов.

Так, при построении адаптивной модели нужно выбирать между общей и частной моделью, постоянно сравнивая их достоинства и недостатки. Окончательно выбирать следует ту модель, от которой ожидается наименьшая ошибка прогнозирования. Только при соблюдении этого правила можно надеяться, что последовательность проделанных итераций, методом проб и ошибок, постепенно приведёт к наиболее эффективному результату [286].

Следует ввести основные понятия, рассматриваемые в этом исследовании.

Понятие *временного ряда* можно определить, как весь объём данных, получаемых одни за другими, с течением времени. Если время рассматривается только на отдельных конечных участках последовательности, то речь идёт о *дискретном временном ряде*. Далее нужно считать, что данные поступают через конечное время, то есть исследуются непрерывные временные ряды.

Переход от одного наблюдения к следующему называют его *шагом*. Если отдельным составляющим временного ряда присвоены значения с помощью некой математической функции, то речь идёт о *детерминированном ряде*. Событие, происходящее на описываемых временных интервалах согласно законам теории вероятностей, является *стохастическим процессом*.

Рассмотрим адаптивные модели более детально. В основе процесса лежит переработанная модель *экспоненциального сглаживания*, опирающаяся на нахождение экспоненциально взвешенной *скользящей средней* (величины). Экспоненциальное сглаживание начального временного ряда x_t определяется:

$$S_t = \alpha x_t + \beta S_{t-1}, \quad (15.1)$$

где S_t – значение экспоненциальной средней в момент t ; S_{t-1} – значение в момент $t - 1$; α – параметр сглаживания, адаптации; $\alpha = \text{const}$, $0 < \alpha < 1$; $\beta = 1 - \alpha$.

Это выражение можно представить в следующем виде

$$S_t = \alpha x_t + (1 - \alpha) \cdot S_{t-1} + \alpha (x_t - S_{t-1}). \quad (15.2)$$

Экспоненциальная средняя, в момент времени t , представлена в виде такой же величины предыдущего момента S_{t-1} , сложенной с долей α отклонения текущего наблюдения x_t от экспоненциальной средней S_{t-1} момента времени $t-1$.

Выразим экспоненциальную среднюю S_t через значения временного ряда:

$$S_t = \alpha x_t + \alpha \beta x_{t-1} + \beta^2 S_{t-2} = \dots = \alpha \sum_{i=0}^{t-1} \beta^i x_{t-i} + S_0, \quad (15.3)$$

где S_0 —величина, характеризующая начальные условия для первого применения формулы, при $t = 1$. Так как $\beta = (1 - \alpha) < 1$, то при $t \rightarrow \infty$, $\beta^t \rightarrow 0$,

$$S_t = \alpha \sum_{i=0}^{t-1} \beta^i x_{t-i}. \quad (15.4)$$

Величина S_t является суммой всех членов ряда—*экспоненциальной средней*.

Так, можно утверждать, что путём повышения параметра адаптации α можно добиться веса свежих наблюдений. Но в тоже время α необходимо уменьшить, чтобы сгладить случайные колебания временного ряда x_t . Чтобы решить это противоречие, в реальности исходят из компромиссного решения.

Этот процесс является примером простой самообучающейся модели.

Можно заметить, что при экспоненциальном сглаживании применяются простые вычисления, на которые приходится меньше элементарных действий, чем при скользящей средней. Вся прошлая информация сокращена до одного значения S_{t-1} . Это модель адаптивно экспоненциального типа.

Экспоненциальное выравнивание всегда требует предыдущего значения экспоненциальной средней величины. Когда процесс только начинается, должна существовать величина S_0 , которую можно использовать в качестве значения, предшествующего S_1 . Если к моменту начала выравнивания есть прошлые данные, то в качестве начального значения S_0 можно использовать арифметическую среднюю всех имеющихся точек, или какой-то их части. Если для оценивания S_0 данных нет, то требуется предсказание начального уровня ряда. Предсказание может быть сделано, исходя из априорных знаний о процессе, или на основе его аналогии с другими процессами.

После k шагов вес, придаваемый начальному значению, равен $(1 - \alpha)^k$. Если у пользователя есть уверенность в правильности начального значения S_0 , то коэффициент α можно взять малым. Если такой уверенности нет, то параметру α следует дать большое значение, с таким расчётом, чтобы влияние начального значения быстро уменьшилось. Однако большое значение α может явиться причиной большой дисперсии колебаний S_t . Если требуется подавление этих колебаний, то, после достаточного удаления от начального момента времени, величину α можно убавить [286]. При этом рекомендуется особое внимание уделить выбору постоянной величины сглаживания.

Нужно отыскать основания, чтобы найти оптимальное значение. Кроме этого, необходимо принять во внимание параметры, при которых эта величина приближается к краевым значениям.

При $\alpha=0$ и $S_t = S_0$ возникает случай *абсолютной фильтрации* и полного отсутствия адаптации, а при $\alpha=1$ получается *наивная модель*, при которой прогноз на любой срок равен текущему фактическому значению ряда [286].

Эта модель часто используется практически в связи со своей простотой.

Можно утверждать, что *постоянная сглаживания* характеризует скорость реакции модели $x_t(t) = S_t = x_t$ на изменения уровня процесса, но одновременно определяет и способность системы сглаживать случайные отклонения. Поэтому величине α рекомендуется присваивать промежуточное значение между 0 и 1, в зависимости от свойств динамического ряда. В качестве удовлетворительного компромисса, Р. Браун рекомендует брать α в пределах от 0,1 до 0,3. [287].

Но бывают ситуации, когда экспериментально доказано, что лучшее значение α очень близко к единице, в этом случае приходится проверять правильность выбора типа используемой модели. Такое развитие событий может возникнуть тогда, когда в рассматриваемом ряде вдруг обнаруживается присутствие резко выраженных сезонных колебаний.

В этом случае строится иная модель прогнозирования. При этом наилучшее значение α должно зависеть от срока прогнозирования x , и здесь необходимо учитывать новую, свежую информацию. Чтобы сгладить колебания, следует учитывать информацию за прошлые периоды времени. Для проведения подобного анализа вводится понятие *среднего возраста данных*.

Если считать за ноль начальный возраст, то возраст предыдущего наблюдения равен 1. Средний возраст данных – это сумма взвешенных возрастов данных, использованных для подсчёта сглаженной величины. Причём значения возраста имеют те же веса, что и соответствующая информация. При экспоненциальном выравнивании, вес, даваемый точке с возрастом k , равен $\alpha\beta^k$, где $\beta=\alpha-1$, и средний возраст информации равен:

$$k = 0 \cdot \alpha + 1 \cdot \alpha\beta + 2 \cdot \alpha\beta^2 + \dots = \alpha \sum_{k=0}^{\infty} k\beta^k. \quad (15.5)$$

Средний возраст увеличивается с уменьшением α . Так, если нужен короткий прогноз, то значение α необходимо увеличивать, а для долгосрочных прогнозов – уменьшать. Эту тенденцию иллюстрирует рис. 15.5, на котором, показана примерная зависимость среднеквадратичной ошибки прогноза от α .




Рисунок 15.5. Примерная зависимость среднеквадратичной ошибки прогноза

При применении простейшей экспоненциальной модели, используя для выбора постоянной сглаживания математический анализ с автокорреляционной функцией вида: где ρ_1 — коэффициент автокорреляции при лаге, равном единице, k — лаг, можно увидеть, что минимум среднего квадрата ошибки при прогнозировании такого ряда на один шаг вперед ($\tau = 1$) будет при

$$\alpha_{opt} = \begin{cases} \frac{3\rho_1 - 1}{2\rho_1}, & \frac{1}{3} < \rho_1 \leq 1, \\ 0, & -1 \leq \rho_1 \leq \frac{1}{3}. \end{cases} \quad (15.6)$$

При этом разброс ошибки прогноза равен

$$D = \begin{cases} \frac{8\rho_1(1-\rho_1)}{(1+\rho_1)^2} \cdot \sigma_x^2, & \frac{1}{3} < \rho_1 \leq 1, \\ \sigma_x^2, & -1 \leq \rho_1 \leq \frac{1}{3}. \end{cases} \quad (15.6)$$

Отсюда можно сделать вывод, что когда данные сильно статистически взаимосвязаны, и период τ мал, то сильно сглаживать не стоит. Для прогноза лучше взять самое последнее наблюдение. Так, можно резюмировать, что рассматриваемые методы, при их применении в прогнозировании, дают хороший результат, и они достаточны комфортны в работе. Несмотря на то, что эти методы могут применяться в различных областях науки и техники, чаще всего экспоненциальное сглаживание используется для прогнозирования рядов спроса и для управления ресурсами вычислительной техники.

Нужно подчеркнуть, что основной негативной чертой при применении рассматриваемых подходов является обособленность в них временного ряда от поступающих дальнейших данных. Эту вновь поступающую информацию применить почти невозможно, разве что для отладки скорости адаптации. К тому же, при достаточно длительном прогнозе заметно теряется точность.

15.1.4. Алгоритм фильтрации Калмана

Чтобы правильно установить местоположение движущихся объектов, на практике чаще всего применяют *алгоритм фильтрации Калмана*. Лучшие результаты он даёт, если динамическая модель является нелинейной, а шумы наблюдений при этом – *Гауссовские*. Алгоритм Калмана используется чаще всего в инженерной или экономической отраслях производства. С его помощью можно оценить вектор состояния изначально известной динамической системы.

Другими словами, для того, чтобы понять, каково состояние этой системы в текущий момент времени, необходимо иметь данные, актуальные сейчас, и, кроме того, иметь сведения о предыдущем состоянии самого фильтра.

Фильтр Калмана – это последовательный рекурсивный алгоритм, использующий принятую модель динамической системы для получения оценки, которая может быть существенно скорректирована в результате анализа каждой новой выборки измерений во временной последовательности. Этот алгоритм находит применение в процессе управления многими сложными динамическими системами – непрерывными производственными процессами, самолетами, БПЛА, ракетами, кораблями и космическими аппаратами. При управлении динамической системой необходимо полностью знать её фазовое состояние в каждый момент времени. Но измерение всех переменных, которыми нужно управлять, не всегда возможно, и в этих случаях фильтр Калмана является тем средством, которое позволяет восстановить недостающую информацию, с помощью имеющихся неточных (зашумленных) измерений [287].

Основной принцип работы алгоритма состоит в том, что при фильтрации используется информация о физике самого явления. Фильтр Калмана, как и другие рекурсивные алгоритмы, используется во временном, а не в частотном представлении [288]. Наглядный пример его возможностей – получение точных, постоянно обновляемых оценок положения скорости некоторого объекта, по результатам временного ряда неточных измерений его местоположения.

При использовании определенной математической модели наблюдений за динамической системой можно записать *дифференциальное уравнение Стратоновича* для вектора состояния в любой момент времени [289]. В общем виде у него решения нет, но аналитическое решение получить можно только в случае ряда ограничений: Гауссова характера апостериорных и априорных плотностей вероятности вектора состояния на любой момент времени, а также формирующих шумов и шумов наблюдений; белых шумов наблюдений; линейности моделей формирующего процесса и модели наблюдений [290].

Классический фильтр Калмана является системой уравнений для расчёта первого и второго момента апостериорной плотности вероятности, т.е. вектора математических ожиданий и матрицы дисперсий. Ввиду того, что для нормальной плотности вероятности математическое ожидание и дисперсионная матрица полностью задают плотность вероятности, можно сказать, что фильтр Калмана рассчитывает апостериорную плотность вероятности вектора состояния на каждый момент времени. А значит, он полностью описывает вектор состояния – как случайную векторную величину. Расчётные значения математических ожиданий являются оптимальными оценками, по критерию среднеквадратической ошибки, что и обуславливает его применение [290].

На сегодняшний день у фильтра Калмана имеется ряд модификаций. Если рассматривать данные этого фильтра, то они основываются на предположении, что стохастическую систему можно описать моделями динамики и измерений (для непрерывного и дискретного случаев), представленными в табл. 15.1.

Модели динамики и измерений

Таблица 15.1

Модель	Непрерывное время	Дискретное время
Система	$\dot{x}(t) = F(t)x(t) + \omega(t)$	$x_k = \Phi_{k-1}x_{k-1} + \omega_k$
Измерения	$z = H(t)x(t) + v(t)$	$z_k = H_k x_k + v_k$
Шум системы	$E \langle \omega(t) \rangle = 0,$ $E \langle \omega(t)\omega^t(s) \rangle = \delta(t-s)Q(t)$	$E \langle \omega_k \rangle = 0,$ $E \langle \omega_k \omega_i^T \rangle = \Delta(k-i)Q_k$
Шум измерений	$E \langle v(t) \rangle = 0$ $E \langle v(t)v^t(s) \rangle = \delta(t-s)R(t)$	$E \langle v_k \rangle = 0$ $E \langle v_k v_i^T \rangle = \Delta(k-i)R_k$

В данном контексте, вектор состояния динамической системы $x(t)$, измерения z_k , полученные в момент времени t_k , шум системы и шум измерения w_k и v_k являются Гауссовскими случайными процессами с математическим ожиданием, равным нулю. Выдвигается гипотеза о присутствии белого шума.

Для уменьшения средне-квадратичной ошибки, находится оценка вектора состояния системы x_k , которую обозначают $\hat{x}_k$, и которая является функцией измерений $z_i \dots z_k$. Для её вычисления используется выражение:

$$E \left\langle [x_k - \hat{x}_k]^T M [x_k - \hat{x}_k]^T \right\rangle, \quad (15.8)$$

где M – симметричная положительно – определенная матрица.

Фильтр Калмана работает по системе «прогноз–коррекция». Предположим, что в определённый момент времени t_{k-1} найдена оценка вектора состояния системы $\hat{x}_{k-1}$, и теперь требуется получить оценку в момент t_k . Далее, делается прогноз оценки $\hat{x}_k(-)$ опираясь на $\hat{x}_{k-1}$, производится измерение z_k и затем оценка корректируется в момент времени t_k , базируясь на прогнозе и измерениях, и, наконец, получается окончательная оценка вектора состояния $\hat{x}_k(+)$. При этом $\hat{x}_k(-)$ является *оценкой априори*, а $\hat{x}_k(+)$ является *оценкой апостериори*» [291].

Наглядное представление о его работе показано на рис. 15.6.




Рисунок 15.6. Принцип работы фильтра Калмана

Нужно отметить важный аспект случайного процесса, требующий описания в терминах ковариационной матрицы, опираясь на соотношение:

$$P(t) = E \left\langle [x(t) - \hat{x}(t)][x(t) - \hat{x}(t)]^T \right\rangle. \quad (15.9)$$

Матрица $P(t)$ является *ковариационной матрицей ошибки оценки вектора состояния*, сокращённо – ковариационная матрица ошибки [292].

Для получения прогнозируемой оценки $\hat{x}_k(-)$ нужно интегрировать модельное динамическое уравнение $\dot{x}(t) = F(t)x(t) + w(t)$ с начальным условием $x(0) = \hat{x}_{k-1}(+)$. Решение этого уравнения записывается в виде:

$$x(t) = \Phi(t, t_0)x(t_0) + \int_{t_0}^t \Phi(t, \tau)\omega(\tau)d\tau. \quad (15.10)$$

Математическое ожидание этой величины выражается как:

$$E \langle x(t) \rangle = \Phi(t, t_0)E \langle x(t_0) \rangle + \int_{t_0}^t \Phi(t, \tau)E \langle \omega(\tau) \rangle d\tau. \quad (15.11)$$

Тогда можно записать:

$$[x(t) - E \langle x(t) \rangle] = \Phi(t, t_0)[x(t_0) - E \langle x(t_0) \rangle] + \int_{t_0}^t \Phi(t, \tau)\omega(\tau)d\tau \quad (15.12)$$

Подставляя выражение (15.11) в формулу (15.9), и вычисляя первую производную функции $P(t)$, получим окончательное выражение:

$$\dot{P}(t) = F(t)P(t) + P(t)F^T(t) + Q. \quad (15.13)$$

Получено *матричное уравнение Риккати*, выражающее продолжение ковариационной матрицы ошибки. Проинтегрировав уравнение (15.13) при исходном условии $P(0) = P_{k-1}(+)$, можно получить прогнозируемую оценку ковариационной матрицы ошибки $P_k(-)$. Исходя из предположения, что все измерения были произведены в момент времени t_k , и полученная информация используется для оценки вектора состояния x рассматриваемой динамической системы в момент времени t_k , можно сделать вывод, что измерения линейно зависят от вектора состояния, и описываются уравнением:

$$z_k = H_k x_k + v_k. \quad (15.14)$$

При этом оценка $\hat{x}_k(+)$ основывается на измерениях z_k , и учитывая, что она является функцией оценки априори $\hat{x}_k(-)$ и z_k , запишем её в виде:

$$\hat{x}_k(+) = K_k^1 \hat{x}_k(-) + \bar{K}_k z_k. \quad (15.15)$$

Матрицы K_k^1 и $\bar{K}_k$ пока не известны. Их величины необходимо определить так, чтобы новая оценка $\hat{x}_k(+)$ удовлетворяла принципу ортогональности, условия которого можно записать в следующем виде:

$$E \langle [x_k - \hat{x}_k(+)] z_i^T \rangle = 0, \quad i = 1, 2, \dots, k-1, \quad (15.16)$$

$$E \langle [x_k - \hat{x}_k(+)] z_k^T \rangle = 0. \quad (15.17)$$

Подставляя в выражение (15.16) значения x_k и $\hat{x}_k(+)$ из соотношений (15.10) и (15.15) и учитывая, что случайные последовательности w_k и v_k являются некоррелированными, коэффициент обратной связи равен:

$$K_k^1 = I - K_k H_k, \quad (15.18)$$

$$\bar{K}_k = P_k(-) H_k^T [H_k P_k(-) H_k^T + R_k]^{-1}. \quad (15.19)$$

Для того, чтобы вывести формулу, которая поможет откорректировать ковариационную матрицу ошибки, необходимо выполнить определённые преобразования. Сначала, исходя из определения, она записывается в виде:

$$P_k(+) = E \langle \tilde{x}_k(+) \tilde{x}_k^T(+) \rangle, \quad (15.20)$$

где
$$\tilde{x}_k(+) = \hat{x}_k(+) - x_k; \quad \tilde{x}_k(-) = \hat{x}_k(-) - x_k. \quad (15.21)$$

Затем, подставляя выражение (15.18) в формулу (15.15), получаем:

$$\hat{x}_k(+) = \hat{x}_k(-) + \bar{K}_k [z_k - H_k \hat{x}_k(-)]. \quad (15.22)$$

Вычитая x_k из обеих частей выражения (15.22), и подставляя в него значение z_k из соотношения (15.14), получим формулу:

$$\tilde{x}_k(+) = (I - \bar{K}_k H_k) \tilde{x}_k(-) + \bar{K}_k v_k. \quad (15.23)$$

На конечном этапе, подставляя формулу (15.23) в уравнение (15.20), получается следующее выражение для ковариационной матрицы ошибки:

$$P_k(+) = (I - K_k H_k) P_k(-). \quad (15.24)$$

15.1.5. Расширенный фильтр Калмана для нелинейных систем

В реальных условиях подавляющее количество динамических систем не являются линейными. На любой протекающий процесс действует огромное количество влияющих на него факторов, разнообразных и непредсказуемых. Однако, несмотря на это, для них можно применять те же методы фильтрации, что и для линейных процессов. Рассмотрим методы, которые позволяют переносить методологию фильтрации Калмана на нелинейные задачи.

Чтобы система была описана нелинейным динамическим модельным уравнением, предполагаются измерения, представленные в табл. 15.2.

Нелинейные модели динамики и измерений

Таблица 15.2

Модель	Непрерывное время	Дискретное время
Система измерения	$x(t) = f(x(t), t) + \omega(t)$ $z(t) = h(x(t), t) + v(t)$	$x_k = f(x_{k-1}, k-1) + \omega_{k-1}$ $z_k = h(x_k, k) + v_k$

Поскольку используется метод линеаризации, то выдвигается условие, чтобы функции f и h были дважды непрерывно дифференцируемыми.

Обозначим δ малое отклонение от оцениваемой траектории:

$$\delta x_k = x_k - x_k(-), \quad (15.25)$$

$$\delta z_k = z_k - h(\hat{x}_k(-), k). \quad (15.26)$$

Иначе, $f(x, k-1)$ в непосредственной близости с $x = \hat{x}_{k-1}(-)$, выглядит как:

$$x_k = f(x_{k-1}, k-1) = x_k(-) + \left. \frac{\partial f(x, k-1)}{\partial x} \right|_{x=\hat{x}_{k-1}(-)} \delta x_{k-1}. \quad (15.27)$$

Таким образом, получаем выражения:

$$\delta x_k \approx \Phi_{k-1}^{[1]} \delta x_{k-1} + \omega_{k-1}, \quad (15.28)$$

$$\Phi_{k-1}^{[1]} = \left. \frac{\partial f(x, k-1)}{\partial x} \right|_{x=\hat{x}_k(-)} \delta x_{k-1}. \quad (15.29)$$

Выражения можно представить в виде разложения в ряд Тейлора

$$h(x, k) = h(\hat{x}_k(-), k) + \left. \frac{\partial h(x, k)}{\partial x} \right|_{x=\hat{x}_k(-)} \delta x_k, \quad (15.30)$$

где
$$\delta z_k = \left. \frac{\partial h(x, k)}{\partial x} \right|_{x=\hat{x}_k(-)} \delta x_k. \quad (15.31)$$

Если в разложении пренебречь членами высокого порядка, то возмущение z_k может быть представлено в виде следующего выражения:

$$\delta z_k = H_k^{[1]} \delta x_k, \quad (15.32)$$

при этом
$$H_k^{[1]} = \left. \frac{\partial h(x, k)}{\partial x} \right|_{x=\hat{x}_k(-)} \quad (15.33)$$

В случае непрерывной системы, матрицы частных производных имеют вид:

$$F^{[1]} = \frac{\partial f(x(t), t)}{\partial x(t)}, \quad (15.34)$$

а также
$$H^{[1]} = \left. \frac{\partial h(x(t), t)}{\partial x(t)} \right|_{x=\hat{x}_k(-)}. \quad (15.35)$$

Множество практических задач рассматривается с помощью непрерывной динамической системы, поэтому целесообразно применить полученные выводы именно на ней. Система может быть записана следующим образом:

$$\dot{x}(t) = f(x(t), t) + \omega(t), \quad (15.36)$$

$$z_k = h_k(x(t_k)) + v_k. \quad (15.37)$$

Интегрируя модельное уравнение, можно определить значения оценок вектора состояния и ковариационной матрицы ошибки $\hat{x}_k(-)$ и $P_k(-)$.

$$\dot{P}(t) = F(\hat{x}(t), t)P(t) + P(t)F^T(\hat{x}(t), t) + Q(t), \quad (15.38)$$

с начальными условиями $\hat{x}(t) = \hat{x}_{k-1}(+)$ и $P(t) = P_{k-1}(+)$.

Выше упоминалось, что рассматривается нелинейная задача, и учитывая это, для определения матриц $F(\hat{x}(t), t)$ используется уравнение (15.34). Выполнив эти преобразования, получим $\hat{x}_k(-)$ и $P_k(-)$.

В итоге, опираясь на уравнение (15.35), можно найти линеаризованную матрицу чувствительности системы, и определить коэффициент обратной связи $\bar{K}_k$. Помимо этого, следует вычислить значения $\hat{x}_k(+)$ и $P_k(+)$ при помощи формул (15.23) и (15.24). Таким образом, будет выполнено описание нелинейной динамической системы, используя метод фильтрации Калмана.

15.1.6. Адаптивный фильтр Калмана и его разновидности

При практической реализации фильтрации Калмана, основная трудность состоит в разрыве между теорией и реальной жизнью. Точность оценивания вектора состояния системы (а именно это указывает на то, что фильтр работает правильно), зависит от статистических свойств шумов, а если быть более точным, то от их ковариационных матриц. Традиционно, для начала, проводя эксперимент и проанализировав результаты, находят значения ковариационных матриц шума измерений и шума процесса. После этого, полученные данные рассматриваются как постоянные. В случае, когда уже при применении этих данных становится ясным, что фильтр работает некорректно, возникает необходимость в перенастройке ковариационных матриц шумов, с целью повышения точности работы фильтра. В связи с этим, ставится задача адаптивной фильтрации, а конкретно: параллельно с оценкой вектора состояния динамической системы необходимо оценивать статистические свойства шумов процесса и измерений в ковариационных матрицах [293].

Среди методов, которые позволяют решать эту задачу можно выделить метод уточнения ковариации по обновляющему процессу (Innovation-Based Adaptive Estimation – IBAE), он основывается на том, что матрица шума процесса равна ковариационной матрице ошибки измерения, а именно:

$$\left[z_k - h(\hat{x}(t_k)) \right] \left[z_k - h(\hat{x}(t_k)) \right]^T \cong R_k. \quad (15.39)$$

Необходимо указать прогнозируемую разность ошибки измерения:

$$r_j \equiv z_j - H_j \hat{x}_j(-). \quad (15.40)$$

Повышая статистическую значимость алгоритма, делается выборка из N . Кроме этого, нужно описать сечение случайного процесса в виде:

$$\frac{1}{N} \sum_{k=1}^N r_j r_j^T \cong R_j. \quad (15.41)$$

Этот же метод применяется и для того, чтобы оценить ковариационную матрицу шума системы, то есть, с помощью оценок вектора состояния, которые были получены на последовательных шагах [294]:

$$q_j = \hat{x}_j - F_{j-1} \hat{x}_{j-1}. \quad (15.42)$$

С помощью N –выборочного среднего (значения), необходимо найти оценку ковариационной матрицы шума нелинейной динамической системы:

$$\frac{1}{N} \sum_{j=1}^N q_j q_j^T \cong Q. \quad (15.43)$$

Основные данные, которые необходимы для того, чтобы описать схему матрицы шумов процесса и измерений приведены в табл. 15.3.

Уточнение ковариации для оценки R и Q

Таблица 15.3

Действия	Оценка R	Оценка Q
Начальные условия	$j = 1, \hat{R}_0 = 0$	$j = 1, \hat{Q}_0 = 0$
Аппроксимация шума	$r_j = z_j - H_j \hat{x}_j (-)$	$q_j = \hat{x}_j - F_{j-1} \hat{x}_{j-1}$
Вычисление	$\hat{R}_j = \frac{j-1}{j} \hat{R}_{j-1} + \frac{1}{j} r_j r_j^T$	$\hat{Q}_j = \frac{j-1}{j} \hat{Q}_{j-1} + \frac{1}{j} q_j q_j^T$
$j=N$	подставляем $\hat{R}_N$ в фильтр	подставляем $\hat{Q}_N$ в фильтр
$j < N$	увеличиваем j на 1 и переходим к шагу 2	

Подчас возникает необходимость выяснить и убедиться, что на изменения ковариации невязки влияют только шумы наблюдений, а не шум вектора состояния или изменение модели нелинейной динамической системы. Это наиболее уязвимая сторона рассматриваемого алгоритма.

Следующий вид адаптивных алгоритмов Калмана [290]: адаптивный алгоритм с плавной подстройкой (Adaptive Fading Kalman Filter – AFKF) настроен на приспособливание (адаптацию) к изменению модели нелинейной динамической системы. Суть его состоит в том, чтобы при повышении ковариации невязки наблюдений, по сравнению с её ожидаемым значением, постепенно увеличивать ковариационную матрицу вектора состояния.

Существуют различные модификации этого метода, и способы его применения, но как правило они различаются только вариантами расчёта весовых коэффициентов $\lambda(k)$. Чаще всего, $\lambda(k)$ вычисляется по формуле:

$$\lambda(k) = \max \left\{ 1, \alpha \cdot \frac{\text{tr}[G(k)]}{\text{tr}[M(k)]} \right\}, \quad (15.44)$$

где $\text{tr}[\cdot]$ – операция нахождения следа матрицы; $k \geq 1$, α – положительная константа; $G(k) = C_0 - R(k) - H(k)Q(k)H^T(k)$; $M(k) = H(k)F(k)P(k)F^T(k)$.

Гибридный IBAE / AFKF алгоритм (Hybrid) обеспечивает одновременную адаптацию к изменению ковариации шума наблюдений и шума системы (манёвра системы). Это происходит за счёт одновременно реализуемых анализа обновляющей последовательности (IBAЕ–адаптация) и плавной регулировки ковариационной матрицы ошибки вектора состояния (AFKF–адаптация).

Последние исследования показывают, что алгоритм IBAE обеспечивает наилучшие (среди рассматриваемых подходов) характеристики в условиях, когда отклонение претерпевает только ковариационная матрица наблюдений. Тем не менее, при наличии маневра в траектории объекта, работоспособность этого метода теряется, так как средняя ошибка места возрастает, начиная с момента смены модели движения. Подводя итоги, можно отметить, что алгоритм AFKF обеспечивает наилучшие характеристики в условиях, когда имеет место только маневр объекта, а дисперсия наблюдений не меняется [292].

Алгоритм при этих условиях продолжает работать, но по сравнению с неадаптивным фильтром нет особого улучшения точности. При условии, что колебательные движения совершает только ковариационная матрица наблюдений, или, когда маневрирует только объект, применение гибридного алгоритма показывает хорошую эффективность. Обычно же в практической реальной обстановке присутствуют оба это условия, и тогда использование гибридного алгоритма будет предпочтительнее всех остальных.

Рассмотренные схемы адаптивных фильтров дают возможность повысить точность оценки вектора состояния системы за счёт настройки ковариационных матриц шумов процесса и измерений. Качественные сравнения работы различных типов адаптивных алгоритмов [293], полученных в результате математического моделирования, позволяют ответить на вопрос о том, какой из них более фильтрации является настройка ковариационной предпочтительнее в той или иной ситуации. Основной проблемой адаптивной матрицы является подавление шума процесса. Необходимо отметить, что перечисленными выше алгоритмами теория фильтрации Калмана не ограничивается. Она широко применяется в связи с разработками различных маневрирующих объектов. Из этого многообразия стоит выделить непрерывный алгоритм Калмана, «цветные» шумы и другие сглаживающие алгоритмы, применяющиеся в измерениях. Они хорошо подходят к решению различных задач управления, особенно если данные «зашумлены» по различным причинам. Например, эти адаптивные фильтры широко используются на практике—в геофизических, радиофизических и астрономических научных исследованиях [289–295].

Критика фильтра Калмана, согласно докладу Е.П. Великанова [292], такова: погрешности представлены белым шумом, которого на самом деле в природе не существует; нет соответствия необходимому и достаточному условию оптимальности; существует ошибка в выводе фильтра Калмана, поскольку требуются противоречивые условия верности разных уравнений алгоритма.

Таким образом, несмотря на существование множества различных методов интеллектуального анализа [295], проблема в задаче динамической обработки данных с изменяющимися массивами объектов всё ещё не решена.

15.2. Модели экстраполяторов в фильтрах сопровождения

15.2.1. Фильтры сопровождения

В последние годы возник большой интерес к исследованиям и разработкам в области автоматической обработки цифровой информации в радиолокационных системах (ЦОРИ, цифровая обработка радиолокационной информации) [295]. Это обусловлено тем, что при решении задач управления движением и противовоздушной обороны, поступающая в быстром темпе от обзорных радиолокационных систем высокоточная информация должна быть впоследствии соответствующим образом обработана.

При определении координат, скорости, характера движения и, возможно, при распознавании цели, применение ЦОРИ обеспечивает большую точность и надёжность, чем методы приёма сигнала, основанные на одноразовом облучении цели, как это показано в [293, 294]. Кроме того, ЦОРИ повышает качество обработки сигналов благодаря уменьшению частоты возникновения ложных тревог, вызванных, например, отражениями от местных предметов.

Цифровая обработка радиолокационной информации может быть применена как в однопозиционных, так и в двухпозиционных (бистатических) радиолокационных станциях (РЛС) с механическим или электронным сканированием луча. Сегодня практический интерес представляет создание сетей РЛС, что в ряде случаев позволит повысить эффективность их работы.

Обработка данных в РЛС происходит с помощью цифрового компьютера, структурно включенного перед индикатором, после устройства выделения траекторий. Процессор данных РЛС может быть определен как совокупность реализованных на ЭВМ алгоритмов, которые по информации, получаемой в нескольких последовательных циклах обзора, позволяют:

- идентифицировать полученные сигналы, относящиеся к одной и той же цели;
- оценивать кинематические параметры обнаруженной цели (координаты, скорость и ускорение), обеспечивая формирование траектории;
- экстраполировать сформированные траектории;
- различать цели и формировать траектории каждой из них;
- выделять истинные цели на фоне ложных тревог и помех, обусловленных как преднамеренными, так и естественными помехами;
- адаптивно корректировать пороговый уровень процессора сигналов, изменяя чувствительность РЛС в зависимости от направления в пространстве, с учётом карты ложных тревог, обновляемой на каждом цикле обзора;
- формировать программу обзора пространства радиолокационной станции с фазированной антенной решёткой для сопровождения маневрирующей цели с заданной точностью, а также оптимальным образом сочетать сопровождение целей с обзором пространства и другими функциями РЛС;
- эффективно использовать информацию обнаружения или сопровождения, поступающую от различных радиолокационных станций, объединённых в сеть и контролирующих одну и ту же область пространства.

Требования к дальности обнаружения и точности радиолокационных систем сопровождения объектов как гражданского, так и военного назначения, а также к их помехозащищённости, живучести и эффективности применения постоянно повышаются, что и вынуждает специалистов искать всё новые решения при разработке подобных систем. Отдельные радиолокационные средства необходимо объединить в одну общую систему, и тогда они будут функционировать в одном масштабе времени. Такой подход называют *принципом многоканального построения* [293, 294].

Но тогда возникают проблемы чёткого совместного функционирования, которые трудно преодолеть. Для наиболее точного сопровождения современных объектов, обладающих возможностью быстро менять характеристики своего движения, растёт количество самих каналов сопровождения. Требуются всё большие объёмы сведений о них, а нужный объём информации можно получить только, если объединить все задействованные информационные каналы. В многопозиционных радиолокационных системах (МПРЛС) информация извлекается из пространственно разнесённых участков электромагнитного поля, излучаемого объектом наблюдения или источником помехи, и число таких участков может достигать до нескольких десятков.

Это позволяет намного качественнее, чем в однопозиционных РЛС, использовать информацию, содержащуюся в пространственной структуре электромагнитного поля, что, в свою очередь, помогает значительно повысить информативность и помехозащищенность всей системы наблюдения. Всё это позволяет рассматривать МПРЛС в качестве перспективной информационно–вычислительной системы, находящей применение в гражданских системах управления воздушным движением и в системах военного назначения [294].

Всё больше исследователей, в том числе за рубежом, посвящают свои труды алгоритмам вторичной обработки радиолокационной информации, чтобы повысить точность оценивания координат сопровождаемых объектов [291–308]. Такие алгоритмы принимают за основу фильтры Калмана, и реализуются на компьютере. Основная проблема, с которой сталкивается исследователь, это тот факт [295], что если принятая им модель нелинейной динамической системы, используемая в фильтре Калмана, включающая уравнения состояния, уравнения измерения и статистические характеристики шумов, *не адекватна реальной системе*, то в результате возрастания ошибок аппроксимации алгоритм фильтрации проявляет *тенденцию к расходимости*.

Общая теория применения алгоритмов фильтрации Калмана, при децентрализованной обработке координатной информации с обратной связью в многопозиционных системах, разработана Н.П. Богомоловым. Несмотря на то, что теория оптимальных методов статистической обработки информации в нелинейных задачах разработана достаточно хорошо, однако практическое применение результатов этой теории связано с большими трудностями. Поэтому на практике часто применяются приближённые *субоптимальные методы* статистической обработки информации [295]. Задачи сопровождения являются очень трудными на практике, поэтому используются *фильтры сопровождения*.

Фильтры сопровождения, являющиеся центральным элементом систем цифровой обработки радиолокационной информации, предназначены для обработки результатов измерений (дальности, азимута и угла места, скорости изменения дальности) и используются в интересах уменьшения ошибок измерений путём усреднения результатов измерений по времени; оценки скорости и ускорения целей; экстраполяции местонахождения цели. Задачи построения фильтров сопровождения относятся к области практического приложения *статистической теории фильтрации*, являющейся одним из направлений современной теории динамических систем.

Теория систем позволяет сформировать единый подход к анализу и разработке автоматических систем управления и связи. Особенностью этой теории является то, что в качестве концептуальных подходов в неё введены принцип динамического изменения переменных, характеризующих состояние систем, метод оптимального управления при чётко заданных возмущениях и входных воздействиях, описание информации, искаженной шумом, с помощью случайных процессов, и неопределенностей, касающихся параметров систем.

Для математического описания поведения, исследуемого физического объекта вводится понятие динамической системы. Предполагается, что система подчиняется принципу причинности, т. е. выходной сигнал при $t < t_0$ не зависит от входных воздействий, поступающих в момент времени $t = t_0$. Рассматриваются системы, работающие в дискретном или непрерывном времени. При этом они могут быть описаны соответственно разностными или дифференциальными уравнениями. Выходные сигналы систем могут изменяться либо в дискретные моменты времени, либо непрерывно. Вместо единственного разностного (дифференциального) уравнения высокого порядка в теории используются системы уравнений первого порядка, с которыми гораздо проще оперировать, если они представлены в векторной или матричной форме. В качестве зависимой переменной этого векторного уравнения выступает *вектор состояния системы*, который объединяет все представляющие интерес переменные параметры рассматриваемого физического объекта. Преобразование динамической системы с течением времени становится связанным с поступающими в неё сигналами и воздействующими шумами. В современной теории систем существует ещё одна характерная особенность, которая состоит в разработанном в ее рамках аппарате оптимального выбора входных сигналов для перевода системы из одного состояния в другое. Исходя из критериев оптимизации, делается определённый выбор, в качестве которого могут служить, например, минимум времени или минимум энергии, необходимые для перевода системы в заданное состояние.

В теории систем есть необходимость использования понятия вероятности и статистических методов. Детерминированная теория систем, по ряду причин, не позволяет с достаточной полнотой исследовать реальные системы.

Во-первых, ни одна математическая модель не может быть идеальной: нельзя полностью избежать приближений, неопределенных параметров, не учитываемых в модели эффектов и других неопределенностей.

Во-вторых, динамические системы находятся под воздействием не только входных команд, но и возмущений внешней среды. Надо учитывать несовершенство передаточного механизма команд. Эти неконтролируемые процессы не могут быть адекватно представлены детерминированными моделями. Наконец, датчики, выдающие информацию о системе, подвержены воздействию шума, вносят временные задержки; поэтому они не могут представить полную и неискаженную информацию о состоянии системы.

Эти причины обуславливают необходимость распространения положений теории динамических систем на стохастический случай, когда неопределённости и приближения моделируются с помощью случайных процессов. Наиболее сложной проблемой, возникающей при этом, является создание методического аппарата оптимального оценивания динамического состояния системы (на базе стохастических моделей и с учетом неполной, искаженной шумом информации датчиков). Проблема решается на основе теории оптимальной фильтрации.

Последние результаты исследований в области теории оптимального оценивания позволяют создавать *адаптивные* и *нелинейные* фильтры. Такие фильтры целесообразно использовать при сопровождении маневрирующих целей, а также при сопровождении целей на фоне ложных отметок, вызванных, например, отражениями от мешающих предметов.

Можно сделать вывод, что сопровождение маневрирующих целей – это задача не из лёгких, в связи с отсутствием точных сведений о движении объекта. Поэтому представляется целесообразным рассмотреть основные способы описания динамики маневрирующих целей более подробно.

15.2.2. Марковский подход

Спецификация задачи последовательного процесса принятия решений для полностью наблюдаемой внешней среды, с определённой моделью перехода и дополнительными вознаграждениями, носит название *Марковского процесса* принятия решений (англ. Markov decision process, MDP). Этот процесс служит математической основой для моделирования процесса принятия решения в ситуациях, где результаты являются частично случайными, и частично находятся под контролем лица, принимающего решения. Сегодня эта спецификация используется во множестве областей, включая робототехнику, автоматизированное управление, экономику и производство [296].

Марковская теория *оптимального оценивания случайных процессов* (МТО), представляет собой созданный на единой основе *Марковских* и *условных Марковских процессов* корректный векторно–матричный математический аппарат, базирующийся на основных положениях теории статистических решений. Аппарат МТО предназначен для проектирования и создания оптимальных радиотехнических систем (или близких к ним). Методы и алгоритмы МТО непосредственно ориентированы на применение цифровой, гибридной другой современной и перспективной технологии. Следует отметить, что МТО имеет широкую сферу применения, так как методы теории не требуют от рассматриваемых процессов того, чтобы векторы состояния, наблюдения, сигналов или помех были бы сами Марковскими процессами. На самом деле, методы МТО предъявляют к процессам гораздо менее жесткое требование: необходимо, чтобы векторы состояния и наблюдения лишь в совокупности образовывали векторный Марковский процесс [297].

Эти методы себя прекрасно зарекомендовали, как на уровне вторичной обработки данных, так и при первичной обработке сигналов. Это указывает на большие возможности исследования методов Марковской теории *оптимального оценивания случайных процессов* при разработке алгоритмов комплексной обработки информации. Однако для решения задачи комплексирования радиолокационного и радионавигационного методов сопровождения, всё– таки лучше использовать вторичную дискретную обработку информации, так как именно она осуществляется в современных вычислительных комплексах.

Работа любого алгоритма сопровождения основана на использовании некоторой модели движения цели. Основой всех моделей динамики объекта является тот или иной физический закон, описывающий способ движения. Объект, совершающий движение в соответствии с известным физическим законом, считается *не маневрирующим*. За маневр принимают внезапное изменение в характере движения объекта, под воздействием случайных, для неуправляемого объекта, или детерминированных, для управляемого объекта, сил. Общим уравнением движения маневрирующей цели является соотношение:

$$X(k+1) = F(k)X(k) + G(k)U(k) + V(k), \quad (15.45)$$

где $X(k)$ – вектор состояния динамического объекта; $U(k)$ – вектор управления; $G(k)$ – матрица интенсивности управления; $V(k)$ – белый шум с нулевым математическим ожиданием и матрицей ковариаций $Q(k)$.

Вектор управления $U(k)$ на практике не известен, поэтому возникает задача определения $U(k)$, решаемая с использованием двух предложений:

1. Вектор $U(k)$ считается случайным и описывается случайным процессом;
2. Вектор $U(k)$ считается детерминированным, заранее предопределённым процессом, и определяется, или оценивается, в реальном времени.

Исходя из статистических характеристик процессов, моделирующих маневр, случайный процесс управления может описываться белым шумом либо *автокоррелированной* (Марковской) последовательностью.

Функционирование реальных систем сопровождения требует оценки входного управляющего воздействия. При этом делается предположение о постоянстве управления на заданном промежутке времени (равном, как правило, интервалу дискретности модели). Оценка проводится по критерию минимума среднего квадратичного отклонения. Результат оценки используется для коррекции оценки вектора состояния объекта либо включается в вектор состояния для последующего оценивания состояния объекта.

15.2.3. Моделирование входного воздействия в виде белого шума

Предполагается, что фильтр сопровождения имеет заданный уровень шума [297]. Определение момента начала маневра происходит по возрастанию величины $e_v(k)$, рассчитываемой в соответствии с выражением:

$$e_v(k) = v^T(k) S^{-1}(k) v(k), \quad (15.46)$$

где $v(k)$ – вектор разности действительного и прогнозируемого измерений; $S(k)$ – матрица точности проведенных измерений.

Величина $e_v(k)$ имеет χ – квадратичное распределение с числом степеней свободы, равным размерности вектора измерения m . По достижении величиной $e_v(k)$ выбранного порога e_{max} , принимается решение об обнаружении маневра, и матрица $Q(k-1)$ пересчитывается, с помощью умножения её элементов на коэффициент ϕ . Тогда матрица $S(k)$ точности измерений принимает вид:

$$S(k) = H(k) [F(k-1)P(k-1)F^T(k-1) + \phi Q(k-1)] H^T(k) + R(k), \quad (15.47)$$

где $H(k)$ – матрица наблюдений размерностью $(n \times m)$; $P(k)$ – матрица ковариации ошибок оценивания $(n \times n)$; $R(k)$ – матрица шумов измерения $(m \times m)$.

Часто, вместо скалярной величины $e_v(k)$, используется набор значений для последовательных моментов времени, полученный с помощью детектора маневра в виде *скользящего окна*. Для селективного изменения элементов матрицы $Q(k)$ вместо коэффициента φ используется диагональная матрица Φ .

Рассмотрим более детально алгоритмы фильтрации, используемые для сопровождения в различных условиях. Базовый алгоритм сопровождения, представленный ранее, на практике требует доработки с учётом особенностей следующих, часто встречающихся, ситуаций сопровождения:

- а) одиночной цели (движущейся прямолинейно и (или) маневрирующей) в простых условиях (без мешающих отражений);
- б) одиночной цели на фоне отражений от местных предметов;
- в) двух целей, находящихся в непосредственной близости;
- г) группы целей, близких друг к другу.

При изменении ситуаций, задача сопровождения существенно усложняется в связи с возможностью принятия неправильных решений относительно принадлежности отметок (истинных или ложных) к траекториям. Другими словами, в дополнение к традиционной задаче оценивания параметров траектории одиночной цели нужно решать следующие задачи идентификации:

- 1) определение числа целей, подлежащих сопровождению и установлению динамики их движения (прямолинейный или маневренный полёт);
- 2) распознавание отметок от сопровождаемых целей, с последующим постоянным обновлением соответствующих траекторий.

Совместное решение задач оценивания и идентификации, как правило, осуществляется с помощью адаптивных фильтров, рассмотренных ранее.

Следует рассмотреть фильтры, играющие важную роль в современных системах сопровождения с измерением *радиальной скорости* целей.

15.2.4. Модель маневра цели Зингера

Более реальной моделью манёвра цели является его описание с помощью коррелированного (цветного) шума. Названная модель манёвра предложена Зингером, чьим именем и назван метод [298]. Рассмотрим его подход.

Согласно этой модели, ускорение наблюдаемой цели $\alpha(t)$ представляется в виде случайного процесса с математическим ожиданием равным нулю, и экспоненциальной автокорреляционной функцией вида:

$$R(\tau) = E[\alpha(t) \cdot \alpha(t + \tau)] = \sigma_m^2 e^{-\alpha|\tau|}, \quad (15.48)$$

где σ_m^2 – дисперсия ускорения; α^{-1} – постоянная времени автокорреляции.

При этом подходе, модель цели формируется сначала в непрерывном времени, а затем, с помощью стандартной процедуры дискретизации осуществляется переход к дискретной модели, что обеспечивает точное статистическое представление типового поведения цели. Для простоты изложения изучается одномерная модель, хотя существуют и многомерные модели (пространством измерений могут служить координаты x и y , дальность, угол места или азимут), что позволяет с точностью оценить характеристики сопровождения при различных комбинациях измеряемых параметров.

Дисперсия ускорения цели рассчитывается по формуле [298]:

$$\sigma_m^2 = \frac{\alpha_m^2}{3}(1 + 4p_m - p_0), \quad (15.49)$$

где α_m – максимальное значение ускорения цели; p_0 – вероятность того, что ускорение равно нулю; p_m – вероятность того, что ускорение равно α_m .

Нелинейная динамическая модель, соответствующая соотношению (15.48), представляет собой Марковскую последовательность первого порядка:

$$\dot{a}(t) = -\alpha a(t) + \tilde{v}(t), \quad (15.50)$$

которая управляет белым шумом с ковариацией:

$$E[\tilde{v}(t)\tilde{v}(\tau)] = 2\alpha\sigma_m^2\delta(t-\tau). \quad (15.51)$$

Существует ряд модификаций модели ускорения, описанной формулой (15.50), предназначенных для решения конкретных задач.

15.2.5. Модель ускорения цели Берга

Эта модель, предложенная Акселем Бергом [299], более точно описывает ускорение движущейся цели, совершающей координированный разворот. Динамика изменения ускорения в этом случае описывается уравнением:

$$\dot{a}(t) = -\alpha a(t) + \dot{a}^m(t) + \tilde{v}(t), \quad (15.52)$$

где $\dot{a}^m(t)$ – это среднее значение возмущения, рассчитываемое на основе оценок скорости и ускорения за последние k шагов.

Известна также модификация модели Берга, которая позволяет повысить точность сопровождения цели, совершающей координированный разворот

$$\dot{a}(t) = -\alpha a(t) + \alpha a^m(t) + \dot{a}^m(t) + \tilde{v}(t), \quad (15.53)$$

где $a^m(t)$ – среднее значение ускорения движущейся цели.

В работе [300] описан алгоритм сопровождения маневрирующей цели, ускорение которой изменяется в соответствии с выражением (15.53). В этом случае, динамика цели описывается следующим уравнением:

$$X_k = FX_{k-1} + \Gamma a_{k-1}^m(t) + L\dot{a}_{k-1}^m(t) + w_{k-1}, \quad (15.54)$$

$$\text{где } F = F(\Delta t) = \begin{vmatrix} E & \Delta t E & \tau^2 \left(-1 + \frac{\Delta t}{\tau} + e^{-\frac{\Delta t}{\tau}} \right) E \\ 0 & E & \tau \left(1 - e^{-\frac{\Delta t}{\tau}} \right) E \\ 0 & 0 & e^{-\frac{\Delta t}{\tau}} E \end{vmatrix}; \quad \Gamma = \begin{vmatrix} \left(\frac{\Delta t^2}{2} - \tau \left(-1 + \frac{\Delta t}{\tau} + e^{-\frac{\Delta t}{\tau}} \right) \right) E \\ \left(\Delta t - \tau \left(1 - e^{-\frac{\Delta t}{\tau}} \right) \right) E \\ \left(1 - e^{-\frac{\Delta t}{\tau}} \right) E \end{vmatrix}$$

$$E - \text{единичная матрица размерности } (3 \times 3); \quad L = \begin{bmatrix} \frac{\Delta t^3}{6E} & \frac{\Delta t^2}{2E\Delta t E} \\ \frac{6E}{2E\Delta t E} & \end{bmatrix}^T; \quad \tau = \frac{1}{\alpha} - \text{время}$$

корреляции манёвра; Δt – период дискретности рассматриваемой модели.

Матрицы Γ и L выводятся на основании соотношения:

$$a^m(t) = a_{k-1}^m(t) + a_{k-1}^m(t - (k-1)\Delta t), \quad (15.55)$$

для $(k-1)\Delta t \leq t \leq k\Delta t$.

Так как возмущение $a^m(t)$ определяется для скоростной системы координат, связанной с маневрирующей целью, а сопровождение ведется в прямоугольной системе координат, связанной с радиолокационной станцией, то возникает необходимость в преобразовании координат цели, и пересчёте вектора состояния, в соответствии с уравнением:

$$X_{R_k} = FX_{R_k} + \Gamma a_{R_k}^m(t) + L\dot{a}_{R_k}^m(t) + M(Z_{k-1})w_{k-1}, \quad (15.56)$$

где $M(Z_{k-1})$ – матрица преобразования координат:

$$M(Z_{k-1}) = \begin{vmatrix} m(Z_{k-1}) & 0 & 0 \\ 0 & m(Z_{k-1}) & 0 \\ 0 & 0 & m(Z_{k-1}) \end{vmatrix}.$$

$M(Z)$ – матрица перехода, устанавливающая связь между указанными системами координат с помощью углов Эйлера.

Ускорение цели в прямоугольной системе координат будет определяться через ускорение в скоростной системе координат, с помощью преобразования:

$$\begin{vmatrix} a_R^m(t) \\ a_R^m(t)_{k-1} \end{vmatrix} = \begin{vmatrix} m(Z_{k-1}) & 0 \\ 0 & m(Z_{k-1}) \end{vmatrix} \begin{vmatrix} a^m(t) \\ \dot{a}^m(t)_{k-1} \end{vmatrix}. \quad (15.57)$$

15.2.6. Алгоритм α – β фильтрации

В настоящее время широко используются способы оценки текущих координат и вектора скорости движения, в которых в текущий момент времени с помощью радиолокационной станции измеряют координаты и сглаживают параметры траектории с помощью α – β фильтра.

Это способ сопровождения траектории движущегося объекта [293], суть которого состоит в том, что на основе вычисления разности между текущими измерениями координат и их экстраполированными значениями (невязки измерения) и сравнения этой разности с пороговым значением, выявляется манёвр, после чего принимаются значения сглаживающих коэффициентов α и β , равными единице (алгоритм назван «альфа–бета алгоритм»).

Рассматриваемый алгоритм обеспечивает сглаживание и экстраполяцию траектории. При его использовании, настоящее значение оценки складывается путём анализа предыдущего и результата текущего измерения. Это алгоритм рекурсивного типа. С его помощью можно найти декартовы координаты объекта движения x, y, z . Далее показано нахождение x ; что же касается двух других координат (y и z), то они вычисляются аналогично.

$$x^S(k) = x^P(k) + \alpha [x^m(k) - x^P(k)], \quad (15.58)$$

$$\dot{x}^S(k) = \dot{x}^P(k) + \frac{\beta}{T} [x^m(k) - x^P(k)], \quad (15.59)$$

$$\dot{x}^P(k+1) = \dot{x}^S(k), \quad (15.60)$$

$$x^P(k+1) = x^S(k) + \dot{x}^S(k)T, \quad (15.61)$$

где $x^P(k)$ – экстраполированная координата на k -м цикле обзора; $x^S(k)$ – координата на выходе фильтра (сглаженная); $x^m(k)$ – измеренная координата; $\dot{x}^S(k)$ – значение скорости на выходе фильтра; $\dot{x}^P(k+1)$ – значение экстраполированной скорости на $(k+1)$ -м цикле обзора радиолокационной станции, T – период обзора РЛС; α и β – весовые коэффициенты фильтра.

Эти коэффициенты определяются выражениями:

$$\alpha = \frac{2(2\Delta k - 1)}{\Delta k(\Delta k + 1)}; \quad \beta = \frac{6}{\Delta k(\Delta k + 1)T}; \quad (15.62)$$

где Δk – количество периодов обзора, на протяжении которых происходит сопровождение траектории движения маневрирующего объекта.

Если увеличить k , то формулы принимают сокращённый вид:

$$\alpha = \frac{4}{\Delta k}; \quad \beta = \frac{6}{\Delta k^2 T}. \quad (15.63)$$

Когда цель движется не по прямой, а маневрирует, резко изменяя направление движения, то их значения откатываются до $k=1$, чтобы не потерять ведомый объект из-за воздействия экстраполяции координат, когда $k > 1$.

Недостаточная точность этого способа определяется тем, что при таком подходе к выбору сглаживающих коэффициентов учитывается только факт наличия маневра и не учитывается его интенсивность [301].

Таким образом, наличие в движении участков маневренного движения приводит к значительной ошибке в оценке текущих координат и вектора скорости движения, поскольку интенсивность маневрирования объекта, а, значит, и значения сглаживающих коэффициентов α и β , обеспечивающие наилучшее сопровождение цели, остаются неизвестными.

15.2.7. Построение модели экстраполятора на основе объединённого принципа максимума

Нахождение решения задачи сопровождения – это сложный, во всех отношениях, процесс. Для нахождения способов его решения был разработан новый подход, названный объединённым принципом максимума (ОПМ).

Предметное содержание этого подхода нашло выражение в применении к интегралу действия Гамильтона–Остроградского *игольчатой вариации* Л.С. Понтрягина. ОПМ позволил определить условия оптимальности, которые отличаются универсальностью, простотой и устойчивостью решений. Этот подход представляет собой дальнейшее развитие принципа максимума Л.С. Понтрягина, который применяется к объектам, движение которых, в свою очередь, подчиняется принципу Гамильтона–Остроградского [302].

После того, как объединённый принцип максимума стал применяться на практике, стало ясно, что с его помощью возможно добиться гораздо лучших решений, которые необходимы для дальнейшего повышения эффективности работы радиолокационных систем различного назначения. Актуальность и заинтересованность в новых решениях обусловлены необходимостью повышения эффективности РЛС в связи с неуклонным ростом маневренных возможностей космических, воздушных, морских и наземных объектов.

Общим для всех этих систем является то, что все они функционируют в условиях информационного конфликта и сложной помеховой обстановки [303].

В работе [304] проведен анализ эффективности решений, полученных на основе объединённого принципа максимума. Отмечается, что их общий недостаток, приводящий к снижению их эффективности при работе с маневрирующими целями, заключается в том, что в основе реализованных решений лежат разработанные ранее базовые соотношения, полученные из предположений о том, что оценки координат движения формируются на основе кинематических соотношений без учёта инерционности. Однако, для обеспечения гарантированно устойчивого высокоточного сопровождения современных маневрирующих целей требуются новые модели, подобные динамическим, синтез которых успешно реализуется на базе нового подхода.

В источниках [304 – 308] показано применение аппарата объединённого принципа максимума к задачам радиолокационного сопровождения и навигации. Его использование дало возможность получить результаты, которые определили кластер алгоритмов с новыми позициями определения параметров их работы. Их главная особенность – присутствие нелинейных структур.

Таким образом, рассматриваемые в [305] основополагающие принципы динамики помогают представить законы движения в виде дифференциальных уравнений, которые, в свою очередь, становятся частью оптимизационных задач при решении задач радиолокации и сопровождения цели. Однако равноправными являются и вариационные формулировки, устанавливающие стационарные свойства величин, зависящих от параметров системы [304].

Новый подход к получению условий оптимальности основывается на использовании инвариантных многообразий, в виде признака действительного движения нелинейной динамической системы, который определяется аналогом принципа Гамильтона—Остроградского или Гаусса. Получить необходимые условия оптимальности в виде принципа максимума, без введения вектора сопряженных переменных, что делает решение задачи синтеза оптимальных систем значительно проще, позволяет применение к этому интегралу метода *игольчатого варьирования*, предложенного Л.С. Понтрягиным [304].

В основе нового подхода к решению проблемы синтеза, изложенного в [304 – 307], лежит идея формирования области допустимых решений из множества, удовлетворяющего фундаментальным вариационным принципам.

Суть подхода состоит в следующем: на траектории истинного движения динамической системы элементарное приращение интеграла действия:

$$\delta R = \int_0^{t_1} (\delta T + \delta' A) dt = 0. \quad (15.64)$$

Здесь δ' – бесконечно малая величина, зависящая от вектора вариаций обобщенных координат. Она не представляет собой версию величины Δ .

$$\frac{d}{dt} \left(\frac{\partial T}{\partial \dot{q}_s} \right) - \frac{\partial T}{\partial q_s} = Q_s, \quad s = \overline{1, n}. \quad (15.65)$$

Ставится задача синтеза – найти обобщенную силу, как функцию текущих обобщенных координат и скоростей, дающую минимум целевому функционалу:

$$J_1 = \int_0^{t_1} F(q, \dot{q}) dt \rightarrow \min. \quad (15.66)$$

Методология решения поставленной задачи заключается в построении расширенного функционала, доставляющего минимальное значение:

$$J = J_1 + \lambda R \rightarrow \min. \quad (15.67)$$

Появляется необходимость в нахождении максимума функции обобщённой мощности [304–307], для нахождения наилучшего (оптимального) решения:

$$\Phi(q, \dot{q}, u) = \max_{Q \in \bar{G}_Q} \sum_{s=1}^n \left[\lambda Q_s + \frac{\partial F}{\partial \dot{q}_s} \right] \dot{q}_s, \quad (15.68)$$

где n – число степеней свободы нелинейной динамической системы; λ – множитель Лагранжа; Q_s – причинный фактор (управление); F – положительно определенная функция целевого функционала.

Если сравнивать метод Л.С. Понтрягина, в котором решение не может быть найдено практически во множестве важных случаях, и объединенный принцип максимума, то можно сделать однозначный вывод о том, что ОПМ обладает значительно большей универсальностью и простотой применения.

Универсальность метода заключается в принципиальной возможности применения аналитической формы выражения оптимального управления, при решении задачи синтеза для произвольных нелинейных динамических систем, удовлетворяющих принципу Гамильтона–Остроградского, и записанных виде системы дифференциальных уравнений второго порядка [304, 306].

Таким образом, можно сделать вывод, что применение объединённого принципа максимума (ОПМ) обеспечивает синтез управлений нелинейными динамическими системами, в том числе системами с заданным терминальным состоянием и в замкнутой форме функции наблюдаемого состояния [306].

Помимо того, его использование позволяет успешно решать трудно разрешимые на основе традиционных подходов задачи, что расширяет класс управлений принципиально новыми возможностями управления, не сводящимися к решениям принципа максимума Л.С. Понтрягина [304 – 307].

Если говорить о разработке моделей, используемых в радиолокационных станциях, то при применении этого метода, как указывается в работах [306, 307], будет происходить адаптация алгоритмов сопровождения и навигации к реально существующей динамике подвижного объекта.

Если рассматривать решение задачи синтеза систем обработки информации средств наблюдения, то применение объединённого принципа максимума проявляется в значительном увеличении устойчивости работы алгоритмов обработки. Использование такой методологии ОПМ позволяет получать новые, эффективные, экономичные в вычислительном плане алгоритмы, которые обеспечивают высокую скорость сходимости и точность оценивания [306, 307].

15.2.8. Применение объединённого принципа максимума в синтезе систем сопровождения и навигации

Для построения *адаптивных фильтров сопровождения* (ФС), применяются *кинематические модели движения* (КМД), которые описываются полиномом, коэффициенты которого являются параметрами траектории цели [302]. В таких кинематических моделях движения учитывается движение центра масс цели, без выявления причин, что определило их относительную простоту, и привело к широкому распространению. Но аппроксимация истинного закона движения, на ограниченном участке траектории, является причиной возникновения многих динамических ошибок, число которые возрастает в случае манёвра цели.

В связи с этим, для практического использования будет предпочтительнее использовать *динамические модели движения* (ДМД, в которых используются сведения об инерции движущегося объекта, а также силах, воздействующих на него), чем не слишком надёжные кинематические модели движения [302].

Возникает вопрос, почему же на практике их применяют не повсеместно? Проблема в их нелинейности. Чаще всего к ним прибегают для описания движения баллистических целей. Но разработка новых способов получения ДМД ведётся постоянно. За этим – будущее при решении задач сопровождения, учитывая разработку всё более сложных маневрирующих объектов.

Из всех путей разработки динамических моделей движения, отдельно стоит задача нахождения путей решения задачи сопровождения, как обратной задачи динамики. Для их решения и применяется подход объединённого принципа максимума, поскольку при любых отличиях построенной модели от реального движения объекта снижается точность систем наблюдения.

Модели движения маневрирующих целей на основе ОПМ [304–307] дающие следующую структуру динамического адаптивного экстраполятора, таковы:

$$\ddot{\hat{q}} = \frac{1}{2} \left[\frac{|\dot{\hat{q}}|\dot{\hat{q}}}{L|\hat{q}|} + R_{\varepsilon}^{-1}(y - \hat{q}) \right], \quad \hat{q}(t_0) = \hat{q}_0, \quad \dot{\hat{q}}(t_0) = \dot{\hat{q}}_0; \quad (15.69)$$

где a – коэффициент квадратичной формы кинетической энергии; $\hat{q}$ – оценка координат наблюдаемой РЛС; R_{ε} – интенсивность помех в канале наблюдений; L – константа кривой переключения; y – измерительная информация.

Путём преобразований, получается следующее выражение:

$$\hat{q}(k+1) = b\hat{q}(k) + c\hat{q}(k-1) + d \frac{\hat{q}^2(k-1)}{\hat{q}(k)} + \nu y(k), \quad (15.70)$$

где k – текущий момент времени; b, c, d, ν – постоянные коэффициенты.

Основное отличие нового алгоритма от алгоритмов, разработанных ранее, это присутствие у него нелинейности. При этом решение задачи синтеза фильтра сопровождения цели, с использованием объединённого принципа максимума и метода инвариантного погружения, имеет вид:

$$\dot{\hat{x}}(t) = f(\hat{x}) + PH^T R_{\varepsilon}^{-1} [y(t) - H\hat{x}]; \quad (15.71)$$

$$\dot{P} = P \frac{\partial f^T(\hat{x})}{\partial \hat{x}} + P \frac{\partial f(\hat{x})}{\partial \hat{x}} + GR_{\eta}G^T - PHH^T P; \quad (15.72)$$

где $P(0) = P^0$, $\hat{x}(0) = x^0$; $x = \begin{bmatrix} q \\ \dot{q} \end{bmatrix}$ – вектор состояния; $f(x(t), t) = \begin{bmatrix} \dot{q} \\ -\frac{|\dot{q}|\dot{q}}{aL|q|} \end{bmatrix}$ – функция

динамики, полученная на базе объединённого принципа максимума; R_{η} – матрица внешних воздействий; $H(\hat{x}(t), t)$ – известная вектор-функция наблюдения.

Главное отличие этих уравнений от разработанных ранее моделей состоит в наличии новой структурной функции $f(x(t), t)$.

Сказанное выше позволяет сделать вывод о том, что использование объединённого принципа максимума даёт наиболее приемлемые результаты.

Кроме того, применение ОПМ делает возможным получение и разработку новых, более точных алгоритмов для решения поставленных задач, что, в свою очередь, делает возможным решение таких задач сопровождения, которые не могли быть решены ранее при использовании старых подходов.

Нужно отметить, что при использовании рассматриваемой методологии, для синтеза динамических систем обработки радиолокационной информации обеспечивается адаптация алгоритмов сопровождения цели и навигации к наблюдаемой динамике подвижного объекта. При решении задачи синтеза систем обработки информации средств наблюдения адаптация проявляется в значительном увеличении устойчивости работы алгоритмов обработки.

Кроме того, использование методологии объединённого принципа максимума в задачах идентификации параметров движущегося объекта позволяет получить новые, экономичные в вычислительном плане, алгоритмы, обеспечивающие высокую скорость сходимости и точность оценивания [307].

Далее следует рассмотреть развитие подходов к синтезу структурно адаптивных фильтров сопровождения с использованием динамических моделей движения, на основе объединённого принципа максимума.

15.2.9. Применение адаптивного экстраполятора

Системы определения параметров движения объекта представляют собой *Калмановскую* структуру, состоящую из *экстраполятора* и взвешенного, с учётом ковариационной матрицы ошибок фильтрации, *дискриминатора*.

Экстраполятор определяется структурой переходной матрицы, которая, в свою очередь, построена на основе *кинематических моделей движения целей*, а они, как уже упоминалось ранее, структурно значительно отличаются от динамических моделей. Как уже упоминалось, это может привести к возникновению существенных ошибок, особенно при маневрировании цели.

При выборе используемой кинематической модели, доминирующим является статистический подход, и решение принимается на заданном классе моделей–претендентов, обладающих различными параметрами. Развитие этого подхода нашло отражение в решении сложной проблемы сопровождения маневрирующих целей, что привело к возникновению многомодельных алгоритмов фильтрации. Однако такие алгоритмы не получили широкой практической реализации из-за сложности процедуры выбора модели.

На сегодня отсутствуют конструктивные подходы и методы регулярного синтеза динамических моделей движения, пригодные для применения на практике. Вместе с тем, нужно обеспечить гарантированно устойчивое и высокоточное сопровождение современных летательных аппаратов, для чего необходимы новые модели, подобные, по своей структуре, динамическим моделям. Они определяют новый класс экстраполяторов в дискретном времени, которые, в сравнении с кинематическими моделями, обладают свойством структурной адаптации к истинной траектории движения [306].

Пользуясь фундаментальными положениями механики [305], получим:

$$\delta' R = \int_{t_0}^{t_1} (\delta T + \delta' A) dt = 0, \quad (15.73)$$

где δ – вариация кинетической энергии; $\delta' A$ – элементарная работа.

Интеграл действия будет иметь вид:

$$R = \int_{t_0}^{t_1} (T + A) dt, \quad (15.74)$$

а кинетическая энергия будет равна:

$$T = \frac{1}{2} \sum_{s=1}^n \sum_{k=1}^n a_{sk} \dot{q}_s \dot{q}_k. \quad (15.75)$$

При этом работа неизвестных обобщенных сил

$$A = \int_{q_s(t_0)}^{q_s(t_1)} \sum_{s=1}^n \left(U_s - \frac{\partial \Phi}{\partial \dot{q}_s} - \frac{\partial \Pi}{\partial q_s} \right) dq_s = \int_{q_s(t_0)}^{q_s(t_1)} \sum_{s=1}^n Q_s(q, \dot{q}, u) dq_s, \quad (15.76)$$

где q – вектор координат цели; u – вектор управлений; $t \in [t_0, t_1]$; a_{sk} – элементы матрицы квадратичной формы кинетической энергии; $\frac{\partial \Pi}{\partial q_s}$ – потенциальные обобщенные силы; U_s – управляющие обобщенные силы; $\frac{\partial \Phi}{\partial \dot{q}_s}$ – диссипативные обобщенные силы; n – число степеней свободы.

Представим уравнения движения маневрирующей цели в форме дифференциального уравнения второго порядка, согласно [305]:

$$\frac{d}{dt} \left(\frac{\partial T}{\partial \dot{q}_s} \right) - \frac{\partial T}{\partial q_s} = Q_s, \quad q(t_0) = q_0, \quad \dot{q}(t_0) = \dot{q}_0, \quad s = \overline{1, n}; \quad (15.77)$$

$$Q \in \bar{G}_Q. \quad (15.78)$$

При этом уравнение наблюдения будет выглядеть следующим образом:

$$y_s(t) = q_s(t) + \xi_s(t), \quad (15.79)$$

где ξ_s – непредсказуемые влияния на наблюдения с определённой частотой.

Вычислим целевой функционал при наблюдении:

$$J_1 = \frac{1}{2} \int_{t_0}^{t_1} \sum_{s=1}^n R_{\xi ss}^{-1} [y_s(t) - \hat{q}_s(t)]^2 dt; \quad (15.80)$$

где $R_{\xi ss}$ – элементы диагональной весовой матрицы, характеризующей значения интенсивности помех в канале наблюдений; знак $\wedge$ означает оценку.

Постановка задачи в данном случае связана с нахождением траектории $\hat{q}(t) \in R^n$ и вектора обобщенных сил Q как функции обобщенных координат, обеспечивающей минимальное значение целевого функционала (15.80) при выполнении ограничений, описанных выражениями (15.77) и (15.78).

Процесс нахождения минимума (15.80) при ограничениях (15.77) и (15.78) с учётом интеграла действия (15.74) требует применения метода неопределённых множителей Лагранжа, применение которого описано в [304, 305]:

$$J = J_1 + \int_{t_0}^{t_1} \lambda [T + A] dt; \quad (15.81)$$

где λ – неопределённый множитель Лагранжа; J_1 – целевой функционал при наблюдении, описанный ранее в выражении (15.80).

Решение задачи, поставленной выше для синтезирующей функции:

$$\mu_s = -\lambda \left| \frac{\dot{\hat{q}}_s}{L \hat{q}_s} \right|; \quad (15.82)$$

где L – константа кривой переключения, имеющая вид:

$$\ddot{\hat{q}}_s(t) = \frac{|Q_s|}{\lambda a_{ss}} \left[\lambda \frac{|\dot{\hat{q}}_s(t)| \dot{\hat{q}}_s(t)}{L_s |\hat{q}_s(t)|} + R_{\xi ss}^{-1} (y_s(t) - \hat{q}_s(t)) \right], \quad q_s(t_0) = q_{0s}, \quad \dot{q}_s(t_0) = \dot{q}_{0s}, \quad s = \overline{1, n}. \quad (15.83)$$

Применение конечномерной аппроксимации позволяет получить следующее выражение для аддитивного экстраполятора [306, 307]:

$$\hat{q}_s(k+1) = 2\hat{q}_s(k) - \hat{q}_s(k-1) + \frac{|\hat{q}_s(k) - \hat{q}_s(k-1)| \hat{q}_s(k) - \hat{q}_s(k-1)}{a_{ss} L \hat{q}_s(k)} + \frac{\Delta t^2}{a_{ss} R_{\xi ss}} (y_s(k) - \hat{q}_s(k)), \quad (15.84)$$

где k – момент времени; Δt – интервал дискретизации.

Применение предлагаемого подхода позволяет получить решение в замкнутой форме, и синтезировать эффективные фильтры сопровождения цели на основе нового класса экстраполяторов. Полученные фильтры сопровождения цели превосходят фильтры класса $\alpha - \beta$, не уступают фильтрам Калмана по параметрам точности, и обладают не слишком большой вычислительной сложностью, что даёт им дополнительное преимущество.

15.3. Исследование алгоритмов обработки информации на основе объединённого принципа максимума

В предлагаемом разделе показаны результаты исследований эффективности *фильтра сопровождения маневрирующей цели*, синтезированного на основе объединённого принципа максимума. Сравнение исследуемого фильтра с α – β фильтром, а также с *фильтром Калмана*, выполненного по методу Зингера, выполнено по критериям точности и объёму вычислительных затрат.

15.3.1. Задача обработки радиолокационной информации

Необходимо постоянно совершенствовать автоматизированные системы управления воздушным движением (АСУВД), а также входящие в них радиоэлектронные системы сопровождения (РЭСС). Научно–технические разработки во всём мире постоянно развиваются и совершенствуются. Возникает необходимость решать следующие проблемы [295, 303]:

1. Повышать точность, быстроту и надёжность сопровождения движущихся объектов с помощью систем радиоэлектронного сопровождения. Это означает, в техническом плане, расширение оценивания фазовых координат состояния.
2. Необходима разработка и применение новых, усложнённых алгоритмов экстраполяции, хотя бы таких, которые учитывают ускорение объекта.
3. По причине неточности отражённого сигнала при манёвре наблюдаемого объекта, его сопровождение становится труднее, из–за снижения соотношения сигнала и шума. Кроме того, возникают сложности из–за использования технологий уменьшения радиолокационной заметности и создания помех.

Всё это говорит о том, что задача улучшения характеристик по точности и защите от помех в радиоэлектронных системах сопровождения должна решаться с помощью использования совместной обработки информации, полученной от измерителей различной физической природы.

Алгоритмическое обеспечение, которое используется на современном этапе, не даёт полноценного и окончательного решения задачи сопровождения воздушного судна, поскольку, исходя из публикаций [301, 302, 304, 306, 307]:

- методы и алгоритмы сопровождения цели, которых требует реальная обстановка на практике, ещё не развиты, или развиты недостаточно;
- вопросы использования датчиков, в том числе, некоординатной информации, в радиоэлектронных системах слежения пока исследованы недостаточно;
- алгоритмы отличаются сложностью, и трудно применимы на практике.

Как элемент радиолокационной системы, система обработки информации непосредственно связана с источниками радиолокационной информации (РЛИ) и должна обеспечивать следующие технические возможности:

- отбрасывание различных шумов, и выделение среди них тех нужных сигналов, которые дают реальную информацию о воздушном объекте (ВО);
- определение параметров отраженных сигналов от воздушного объекта;
- соединение полученных сигналов в траектории движения воздушных объектов, а также нахождение их определяющих факторов;
- селекцию траекторий воздушных объектов по их важности;
- формирование обобщенной воздушной обстановки.

Сложность системы обработки радиолокационной информации, и слишком большое количество реализуемых этой системой различных функций, которые необходимы для поэтапной переработкой больших информационных потоков данных, затрудняет формализацию и анализ её работы в целом. Поэтому целесообразно выполнить разбиение процесса обработки радиолокационной информации на функционально законченные операции (этапы). Процесс обработки РЛИ, можно условно разбить на несколько этапов [295]:

1. *Первичная* обработка радиолокационной информации: обнаружение отражённых от воздушных объектов сигналов; создание радиолокационных отметок; определение (оценка) координат радиолокационных отметок.

2. *Вторичная* обработка радиолокационной информации: обнаружение и формирование траекторий воздушных объектов; вычисление начальных значений параметров траекторий воздушных объектов; сопровождение их траекторий путём отбора новых отметок для продолжения траекторий.

3. *Третичная* обработка радиолокационной информации: объединение данных, сформированных несколькими источниками РЛИ, имеющими общую систему вторичной обработки информации систем сопровождения.

Так, модель радиолокационной обстановки, модель пространственно–временного сигнала и шума, а также модель обработки представляют собой этап первичной обработки. Задача сопровождения траекторий воздушных объектов является составной частью этапа вторичной обработки радиолокационной информации. Задача сопровождения траекторий воздушных объектов, по своей сути, является статистической задачей обработки совокупностей сигналов и различного рода шумов. Исторически сложилось два варианта возможного решения такой задачи: одноцелевое и многоцелевое направления.

Процесс обработки радиолокационной информации показан на рис. 15.7.




Рисунок 15.7. Модель процесса обработки радиолокационной информации

При *одноцелевой обработке* радиоэлектронной информации (ещё на этапе вторичной обработки) отдельно рассматривается каждая отметка. Используя определенные решающие правила, принимается решение о привязке её к одной из всей совокупности траекторий. Часто, в качестве истинного значения, принимается измеренное значение (отметка), ближайшее к прогнозируемому.

При *многоцелевой обработке*, рассмотрению подлежат одновременно все отметки в зоне ответственности источника радиолокационной информации, а также все сопровождаемые траектории (или их некоторая совокупность).

Развитию *одноцелевого подхода*, при обнаружении и сопровождении траекторий воздушных объектов, посвящено множество работ, в которых получены новые практические результаты – алгоритмы, реализованные в существующих системах вторичной обработки радиолокационной информации. Главным достоинством одноцелевого подхода является тот факт, что при его использовании алгоритмы обнаружения и сопровождения траекторий воздушных объектов достаточно просты, и могут быть реализованы на вычислительных средствах ограниченной производительности. Сегодня одноцелевое направление можно считать сложившимся и получившим каноническую форму.

Задача сопровождения траекторий воздушных объектов при *многоцелевой обработке* характерна для обзорных радиолокационных систем, работающих: при высоком уровне помех; в случае наблюдения нескольких воздушных объектов, когда расстояния между ними имеют тот же порядок, что и дисперсия их расчётных положений (в случае групповых ВО); в условиях недостаточной разрешающей способности; в условиях пересекающихся траекторий и т.д.

Методы и алгоритмы обнаружения и сопровождения траекторий [304] ВО многоцелевой обработки намного превосходят одноцелевые аналоги [306, 307]. Разработка эффективных методов и алгоритмов обнаружения и сопровождения траекторий движущихся воздушных объектов с использованием многоцелевого подхода является одной из актуальных задач современной радиолокации.

15.3.2. Анализ качества функционирования алгоритма объединённого принципа максимума в зависимости от входящих параметров в задачах навигации и сопровождения

Для оценки эффективности функционирования предложенного фильтра, использующего объединённый принцип максимума, а также для сравнения исследуемого фильтра с α – β фильтром, а также с фильтром Калмана по Зингеру, по критериям точности и объёму вычислительных затрат, была разработана компьютерная программа. Учитывая сведения из работы [308] было проведено математическое моделирование в среде MathCAD.

Использовались следующие обозначения: R —это вектор начальных данных, $N_0 = \text{rows}(R)$ —количество отсчётов в файле ($N_0 = 78$), $iR = 1, \dots, N_0 - 2$, $\text{taimer}_{iR} = t_{iR} - R_{iR,0}$ —время (в секундах), $\text{Azimuth}_{iR} = R_{iR,1}$ — параметр азимута (в градусах), $\text{Ugol}_{iR} = R_{iR,2}$ — параметр угла места (в градусах), $dt_{iR} = \text{taimer}_{iR} - \text{taimer}_{iR}$.

Результаты математического моделирования приведены далее.

15.3.2.1. Реализация алгоритмов фильтров

В программе были рассмотрены реализации в зависимости от различных входящих параметров, следующих алгоритмов фильтрации:

Алгоритм α – β (Альфа–Бета) фильтра:

$$\hat{x}\left(\frac{k}{k}\right) = \hat{x}\left(\frac{k}{k}-1\right) + \begin{bmatrix} a_x & 0 \\ \beta_x/T & 0 \\ 0 & a_y \\ 0 & \beta_y/T \end{bmatrix} \left[z(k) - H(k) \hat{x}\left(\frac{k}{k}-1\right) \right], \quad (15.85)$$

где вектор состояния цели принимает вид: $x(k) = [x(k) \quad \dot{x}(k) \quad y(k) \quad \dot{y}(k)]^T$.

$$\frac{\sigma_{\dot{x}}^2}{\sigma_w^2} = \frac{2\alpha^2 - 3\alpha\beta + 2\beta}{\alpha(4 - 2\alpha - \beta)}; \quad \frac{\sigma_{\dot{x}\dot{x}}}{\sigma_w^2} = \frac{\beta(2\alpha - \beta)}{T\alpha(4 - 2\alpha - \beta)}; \quad (15.86)$$

$$\frac{\sigma_{\dot{x}}^2}{\sigma_w^2} = \frac{2\beta^2}{T^2\alpha(4 - 2\alpha - \beta)}; \quad \frac{\sigma_{\dot{x}_0}^2}{\sigma_w^2} = \frac{2\alpha^2 + \alpha\beta + 2\beta}{\alpha(4 - 2\alpha - \beta)}; \quad (15.87)$$

где $\sigma_{\dot{x}}^2, \sigma_{\dot{x}}^2, \sigma_{\dot{x}_0}^2$ — дисперсии координаты, скорости и экстраполяции; $\sigma_{\dot{x}\dot{x}}$ — корреляционный момент; σ_w^2 — дисперсия измерений радиолокационной станции.

Алгоритм фильтра Калмана по Зингеру:

$$\hat{x}\left(k + \frac{1}{k}\right) = \Phi(T, \alpha) \hat{x}\left(\frac{k}{k}\right), \quad (15.88)$$

$$\hat{x}\left(\frac{k}{k}\right) = \hat{x}\left(\frac{k}{k}-1\right) + P\left(\frac{k}{k}-1\right) \hat{H}^T \left[HP\left(\frac{k}{k}-1\right) \hat{H}^T + \sigma_R^2 \right]^{-1} \times \left[y(k) + H\hat{x}\left(\frac{k}{k}-1\right) \right], \quad (15.89)$$

где обозначено: $\hat{x}\left(\frac{k}{k}\right)$ – оптимальная (по критерию минимальной средней квадратичной ошибки) оценка $x(k)$ по всем предыдущим данным измерителя, включая и последнее k -е значение (фильтрация), $\hat{x}\left(\frac{k+1}{k}\right)$ – оптимальная (по критерию минимальной средней квадратичной ошибки) оценка, $x(k+1)$ по всем предыдущим данным измерителя, включая и последнее k -е значение (предсказание на шаг вперед). Матрицы $P\left(\frac{k}{k}\right)$ и $P\left(\frac{k}{k}-1\right)$ являются ковариационными матрицами ошибок фильтрации и ошибок предсказаний на шаг вперед. Эти матрицы удовлетворяют рекуррентным уравнениям:

$$P\left(\frac{k}{k}-1\right) = \Phi(T, \alpha) P\left(\frac{k-1}{k-1}\right) \Phi^T(T, \alpha) + Q(k), \quad (15.90)$$

$$P\left(\frac{k}{k}\right) = P\left(\frac{k}{k}-1\right) - P\left(\frac{k}{k}-1\right) \hat{H}^T \left[HP\left(\frac{k}{k}-1\right) \hat{H}^T + \sigma_R^2 \right]^{-1} \times HP\left(\frac{k}{k}-1\right). \quad (15.91)$$

Матрица $Q(k)$ является ковариационной матрицей, возбуждающей функции $u(k)$ входа, которая имеет следующий вид:

$$Q(k) = E \left[u(k) u^T(k) \right] = 2\alpha \sigma_M^2 \begin{vmatrix} q_{11} & q_{21} & q_{31} \\ q_{12} & q_{22} & q_{32} \\ q_{13} & q_{23} & q_{33} \end{vmatrix}, \quad (15.92)$$

где обозначено:

$$q_{11} = \frac{1}{2\alpha^5} \left[1 - e^{-2\alpha T} + 2\alpha T + \frac{2\alpha^3 T^3}{3} - 2\alpha^2 T^2 - 4\alpha T e^{-\alpha T} \right], \quad (15.93)$$

$$q_{12} = \frac{1}{2\alpha^4} \left[e^{-2\alpha T} + 1 - 2e^{-\alpha T} + 2\alpha T e^{-\alpha T} - 2\alpha T + \alpha^2 T^2 \right], \quad (15.94)$$

$$q_{13} = \frac{1}{2\alpha^3} \left[1 - e^{-2\alpha T} - 2\alpha T e^{-\alpha T} \right], \quad (15.95)$$

$$q_{22} = \frac{1}{2\alpha^3} \left[4e^{-\alpha T} - 3 - e^{-2\alpha T} + 2\alpha T \right], \quad (15.96)$$

$$q_{23} = \frac{1}{2\alpha^2} \left[e^{-2\alpha T} + 1 - 2e^{-\alpha T} \right], \quad (15.97)$$

$$q_{33} = \frac{1}{2\alpha} \left[1 - e^{-2\alpha T} \right]. \quad (15.98)$$

А также алгоритм объединённого принципа максимума:

$$q_{k+1} = q_k + \frac{(q_k - q_{k-1})(t_{k+1} - t_k)}{t_k - t_{k-1}} - \frac{(q_k - q_{k-1})^2 \text{sign}(q_k - q_{k-1})(t_{k+1} - t_{k-1})(t_{k+1} - t_k)}{\lambda L q_k (t_k - t_{k-1})^2} - N^{-1} (t_{k+1} - t_{k-1})(t_{k+1} - t_k)(q_k - y). \quad (15.99)$$

15.3.2.2. Результаты математического моделирования исследуемых алгоритмов

На рис. 15.8 – 15.25 показаны графики сравнения качества работы алгоритмов, в зависимости от входящих параметров, и рассмотрена динамика изменения точности оценок. Приведены сравнения ошибок, возникающих при реализации алгоритмов. Среднеквадратическая ошибка оценки координат цели используется в качестве показателя точности. На представленных рисунках рассмотрены четыре исходных набора данных.




Рисунок 15.8. Первый набор исходных данных




Рисунок 15.9. Ошибки первого набора исходных данных




Рисунок 15.10. Второй набор исходных данных




Рисунок 15.11. Ошибки второго набора исходных данных




Рисунок 15.12. Третий набор исходных данных




Рисунок 15.13. Ошибки третьего набора исходных данных




Рисунок 15.14. Четвёртый набор исходных данных




Рисунок 15.15. Ошибки четвёртого набора исходных данных




Рисунок 15.16. Сравнение функций фильтров, часть 1




Рисунок 15.17. Сравнение функций фильтров, часть 2




Рисунок 15.18. Сравнение ошибок фильтров, часть 1




Рисунок 15.19. Сравнение ошибок фильтров, часть 2




Рисунок 15.20. Сравнение ошибок фильтров, часть 3




Рисунок 15.21. Сравнение ошибок

Проанализировав данные, представленные на рис. 15.8 – 15.21, можно утверждать, что исследуемый фильтр сопровождения маневрирующей цели, описанный выражением (15.84), полученный на основе ОМП (объединённого принципа максимума), значительно превышает точность α - β фильтра, а также фильтра Зингера, уже на этапе манёвра динамического объекта.

Анализируя результаты математического моделирования представленного фильтра сопровождения с использованием ОПМ на основе математических моделей (15.84) и (15.99), опираясь на публикацию [306], можно сделать вывод, что по сравнению, например, с $\alpha - \beta$ фильтром, исследуемый фильтр ОПМ на этапе маневра обеспечивает уменьшение среднеквадратичного отклонения, в среднем на 30%. Для тех случаев, когда движение происходит прямолинейно и равномерно, то результаты моделирования оценки среднеквадратичного отклонения (СКО) фильтра, выполненного на базе модели ОПМ, по средним значениям, примерно совпадают с оценками $\alpha - \beta$ фильтра.

В работе [307] указывается, что описываемый фильтр работает при гораздо меньших затратах вычислительных ресурсов, а конкретнее, то на один цикл фильтра ОПМ приходится 38 элементарных математических операций, а один цикл $\alpha - \beta$ фильтра требует выполнения 72 элементарных операций.

По данным из тех же источников [306 и 307], подсчёт элементарных операций для других сравниваемых фильтров показывает следующее: для реализации фильтра Калмана с моделью Зингера необходимо совершить 215 элементарных операций, а для разработанного авторами фильтра ОПМ – всего 73 элементарных операции. Результаты математического моделирования позволяют утверждать, что исследуемый фильтр, описываемый математической моделью (15.84), отвечает на маневрирование цели с большей скоростью, и выигрывает в точности по сравнению с фильтрами Калмана, выполненными по модели Зингера, что объясняется применением нового экстраполятора с эффектом структурной адаптации. Практическая реализация разработанного авторами фильтра ОПМ потребует вычислительных затрат объёмом в 2,9 раза меньшим, в сравнении с фильтром Калмана, выполненным по модели Зингера.

Приведенные результаты исследований свойств фильтра сопровождения маневрирующей цели, полученного на основе ОПМ и описывающегося формулой (15.84) показали его существенные преимущества перед фильтром $\alpha - \beta$ и фильтром Калмана, выполненным по модели Зингера, по критерию минимума вычислительных затрат. На этапе манёвра явно просматривается преимущество в точности фильтра ОПМ, и перед фильтром $\alpha - \beta$, и перед фильтром Калмана, выполненным по модели Зингера.

Таким образом, применение в радиолокационных станциях фильтра, выполненного на основе объединённого принципа максимума, позволяет обеспечить устойчивое высокоточное сопровождение маневрирующих целей при значительном сокращении вычислительных затрат.

15.3.3. Применение экстраполятора в задачах о разделении цифровых потоков при контроле радиоэлектронной обстановки

Для успешной реализации задача контроля радиоэлектронной обстановки необходимо разделить цифровые потоки принимаемых сигналов. Иногда в пределах видимости радиолокационной станции находится множество объектов, у которых очень похожие частотные характеристики, и тогда для их разделения нужны другие пространственные признаки, которые будут способны учитывать их движения. Это приобретает особую важность, если, вследствие того, что объект движется не прямолинейно, а нелинейно, возникающие ошибки при измерении данных приближаются к динамическим ошибкам.

Актуальность решения этой задачи связана с тем, что в нынешних радиолокационных станциях для разделения сигналов используются антенные системы с узкими диаграммами направленности. Они обеспечивают *Релеевское разрешение* по пространству, в совокупности со статистической обработкой потоков импульсов. Среди их главных недостатков выделяются низкое разрешение по пространству групповых целей, слишком небольшое количество статистически разделяемых импульсных потоков и низкое быстродействие, связанное с необходимостью медленного сканирования по пространству [295].

Можно утверждать, что решением задачи разделения цифровых потоков может стать применение, в качестве параметра разрешения сигналов, *пеленга пространства*, а разделение цифровых потоков на практике имеет в основе методы кластерного анализа [306, 307]. Задача кластеризации требует учёта двух моментов: *первый* – предполагает необходимость производить разработку алгоритма кластеризации по специальному критерию, определяющемуся статистикой набега фазы импульса сигнала, отличающейся от гауссовой, и метрикой амплитудно–фазовых распределений множества источников импульсных сигналов, формируемых фронтами излучений [306, 307]. *Второй* момент связан с тем, что среди множества объектов присутствуют быстрые и манёвренные, что вносит динамические ошибки при определении пеленгов.

К примеру, при скорости ~ 40 узлов динамическая ошибка определения пространственной координаты, за несколько периодов обзора $T=25$ с, достигает 500 м, а на расстоянии до цели 10 км – $2,5^\circ$ по азимуту. Это говорит о том, что в некоторых случаях динамические ошибки пеленга становятся сравнимыми со случайными ошибками, что при последующем использовании *методов сверхразрешения* с прореживанием данных может привести к существенным ошибкам и появлению ложных максимумов [306, 307].

Во время движения исследуемого воздушного объекта, при осуществлении кластеризации, на первое место выходит проблема определения оценки смещения центра кластера [306]. Однако, если решать эту задачу с помощью *алгоритмов скользящего среднего*, то решение будет не самым лучшим [307].

В этом случае строится предположение, объясняющее принцип движения объекта. Однако, на практике выдвинутая гипотеза может не соответствовать действительности. Сложность реализации алгоритмов скользящего среднего заключается в отсутствии адекватной модели движения кластера [308].

Можно утверждать, математическое моделирование показывает, что представленный алгоритм ОПМ (15.84) *оценки смещения пеленга* позволяет получить уменьшение среднеквадратичной ошибки, при определении центра кластера, до 35 % по сравнению с оценками скользящего среднего [306, 307].

Таким образом, применение представленного алгоритма на основе ОПМ (15.84), несомненно, обладает значительным преимуществом. На рис. 15.22 показан описываемый процесс определения пеленга, данные для которого получены на основе проведённого математического моделирования.




Рисунок 15.22. Результаты математического моделирования

Можно сделать вывод, что применение разработанного экстраполятора в задачах о разделении цифровых потоков лучше реализовывать в два этапа. Вначале, на основе *алгоритма скользящего среднего* формируется матрица близости, чтобы предварительно рассчитать центр кластера и формирование его элементов, а затем оценка центра кластера осуществляется в соответствии с алгоритмом, описываемым математической моделью (15.84).

В представленном проекте был проведён анализ различных методов динамической оценки данных, на основе которого был представлен новый подход к синтезу экстраполяторов для широкого класса объектов, движение которых подчинено вариационному принципу Гамильтона–Остроградского.

Разработан шаговый динамический экстраполятор, в форме, пригодной для практической реализации в радиолокационных станциях – современных системах контроля радиоэлектронной обстановки, на основе объединённого принципа максимума. Разработанный подход к синтезу экстраполяторов учитывает динамический характер движения объекта. Экстраполятор может быть использован для решения широкого круга задач, таких как задачи сопровождения и навигации летательных аппаратов, как управляемых пилотом, так и беспилотных, для декомпозиции цифровых потоков и других.

Для анализа эффективности представленного фильтра было проведено математическое моделирование в среде MathCAD, на основе которого был выполнен анализ эффективности функционирования разработанного экстраполятора в задачах обработки радиолокационной информации.

Анализ эффективности функционирования экстраполятора показывает, что в условиях маневрирования динамических объектов и возмущений измерительного процесса он обеспечивает повышение точности определения параметров движения объектов на 5 – 10%, при решении задач навигации и сопровождения при низком уровне вычислительных затрат (30 % базового).

Таким образом, цель исследования полностью достигнута: разработан новый алгоритм оценки параметров движения в задачах сопровождения цели, обеспечивающий повышение точности и снижение затрат на его реализацию.

При этом решены задачи, поставленные техническим заданием:

- проведен анализ существующих методов и моделей динамической оценки данных и разработанных на их основе алгоритмов оценки параметров движения;
- приведено математическое обоснование процесса синтеза алгоритмов на основе объединенного принципа максимума Понтрягина;
- разработан динамический экстраполятор функций в форме, пригодной для реализации в современных системах контроля радиоэлектронной обстановки;
- выполнен анализ эффективности функционирования предлагаемого алгоритма на основе числового моделирования.

16. БЕЗОПАСНОСТЬ ИНТЕЛЛЕКТУАЛЬНЫХ ИНФОРМАЦИОННЫХ СИСТЕМ БЕСПИЛОТНЫХ ТРАНСПОРТНЫХ СРЕДСТВ

Компьютеры, лежащие в основе интеллектуальных систем вождения транспортных средств, имеют специализированные процессоры, настроенные на выполнение большого количества вычислений, нужных для обеспечения своевременного принятия решений и управления системами беспилотного автомобиля [309]. У рядового водителя (и пешехода) этот факт вызывает беспокойство. Похожее чувство обычные люди испытывали при упоминании суперкомпьютеров в 80–е годы прошлого века [310]. При этом, современные суперкомпьютеры, по производительности, многократно превосходят системы, на которых сегодня строятся беспилотные автомобили. Интеллектуальные информационные системы для беспилотного движения – только один пример вычислительной системы, находящейся внутри современного автомобиля.

Современный автомобиль содержит множество электронных систем, независимо от того, является ли он беспилотным транспортным средством, или управляется человеком. Так, в автомобиле находится один или несколько электронных блоков управления (ЭБУ): это электронные блоки управления двигателем, трансмиссией, климатом, безопасностью, и др. Количество таких блоков зависит от марки и модели автомобиля, и оно продолжает расти, поскольку покупатели автомобилей заинтересованы в наличии большого количества вспомогательных функций, в том числе таких, как контроль движения в полосе, самостоятельная парковка, бесключевой доступ, и прочее.

В тоже время, каждое новое электронное устройство, внедряемое в автомобиль, является потенциально слабым и уязвимым местом в отношении кибербезопасности. Так, недавняя официальная новость от компании «BMW», о введении абонентской платы за использование некоторых функций автомобилей [311] стала чем–то вроде «красной тряпки» для сообщества автомобилистов, что, в свою очередь, обязательно приведёт к попыткам обхода программных блокировок. А так как количество электронных устройств, задействованных в управлении современным транспортным средством, будет только возрастать, то надёжное обеспечение кибербезопасности автомобиля становится все более актуальной задачей, которая должна найти своё решение.

Скептицизм относительно возможности использования на дорогах общего пользования полностью автономных беспилотных автомобилей возникает из поиска решений моральных дилемм, а также отсутствия на данный момент действующего успешного примера использования искусственного интеллекта. Здесь необходимо дополнительно уточнить, что имеется в виду, когда речь идет о настоящих беспилотных автомобилях [312].

16.1. Уровни автоматизации беспилотных автомобилей

Существует пять уровней автоматизации беспилотных транспортных средств, а также нулевой уровень, в котором любая автоматизация отсутствует.

Беспилотные автомобили, о которых скептики ведут столько споров – это те транспортные средства, в которых искусственный интеллект управляет автомобилем полностью самостоятельно, и во время вождения никакой помощи со стороны человека нет. То есть, беспилотные автомобили, вызывающее сомнения у скептиков, представляют собой автономные транспортные средства, полностью управляемые ИИ, без какого-либо вмешательства в работу систем со стороны человека–водителя, который мог бы их контролировать [313].

Если рассматривать уровни автоматизации транспортных средств (ТС) (рис. 16.1), то беспилотными автомобилями можно считать те, которые входят в *четвёртый* и в *пятый* уровни. Если автомобиль требует участия в управлении человека–водителя, то он рассматривается на *втором* или на *третьем* уровне автоматизации, что продемонстрировано на рис. 16.1.



Рисунок 16.1. Уровни автоматизации автомобиля

Уровень 0 (полное отсутствие автоматизации вождения). Большинство автомобилей на дорогах сегодня находятся на уровне автоматизации 0, то есть являются транспортными средствами с исключительно ручным управлением. Человек–водитель самостоятельно выполняет динамическую задачу вождения, хотя в таком автомобиле могут существовать помогающие ему системы. Примером служит система экстренного торможения, но, поскольку технически она не управляет автомобилем, то автоматизированной не считается.

Уровень 1 (помощь водителю). Это самый низкий уровень автоматизации. Автомобиль оснащен одной–единственной автоматизированной системой помощи водителю, такой, как рулевое управление, или ускорение (круиз–контроль). Адаптивный круиз–контроль, позволяющий автомобилю держаться на безопасном расстоянии позади предыдущего автомобиля, относится к первому уровню автоматизации, поскольку человек–водитель контролирует другие аспекты вождения, такие, как управление и торможение.

Уровень 2 (частичная автоматизация вождения) включает в себя такие системы, как передовые системы помощи водителю или ADAS (Advanced Driver Assistance System) [314]. С этим уровнем автоматизации, автомобиль может автоматически контролировать рулевое управление, а также ускорение / замедление. На втором уровне автоматизация не может рассматриваться, как достаточная для самостоятельного вождения, поскольку человек находится на водительском месте и должен быть готовым в любой момент взять управление автомобилем на себя. Ко второму уровню автоматизации относятся такие системы, как Tesla Autopilot и Cadillac (General Motors) Super Cruise [315].

Уровень 3 (условная автоматизация вождения). Переход от уровня 2 к уровню 3 является значительным с технологической точки зрения, хотя для человека он едва заметен. Автомобили 3–го уровня обладают возможностями обнаружения окружающей среды, и их система управления самостоятельно может принимать обоснованные решения, например, ускориться, опережая медленно движущийся предыдущий автомобиль. Но они, все ещё, требуют контроля со стороны человека. Водитель должен оставаться бдительным и готовым взять управление на себя, если система не сможет выполнить задачу. К примерам третьего уровня автоматизации транспортных средств можно отнести системы управления, включенные во флагманский седан компании Audi (Volkswagen), представленный в 2019 году [316].

Автомобиль оснастили системой Traffic Jam Pilot, которая сочетает в себе лазерный сканирующий дальномер с передовыми датчиками и вычислительной мощностью (плюс встроенные резервные системы на случай отказа одного из компонентов). Автомобиль Audi A8L стал первым в мире серийно выпускаемым транспортным средством, имеющим третий уровень автоматизации.

Уровень 4 (высокая степень автоматизации вождения). Ключевое различие между автоматизацией уровня 3 и уровня 4 заключается в том, что автомобили уровня 4 способны вмешиваться в процесс управления, в том числе, способны самостоятельно принимать решения в критических ситуациях, или в случае отказа систем. В этом смысле, такие автомобили, в большинстве случаев, не требуют вмешательства человека – водителя. Однако у человека, все ещё, есть возможность вручную отменить решение, принятое системой управления.

Автомобили четвертого уровня могут работать в режиме самостоятельного вождения. Но до тех пор, пока не разовьется соответствующее законодательство и инфраструктура, они могут делать это только в пределах ограниченной территории (обычно в городской среде, где максимальная скорость достигает, в среднем, 60 километров в час). Этот процесс известен, как *геозонирование (геофенсинг)*. Поэтому большинство существующих автомобилей четвертого уровня предназначены для комбинированных поездок, с управлением как человеком – водителем, так и с интеллектуальной системой управления. Среди автомобильных компаний, работающих в направлении обеспечения систем управления автомобилями четвертого уровня автономности, следует выделить:

- *NAVYA* – французскую компанию, которая уже строит и продает в США *шаттлы* и *такси* с четвертым уровнем автоматизации, работающие полностью на электричестве, и развивающие максимальную скорость до 55 миль / час [317].
- *Waymo* – компанию, принадлежащую *Alphabet*, которая представила сервис самодвижущихся такси 4-го уровня в США, в штате Аризона, где она тестировала беспилотные автомобили без водителя на сиденье в течение более года, которые самостоятельно проехали более 10 миллионов миль [317].
- *Magna*, канадского поставщика автомобилей, разработавшего технологию MAX4 для обеспечения возможностей четвертого уровня автоматизации, как в городских условиях, так и на шоссе. Magna сотрудничает с компанией Lyft, поставляя высокотехнологичные комплекты, позволяющие переоборудовать обычные автомобили для их использования в качестве беспилотных.

- *Volvo* и *Baidu*, объявивших стратегическое партнерство для совместной разработки электромобилей четвертого уровня автоматизации для обслуживания рынка роботакси в Китае и других странах Юго–Восточной Азии.

Уровень 5 (полная автоматизация вождения). Автомобили пятого уровня вообще не требуют внимания человека – динамическая задача вождения отпадает. У автомобилей этого уровня не должно быть даже рулевого колеса, или педалей ускорения / торможения. Транспортные средства такого уровня автоматизации будут свободны от *геозон*, смогут ехать куда угодно, и выполнять все те операции, которые может сделать опытный водитель–человек.

Таким образом, после уточнения терминологии и понимания сути автоматизации транспортных средств, необходимо рассмотреть источники угроз кибербезопасности современных автомобилей, оснащенных компьютерами, и, в особенности, новым беспилотным автомобилям и другим транспортным средствам, использующим методы искусственного интеллекта.

16.2. Беспилотные автомобили и уязвимости их кибербезопасности

В соответствии с приведенной градацией уровней автоматизации транспортных средств, можно сделать вывод, что наиболее восприимчивыми к кибератакам являются беспилотные автомобили, использующие в системах управления методы искусственного интеллекта, то есть транспортные средства четвертого и пятого уровней автоматизации. При этом важно отметить, что современные интеллектуальные системы управления транспортом не являются, в полном смысле этих слов, полноценным ИИ. Другими словами, это совокупность компьютерных программ и алгоритмов, не способная рассуждать, а также критически анализировать внешние воздействия [318].

С этим разъяснением можно представить, что интеллектуальная система вождения не будет изначально “знать” обо всех аспектах управления транспортными средствами, в том числе – правил дорожного движения. Функции вождения автомобиля и все, что с ним связано, должно быть запрограммировано как часть информационного, аппаратного и программного обеспечения беспилотного транспортного средства [319].

К обсуждению киберпреступности применительно к транспортным средствам необходимо относиться серьезно, основываясь на фактах [320].

В качестве примера того, как эти темы должны действительно публично обсуждаться, можно обратиться к отчёту Исследовательской службы Конгресса США (CRS), озаглавленному «Проблемы при тестировании и развертывании автономных транспортных средств», написанному Биллом Канисом [321]. Рассмотрим конкретные компоненты, которые могут оказаться брешью в кибербезопасности беспилотных автомобилей пятого уровня, использующих методы искусственного интеллекта. Таких уязвимостей насчитывается много.

16.2.1. Разъём OBD

Первая потенциальная точка входа, заслуживающая внимания, связана с разъёмом OBD (бортовой диагностики). OBD или его аналоги, с середины 90-х годов, есть в любом обычном автомобиле (рис. 16.2).




Рисунок 16.2. Разъём OBD (On-Board Diagnostics)

Диагностический разъём OBD предназначен для сервисного обслуживания электронных систем автомобиля. Для подключения к такому разъёму можно использовать портативное устройство, которое находится в свободном доступе, и любой сотрудник специализированной мастерской или автолюбитель в состоянии произвести диагностику транспортного средства с его помощью.

Этот цифровой коммуникационный порт может предоставлять важные данные, в режиме реального времени, о внутренних проблемах автомобиля, передаваемые через стандартизированный набор кодов неисправностей.

На первый взгляд кажется, что порт OBD – это средство только для диагностики и считывания состояний, что не совсем так. Порт OBD позволяет подключаться к более широкому спектру встроенных систем в автомобиле. Кроме того, его можно использовать для отправки инструкций или данных в различные подключенные системы [322], и использовать не только для чтения данных, но и для программирования встроенных систем управления, в том числе и систем безопасности автомобиля, противодействующих угону.

Достаточным фактором обеспечения безопасности обычно является тот факт, что автопроизводители намеренно препятствуют распространению информации о рабочих протоколах OBD, а физический доступ к разъёму может осуществляться только путём проникновения внутрь транспортного средства. Это, возможно, достаточная мера для персональных пилотируемых автомобилей, но с точки зрения настоящих самоуправляемых автомобилей, на основе искусственного интеллекта, наличие свободного доступа к разъёму OBD вызывает озабоченность, так как злоумышленник может попытаться использовать этот разъём для обмана системы управления беспилотника.

Контраргумент заключается в том, что система управления может быть защищена своим собственным уровнем системной безопасности, чтобы не реагировать на команды, отправленные через OBD разъём. Проблема наличия в системах управления автомобиля такого доступа к внутренним системам может быть переоценена, но нельзя игнорировать такой важный аспект, заключающийся в том, что вся система управления транспортным средством полагается на большое количество встроенных автомобильных подсистем, которые могут быть взломаны или искажены в результате действий хакера.

16.2.2. Беспроводное обновление программного обеспечения (OTA)

Наиболее уязвимой точкой самоуправляемых автомобилей может стать возможность электронной связи беспроводного обновления программного обеспечения OTA (Over-The-Air). Беспилотные транспортные системы имеют устройство связи, позволяющее подключаться к платформе облачных вычислений, которая может поддерживаться автопроизводителем, оператором автопарка или авторизованными сервисами (рис. 16.3).

Патчи и различные обновления программного обеспечения для системы интеллектуального вождения могут быть легко загружены и установлены.

Это позволяет быстро вносить изменения, что, несомненно, крайне важно для системы, действующей в полевых условиях, и избегать необходимости доставлять автомобиль местному дилеру или в ремонтную мастерскую.



Рисунок 16.3 — Структура OTA (Over-The-Air)

OTA также предоставляет средство для сбора данных с беспилотного автомобиля. Самоуправляемые автомобили будут собирать массивы данных с помощью встроенных датчиков. Эти данные используются для улучшения возможностей системы управления, путём анализа поездок, совершённых транспортным средством. У такого метода огромный потенциал для быстрого развития систем управления, но в тоже время он вызывает беспокойство по поводу вторжения в частную жизнь и безопасности личной информации.

OTA представляет собой потенциальную дыру для злоумышленников, любых киберхакеров, которые могут проникнуть в интеллектуальную систему управления автомобилем и получить доступ к личным данным его владельца. Атака на OTA-сервисы является особенно привлекательной для киберпреступника, так как потенциально позволяет атаковать весь парк самоуправляемых автомобилей, обслуживаемых одним оператором, нанося этим огромный ущерб владельцам и представляя для них огромную опасность.

16.2.3. Интернет вещей (IoT)

Современные транспортные средства, как и другие устройства, становятся более удобными в использовании с помощью смартфона (рис. 16.4).

Интернет вещей (Internet of Things – IoT) включает в себе концепцию объединения в единую сеть, единое информационное поле с удобным доступом к функциям. Владелец, сажающийся в беспилотный автомобиль, может принести с собой множество устройств, поддерживающих IoT, такие как умные часы или смартфоны. Каждое из устройств «Интернета вещей» потенциально способно получить доступ к беспилотному автомобилю для обмена информацией, зарядки аккумуляторов, или других действий.




Рисунок 16.4. Схема работы Интернета вещей

Это означает, что среди таких «умных» устройств могут оказаться как специализированные устройства для осуществления кибернетических атак, так и устройства, заражённые вредоносным программным обеспечением.

16.2.4. Электронные блоки управления (ЭБУ)

Как упоминалось ранее, в современный автомобиль встроено множество электронных блоков управления, используемых для управления двигателем, рулевого управления, торможения, управления подушками безопасности, системы контроля давления в шинах TPMS, и др., которые могут быть использованы и системами беспилотных автомобилей (рис. 16.5).




Рисунок 16.5. Электронные блоки управления в автомобиле

Все эти встроенные электронные подсистемы управления потенциально являются уязвимыми к кибератакам, и содержать в себе множество брешей.

Одна из проблем заключается в том, что хакер может взломать один из электронных блоков управления и обмануть загруженную в транспортное средство систему управления. Таким образом, злоумышленник способен повлиять на процесс управления автомобилем. Блоки управления обычно не имеют серьёзной защиты, так как являются внутренними скрытыми подсистемами управления автомобилем [323]. Взлом может начинаться с самых безобидных электронных блоков, что постепенно может привести к подмене данных, получаемых системой управления, и в конце концов – к введению в заблуждение стратегической системы управления транспортным средством, основанной на алгоритмах искусственного интеллекта.

16.2.5. Внутренняя сеть (CAN)

Ввиду наличия в автомобилях большого количества электронных устройств, современные производители транспортных средств пришли к единому стандарту, который позволяет установить устойчивую связь между блоками и сократить количество кабелей, то есть организовать внутреннюю электронную сеть, которая позволяет различным системам и подсистемам взаимодействовать друг с другом в электронном виде. На техническом языке такая сеть называется *CAN-шиной* (Controller Area Network, локальная сеть контроллера), поскольку это своего рода канал для обмена сообщениями [324]. Любое из устройств, подключенных к CAN, отслеживает проходящую информацию, и, если это сообщение будет адресовано ему, принимает и обрабатывает его согласно заложенному в нём алгоритму работы. Если злоумышленник найдет способ проникнуть в шину CAN, ему станет доступно большое количество информации, передаваемое устройствами. Такая угроза является классической атакой с названием «человек посередине».

16.2.6. V2V и V2X

Использование систем для обмена информацией между транспортными средствами (V2V, Vehicle-To-Vehicle) и между транспортными средствами и инфраструктурой (V2I, Vehicle-To-Infrastructure) является важным элементом для развития интеллектуальных беспилотных транспортных средств.

Связь V2V может быть организована, например, с помощью выделенной связи на короткие расстояния DSRC (Dedicated Short Range Communication).

Суть связи DSRC заключается в том, что беспилотный автомобиль периодически отправляет информацию другим беспилотным транспортным средствам, например, о ремонтных работах или препятствиях на дороге впереди. В свою очередь, система V2I может использоваться для оптимизации дорожного движения, например, могут использоваться светофоры, способные отправлять беспилотным автомобилям электронные сообщения о включенном красном или зеленом свете, о своей работоспособности, и др.

Транспортные средства с поддержкой V2V и V2I – это следующее поколение наземных транспортных систем. Подключенные транспортные средства (CV – Connection Vehicles) обмениваются информацией с другими транспортными средствами и с транспортной инфраструктурой с помощью беспроводной связи, что повышает безопасность движения, обеспечивает эффективные услуги мобильности и снижает воздействие на окружающую среду [325]. Однако риск кибератак возрастает по мере того, как транспортные средства все более подключаются через Интернет и беспроводные сети.

Архитектура эталонной реализации подключённых транспортных средств (CVRIA) [326], разработанная Министерством транспорта США (USDOT) определило сотни приложений CV на сегодняшний день. Среди них более 20 приложений связаны с V2I. Многие из них связаны с безопасностью V2I (например, предупреждение о превышении скорости на повороте, бортовые указатели и система помощи при пропуске стоп– сигналов).

Согласно CVRIA, эти приложения имеют некие общие подприложения (например, предупреждение о превышении скорости, безопасность на перекрёстках), и используют общие процессы (например, сбор данных о безопасности дорожного движения, и обработка собранных данных о безопасности транспортных средств) для поддержки этого уровня приложений. По этой причине, потоки данных могут представлять риски для безопасности при обмене между этими приложениями. Так, если угроза кибербезопасности присутствует в любом из общих подприложений или процессов, другие приложения также могут подвергнуться риску реализации угроз.

Одним из шлюзов кибератак на подключенные автомобили является V2I. Кибератаки на V2I могут иметь катастрофические последствия, если системы V2I не защищены должным образом. V2I приложения имеют целый ряд уязвимостей, которые создают привлекательную цель для хакеров.

Например, хакеры могут взять под контроль сигналы светофора, создать опасность и даже вызвать поломку дорожной системы. Вот почему очень важно разработать новые решения по безопасности, для защиты V2I среды.

Проведено много исследований по обеспечению конфиденциальности, поддержанию аутентификации и обеспечения целостности, направленных на V2V коммуникацию. Однако очень мало исследований посвящено безопасности на уровне V2I, как части решений по обеспечению безопасности в автомобиле и V2V. Поэтому исследования, которые сосредоточены исключительно на решениях безопасности V2I, требуют большего внимания.

В предлагаемой авторами разработке оценивается значение безопасности приложений V2I и предлагается инновационная архитектура безопасности V2I – CVGuard, способная идентифицировать, предотвращать и обеспечивать противодействие угрозам безопасности для защиты V2I приложений.

16.3. Исследования безопасности системы обмена информацией V2I

Основной целью исследований является всестороннее обобщение аспектов кибербезопасности системы V2I. Прежде чем разрабатывать решение, нужно определить требования к кибербезопасности системы, изучить различные типы потенциальных кибератак и рассмотреть существующие решения. При разработке решений по кибербезопасности системы V2I необходимо провести обзор новых технологий, пригодных для решения задачи.

16.3.1. Требования к безопасности V2I

В среде подключенных транспортных средств, устройства автомобиля могут обмениваться данными с внутренней (V2S, автомобиль–датчик) и внешней средой (системы V2V и V2I), включая *придорожные устройства* (RSU – Roadside Units), которые используют *выделенную связь* малого радиуса действия (DSRC) [326]. Бортовое устройство (БУ), размещённое внутри транспортного средства, передаёт информацию в окружающую среду. RSU собирают данные с транспортных средств, а приложения, установленные в RSU, предоставляют запрашиваемые услуги [327]. Согласно CVRIA, все решения безопасности, связанные с V2I и V2V, должны быть сосредоточены на трёх элементах: конфиденциальность, целостность и доступность [328].

Конфиденциальность. Содержание сообщений, которыми обмениваются в среде V2I, должно быть конфиденциальным, т.е. содержимое не может быть доступно неавторизованным и непреднамеренным пользователям. Однако большинство сообщений в среде подключённых транспортных средств являются публичными, особенно те, которыми обмениваются транспортные средства и инфраструктура. Конфиденциальность данных и сообщений, при разработке безопасной среды V2I, должны быть обеспечены [329].

Целостность сообщений, которыми обмениваются транспортное средство и инфраструктура, должны быть защищены от любых несанкционированных изменений или модификаций. Это обеспечивает точность, надёжность и достоверность сообщений. Каждое решение безопасности должно обеспечивать защиту от несанкционированных преднамеренных или непреднамеренных изменений. Потеря целостности может привести к ухудшению качества услуг, предоставляемых информационной средой V2I [330].

Доступность гарантирует, что системы и информация доступны и пригодны для использования уполномоченными лицами. В среде V2I все RSU должны быть доступны в любое время. Так, критическая задержка для предупреждения о столкновении на перекрёстке должны составлять менее 100 миллисекунд [331]. Решения по безопасности должны обеспечивать работоспособность системы даже при наличии неисправностей или рискованных условий.

16.3.2. Кибернетические атаки на V2I

Классификации вредоносных действий и угроз безопасности, а также злоумышленников в автомобильной среде, неоднократно обсуждались. Так, хакеры, по безопасности, классифицируются как внутренние или внешние, на основе своей функциональности [332, 333]. Уровни активности определяют, являются ли действия злоумышленников активными или пассивными. Оценка намерения или причины атаки классифицируют хакеров как испытателей или взломщиков. Однако существующие работы сосредоточены исключительно на проблемах, стоящих за атаками безопасности V2V.

Предлагаемое исследование направлено на кибератаки V2I, в контексте новых приложений для подключенных автомобилей. В табл. 16.1 показаны кибератаки, которые могут произойти в интерфейсе V2I при уязвимости конфиденциальности, целостности и доступности. При этом прогнозируемая вероятность атаки оценивается как *высокая, средняя и низкая*.

Таблица даёт общее представление о влиянии потенциальных кибератак, проводимых злоумышленниками, на интерфейс системы обмена информацией между транспортными средствами и инфраструктурой V2I [333].

Различные типы кибератак в среде V2I

Таблица 16.1

Тип атаки	Скомпрометированный элемент безопасности			Влияние атаки на среду «автомобиль – инфраструктура»	Вероятность
	Доступность	Целостность	Конфиденциальность		
Распределённый отказ в обслуживании сервиса (DDoS)	Высокая	Средняя	Низкая	Недоступность услуг, разрушение сети, нарушение целостности услуг	Высокая
Имперсонализация	Низкая	Средняя	Высокая	Нарушение работы сети, сокрытие личности и получение привилегий являются основными мотивами для хакера	Высокая
Чередование сообщений	Средняя	Высокая	Средняя	Влияет на целостность и конфиденциальность среды V2I среды, тем самым влияя на безопасность услуг, предоставляемых RSU. Реагирование на этот тип атаки зависит от решений по защите от кражи, предоставляемых транспортными средствами или RSU	Средняя

Продолжение табл. 16.1

Вредоносные программы и спам	Средняя	Низкая	Высокая	Вредоносное ПО может вызвать потенциально серьезные сбои в обслуживании RSU. Воздействие считается высоким из-за длительных перебоев в работе. Вредоносное ПО может быть внедрено в систему во время обновления RSU.	Низкая
Подслушивание	Низкая	Низкая	Высокая	Как активные, так и пассивные злоумышленники и могут украсть конфиденциальную и частную информацию, что нарушает конфиденциальность водителей и транспортных средств.	Средняя

16.3.3. Новые технологии кибербезопасности

В настоящее время появился ряд новых технологий, позволяющих сделать коммуникационные сети более безопасными, масштабируемыми и способными обеспечить более тонкий контроль. Кратко обсудим использование этих технологий в решениях по информационной безопасности V2I.

Пограничные вычисления—это метод, при котором данные обрабатываются в непосредственной близости от источника данных. Пограничные вычисления обеспечивают динамическое управление контентом, правильное распределение ресурсов и низкую задержку. Метод обеспечивает высокую пропускную способность, распределяя вычислительные задачи по разным краям [334, 335].

В контексте системы V2I, модули безопасности должны находиться рядом с источником данных (т.е. RSU) для более ускоренной обработки, что может быть достигнуто с помощью пограничных вычислений.

Программно–определяемые сети (SDN, Software–Defined Networking). Традиционное управление компьютерной сетью является сложным, хрупким и подверженным ошибкам процессом [336]. Эти проблемы вызваны тесной связью плоскости данных (используемой для пересылки данных) и плоскости управления (используемой для логики маршрутизации, управления пакетами и контроля доступа). Благодаря разделению плоскости управления и плоскости данных, а также программируемости, SDN упрощает задачу управления сетью (реконфигурирование топологии сети, изменение логики маршрутизации и др.) и обеспечивает большую гибкость в отношении распределения данных. В среде CV SDN могут использоваться для динамического перенаправления данных в различные пункты назначения по мере необходимости. В работе [337] показан пример использования SDN для обеспечения более гибких стратегий защиты, и лучшего управления ресурсами при защите от кибератак при минимизации перегруженности сети и воспринимаемой пользователем задержки. Так, SDN могут помочь в создании систем защиты от угроз V2I.

Виртуализация сетевых функций (NFV, Network Functions Virtualization)

Сетевые функции, такие, как брандмауэры и системы обнаружения вторжений (IDS), в настоящее время реализуются на специализированном оборудовании, таком как полевые программируемые матрицы (FPGA) [338]. Хотя специализированное оборудование обеспечивает более высокую производительность, оно также приводит к высокой стоимости, сложности обслуживания и снижению гибкости. Для преодоления этих проблем появилась технология NFV [339], которая снижает стоимость и предоставляет новые возможности в масштабируемости и реализации сетевых функций в товарном оборудовании с тонким контролем [340]. NFV и SDN сыграют важную роль в обеспечении безопасности среды CV в ближайшем будущем. Ведущие игроки отрасли (Verizon и AT&T) внедряют эти технологии [337].

Исследование авторов посвящено безопасности на уровне сети V2I и описывает распределенную вычислительную платформу CVGuard, которая обеспечивает конфиденциальность, целостность и доступность данных с помощью развивающихся технологий пограничных вычислений SDN и NFV.

16.4. Разработка системы CVGuard

Для достижения цели исследования первым шагом является определение компонентов и функциональных возможностей системы CVGuard (рис. 16.6), а также создание формулировки среды CV для обнаружения и предотвращения кибератак на интеллектуальные транспортные средства, работающие в сети.




Рисунок 16.6. CVGuard: архитектура безопасности подключенного автомобиля V2I

Обзор системы. CVGuard – это новая архитектура безопасности на основе программного обеспечения, предназначенная для защиты приложений V2I. Используются три новые технологии: граничные вычисления, SDN и NFV. Основной целью CVGuard является обнаружение и изоляция любых кибератак в среде V2I, прежде чем они смогут негативно повлиять на транспортные средства или транспортные сети, что может привести к авариям и препятствовать внедрению технологий подключенных транспортных средств. На рис. 16.7 показана высокоуровневая концепция CVGuard, включающая в себя два основных компонента. *Первый компонент* состоит из настраиваемых модулей (это небольшие сетевые функции безопасности). Эти программные модули располагаются в каждом фиксированном узле (например, RSU) и действуют как шлюзы безопасности для каждого транспортного средства (т.е. мобильной границы). Они также обеспечивают динамическую возможность перехвата и анализа атак для интерфейсов V2I. *Вторым компонентом* является контроллер CVGuard, который логически централизован и находится в облаке, в качестве регионального края, где он отслеживает контексты различных транспортных средств, RSU, а также коммуникации V2I.

Контроллер CVGuard также идентифицирует угрозы безопасности, анализирует их и управляет модулями для устранения угроз. RSU представляют собой точку входа для потенциальных кибератак, и модули в каждом RSU выполняют пограничные вычисления на входящих данных для обнаружения возможных кибератак на первом уровне CVGuard.

Функции безопасности должны потреблять как можно меньше ресурсов (например, памяти, времени обработки). Небольшие программные функции безопасности в модулях обеспечивают эффективное использование ресурсов в RSU, поскольку они создаются только тогда, когда это нужно, и уничтожаются, когда необходимость в них отпадает. Кроме того, коммуникационные сети между RSU необходимы для распространения информации об атаке среди соседних RSU. Используя технологии NFV и SDN, контроллер CVGuard может гибко и быстро создавать или уничтожать функции безопасности. Контроллер CVGuard может динамически направлять информацию об атаках и политике их предотвращения функциям безопасности. Контроллер CVGuard действует как централизованный контроллер функций безопасности для обеспечения динамического взаимодействия и автоматической реконфигурации программных функций безопасности, распределенных в различных RSU.

CVGuard поддерживает два типа функций сетевой безопасности:

- детектирование кибератак, обеспечиваемое системой обнаружения вторжений (IDS) и детектором DDoS-атак [341],
- предотвращение атак, обеспечиваемое межсетевыми экранами и системой предотвращения вторжений (IPS). Как только функции обнаружения атак функции замечают потенциальную угрозу, CVGuard идентифицирует проблему и динамически запускает функции предотвращения атак.

Обнаружение атаки CVGuard основано на динамических корректировках правил безопасности, которые разработаны на основе среды CV, где все транспортные средства находятся в движении и непрерывно передают основные сообщения безопасности (BSM – Base Security Messages) – часть 1 со скоростью 10 Гц (10 пакетов в секунду). Используя беспроводную связь, каждое транспортное средство может общаться в определенном частотном диапазоне. Из диапазона влияния воздействия RSU, являясь статичным компонентом в среде CV, транспортные средства входят в частотный диапазон связи с RSU, и покидают его через определенный период времени.

Для количественной оценки среды CV, свойства и функциональные возможности компонентов CV представляются в надлежащем и реалистичном образе. Например, каждое транспортное средство может быть представлено как движущийся автомобильный узел, обладающий такими свойствами, как скорость (S_i) и местоположение ($L_i(x, y)$). В табл. 16.2 приведены общие свойства компонентов, встречающихся в среде CV:

Свойства транспортного узла

Таблица 16.2

Обозначение	Описание
$L_i(x, y)$	Местонахождение i -го беспилотного транспортного средства, с координатами: долготой x и широтой y .
$L_{rsu}(x, y)$	Местоположение RSU с долготой x и широтой y .
$S_i(x, y)$	Двумерная скорость i -го транспортного средства
S_i	Результирующая скорость i -го транспортного средства
R_i	Диапазон связи i -го транспортного средства
R_{rsu}	Диапазон связи RSU
$T_{i, start}$	Время, когда i -ое транспортное средство входит в зону связи RSU
$T_{i, end}$	Время, когда i -ое транспортное средство покидает зону связи RSU
$D_{i,j}$	Расстояние между i -м автомобилем и j -м автомобилем
$e_{i,j}$	Соседство между i -м транспортным средством и j -м автомобилем
$\tilde{N}$	Возможное максимальное количество соседствующих автомобилей
N_{rsu}	Количество транспортных средств в пределах диапазона связи RSU
DRR_i	Скорость приема данных i -го транспортного средства
S_{max}	Максимальная скорость движения по проезжей части
S_{min}	Минимальная скорость движения по проезжей части

Основываясь на свойствах автомобильного узла, перечисленных в табл. 16.2, можно сформулировать правила, необходимые в среде CV. Правила, соответствующие нормальному поведению автомобиля без кибератаки:

а) Каждый RSU имеет диапазон связи, основанный на средстве связи (например, рекомендуемый диапазон DSRC составляет до 300 м [335]. Таким образом, RSU будет получать данные только от тех транспортных средств, которые находятся в пределах диапазона DSRC. Аномальное местоположение может быть обнаружено с помощью следующего правила:

$$|L_i(x, y) - L_{rsu}(x, y)| < R_{rsu} \quad (16.1)$$

б) RSU содержит информацию о геометрии проезжей части (например, расположение дороги, картографическую информацию) окружающей его территории. Кроме того, местоположение каждого транспортного средства будет находиться внутри геометрии дорожного полотна.

$$L_i(x, y) \in \text{Геометрии дорожного полотна} \quad (16.2)$$

с) Необходимо вычислить прогнозируемый подход к определению местоположения транспортных средств. Если $L_{current}(x, y)$ обозначает текущее местоположение транспортного средства, а $L_{prev}(x, y)$ обозначает предыдущее местоположение того же транспортного средства, то связь между ними может быть представлена следующим образом, где δ – константа, зависящая от дорожной ситуации (например, интенсивности движения, очереди):

$$|L_{current}(x, y)| \leq |L_{prev}(x, y) + \delta| \quad (16.3)$$

д) Каждое транспортное средство поддерживает минимальную дистанцию движения (ϵ) от других транспортных средств (уравнение (16.4)) и дистанцию (h_i) от транспортного средства, находящегося перед ним (уравнение (16.5)).

$$|L_i(x, y) - L_j(x, y)| > \epsilon \quad (16.4)$$

$$|L_i(x, y) - L_{i+1}(x, y)| \approx h_i \quad (16.5)$$

е) Каждый беспилотный автомобиль будет передавать сигнал BSM с определенной скоростью, а RSU будет получать эти данные со скоростью, не превышающей его скорость распространения, C_1 .

$$DRR_i \leq C_1 \quad (16.6)$$

ф) RSU будет получать данные от каждого беспилотного транспортного средства. Для обеспечения надлежащего обслуживания RSU, значение DRR должно быть выше порогового значения C_2 .

$$DRR_i \geq C_2 \quad (16.7)$$

г) Имея определенный частотный диапазон связи, RSU может принимать определенное количество транспортных средств в пределах своего диапазона:

$$N_{rsu} \leq \text{Количество транспортных средств в радиусе действия RSU} \quad (16.8)$$

h) Транспортные средства могут общаться с определенным количеством транспортных средств, находящихся в радиусе их действия.

$$\tilde{N} < \text{Количество соседей для каждого ТС} \quad (16.9)$$

и) Структура сети или топология может быть установлена с помощью определения соседства, где два транспортных средства (V_i и V_j) считаются соседями, если физическое расстояние меньше определенного значения (μ).

$$V_i \text{ и } V_j \text{ соседи } (e_{i,j}=1), \text{ if } |L_i(x,y) - L_j(x,y)| < \mu \quad (16.10)$$

ж) Для определенного участка дороги или коридора, скорость каждого транспортного средства будет находиться в определенных границах:

$$S_{\min} \leq S_i \leq S_{\max} \quad (16.11)$$

к) Транспортное средство (i -й автомобиль) войдет в зону связи с RSU в момент времени $\tau_{i, \text{start}}$ и оставит диапазон связи в момент $\tau_{i, \text{end}}$. Из-за определенного частотного диапазона связи (R_{rsu}) для RSU, разница между $T_{i, \text{end}}$ и $T_{i, \text{start}}$ будет меньше постоянной τ :

$$T_{i, \text{end}} - T_{i, \text{start}} \leq \tau \quad (16.12)$$

В CVGuard эти правила находятся внутри модулей, которые отслеживают контекст каждого транспортного средства. Поступающие данные о транспортных средствах и набор правил, состоящий из правил поведения и правил нарушения, подаются на вход модуля. Данные о транспортных средствах и набор правил действуют как небольшой программный модуль безопасности. Набор правил динамически создается контроллером CVGuard и подается на модуль. Основываясь на наборе правил и типах нарушений, модуль может обнаружить типы кибернетических атак, выполняемых различного рода злоумышленниками. На рис. 16.7 показана абстрактная идея метода такого обнаружения.




Рисунок 16.7. Рабочий процесс модуля для обнаружения и предотвращения атак

На рис. 16.7 тип кибератаки X определяется, если данные транспортного средства нарушают политику безопасности P , которая состоит из правил: $\{a, b\}$. Аналогично, нарушение набора политик безопасности Q , состоящего из набора правил $\{b, c, d\}$, приводит к возможности кибератаки типа Y .

Предотвращение атак. В зависимости от типа атаки, CVGuard может принимать контрмеры, направленные на предотвращение. При обнаружении любой атаки модуль направляет данные от атакующих и легитимных транспортных средств в систему предотвращения, как показано на рис. 16.7. Затем данные злоумышленника помещаются в карантин и передаются в приложение CV в зависимости от потребностей приложения.

Например, если транспортное средство выполняет атаку на ложное местоположение, RSU может выполнить оценку правильного местоположения злоумышленников на основе данных, собранных с других транспортных средств. Затем это локализованное значение может быть передано приложениям CV. Политики предотвращения могут быть изменены динамически в зависимости от типа атаки с помощью контроллера CVGuard, что делает систему более гибкой, надежной и масштабируемой. Например, для атаки DDoS набор нарушений включает $\{e, f\}$, что создает более высокий DRR для одного транспортного средства, вызывая снижение DRR других транспортных средств. Для предотвращения кибератаки DDoS, CVGuard может отбрасывать или фильтровать данные на основе потребностей приложения для обеспечения надлежащего вывода данных из приложения CV.

16.5. Тематическое исследование приложения Stop Sign Gap Assist (SSGA)

Проведём тематическое исследование с точки зрения приложения системы обмена информацией между транспортными средствами и инфраструктурой – Vehicle-To-Infrastructure (V2I), т.е. приложения SSGA. Для этого нужно разработать модель DDoS-атаки, чтобы затем использовать её для оценки негативного воздействия этой кибератаки на работу приложения SSGA.

Обзор применения SSGA. В проведенном тематическом исследовании было выбрано приложение для обеспечения безопасности V2I – SSGA. Цель приложения: повышение безопасности нерегулируемого перекрестка (с установленным знаком "Стоп") путём предоставления предупреждающих и консультативных сообщений, связанных с безопасностью транспортных средств, приближающимся транспортным средствам на перекрестке.

В приложении SSGA (Stop Sign Gap Assist) второстепенные транспортные средства приближаются к знаку остановки, а RSU (придорожные блоки, Roadside Units) предоставляет второстепенным транспортным средствам сообщения о безопасности на основе состояния перекрёстка (например, доступного безопасного зазора для основных транспортных средств). На перекрестке, предупреждения и сообщения SSGA указывают на небезопасные зазоры на основе скорости приближающегося транспортного средства главной дороги и расстояния до перекрестка. В результате предупреждения и оповещения в реальном времени на перекрестке снижается количество дорожно–транспортных происшествий с прямым углом поворота [342]. Производительность приложения SSGA зависит от наличия данных от транспортных средств, движущихся по основным и второстепенным дорогам. Так как это приложение связано с безопасностью, то соответствующая дезинформация, полученная в качестве данных, может привести к авариям на перекрестках. В связи с тем, что приложение SSGA имеет большое значение для безопасности транспортных средств, оно подходит для тематического исследования по определению эффективности системы CVGuard.

Разработка модели DDoS атаки. Сосредоточимся на общей DDoS–атаке (например, SYN Flood) против приложения CV, работающего в придорожной инфраструктуре. Цель проводимого эксперимента – истощить сеть и нарушить работу приложения CV. Атака SYN Flood — это один из видов DDoS–атаки, при которой злоумышленник передаёт огромное количество ненужных данных [343]. Создавая атаку SYN Flood, злоумышленник может сделать сервисы CV–приложений недоступными, что приведёт к загрузке вычислительных ресурсов приложений. Предположим, что консультативная модель может контролировать свой собственный блок управления (один или несколько БУ) и может контролировать блоки управления других транспортных средств, для создания DDoS–атаки. Цель хакеров–нарушить нормальную работу приложения безопасности, чтобы спровоцировать аварийную ситуацию. Поскольку приложение безопасности, например, SSGA, использует только данные BSM (основные сообщения безопасности, Base Security Messages) для вычисления операций безопасности, то можно предположить, что хакер создаст атаку SYN Flood только с помощью BSM. Для простоты эксперимента, ограничим своё исследование рассмотрением только одного элемента придорожной инфраструктуры – придорожных блоков RSU.

В процессе моделирования DDoS-атаки сначала была разработана формулировка DDoS-атаки для оценки её осуществимости. Во-вторых, из коммерчески доступных устройств DSRC (выделенной связи на короткие расстояния, Dedicated Short Range Communication) были извлечены значения параметров (например, доступность канала DSRC, размер пакета, задержка передачи и пропускная способность), необходимых для создания DDoS-атаки. В-третьих, используя эти извлеченные параметры, в среде моделирования была запущена атака на приложение SSGA. Эти шаги приведены ниже.

Формулировка модели атаки DDoS. Злоумышленники запускают DDoS-атаку путём переполнения канала связи. Как правило, хакер использует свою максимальную пропускную способность для перегрузки сети. Для создания сбоя в работе приложения V2I, злоумышленникам необходимо передать больше данных, чем максимальная приёмная способность приёмника (например, RSU), которая может быть рассчитана как:

$$\text{Передающая способность атакующего} \geq \text{пропускная способность приемника} \quad (16.11)$$

$$N_{attackers} * (Tx_a) \geq CRx_{max} \geq \quad (16.12)$$

где $N_{attackers}$ – количество атакующих хакеров, Tx_a – скорость передачи данных атакующими хакерами, CRx_{max} – максимальная пропускная способность устройств придорожной инфраструктуры RSU на приём сообщений.

Когда злоумышленники заполонят сеть, RSU не сможет получать данные от верифицированных транспортных средств, и не сможет предоставлять надлежащие услуги верифицированным транспортным средствам.

Возможность проведения успешной атаки зависит от скорости передачи злоумышленников ($\tilde{x}$, приёмной способности устройств (например, $RSU(\tilde{x})$), среднего размера пакета (y), накладных расходов на передачу (δ) и процента служебного канала (SCH), а также доступности (ρ). Используя эти зависимые параметры, как показано в уравнении (16.12), впоследствии можно использовать уравнение (16.13) для оценки количества злоумышленников ($N_{attackers}$), необходимых для создания DDoS-атаки на приложение V2I.

$$N_{attackers} \geq \rho \left(\frac{1}{x} x + o * \frac{10^6}{8y} x \right) \quad (16.13)$$

Извлечение параметров из реальных устройств. Следующим шагом является проверка осуществимости создания DDoS-атаки, когда хакеры – используют реальные устройства на основе уравнения (16.13).

Этот анализ осуществимости был проведен на коммерчески доступных RSU. Целью анализа было найти возможности атакующего злоумышленника (например, минимальные накладные расходы и задержка передачи) с различными конфигурациями; а затем извлечённые значения использовались для создания DDoS-атак в симуляции, при моделировании. Эксперимент показал, что минимальные накладные расходы на передачу составляют примерно 2,456 миллисекунды (мс) с 1 миллисекундой межпакетного разрыва (IPG), когда устройство настроено на скорость 3 Мбит/с. Кроме того, на стороне приёмника, для одного устройства, доступно 46 мс окна для SCH в 100 мс временного окна; таким образом, доступное SCH составляет 46% времени RSU. Используя эту задержку и другие стандартные конфигурации, как показано ниже, уравнение (16.13) даёт минимальное количество бортовых устройств (БУ) ($\min(N_{\text{attackers}})=3$), которые рассматриваются как злоумышленники для создания DDoS-атаки в проводимом эксперименте. При проведении описываемого эксперимента (опыта) принимались следующие параметров:

- Средний размер пакета, $y = 220$ байт
- Скорость передачи данных злоумышленниками, $\tilde{x} = 3$ Мбит/с
- Пропускная способность приёмника, $x = 12$ Мбит/с
- Общие накладные расходы на передачу,

$$\delta = \text{IPG} + \text{Накладные расходы на передачу} = (1 + 2,456) \text{ мс},$$

$$\text{Итак, } \delta = 3,465 \text{ мс} = 0,003465 \text{ сек.}$$

- Доступность SCH, $\rho = 46\%$.
- Минимальное необходимое количество атакующих:

$$\tilde{N}_{\text{attackers}} \geq 2,83 \text{ или } \min(\tilde{N}_{\text{attackers}}) = 3.$$

Влияние уровня приложения при DDoS-атаке. Используя параметры задержки от коммерчески доступных устройств DSRC, как описано ранее, были созданы различные сценарии атак для оценки влияния DDoS-атак на SSGA в симуляции, при моделировании. При разном количестве атакующих производительность RSU оценивалась на основе скорости получения данных приложением. Поскольку атакующие перегружали RSU, значительное количество данных от верифицированных транспортных средств было потеряно. Как показано на рис. 16.8, с увеличением числа атакующих DRR приложения снижалась из-за DDoS-атаки. При пяти атакующих, DRR снизился до 10%, что является самым низким показателем.

Из-за потери данных от других верифицированных транспортных средств приложение безопасности CV не сможет определить местоположение верифицированных транспортных средств. Это приведет к тому, что приложение безопасности не сможет выдать точный результат. Например, если приложение SSGA выдает неверный результат, конфликт между транспортными средствами может иметь негативные последствия, и конфликт может потенциально привести к аварии. В наших экспериментах конфликт регистрировался как происходящий, когда два транспортных средства находятся в непосредственной близости друг от друга с временным интервалом менее 1.5 с [344]. Ранее была проведена оценка вероятности того, что конфликт может быть вызван DDoS-атакой.




Рисунок 16.8. Влияние на скорость получения данных при различном количестве DDoS-атакующих хакеров

Обнаружение атак с помощью CVGuard. Как обсуждалось ранее, CVGuard отслеживает контекст транспортных средств. Когда правила, определённые для этих транспортных средств, нарушаются, возникают угрозы безопасности. CVGuard может обнаружить DDoS-атаки и идентифицировать злоумышленника в среде CV, используя правила обнаружения (например, набор правил $\{e, f\}$) по отсутствующим данным и DRR злоумышленника. В случае DDoS-атаки DRR атакующего будет высоким, а DRR других транспортных средств будет снижаться, как показано в ранее. Это приведет к нарушению набора правил $\{e, f\}$. Согласно правилу $\{e\}$ RSU получит от злоумышленника больше данных, чем ожидалось. Кроме того, из-за перегрузки сети RSU не получит данные от других транспортных средств, что приведет к нарушению правила $\{f\}$.

Таким образом, он получит меньшее количество данных от других транспортных средств для нормальной работы приложения, что сделает службу приложения недоступной. Однако, отслеживая нарушение набора правил $\{e, f\}$, модуль сможет обнаружить DDoS-атаку.

16.6. Предотвращение атак с помощью CVGuard

CVGuard не только идентифицирует злоумышленников, но и может реализовать контрмеры для смягчения последствий атак. В среде CV пострадавшие компоненты не могут просто блокировать атакующих, как это обычно происходит в традиционных системах предотвращения DDoS, поскольку для выполнения операций безопасности также необходима информация о местоположении атакующих. После обнаружения DDoS-атаки CVGuard создает модуль для предотвращения DDoS-атаки. Цель этого модуля – ограничить поток данных для приложения безопасности. Если мы сможем ограничить поток данных в приложение, оно не будет перегружено ненужными BSM-сообщениями от злоумышленников. Мы можем установить границу потребления сообщений приложением следующим образом:

$$\alpha \leq DRR_{application} \leq \frac{C}{N_{number_of_vehicles}} * \beta \quad (16.14)$$

где $DRR_{application}$ – скорость приёма данных для правильной работы приложения, α – минимальная скорость приёма данных, необходимая для работы приложения и обеспечения правильного вывода, C – максимальная количество устройств, а β – ограничивающий фактор для верхней границы скорости передачи данных. Значения α и β зависят от требований приложений CV и скорости передачи данных злоумышленников. Например, приложение SSGA, работающее на частоте 10 Гц. означает, что приемник должен получать данные каждые 100 мс, что также можно назвать временем выборки. Для приложения SSGA требование состоит из безопасного расстояния и средней скорости потока. Определение времени выборки $T_{interval}$ имеет решающее значение для обеспечения лучшего обслуживания других транспортных средств. Модуль предотвращения DDoS для SSGA будет определять величину выборки. Выбор $T_{interval}$ может быть математически выражен как:

$$T_{interval} \geq \frac{D_{safe}}{V_{avg}} \quad (16.15)$$

где $T_{interval}$ – время выборки для сбора данных от верифицированных транспортных средств, D_{safe} – минимальное расстояние для безопасной работы, которое зависит от состояния дорожного полотна, и V_{avg} – средняя скорость транспортного средства на рассматриваемой дороге, которая извлекается из данных о других транспортных средствах. Было выбрано минимальное значение 100 мс и $1/T_{interval}$ в качестве α в уравнении (16.14), чтобы обеспечить нормальную работу приложения SSGA. Как показано на рис. 16.8, модуль предотвращения атаки сначала классифицирует данные на две категории: достоверные данные и данные злоумышленников. Достоверные данные будут обработаны нормально и переданы приложению. Данные злоумышленников будут обработаны модулем предотвращения атаки.

В случае DDoS-атаки данные будут отобраны в соответствии с уравнением (16.15). Основные действия, предпринимаемые CVGuard при обнаружении злонамеренной DDoS-атаки, описаны ниже.

(а) *Действие 1*: в соответствии с результатом обнаружения, запускается модуль предотвращения DDoS-атаки, состоящий из трёх компонентов: классификация трафика, смягчение атаки и обычная обработка.

(б) *Действие 2*: Компонент снижения последствий атаки рассчитывает $T_{interval}$ на основе условий атакующих (например, количество атакующих злоумышленников, скорость передачи данных атакующими хакерами) и условий других транспортных средств (например, количество транспортных средств, средняя скорость), учитывая значения α и β .

(с) *Действие 3*: Компонент снижения воздействия собирает данные верифицированного транспортного средства за время $T_{interval}$ и данные злоумышленников за интервал времени $1/T_{interval}$; затем эти данные передаются в приложение CV подключенных транспортных средств (Connection Vehicles).

16.7. Оценка работы системы CVGuard в условиях DDoS-атаки

Оценка эффективности системы CVGuard при DDoS-атаках проводилась как с использованием приложения SSGA с CVGuard, так и без него. При проведении эксперимента, три DDoS-злоумышленника атаковали приложение SSGA, что привело к конфликтам автомобилей на перекрёстке, поскольку приложение SSGA не смогло определить местоположение как основных, так и второстепенных беспилотных транспортных средств.

В реальном мире, условия движения на дорогах часто меняются. Моделирование включало 50 основных транспортных средств и различное количество второстепенных (от 5 до 45). Используя соотношение автомобилей на второстепенных и основных дорогах, было определено влияние состояния дорожного движения (например, количество конфликтов) во протяжении DDoS-атаки. Установлено $T_{interval}$ на 100 мс в качестве минимального времени выборки при $\beta = 1$. Как показано на рис. 16.9, а, при использовании группы из трёх злоумышленников, каждый из которых передаёт данные со скоростью 500 пакетов/сек, средний процент конфликтов составлял около 28,35%, до вмешательства CVGuard, а после развертывания CVGuard средний процент конфликтов составил около 12,65%. Кроме того, процент конфликтов зависит от сообщений атакующих хакеров и их параметров (например, скорости передачи). Рис.16.9, б показывает, что при увеличении скорости передачи данных со стороны злоумышленников, вероятность конфликтов на перекрестке пропорционально возрастает. Однако, после интеграции CVGuard, вероятность конфликтов снижается, обеспечивая большую безопасность при сценарии DDoS-атаки с тремя злоумышленниками. Например, наблюдалось снижение вероятности конфликтов на 46,87% до 18,75%, когда скорость передачи данных каждого из злоумышленников составляла 1000 пакетов/сек. На рис. 16.9, с показано процентное снижение количества конфликтов, когда CVGuard был развернут в условиях DDoS-атаки. После интеграции CVGuard, вероятность возникновения конфликтов снизилась, в среднем, на 60%.




Рисунок 16.9, а. Сравнение процента конфликтов до и после развертывания CVGuard при $N_{attackers} = 3$ и скорости передачи данных злоумышленников = 500 пакетов/сек.




Рисунок 16.9, b. Сравнение процента конфликтов до и после развёртывания системы CVGuard, при $N_{attackers} = 3$.



Рисунок 16.9, c. Уменьшение количества конфликтов с помощью CVGuard при DDoS– атаке
Рисунок 16.9. Улучшение условий до и после внедрения CVGuard

В этом исследовании были проанализированы современные тенденции разработки беспилотных транспортных средств, использующих алгоритмы искусственного интеллекта, для решения задач управления автомобильным транспортом. Приведена классификация транспортных средств по уровням автоматизации и описаны наиболее уязвимые для атак злоумышленников составляющие внутренних и внешних систем беспилотного транспорта.

Среда подключенного интеллектуального транспортного средства (CV) состоит из разнообразных систем сбора данных, передачи и распространения данных, а также систем вычислительной инфраструктуры, которые уязвимы к тем же кибератакам, что и все традиционные вычислительные среды.

Кибератаки могут поставить под угрозу ожидаемые преимущества безопасности, мобильности, энергопотребления и экологии от использования подключенных транспортных средств. Поскольку кибератаки могут привести к серьезным дорожным происшествиям, они стали одной из основных проблем в сфере применения подключенных транспортных средств.

Поскольку системы транспортных средств, подключённых к среде, быстро развиваются, уже в ближайшем будущем необходимо обеспечить их кибербезопасность. Высокая стоимость и отсутствие стандартизированного подхода к конфигурации аппаратных средств у производителей автомобилей подталкивают к разработке программных продуктов для обеспечения безопасности. Перед исследователями в таком случае стоит задача выбора подходящих методов защиты транспортных средств, управляемых системами искусственного интеллекта, подключенных к инфраструктуре, от угроз их кибербезопасности, выражающихся в проведении различных кибератак.

В предложенном исследовании представлена новая безопасная архитектура CVGuard, предназначенная для снижения угроз кибербезопасности V2I за счет использования пограничных вычислений, SDN и NFV. Было проведено тематическое исследование, включающее имитацию DDoS-атаки для определения связанных с ней негативных последствий для SSGA.

Анализ моделирования показал, что из-за DDoS-атаки DRR RSU для SSGA снизился до 10% по сравнению с нормальным DRR (93%). С точки зрения приложения V2I, снижение скорости приёма данных привело к сбою в работе приложения SSGA и возникновению конфликтов транспортных средств на нерегулируемом перекрестке. Были продемонстрированы возможности CVGuard по обнаружению и предотвращению DDoS-атак. Анализ показал, что стратегии, принятые CVGuard, позволили на 60% снизить количество конфликтов между транспортными средствами, вызванных DDoS-атакой на приложение SSGA на нерегулируемом перекрестке. В ходе моделирования рассматривалась ситуация с 100% подключенных автомобилей к системе V2I, но в реальном трафике всегда будет существовать смешанная дорожная ситуация с подключенными и неподключенными беспилотными транспортными средствами и автомобилями в транспортном потоке.

ЗАКЛЮЧЕНИЕ

Коллективная монография «Применение технологий искусственного интеллекта и поддержки принятия решений в задачах информационной безопасности» охватывает многие задачи современной кибербезопасности и защиты данных, решить которые возможно только с помощью применения методов искусственного интеллекта и теории поддержки принятия решений:

Глава 1 посвящена реализации криптографического протокола Диффи – Хеллмана с применением нейрокриптографии – технологии искусственного интеллекта, включающей синхронизацию двух древовидных машин чётности, особого вида многоуровневых нейронных сетей прямого распространения.

Глава 2 описывает разработку алгоритма хеширования изображений, с сохранением их семантических признаков, в базе данных, созданной на основе искусственной свёрточной нейронной сети, что включает в себя масштабно-инвариантную трансформацию признаков изображения в хеш – пространство.

Глава 3 рассматривает вопросы распознавания деструктивных эмоций человека по его изображению, с помощью обучения свёрточной нейронной сети, а также разработку программного средства на базе нейросетевых алгоритмов, обрабатывающего как фотографии, так и кадры из видеопотока Web-камеры.

Глава 4 продолжает исследование вопросов распознавания человеческих эмоций, проявляемых в различных областях жизни. Изучена проблема извлечения эмоциональных характеристик из речевых сигналов, с целью формирования данных для обучения нейронных сетей и формирования оптимального алгоритма, а также реализовано мобильное приложение распознавание эмоций по голосу.

Глава 5 посвящена задаче распознавания объектов, представляющих угрозу, на изображении, их классификации, с применением свёрточных нейронных сетей и технологии компьютерного зрения, а также разработке оптимального алгоритма, способного находить, определять и распознавать неопознанный объект, потенциально представляющий угрозу, и его программной реализации.

Глава 6 рассматривает задачу *прокторинга* – отслеживания деструктивного поведения обучающихся – школьников и студентов во время тестирования, при дистанционном проведении экзаменов, зачётов и др. Разработан комплекс программных модулей, с использованием технологий машинного обучения и компьютерного зрения, отслеживающий в реальном времени деструктивное поведение обучающихся во время аттестационных мероприятий.

Глава 7 описывает процесс создания и обучения нейронной сети для распознавания деструктивных черт характера человека по его рукописному почерку. Реализация программного средства для графологического анализа психологии личности сегодня находит широкое применение в криминалистике, для выявления лиц, потенциально склонных к совершению преступлений.

Глава 8 посвящена процессу семантического анализа текста Web-сайтов, для распознавания их содержания с помощью технологий нейронных сетей, с целью блокировки деструктивного контента социальных сетей, негативно влияющего на психическое здоровье детей и несовершеннолетних подростков.

Глава 9 показывает возможное решение проблемы поиска потенциально опасных конструкций и уязвимостей в исходных текстах программного кода с помощью искусственных нейронных сетей. Разработан алгоритм работы анализатора исходных текстов программ, а также его программная реализация.

Глава 10 содержит разработку подсистемы поддержки принятия решений при идентификации объектов критической информационной инфраструктуры, что предполагает использование нормативно-правовой базы России, создание алгоритма идентификации объектов и его программную реализацию.

Глава 11 показывает процесс создания системы поддержки принятия решений при идентификации множества демаскирующих признаков объектов организации, защищаемой от угроз промышленного шпионажа и технической разведки противника. При разработке применены методы системного анализа, коэффициентные методики и экспертные оценки теории принятия решений.

Глава 12 продолжает исследования, выполненные в предыдущей главе, с использованием нейро-нечётких алгоритмов искусственного интеллекта. В проекте разработана методика построения fuzzy-система идентификации множества демаскирующих признаков объектов защищаемой организации.

Глава 13 посвящена созданию подсистемы поддержки принятия решений, при идентификации технических каналов утечки информации в защищаемой комплексной информационной системе организации, с применением методов системного анализа, коэффициентной методики и экспертных оценок.

Глава 14 продолжает исследования предыдущей главы, с применением интеллектуальных алгоритмов нейро-нечёткой логики. Разработан адаптивный fuzzy – алгоритм идентификации технических каналов утечки информации в защищаемой комплексной информационной системе организации, выполнены его программная реализация и тестирование программного обеспечения.

Глава 15 посвящена интеллектуальному анализу данных, с учётом свойств динамических процессов, и разработке алгоритмов оценки параметров движения динамических объектов в задачах сопровождения. Применён новый подход к синтезу экстраполяторов для широкого круга объектов, движение которых подчинено вариационному принципу Гамильтона–Остроградского. Разработан динамический экстраполятор функций в форме, пригодной для реализации в новых радиолокационных системах контроля радиоэлектронной обстановки.

Глава 16 содержит исследования проблем безопасности интеллектуальных информационных систем беспилотных транспортных средств. Классификация уровней автоматизации беспилотных автомобилей показывает суть процессов автоматизации транспортных средств, а также угроз их кибербезопасности. Уязвимости интеллектуальных беспилотных транспортных средств пятого уровня автоматизации могут оказаться той брешью в их кибербезопасности, которой не преминут воспользоваться различного рода злоумышленники. Исследованы проблемы безопасности системы обмена информации V2I между транспортными средствами и инфраструктурой, возможные кибернетические атаки на неё, и методы противодействия этим кибератакам. Рассмотрена система CVGuard, предназначенная для обнаружения и предотвращения кибератак на интеллектуальные беспилотные транспортные средства, работающие в сети Интернет. Проведено тематическое исследование приложения SSGA, изучена возможность предотвращения атак с помощью системы CVGuard, дана оценка работы этой системе в условиях проведения DDoS-атаки группой хакеров, состоящей из трёх злоумышленников. Проведённые эксперименты, анализ результатов моделирования и компьютерной симуляции наглядно показал, что использование системы CVGuard позволило на 60% снизить количество конфликтов между беспилотными транспортными средствами, вызванных DDoS-атакой на приложение SSGA на нерегулируемом перекрестке.

Главы 1–15 написаны ведущими учёными и преподавателями кафедры «Кибербезопасность информационных систем» факультета «Информатика и вычислительная техника» ДГТУ, представляющими свои научно-технические проекты, выполненные ими совместно с выпускниками кафедры.

Глава 16 написана ведущими сотрудниками научно-исследовательской лаборатории «Интеллектуальные электрические сельскохозяйственные машины и комплексы» Донского государственного технического университета.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК

К 1 главе

1. Ruttor, A. Neural Synchronization and Cryptography. / PhD thesis, Bayerische / A. Ruttor: Julius–Maximilians–Universität Würzburg, 2006.–p.120.
2. Червяков, Н.И. Применение искусственных нейронных сетей и системы остаточных классов в криптографии / Червяков Н.И., Евдокимов А.А., Галушкин А.И., Лавриненко И.Н.: БХВ–Петербург, 2010. – 274 с.
3. Джонс, Т. Программирование искусственного интеллекта в приложениях: Москва: Техносфера, 2004. – 311 с.
4. Чмора, А.Л. Современная прикладная криптография / А.Л. Чмора. – М.: Гелиос АРВ, 2001. – 256 с.
5. Каллан, Р. Нейронные сети. Краткий справочник / Р. Каллан. – М.: Вильямс, 2017. – 288 с.
6. Рассел, Д. Нейрокриптография / Д. Рассел, Р. Кон. – СПб.: VSD, 2013.– с. 97.
7. Бабаш, А.В. Криптографические методы защиты информации / А.В. Бабаш, Е.К. Баранова. – М.: Кнорус, 2016. – с. 190.
8. Иванов, М.А. Криптографические методы защиты информации в компьютерных системах и сетях / М.А. Иванов. – М.: Кудиц–Образ, 2001. – с. 368.
9. Ахметов, Б.С. Технология использования больших нейронных сетей для преобразования нечетких биометрических данных в код ключа доступа / Б.С. Ахметов, А.И. Иванов, В.А. Фунтиков [и др]. – Алматы: ТОО «Издательство LEM», 2014. – с. 144.
10. Шнайер, Б. Прикладная криптография. Протоколы, алгоритмы, исходные тексты на языке Си / Б. Шнайер. – М.: Триумф, 2012. – с. 815.
11. Молдовян, Н.А. Введение в криптосистемы с открытым ключом / Н.А. Молдовян // СПб.: ВHV, 2014. – с. 288.
12. Каллан, Р. Основные концепции нейронных сетей / Р. Каллан. – М.: Вильямс, 2017. – с. 288.
13. Кузнецов, М. Объектно–ориентированное программирование на PHP / М. Кузнецов, И. Симдянов. – М.: БХВ–Петербург, 2012. – 608 с.
14. Мельников, Д. Информационная безопасность открытых систем / Д. Мельников. – М.: Флинта, 2013. – с. 448.
15. Дорогов А.Н. Теория и проектирование быстрых перестраиваемых преобразований и слабосвязанных нейронных сетей / А.Н. Дорогов. – М.: Политехника, 2014. – с. 328.

К 2 главе

16. Крижевский А., [et al]. " ImageNet Classification with Deep Convolutional Neural Networks". DOI: 10.1145/3065386. ISSN 0001–0782. S2CID 195908774.
17. Lin K., Yang H. F. [et al.]. “Deep learning of binary hash codes for fast image retrieval”. // IEEE (CVRPW). – 2015. – DOI: 10.1109/CVPRW.2015.7301269. – URL: ieeexplore.ieee.org/document/7301269 (date of application: 30.01.2021).
18. Cao Yu. “Deep Visual–Semantic Quantization for Efficient Image Retrieval” [URL:https://github.com/caoyue10/DeepHash](https://github.com/caoyue10/DeepHash)-Papers (date of application:21.01.2021)
19. Zuo Zh., Shuai B. [et al.]. “Convolutional Recurrent Neural Networks: Learning Spatial Dependencies for Image Representation”//IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops (CVRPW). DOI: 10.1109/CVPRW.2015.7301268.URL:ieeexplore.ieee.org/document/7301268 (date of the application: 30.01.2021).
20. Fang Y., Yue–Hei J., [et al.]. “Exploiting Local Features from Deep Networks for Image Retrieval”// IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops. DOI: 10.1109/CVPRW.2015.7301272. – URL: ieeexplore.ieee.org/document/7301272 (date of the application: 30.01.2021).
21. Lin K., Yang H.F. [et al.]. “Learning Compact Binary Descriptors with Unsupervised Deep Neural Networks”// IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVRP). 2016. DOI: 10.1109/CVPR.2016.133. – URL: ieeexplore.ieee.org/document/7780502 (date of the application: 14.01.2021).
22. Lu J., Chen Ch. [et al.]. “Feature Extraction using Convolution Neural Networks (CNN) and Deep Learning” // IEEE International Conference on Recent Trends in Electronics, Information and communication technology (RTEICT). – 2018.DOI:10.1109/RTEICT42901.2018.9012507.URL:ieeexplore.ieee.org/document/9012507 (date of the application: 21.01.2021).
23. Babenko A., Maire M., [et al.]. “Latent Embeddings for Zero–Shot Classification”// IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVRP).2016.doi:10.1109/CVPR.2016.15. – URL: ieeexplore.ieee.org/document/7780384 (date of the application: 14.01.2021). – Access mode: free.
24. Lowe D. “Object Recognition from Local Scale – Invariant Features” // IEEE (ICCV).DOI: 10.1109/ICCV.2019.790410. – URL: ieeexplore.ieee.org/document/790410 (date of the application: 16.01.2021).

25. Yoo D., Park S. [et al.]. Multi-Scale Pyramid Pooling for Deep Convolutional Representation // IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). DOI: 10.1109/CVPRW.2015.7301274. URL: ieeexplore.ieee.org/document/7301274 (date of the application: 30.01.2021).
26. Lin K., Elkins J., Hossain G. [et al.]. “Multinomial Processing Models in Visual Cognitive Effort Diagnostics” // IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops (CVPRW 2017). DOI: 10.1109/ CVPRW.2015.7301287. URL: ieeexplore.ieee.org/ document/ 7301287 (date of the application: 30.01.2021). – Access mode: free.
27. Kruthiventi S., Babu V. [et al.]. “Dominant Flow Extraction and Analysis in Traffic Surveillance Videos”// IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). DOI: 10.1109/CVPRW. 2019. 7301285. URL: ieeexplore.ieee.org/document/7301285 (date of application: 30.01.2021).
28. Reed S., Akata Z. [et al.]. “Learning Deep Representations of Fine-Grained Visual Descriptions” // IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVRP). 2018. DOI: 10.1109/CVPR.2018.13. – URL: ieeexplore.ieee.org/document/7780382 (date of the application: 14.01.2021).
29. Maire M. “Affinity CNN: Learning Pixel-Centric Pairwise Relations for Figure/Ground Embedding”// IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVRP). 2019. DOI: 10.1109/CVPR.2019.26. URL: ieeexplore.ieee.org/document/7780395 (date of the application: 14.01.2021).
30. Maire M. [et al.]. “Compact bilinear pooling”// IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVRP). DOI: 10.1109/ CVPR. 2018. 41. URL: ieeexplore.ieee.org/document/7780410 (date of application: 14.01.2021).
31. Maire M., Narihira T. [et al.]. “Object Contour Detection with Fully Encoder Convolutional Decoder Network”//IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVRP). DOI: 10.1109/CVPR.2019.28. URL: ieeexplore.ieee.org/document/7780397 (date of the application: 14.01.2021).
32. Liu Yu., Lew M. [et al.]. “Learning Relaxed Deep Supervision for Better Edge Detection”// IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVRP). DOI: 10.1109/CVPR.2018.32. URL: ieeexplore.ieee.org/ document/ 7780401 (date of the application: 14.01.2021).
33. Fu H., Chaohui W. [et al.]. “Occlusion boundary detection via exploration of context” // IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVRP). DOI: 10.1109/CVPR.2019.33. URL: ieeexplore.ieee.org/ document/7780402 (date of the application: 14.01.2021).

К 3 главе

34. Китай внедряет технологии распознавания эмоций. Чем это грозит остальному миру? / Текст: Электронный ресурс // polit: 2020. URL: <https://polit.ru/article/2021/03/05/chinaemotions/> (дата обращения: 27.05.2021).

35. Сверточные нейронные сети. Wikikonспекты. Текст: Электронный ресурс. 2020. URL: <https://neerc.ifmo.ru/wiki/index.php?title> (дата обращения: 27.05.2021).

36. Метод распознавания лиц Виолы–Джонса. / Текст: Электронный ресурс // oxozle: 2015. – URL: <https://oxozle.com/2015/04/11/metod-raspoznavaniya-lic-violy-dzhonsa-viola-jones/> (дата обращения: 27.05.2021).

37. Исследование рынка систем распознавания эмоций. Текст: Электронный ресурс//habr: 2019. URL: <https://habr.com/ru/post/133686/> (дата обр.: 28. 05.2021).

38. Приложение Magic распознает эмоции в реальном времени. Текст: Электр. ресурс//life: 2019. URL: <https://life.ru/p/985737> (дата обращения: 07.06. 2021).

39. Top 10 Datasets Available For Emotion Detection: / Analytics India Magazine. Текст: Электронный ресурс //analyticsindiamag: 2020. URL: <https://analyticsindiamag.com/top-10-datasets-available-for-emotion-detection> (дата обр.: 27.05.2021).

40. Топ 10 фреймворков для искусственного интеллекта. Текст: Электронный ресурс//vc.ru 2020. URL: <https://vc.ru/ml/80391-top-10-freymvorkov-dlya-iskusstven-nogo-intellekta-chast-pervaya> (дата обращения: 01.06.2021).

41. C++. Текст: Электронный ресурс // Wikipedia: 2019. URL: <https://ru.wikipedia.org/wiki/C%2B%2B> (дата обращения: 06.06.2021).

42. Install and Configure OpenCV. Текст: Электронный ресурс // towards_data_science: 2019. URL: <https://towardsdatascience.com/install-and-configure-opencv-4-2-0-in-windows-10-vc-d132c52063a1> (дата обращения: 06.06.2021).

43. Python. сайт / Википедия. Текст: Электронный ресурс // Wikipedia: 2021. URL: <https://ru.wikipedia.org/wiki/Python> (дата обращения: 06.06.2021).

44. Anaconda (дистрибутив Python). Текст: Электронный ресурс // Wikipedia: 2021. URL: <https://ru.wikipedia.org/wiki/Anaconda> (дата обращения: 04.06.2021).

45. Введение в работу с Jupyter Notebook. Текст: Электронный ресурс // Python.ru: 2019. URL: <https://pythonru.com/baza-znaniy/jupyter-notebook-dlja-nachinajushhih> (дата обращения: 04.06.2021).

К 4 главе

46. Хрисанфова Е.В. Эмоциональный искусственный интеллект: кто и зачем распознаёт эмоции в России и за рубежом. Текст: электронный ресурс // РБ.ру. 2021. URL: <https://rb.ru/longread/emotion-ai/> (дата обращения: 11.04.2021).

47. Калинин И.Н. Понимающие алгоритмы: зачем бизнесу нужны боты с распознаванием эмоций. Текст: электронный ресурс // РБ.ru. 2021. URL: <https://rb.ru/opinion/emotional-robots/> (дата обращения: 11.04.2021).
48. Калинин И.Н. Разговор с роботом: как ИИ меняет бизнес-процессы уже сегодня. Текст: электронный ресурс // Хайтек.fm. 2021. URL: <https://hightech.fm/2020/09/16/chat-bot-business> (дата обращения: 11.04.2021).
49. Управление ресурсами и службами здравоохранения. Аутистическое расстройство. Текст: электронный ресурс // CDC.gov. 2012. URL: https://www.cdc.gov/media/releases/2013/a0320_autism_disorder.html (дата обр.: 11.04.2021).
50. Russcol A. The Unproven Invasive Surveillance Technology School are Using to Monitor School. Текст: электронный ресурс // ProPublica.org/ 2021. URL: <https://features.propublica.org/aggression-detector/theunproven-invasive-surveillance-technology-schools-are-using-to-monitorstudents/> (дата обр: 17.04.20 21).
51. Matheson R. Нейросетевая модель распознавания депрессии. Текст: Электронный ресурс // МитНьюс.edu. 2021. URL: <https://news.mit.edu/2018/neural-network-model-detect-depressionconversations-0830> (дата обр.: 25.04.2021).
52. Beyond Verbal: официальный сайт. Ньютон. Обновляется в течение суток. URL: <https://vocalishealth.com> (дата обращения: 25.04.2021).
53. Де Валь Франс, В.М. Истоки морали. В поисках человеческого у приматов. Москва: Альпина нон-фикшн 2014. 442 с. (дата обращения: 27.04.2021).
54. Aleix R., Shichuan D., Martinez L. A Model of the Perception of Facial Expressions of Emotion by Humans: Research Overview and Perspectives. // The Journal of Machine Learning Research. N 235. Pp.1589–1608 с.
55. Леонтьев А.Н. Потребности, мотивы и эмоции человека. Текст: электронный ресурс // МитНьюс.edu. 2021. URL: <https://news.mit.edu/2018/potrebnosty-motivi-i-emocii> (дата обращения: 27.04.2021).
56. Hudlicka E. To Feel or not to Feel: The Role of Affect in Human Computer Interaction. Текст: электронный ресурс // International Journal of Human-Computer Studies. N 59 (1–2) Pp. 1–32. (дата обращения: 27.04.2021).
57. Изард К. Эмоции человека. Москва: Вильямс, 1980. 256 с.
58. Мел-кепстральные коэффициенты. Текст: электронный ресурс // Habr.com. 2021. URL: <https://habr.com/ru/post/140828/> (дата обр.: 13.05.2021).
59. Tensorflow Lite. Текст: электронный ресурс // TensorFlow.org. 2021. URL: <https://www.tensorflow.org> (дата обращения: 13.05.2021).
60. Android vs IOS. Текст: электронный ресурс // VC.ru. 2021. URL: <https://vc.ru/dev/181153-ios-ili-android-chto-vybrat> (дата обращения: 13.05.2021).

К 5 главе

61. Харрисон М. Машинное обучение. Краткое руководство по методам структурированного машинного. / М. Харрисон. - Москва: Диалектика, 2020 г. – 320с. - ISBN: 978-5-907203-17-4

62. Чيو К. Машинное обучение и безопасность. Защита систем с помощью данных и алгоритмов. / К. Чيو. - Москва: ДМК-Пресс, 2020 г. – 388 с.

63. Рашка С. Python и машинное обучение: машинное и глубокое обучение с использованием Python, scikit-learn и Ten. / С. Рашка. - Ростов-на-Дону: Вильямс, 2019 г. – 656 с. - ISBN: 978-5-907114-52-4

64. Янсен С. Машинное обучение для алгоритмической торговли. Практикум. / С. Янсен. - Москва: BHV, 2020 г. 560 с. -ISBN: 978-5-9775-6595-0

65. Buldumac V. Модуль subprocess — Работаем с процессами/ V.Buldumac. - Текст: электронный // python-scripts.com: [сайт]. - 2018. - URL: <https://python-scripts.com/subprocess> (дата обращения 10.05.2021)

66. Таринов Д. Модуль subprocess/ Д. Таринов - Текст: электронный // pythonworld.ru: [сайт]. - 2018. - URL: <https://pythonworld.ru/moduli/modul-subprocess.html> (дата обращения 10.05.2021)

67. Хилпиш И. Python для финансовых расчетов. / И. Хилпиш. - Москва: Диалектика, 2021 г. – 800 с. - ISBN: 978-5-907203-03-7

68. Маккини У. Python и анализ данных. / У. Маккини. - Москва: ДМК-Пресс, 2020 г. – 540 с. - ISBN: 978-5-97060-590-5 4

69. Python/C API Reference Manual: сайт / Python. - 2021. - URL: <https://docs.python.org/3/c-api/index.html> (дата обращения 15.04.2021)

70. Adam R.S. Введение в Pandas / R.S. Adam. - Текст: электронный // khashtamov.com: [сайт]. – 2017. - URL: <https://khashtamov.com/ru/pandas-introduction/> (дата обращения 02.05.2021)

71. Vosk documentation: сайт / Vosk. 2019. URL: <https://alphacephei.com/vosk/> (дата обращения 20.04.2021)

72. Oberneder A. Cmd Commands Under Windows/ A. Oberneder . - Текст: электронный // thomas-krenn.com: [сайт]. – 2021. – URL: https://www.thomas-krenn.com/en/wiki/Cmd_commands_under_Windows (дата обращения 19.04.2021)

73. Pavlow S.W. RHVoice в pytsx3/ S.W. Pavlow. - Текст: электронный // habr.com: [сайт].-2019.-URL: <https://qna.habr.com/q/906683> (дата обр. 05.05.2021)

74. Пэйн Б. Python для детей и родителей. / Б. Пэйн. - Москва: Эксмо, 2017 г. – 352 с. - ISBN: 978-5-699-95169-7

75. Shinnars P. Python Pygame Introduction/ P. Shinnars - Текст: электронный // pygame.org: [сайт].-2017.-URL:<https://www.pygame.org/docs/tut/PygameIntro.html> (дата обращения 15.05.2021)

К 6 главе

76. Норвиг П., Рассел С. Искусственный интеллект: современный подход / П. Норвиг, С. Рассел. Москва: Вильямс, 2007. – 1408 с.

77. Oracle. Искусственный интеллект. – Текст : электронный // Oracle : [сайт]. – 2021. – URL: <https://www.oracle.com/ru/artificial-intelligence/what-is-ai/#ai-terms> (дата обращения: 09.05.2021).

78. CloudMTS. «Машинное обучение»: Потенциал и возможности. – Текст : электронный // Habr : [сайт]. – 2016. – URL: <https://habr.com/ru/company/it-grad/blog/306220/> (дата обращения: 09.05.2021).

79. ProctorU - организация, специализирующаяся на надзоре (прокторинге). Как работает прокторинг на индивидуальном компьютере. – Текст : электронный // Timkin.blog [сайт]. – 2013. – URL: <http://timkin-blog.blogspot.com/2013/12/proctoru.html> (дата обращения: 12.05.2021).

80. Microsoft. Руководство по архитектуре приложений Microsoft / Microsoft – Изд. 2-е, 2009. – 529 с. – ISBN: 978-0-7356-2710-9

81. Муджтаба Х. Распознавание лиц с помощью Python и OpenCV. – Текст : электронный // GreatLearning : [сайт].-2020. – URL: <https://www.mygreatlearning.com/blog/face-recognition/#sh1> (дата обращения: 15.05.2021).

82. Левчук С.А., Якименко А.А. Исследование характеристик алгоритмов распознавания лиц /С.А. Левчук, А.А. Якименко.–Текст: электронный // Сборник научных трудов НГТУ. – Новосибирск: НГТУ, 2018.–С.40-58.– URL:<https://elibrary.ru/item.asp?id=38073224> (дата обр. 15.05.2021)

83. Towards data science. Что нового в YOLOv3? – Текст : электронный // Towards Data Science : [сайт]. – 2021. – URL: <https://towardsdatascience.com/yolo-v3-object-detection-53fb7d3bfe6b> (дата обращения: 16.05.2021).

84. Рашка С. Python и машинное обучение / С. Рашка. – пер. с англ. – Москва: ДМК Пресс, 2017. – 418. – ISBN: 978-5-97060-409-0.

85. Редмон Д., Дивелла С., Гиршик Р., Фархади А., You Only Look Once: Unified, Real-Time Object Detection – Текст : электронный // YOLO : [сайт]. – 2021. –URL: https://pjreddie.com/media/files/papers/yolo_1.pdf (дата обр.: 17.05.2021).

86. Рашка С., Мирджалили В. Python и машинное обучение: машинное и глубокое обучение с использованием Python, scikit-learn и Tensorflow 2 / С. Рашка, В. Мирджалили. – Санкт–Петербург: «Диалектика», 2020. – 848 с.

К 7 главе

87. Графология: характер человека. Учебно-методическое пособие – Текст : электронный // Верити.рф : [сайт]. – 2021. – URL: <https://bnti.ru/showart.asp> (дата обращения: 11.05.2021).

88. Инсайт Клиника. Текст : электронный // Masterhost.ru : [сайт]. – 2021. – URL: <https://clinica.nsk.ru> (дата обращения: 12.05.2021).

89. Дополнительное образование – Текст : электронный // Info.ch : [сайт]. – 2021. – URL: http://inpsycho.ru/additional_educat (дата обращения: 14.05.2021).

90. Программирование Python – Текст : электронный // Stepik: [сайт]. – 2021. – URL: <https://stepik.org/course/67/promo> (дата обращения: 15.05.2021).

91. Самоучитель Python – Текст : электронный // Python: [сайт]. – 2021. – URL: <https://pythonworld.ru/samouchitel-python> (дата обращения: 15.05.2021).

92. Python – Текст : электронный // Hostiq: [сайт]. – 2021. – URL: <https://pythonworld.ru/samouchitel-python> (дата обращения: 16.05.2021).

93. Math – Текст : электронный // Python: [сайт]. – 2021. – URL: <https://pythonworld.ru/moduli/modul-math.html> (дата обращения: 16.05.2021).

94. Pythonlib – Текст : электронный // Ру: [сайт]. – 2021. – URL: <https://metanit.com/python/tutorial/6.2.php> (дата обращения: 16.05.2021).

95. OpenCV – Текст : электронный // Spinch: [сайт]. – 2021. – URL: <http://pypi.org/project/opencv-python/> (дата обращения: 18.05.2021).

96. DocOpenCV – Текст : электронный // Mb4: [сайт]. – 2021. – URL: <https://docs.opencv.org/4.5.2/> (дата обращения: 18.05.2021).

97. Python + OpenCV – Текст : электронный // Aitishnik: [сайт]. 021. URL: <https://mirrobo.ru/pilot/jazyk-programmirovaniya-python/> (дата обр: 20.05.2021).

К 8 главе

98. Автоматическая обработка текстов на естественном языке и компьютерная лингвистика: учебное пособие / Е.И. Большакова, Э.С. Клышинский, Д.В. Ландэ [и др.]. Москва: МИЭМ, 2011. — 272 с.

99. Bird, S. Natural Language Processing with Python / S. Bird, E. Klein, E. Loper. — Newton, USA: O'Reilly Media Inc., 2009. 504 с.

100. Вейник, П. Обработка естественного языка: краткий ликбез для разработчиков / П. Вейник. – Текст: электронный// dev.by: [сайт]. – 2016. – 12 июля – URL: <https://dev.by/news/obrabotka-estestvennogo-yazyka-kratkiy-likbez-dlya-razrabotchikov> (дата обращения 03.06.2021).

101. Виды ансамблей Текст: электронный// neerc.ifmo.ru: [сайт] 2020. URL: https://neerc.ifmo.ru/wiki/index.php?title=Виды_ансамблей (дата обр. 03.06.2021).
102. Leventis D. XGBoost Mathematics Explained / D. Leventis Текст: электр. // towardsdatascience.com: [сайт]. 2018. URL: [https:// towardsdata science. com/xgboost-mathematics-explained-58262530904a](https://towardsdatascience.com/xgboost-mathematics-explained-58262530904a) (дата обр. 03.06.2021).
103. Geitgey A. Natural Language Processing is Fun! / A. Geitgey. Текст: электр. // medium.com: [сайт]. 2018. URL: <https://medium.com/@ageitgey/natural-language-processing-is-fun-9a0bff37854e> (дата обращения 03.06.2021).
104. Jeřek K. Automatic Text Summarization: State of the art and new challenges / K. Jeřek, J. Steinberger. Czech Republic: Proceedings of Znalosti, 2008. 12 с.
105. Бирюкова Т.Г. Анализ и синтез текста: Елец: ЕГУ, 2007. 98 с.
106. Luhn H.P. Automatic Creation of Literature Abstracts: London, 1958. 165 с.
107. Орлов, А.И. Организационно–экономическое моделирование. Москва: МГТУ им. Н.Э. Баумана. 2011. 486 с.
108. Mikolov, T. Efficient Estimation of Word Representations in the Vector Space: Czech Republic – Cornell University, 2013. – 12 с.
109. Немного про word2vec: полезная теория – Текст: электронный// nlpх.net: [сайт] 2015. 3 ноября URL: <http://nlpх.net/archives/179> (дата обр. 03.06.2021).
110. Борисов Е.С. Автоматизированная обработка текстов на естественном языке, с использованием инструментов языка Python. Текст: электр.// mechanoid.su: [сайт]. 2017. URL: <http://mechanoid.su/ml-text-proc.html>
111. Селиверстов, В. Word2Vec: покажи мне свой контекст, и я скажу, кто ты Текст: электронный// sysblok.ru: [сайт] 2019. URL: <https://sysblok.ru/knowhow/word2vec-pokazhi-mne-svoj-kontekst-i-ja-skazhu-kto-ty/> (дата обр. 03.06.2021).
112. Alammar, J. Word2vec в картинках. Текст: электронный// habr.com: [сайт]. 2019. URL: <https://habr.com/ru/post/446530/> (дата обр. 03.06.2021).
113. КиберЛенинка: Научная электронная библиотека: сайт – Москва – URL: <https://cyberleninka.ru> (дата обращения 03.06.2021).

К 9 главе

114. Федеральный закон РФ от 27 июля 2006 г. № 149-ФЗ «Об информации, информационных технологиях и о защите информации».
115. Кармановский Н.С., Михайличенко О.В., Савков С.В. Организационно–правовое и методическое обеспечение информационной безопасности: учебное пособие /Н.С. Кармановский. – СПб: НИУ ИТМО, 2013. – 148 с.

116. Никифоров С.Н. Защита информации. Защита от внешних вторжений. – СПб.: Государственный архитектурно–строительный университет, 2017. – 45 с.
117. Меры защиты информации в государственных информационных системах. Утверждены ФСТЭК России 11.02.2014 года.
118. Руководящий документ. Автоматизированные системы управления. Защита от несанкционированного доступа к конфиденциальной информации. Классификация автоматизированных систем и требования по защите информации. Утвержден решением председателя Государственной технической комиссии при Президенте Российской Федерации от 30 мая 1992 г.
119. ГОСТ Р 7.0.97–2016. Система стандартов по информации, библиотечному и издательскому делу. Организационно–распорядительная документация. Требования к оформлению документов. М.: Издательство стандартов, 2016. 27 с.
120. ГОСТ Р 7.0.8-2013. Система стандартов по информации, библиотечному и издательскому делу. Делопроизводство и архивное дело. Термины и определения. Введ. 2014-03-01. М.: Издательство стандартов, 2013. 9 с.
121. Руководящий документ. Защита от несанкционированного доступа к информации. Часть 1. Программное обеспечение средств защиты информации. Классификация по уровню контроля отсутствия не декларированных возможностей. Утвержден решением председателя Государственной технической комиссии при Президенте Российской Федерации от 4 июня 1999 г.
122. Коваленко Ю.И. Правовой режим лицензирования и сертификации в сфере информационной безопасности. М.: Горячая линия. Телеком, 2012. 14с.
123. Гвидо С. Введение в машинное обучение с помощью Python / А. Мюллер, С. Гвидо. М. Издательский дом «Вильямс», 2015. 148 с.
124. Роджас Р. Нейронные сети и способы их обучения / Р. Роджас. М. Издательский дом «Springer», 2017. 57 с.
125. Рашка С. Машинное обучение на Python / С. Рашка; Истомин В.И. – М.: Издательский дом «Packt», 2016. – 49 с.
126. Бишоп К. Распознавание образов и машинное обучение / К. Бишоп, Патрушина П. Е. М.: Издательский дом «Вильямс», 2014. 78 с.
127. Рашид Т. Создай свою собственную нейронную сеть / Т. Рашид, Д.А. Лебедева. М.: Издательский дом «Springer», 2016. 107 с.
128. Вандер Д. Python для сложных задач. Наука о данных и машинное обучение / Д. Вандер. СПб.: Издательский дом «Питер», 2016. 127 с.

К 10 главе

129. О безопасности критической информационной инфраструктуры Российской Федерации: федеральный закон от 26 июля 2017 г. №187 // Собрание законодательства РФ. – 2017. – 20с.

130. Национальный форум информационной безопасности «ИнфоФорум 2020» // Официальный сайт URL: <https://infoforum.ru/conference/conference/program/cid/59?cid=9> (дата обращения: 07.05.2020).

131. Международная компания, работающая в сфере информационной безопасности «Лаборатория Касперского» // Официальный сайт URL: <https://www.kaspersky.ru/> (дата обращения: 20.05.2020).

132. Российский разработчик сертифицированных средств защиты информации «Код безопасности» // Официальный сайт. URL: <https://www.securitycode.ru/> (дата обращения: 21.05.2020).

133. О внесении изменений в Положение о Федеральной службе по техническому и экспортному контролю, утверждённое Указом Президента Российской Федерации от 16 августа 2004 года №1085: указ Президента РФ от 25 ноября 2017 года №569 // Собрание законодательства РФ. – 2017. – 21с.

134. О совершенствовании государственной системы обнаружения, предупреждения и ликвидации последствий компьютерных атак на информационные ресурсы Российской Федерации: указ Президента РФ от 22 декабря 2017 года №620 // Собрание законодательства РФ. – 2017. – 11с.

135. О внесении изменений в Перечень сведений, отнесённых к государственной тайне, утверждённый Указом Президента Российской Федерации от 30 ноября 1995 года №1203: указ Президента РФ от 2 марта 2018 года №98 // Собрание законодательства РФ. – 2018. – 10с.

136. Об утверждении Правил категорирования объектов КИИ Российской Федерации, а также перечня показателей критериев значимости объектов критической информационной инфраструктуры Российской Федерации и их значений: постановление Правительства Российской Федерации от 8 февраля 2018 года №127 // Собрание законодательства РФ. – 2018. – 21с.

137. Об утверждении Правил осуществления государственного контроля в области обеспечения безопасности значимых объектов КИИ: постановление Правительства Российской Федерации от 17 февраля 2018 года №162 // Собрание законодательства РФ. – 2018. – 13с.

138. Об утверждении требований к созданию систем безопасности значимых объектов КИИ и их функционирования: приказ ФСТЭК России от 21 декабря 2017 года №235 // Собрание законодательства РФ. – 2017. – 14с.

139. Об утверждении формы направления сведений о результатах присвоения объекту КИИ одной из категорий значимости: приказ ФСТЭК России от 22 декабря 2017 года №236 // Собрание законодательства РФ. – 2017. – 7с.

140. Об утверждении требований по обеспечению безопасности значимых объектов КИИ: приказ ФСТЭК России от 25 декабря 2017 года №239 // Собрание законодательства РФ. – 2017. – 32с.

141. Об утверждении формы акта проверки, составляемого по итогам проведения государственного контроля в области обеспечения безопасности значимых объектов критической информационной инфраструктуры российской федерации: приказ ФСТЭК России от 11 декабря 2017 года №229 // Собрание законодательства РФ. – 2017. – 21с.

142. Об утверждении порядка ведения реестра значимых объектов КИИ: приказ ФСТЭК России от 6 декабря 2017 года №227 // Собрание законодательства РФ. – 2017. – 11с.

143. Об утверждении Положения о Национальном координационном центре по компьютерным инцидентам: приказ ФСБ России от 24 июля 2018 года №366 // Собрание законодательства РФ. – 2018. – 21с.

144. Об утверждении Перечня информации, представляемой в государственную систему обнаружения, предупреждения и ликвидации последствий компьютерных атак на информационные ресурсы Российской Федерации и Порядка представления информации в государственную систему обнаружения, предупреждения и ликвидации последствий компьютерных атак на информационные ресурсы Российской Федерации: приказ ФСБ России от 24 июля 2018 года №367 // Собрание законодательства РФ. – 2018. – 12с.

145. Об утверждении Порядка информирования ФСБ России о компьютерных инцидентах, реагирования на них, принятия мер по ликвидации последствий компьютерных атак, проведенных в отношении значимых объектов КИИ Российской Федерации: приказ ФСБ России от 19 июня 2019 года №282 // Собрание законодательства РФ. – 2019. – 21с.

146. Об утверждении Порядка, технических условий установки и эксплуатации средств, предназначенных для обнаружения, предупреждения и ликвидации последствий компьютерных атак и реагирования на компьютерные инциденты, за исключением средств, предназначенных для поиска признаков компьютерных атак в сетях электросвязи, используемых для организации взаимодействия объектов КИИ Российской Федерации: приказ ФСБ России от 19 июня 2019 года №281 // Собрание законодательства РФ. – 2019. – 23с.

147. Об утверждении порядка об обмене информации о компьютерных инцидентах между субъектами КИИ: приказ ФСБ России от 24 июля 2018 года №368 // Собрание законодательства РФ. – 2018. – 21с.

148. Об утверждении требований к средствам, предназначенным для обнаружения, предупреждения и ликвидации последствий компьютерных атак и реагирования на компьютерные инциденты: приказ ФСБ России от 6 мая 2019 года №196 // Собрание законодательства РФ. – 2019. – 21с.

149. Об утверждении порядка, технических условий, установки и эксплуатации средств обнаружения, предупреждения и ликвидации компьютерных атак на сетях связи: приказ Минкомсвязи России // Собрание законодательства Российской Федерации. – 2019. – 21с.

150. Об утверждении Доктрины информационной безопасности Российской Федерации: указ Президента Российской Федерации от 05.12.2016 г. № 646 // Собрание законодательства РФ. – 2016. – 17с.

К 11 главе

151. Носуленко В.Н. Психология слухового восприятия / В.Н. Носуленко - Москва: Наука, 1988. – 216 с.

152. Привалов Е. Е. Электротехническое материаловедение: учебное пособие / Е. Е. Привалов. – М. – Берлин: “Директ–Медиа”, 2015. - 234 с.

153. ГОСТ Р 51275-2006 Объект информатизации. Факторы, воздействующие на информацию – Введ. 2008-02-01. – М.: Издательство стандартов, 2007. – 7 с.

154. Гражданская защита. Понятийно–терминологический словарь. / под. общ. ред. Ю. Л. Воробьева М.: Издательство “Флайст”, Информационно-издательский центр «Геополитика», 2001. – 240 с.

155. ГОСТ Р 50922-2006. Защита информации. Основные термины и определения. Введение. 2008-02-01. – М.: Издательство стандартов, 2007.– 7 с.

156. Гуляев В.П. Анализ демаскирующих признаков объектов информатизации и технических каналов утечки информации / В.П. Гуляев – Екатеринбург: Издательство Уральского университета, 2014. – 164 с.
157. Халяпин Д.Б. Защита информации. Вас подслушивают? Защищайтесь! / Д.Б. Халяпин. —М.: НОУ ШО «Баярд», 2004. – 432 с.
158. Торокин А.А. Инженерно–техническая защита информации: учеб. пособие для студентов, обучающихся по специальностям информационной безопасности / А. А. Торокин. — М.: Гелиос АРВ, 2005. — 960 с.
159. ГОСТ 17657-79. Передача данных. Термины и определения – Введ. 1980-07-01. – М.: Издательство стандартов, 1979. – 59 с.
160. Королев А. Ю. Маскировка вооружения, техники и объектов. / А.Ю. Королев, А.А. Королева, А.Д. Яковлев – СПб: Университет ИТМО, 2015. –155 с.
161. Аэрозоли – дисперсные системы: Монография / Чекман И.С. [и др.]. – Харьков: «Цифровая типография №1», – 2013. 100 с.
162. Ардашев А.Н. Боевая подготовка воздушно–десантных войск. ВДВ – универсальный солдат / А.Н. Ардашев – Москва: Яуза: Эксмо, 2014. –416 с.
163. Грузевич Ю.К. Оптико–электронные приборы ночного видения. Ю.К. Грузевич / М.: ФИЗМАТЛИТ, 2014. — 276 с.
164. Кекчеев К.Х. Психофизиология маскировки и разведки / К.Х. Кекчеев – М.: Советская наука, 1942. – 108 с.
165. Подготовка войскового разведчика / П.Я. Поповских [и др.]. – М.: Воениздат, 1991. – 336 с.
166. Меньшаков Ю.К. Теоретические основы технических разведок: Учеб. пособие / Ю.К. Меньшаков. – М.: Изд–во МПУ им. Н.Э. Баумана, 2008. – 536 с.
167. ГОСТ 24375–80. Радиосвязь. Термины и определения – Введ. 1982–01-01. – М.: Издательство стандартов, 2005. – 37 с.
168. Маринченко А.В. Экология: учебник для студентов вузов / А.В. Маринченко. – М.: Дашков и К.° – 2015. – 304 с.
169. Диксон Р.К. Широкополосные системы: Пер. с англ. / Р.К. Диксон; под ред. В.И. Журавлева. – М.: Связь, 1979. – 304с.
170. ГОСТ 17657-79 Передача данных. Термины и определения – Введ. 1980-07-01. – М.: Издательство стандартов, 2005. – 25 с.
171. Прокис Джон. Цифровая связь. Пер. с англ. / Под ред. Д.Д. Кловского. – М.: Радио и связь. 2000. – 800 с.
172. Теория электрической связи: учебное пособие / К.К. Васильев [и др.]; под общ. ред. К.К. Васильева. – Ульяновск: УлГТУ, 2008. – 452 с.

173. Санитарно–эпидемиологические требования к обращению с медицинскими отходами: Санитарно–эпидемиологические требования, правила и нормативы. М: Федеральный центр гигиены и эпидемиологии Роспотребнадзора, 2011.–31 с.
174. Радиационные методы получения информации и возможности технических средств радиационной разведки / Дудыкевич В.Б. [и др.]. Защита информации. – Том 10. – 2008. – 30 октября (№4). – С. 5361.
175. Об отходах производства и потребления: федеральный закон: – М.: Собрание законодательства РФ", № 26, 29 июня 1998 года, ст. 3009, 1998. – 7 с.
176. Operating System Market Share. URL: [https:// netmarketsBare.com/operating-system-market-share.aspx](https://netmarketsBare.com/operating-system-market-share.aspx) (дата обращения: 06.05.2018).
177. TIOBE Index for May 2018. URL: <https://www.tiobe.com/tiobe-index> (дата обращения: 06.05.2018).
178. Орлов А.И. Теория принятия решений Учебное пособие. / Орлов А.И. – М.: Издательство "Март", 2004. – 374 с.
179. НПБ 105–03. Определение категорий помещений, зданий и наружных установок по взрывопожарной и пожарной опасности. М.: ФГУП ЦПП, 2003. 44 с.

К 12 главе

180. Бархоткин В.А., Кочетков М.П. Построение базы нечётких правил для идентификации объектов по обучающей выборке ограниченного объема // Известия ТулГУ. Технические науки. 2014. №12–2. URL: <https://cyberleninka.ru/article/n/postroenie-bazy-nechetkih-pravil-dlyaidentifikatsii-obektov-po-obuchayushey-vyborke-ogranichennogo-obema> (дата обращения: 23.03.2019).
181. Hagan M.T., Demuth H.B., Beale M. Neural Network Design, Boston: PWS Publishing Company, 1995.
182. Обобщенная колоколообразная функция принадлежности // MatLAB. Exponenta. URL: <http://matlab.exponenta.ru/fuzzylogic/book2/1/gbellmf.php> (дата обращения: 2.03.2019).
183. Azar A.T., Yucel R.K. Adaptive Neuro–Fuzzy Systems. Fuzzy systems. IN–TECH, Austria. 2010. Pp. 85–110.
184. Al–Hmouz A., Shen J., Al–Hmouz R., Yan, J. Modeling and Simulation of an Adaptive Neuro–Fuzzy Inference System (ANFIS) for mobile learning. IEEE Trans. Learn. Technol. 5. 2012. P. 226–237

185. Buragoham M. Adaptive Network Based Fuzzy Inference System (ANFIS) as Tool for System Identification with Special Emphasis on Training Data Minimization. // Thesis Submitted in Partial Fulfilment of the Requirements for the Degree of Doctor of Philosophy. Department of Electronics and Communication Engineering. Indian Institute of Technology Guwahati, Guwahati, India. 2008. URL: http://www.iitg.acin/engfac/chitra/notes/Thesis_Mrinal.pdf (дата обращения: 8.03.2019).
186. Hassan O., Abdelouahed S., Abdelali E., etc. ANFIS–Based Climate Controller for Computerized Greenhouse System. *Advances in Science, Technology and Engineering Systems Journal*. 5, 2020. Pp. 8–12. DOI: 10.25046/aj050102.
187. Jang J.S.R., ANFIS: Adaptive-Network-Based Fuzzy Inference System, *IEEE Trans. Syst. Man Cybern.* 23(3), 1993. P. 665–685.
188. Razavi R., Sabaghmoghadam A., Bemani A., etc. Application of ANFIS and LSSVM Strategies for Estimating Thermal Conductivity Enhancement of Metal and Metal Oxide Based Nanofluids. *Engineering Applications of Computational Fluid Mechanics*. 13. 2019. P. 560–578. DOI: 10.1080/19942060.2019.1620130.
189. Venugopal C., Devi S., Rao K., Predicting ERP User Satisfaction – Adaptive Neuro Fuzzy Inference System (ANFIS) Approach, *Intelligent Information Management*, 2 (7), 2010, Pp. 422–430. doi: 10.4236/iim.2010.27052.
190. Yıldız A., Yazar A., etc. Numerical and ANFIS Modeling of Flow over Ogee–Crested Spillway. *Applied Water Science*. 10, 2020. doi: 10.1007/s13201-020-1177-4.
191. Bystrov D. Neuro–Fuzzy Logic Systems MatLAB Toolbox GUI, Retrieved, 2016. URL: <http://users.du.se/~jwe/fuzzy/NFL/F10.PDF> (дата обращения: 7.04.2020).
192. Comparison of ANFIS and Neuro-Fuzzy Designer Functionality // MathWorks URL: <https://www.mathworks.com/help/fuzzy/comparison-of-anfis-and-neurofuzzy-designer-functionality.html> (дата обращения: 24.02.2019).
193. Cintula P., Fermüller C., Noguera C. Fuzzy Logic, *Stanford Encyclopedia of Philosophy* (Fall 2017 Edition) // *Stanford Encyclopedia of Philosophy* URL: <https://plato.stanford.edu/entries/logic-fuzzy/> (дата обращения: 29.03.2020).
194. Sujatha K., Vaisakh K., Implementation of Adaptive Neuro Fuzzy Inference System in Speed Control of Induction Motor Drives, *Journal of Intelligent Learning Systems and Applications*, 2(2), 2010. Pp. 110–118. DOI: 10.4236/jilsa.2010.2204.
195. Гончаров Р.А., Короченцев Д.А., Павленко А.С. Разработка подсистемы поддержки принятия решений идентификации множества демаскирующих признаков // Национальная ассоциация ученых (НАУ). Ежемесячный научный журнал. –Екатеринбург, 2018. – №39. – С 25–30.

196. Короченцев Д.А., Павленко А.С. О программной реализации системы идентификации демаскирующих признаков объектов защиты // Colloquium Journal – 2018. – № 13(24), 2018 – С. 5–8.

197. Гуляев В.П. Анализ демаскирующих признаков объектов информатизации и технических каналов утечки информации: учебно-методический комплект / В.П. Гуляев – Екатеринбург: Издательство Урал. ун-та, 2014. – 164 с.

198. Top 6 Data Science Programming Languages for 2019// A Medium Corporation URL: <https://medium.com/datadriveninvestor/top-6-data-science-programming-languages-for-2019-39ba1b6819a8> (дата обращения: 24.06.2019).

199. Overview of wxPython // wxPython URL: <https://wxpython.org/pages/overview/> (дата обращения: 1.04.2020).

200. Software Library for the Rapid Development of Hardware–Accelerated Multitouch Applications. // The Python Package Index URL: <https://pypi.org/project/Kivy/> (дата обращения: 12.05.2020).

201. Best Python GUI Framework // TechSore URL: <https://techsore.com/best-python-gui/> (дата обращения: 3.05.2020).

202. Customized Linear // GitHub URL: <https://github.com/uchida-takumi/Customized-Linear> (Дата обращения: 10.09.2019)

203. Amiri, A.N., Navid Y.A. (2020). Comparing the Efficiency of Different Computation Intelligence Techniques in Predicting Accident Frequency. IATSS Research. Doi: 10.1016/j.iatssr.2020.03.003.

204. Python GUI Programming With Tkinter // Real Python URL: <https://realpython.com/python-gui-tkinter/> (дата обращения: 15.05.2020).

205. Tay, K. Muwafaq H., Ismail S., etc. Electricity Consumption Forecasting Using Adaptive Neuro–Fuzzy Inference System (ANFIS). Universal Journal of Electrical and Electronic Engineering. 6. 2019. Pp. 37–48. Doi: 10.13189/ujeee.2019.061606.

206. Deep Learning Frameworks Comparison. Tensorflow, PyTorch, Keras, MXNet, Microsoft Cognitive Toolkit, Caffe, Deeplearning4j, Chainer // Netguru URL: <https://www.netguru.com/blog/deep-learning-frameworks-comparison> (дата обр:24.06.2019).

207. Torch.Tensor // PyTorch URL: <https://pytorch.org/docs/stable/tensors.html> (Дата обращения: 27.08.2019).

207. Seyedmehdi S., Mojtaba M., etc. QSPR based ANFIS Model for Predicting Standard Molar Chemical Exergy of Organic Materials. Petroleum Science and Technology. 37, 2019. Pp. 1–8. Doi: 10.1080/10916466.2018.1496100.

208. Application of Selected Artificial Intelligence Methods in System Predicting the Microstructure of Compacted Graphite Iron // Mrzygłód, B., Gumienny, G., Wilk-Kołodziejczyk, D. 2019. Doi: 10.1007/s11665-019-03932-4
209. Ata, R. Adaptive Neuro-Fuzzy Inference System Approach for Prediction of Tip Speed Ratio in Wind Turbines. Expert Systems. 37, 2010. P. 5454–5460.
210. Wang C. Study of Membership Functions on Mamdani-Type Fuzzy Inference System for Industrial Decision-Making.//Theses and Dissertations. Paper 1665, 2015.
211. Defuzzification Methods // MathWorks URL: <https://www.mathworks.com/help/fuzzy/defuzzification-methods.html> (дата обращения: 29.03.2020).
212. Haykin S.S., Haykin S., Neural Networks and Learning Machines, New York, NY, USA: Prentice-Hall, 2009.
213. Improving Anomaly Detection Process in Computer Networks Having Existing IDs Using Additional Behavioral Layer Optimized Back Propagation Neural Network and Mobile Agents Multi Class Attack Detection // Shodhganga URL: <http://hdl.handle.net/10603/86847> (дата обращения: 28.03.2020).
214. Penghui L., Ewees A., etc. Metaheuristic Optimization Algorithms Hybridized with Artificial Intelligence Model for Soil Temperature Prediction: Novel model. IEEE Access. 2020. Pp. 51884–51904. Doi: 10.1109/ACCESS.2020.2979822.
215. Kriesel D. Brief Introduction to Neural Networks, 2007. URL: <http://www.dkriesel.com> (дата обращения: 3.04.2019).
216. Pezeshki Z., Mazinani S.M. Comparison of Artificial Neural Networks, Fuzzy Logic and Neuro Fuzzy for Predicting Building Optimization of Thermal Consumption: Survey. Artificial Intelligence Review.2018. Doi: 10.1007/s10462-018-9630-6
217. Singh J., «A Parameterized Comparison of Fuzzy Logic Neural Network and Neuro Fuzzy System: Literature», International Journal of Computer Science and Mobile Computing, 5(5). 2016. Pp. 478–482.
218. Studies on the Damping Improvement of Power Systems by Static Synchronous Series Compensators and Power System Stabilizers // Shodhganga URL: <http://hdl.handle.net/10603/24154> (дата обращения: 25.03.2020).
219. Технические средства и методы защиты информации: Учебник для вузов / Зайцев А.П., Шелупанов А.А., Мещеряков Р.В. и др.; под ред. А.П. Зайцева – М.: ООО «Издательство Машиностроение», 2009 – 508 с.

220. Торокин А.А. Инженерно–техническая защита информации: учеб. пособие для студентов, обучающихся по специальностям в области информационной безопасности – М.: Гелиос АРВ, 2005. – С. 55–56.

К 13 главе

221. ГОСТ Р 50.1.053. Информационные технологии. Основные термины и определения в области технической защиты информации.

222. Положение о Федеральной службе по техническому и экспортному контролю. Утверждено Указом Президента РФ от 16.08.2004 г. № 1085 "Вопросы Федеральной службы по техническому и экспортному контролю".

223. Торокин А.А. Инженерно–техническая защита информации. Учебное пособие. – М.: Министерство обороны РФ. 2004. – 962 с.

224. Зайцев А.П. Технические средства и методы защиты информации: Учебник для вузов / А.П. Зайцев, А.А. Шелупанов, Р.В. Мещеряков /М.: ООО Издательство «Машиностроение», 2009. – 508 с.

225. Хорее А.А. Методы защиты речевой информации и оценки их эффективности /А.А. Хорее, Ю.К. Макаров // Конфидент. – 2001. № 4. 223 с.

226. Долгов А.И. Методика решения некоторых задач оценки объектов с помощью ЦВМ / А.И. Долгов, В.И. Журавлев // Автоматика и вычислительная техника. 1965. № 9. С. 35 – 45.

227. Долгов А.И. Метод кусочно-линейной рейтинговой нормализации // Автоматика и вычислительная техника. 2006. № 3.

228. Халяпин Д.Б. Защита информации. Вас подслушивают? Защищайтесь! М.: НОУ ШО "Баярд", 2004. – 432 с.

229. Халяпин Д.Б. Акустоэлектрические, акустопреобразовательные каналы утечки информации и возможные способы их подавления // Мир безопасности. – № 5. 47 – 53 с.

230. Халяпин, Д.Б. Визуально–оптический канал утечки информации // Мир безопасности. – 1998. - № 7. – 48 – 50 с.

231. Бузов, Г.А. Защита от утечки информации по техническим каналам /Г.А. Бузов, С.В. Калинин, А.В. Кондратьев / Учебное пособие. – М.: Горячая Линия –Телеком, 2005. – 225 с.

232. Ярочкин, В.И. Технические каналы утечки информации. – М.: Институт повышения квалификации информационных работников, 1994. – 106 с.

233. Хорев А.А. Классификация и характеристика технических каналов утечки информации, обрабатываемой ТСПИ и передаваемой по каналам связи. URL:http://www.ess.ru/sites/default/files/files/articles/1998/02/1998_02_06.pdf (дата обращения: 26.04.2018).
234. Хорев А.А. Технические каналы утечки акустической (речевой) информации URL:http://www.ess.ru/sites/default/files/files/articles/2004/04/2004_04_04.pdf (дата обращения: 27.04.2018).
235. Сидоров, И.Н. Микрофоны и телефоны / И.Н. Сидоров, А.А. Дмитриев / М.: Радио и связь, 1993. – 152 с.
236. Специальные требования и рекомендации по технической защите конфиденциальной информации. Гостехкомиссия России. – М.: 2002 г.
237. ГОСТ Р 51275–99. Защита информации. Объект информатизации. Факторы, воздействующие на информацию. Общие положения. (Принят и введен в действие Постановлением Госстандарта России от 12 мая 1999 № 160).
238. Спирин, А. А. Волоконно–оптические сети: введение в технологию // Мир персональных компьютеров. – 1994.– № 8.
239. Волегов, К.А. Технические средства защиты информации. Курс лекций К.А. Волегов, А.П. Бацула, Р.В. Литвинов, 2006.
240. Емельянов, С. Л. Техническая разведка и технические каналы утечки информации // Системы обработки информации. – 2010. – Вып. 3. – 203 с.
241. Государственный стандарт РФ ГОСТ Р 50922–2006. Защита информации. Основные термины и определения. Утвержден приказом ФА по техническому регулированию и метрологии от 27 декабря 2006 г. N 373–ст.
242. ГОСТ 17187–81 (СТ СЭВ 1351–78). Шумомеры. Общие технические требования и методы испытаний (с Изменением N 1).
243. Василевский, И.В. Методы и способы защиты телефонных линий / И.В. Василевский, Д.И. Белорусов // Специальная техника. 1999. № 5. – С. 11–14.
244. Максимов Ю.Н. Технические методы и средства защиты информации. [и др.] – СПб.: Издательство «Полигон», 2000.
245. Цветное В.В. Радиоэлектронная борьба: радиоразведка и радио противодействие / В.В. Цветное, В.П. Демин, и др. /М.: Изд–во МАИ, 1998.
246. Классификация и характеристика основных средств предотвращения утечки информации по материально–вещественному каналу. URL: <https://studfiles.net/preview/5868802/page:10/> (дата обращения: 12.05.2018).

247. Google Trends. Динамика языков программирования. URL: <https://trends.google.ru/trends/?geo=RU> (дата обращения: 21.08.2022).

248. Java URL: <https://ru.wikipedia.org/wiki/Java> (дата обращения: 15.05.2018).

249. Введение в C#. URL: <https://metanit.com/sharp/tutorial/1.1.php> (дата обращения: 15.05.2018).

250. Python. URL: <https://ru.wikipedia.org/wiki/Python> (дата обр: 15.05.2018).

К 14 главе

251. Круглов В.В. Нечёткая логика и искусственные нейронные сети / В.В. Круглов, Р.Ю. Голунов. – М.: Горячая Линия – Телеком. – 2013. – 779 с.

252. Леоненков А.В. Нечёткое моделирование в среде MatLAB и FuzzyTECH. Учебное пособие. – СПб.: БХВ–Петербург, 2005. – 736 с.

253. Яхьяева Г.Э. Нечёткие множества и нейронные сети: учебное пособие / Г. Э. Яхьяева. – М.: Интернет–университет ИТ. – 2016. – 320 с.

254. Боженюк А.В. Принятие решений на основе нечёткой экспертной информации: дис... канд. тех. наук: 05.13.17: защищена 04.06.15 / А.В. Боженюк – Таганрог: Технологический институт ЮФУ, 2015. – 145 с.

255. Мелихова З.А. Использование аппарата нечёткой математики при моделировании систем поддержки принятия решений. / З.А. Мелихова, О.А. Мелихова // Известия ЮФУ. Технические науки. – 2012. – №14. – С. 10–14.

256. Заргарян Ю.А. Разработка и исследование методов принятия решений в условиях неполноты данных при нечётком описании параметров моделей: дис... канд. тех. наук: 05.13.17: / Ю.А. Заргарян – Таганрог: ТТУ, 2015. – 100 с.

257. Хайкин С.А. Нейронные сети: полный курс: учебник для вузов / С.А. Хайкин. – М.: Вильямс. – 2016. – 781 с.

258. Ширяев В.И. Нейронные сети, нелинейная динамика: учебник для вузов / В. И. Ширяев. – М.: Либроком. – 2017. – 232 с.

259. Усков А.А., Кузьмин А.В. Интеллектуальные технологии управления. Искусственные нейронные сети и нечёткая логика. – М.: Издательство «Горячая линия» – «Телеком», 2004. – 143 с.

260. Рутковская М.А., Плинский Л.М. Нейронные сети, генетические алгоритмы и нечёткие системы–М.: «Горячая линия»–«Телеком», 2016.–143 с.

261. Нейронная сеть–введение. URL:<http://robocraft.ru/blog/algorithm/558.html> (дата обращения: 01.01.2019).

262. Искусственные нейронные сети. Их разновидности. URL: <https://habr.com/ru/post/312450/> (дата обращения: 20.07.2019)
263. Галушкин, А.И. Нейронные сети. Основы теории: учебное пособие / А.И. Галушкин. – М.: Горячая Линия – Телеком. – 2016. – 496 с.
264. Троелсен Э.А. Язык программирования C# 5.0 и платформа .NET 4.5 / монография / Э.А. Троелсен. – М.: Вильямс. – 2015. – 633 с.
265. Преимущества нейронных сетей. URL: [https://sibac.info/conf/ Modern_Science/v/85515](https://sibac.info/conf/Modern_Science/v/85515) (дата обращения 01.10.2019)
266. Little J. D. C. Models and managers: The concept of decision calculus // ManagementScience. 1970. Vol. 16. № 8. Pp. 466 – 485.
267. Обработка исключений, конструкция «try...catch...finally». URL: <https://metanit.com/sharp/tutorial/2.14.php> (дата обращения: 24.04.2019).
268. Обработка исключений. URL: <https://prog-cpp.ru/cpp-exception/> (дата обращения: 12.03.2019).
269. Зеленский А.А., Короченцев Д.А., Ревякина Е.А. Разработка адаптивного fuzzy-алгоритма идентификации технических каналов утечки информации. Colloquium – journal №11 (63), 2020 г. – 40 с.
270. Keen P. G. W. Decision support systems: The next decades // Decision Support Systems. 1987. Vol. 3. Pp. 253 – 265.
271. Раевская Е.А. Программный инструментарий поддержки принятия решений на основе методов системного анализа / Е.А. Раевская, А.Г. Пимонов, Н.Б. Новаковский // Вестник Кузбасского государственного технического университета. – 2013. – № 11. – С.5 – 9.
272. Рахимов Е.А. Модели и методы поддержки принятия решений в интеллектуальной системе защиты информации: дис. канд. тех. наук: 05.13.19: защищена 06.02.17 / Е.А. Рахимов – Уфа: УГТУ, 2017. 156 с.
273. Абрамов Е.С. Построение адаптивной системы информационной безопасности. / Е.С. Абрамов, И.Н. Николина // Известия Южного федерального университета. Технические науки. – 2009. – №13. – С. 6–10.
274. Системы поддержки принятия решений. URL: https://studme.org/212173/informatika/sistemy_podderzhki_prinyatiyaresh-eniy (дата обращения: 15.05.2019).
275. Нестерук Ф.Г. Разработка модели адаптивной системы защиты информации на базе нейро-нечётких сетей: дис... канд. тех. наук: 05.13.19: защищена 09.04.15 / Ф.Г. Нестерук – СПб: СПТУ, 2015. – 134 с.

276. Ананьев Н.С. Методы и средства анализа данных в системах поддержки принятия решений: дис... канд. тех. наук: 05.25.05: защищена 02.03.16 / Н.С. Ананьев – Москва: МТИ, 2016. – 75 с.

277. Панченко Е.М. Проблемы защиты объектов вычислительной техники от утечки информации по каналам побочных электромагнитных излучений и наводок в современных условиях / Е.М. Панченко, В.В. Каверин, В.А. Бабанских // Известия ЮФУ. Технические науки. – 2017. – №3. – С. 13–17.

278. Халяпин, Д.Б. Технические каналы утечки речевой информации через извещатели охранно–пожарной сигнализации / Д.Б. Халяпин, Е.Б. Терентьев // Известия ЮФУ. Технические науки. – 2016. № 9. – С. 10 – 15.

279. Джарратано Д.А. Экспертные системы. Принципы разработки и программирование. Технические науки. – 2015. – № 4. – С. 25 – 38.

280. Бузов Г.А. Защита от утечки информации по техническим каналам / Г.А. Бузов, С.В. Калинин. – М.: Горячая линия – Телеком, 2005. – 225 с.

281. Волегов К. А. Технические средства защиты информации / К.А. Волегов, А.П. Бацула, Р.В. Литвинов. – М.: Горячая линия – Телеком, 2006. – 144 с.

К 15 главе

282. Верба, В. С. Авиационные комплексы радиолокационного дозора и наведения: принципы построения, проблемы разработки и особенности функционирования: монография / В. С. Верба. М.: Радиотехника, 2014. 528 с.

283. Rong L.I., Survey of Maneuvering Target Tracking. Part I: Dynamic Models / X. Rong L.I., Vesselin P. Jilkov. // IEEE Transactions on Aerospace and Electronic Systems. — 2003. —Vol. 39. No. 4. October. P. 1333 – 1364.

284. Барсегян, А.А. Анализ данных и процессов: учеб. пособие /А.А. Барсегян, М.С. Куприянов, И.И. Холод. СПб.: БХВ–Петербург, 2009. 490 с.

285. Лукашин Ю.П. Адаптивные методы краткосрочного прогнозирования временных рядов. / Ю.П. Лукашин. М.: Финансы и статистика, 2003. 416 с.

286. Фомин, В.Н. Рекуррентное оценивание и адаптивная фильтрация: монография / В.Н. Фомин. — М.: Наука. 1984. — 288 с.

287. Балакришнан А.В. Теория фильтрации Калмана /А.В. Балакришнан; М. Зув, под ред. А.А. Новикова. — Москва: Мир, 1988. —168с.

288. Andreasen M. Nonlinear DSGE Models, Central Difference Kalman Filter, and MeanShied Particle Filter. [URL:ftp://p.econ.au.dk/creates/rp/08/rp08_33. pdf](http://p.econ.au.dk/creates/rp/08/rp08_33.pdf)

289. Дегтярёв А.А. Элементы теории адаптивного расширенного фильтра Калмана // Препринт ИПМ им. М.В. Келдыша РАН, М., 2003. №26. – 35с. URL: http://www.keldysh.ru/papers/2003/prep26/prep2003_26.pdf (дата обр.: 09. 03. 2018).
290. Елисеев А. В. Метод адаптивной настройки фильтра Калмана в задаче слежения за динамическим объектом с неизвестным ускорением / А.В. Елисеев, Н.Ю. Музыченко. // Радиотехника. 2014. № 8. С. 39 – 44.
291. Уидроу Б. Адаптивная обработка сигналов. М.: Радио и связь, 1989. 440 с.
292. Великанов Е.П. Адаптивная фильтрация координат маневрирующего объекта при изменениях условий передачи в радиолокационном канале/ Е.П. Великанова. // Доклады ТУСУРа. —2012. — № 2 (26), часть 1.
293. Фари́на А.Н. Цифровая обработка радиолокационной информации. Сопровождение целей/А.Н. Фари́на, Ф.И. Студер.М.:Радио и связь. 1993. 320 с.
294. Бочкарев, А.М. Цифровая обработка радиолокационной информации при сопровождении целей / Зарубежная радиоэлектроника. 1991. № 3. С. 3–22.
295. Панасюк, Ю.Н. Обработка радиолокационной информации в радио технических системах: учебное пособие / Ю. Н. Панасюк, А. П. Пудовкин. – Тамбов: Издательство ФГБОУ ВПО «ТГТУ», 2016. – 84 с.
296. Ярлыков, М.С. Марковская теория оценивания случайных процессов / М.С. Ярлыков, М.А. Миронов. – Москва: Радио и связь, 1993.
297. Горбачев А.Ю. Критерии оценки алгоритмов оптимальной фильтрации //Авиакосмическое приборостроение. —2008. — № 6.
298. Baheti R. S. Estimating Optimal Tracking Filter Performance For Manned Maneuvering Targets // IEEE Trans., 1986, v. AES–22, N 1, pp. 8— 14.
299. Blom H. A. P., Bloem E. A. Combining Imm And Jpda For Tracking Multiple Maneuvering Targets Inclutter. Proc. 5th Int. Conf. on Information Fusion. Annapolis. USA. 2002. Pp. 705 – 712.
300. Bar–Shalom Y., Li X. R., Kirubarajan T. Estimation with Applications to Tracking and Navigation: Theory, Algorithms, Software. New York: Wiley, 2001. 558 p.
301. Харитонов, А.В. Исследование влияния ошибки определения угловых координат на определение координат цели в обзорной РЛС / А.В. Харитонов, Международный научный журнал «Инновационная наука». 2016. №6.
302. Костоглотов, А.А. Синтез фильтра сопровождения со структурной адаптацией на основе объединённого принципа максимума / А.А. Костоглотов, С.В. Лазаренко // Информационно–управляющие системы. 2015. № 4.

303. Ашурбейли, И. Р. Основные направления развития средств воздушно-космической обороны Российской Федерации / И.Р. Ашурбейли, А.И. Лаговьер. // Успехи современной радиоэлектроники. 2009. № 12. С. 46 – 54.

304. Костоглотов А.А. Анализ эффективности инновационных решений на базе объединённого принципа максимума в задачах обработки информации и управления / А.А. Костоглотов // Инноватика и экспертиза. 2015. № 2.

305. Лурье А. И. Аналитическая механика. М.: Ред. физ.–мат. лит.1961. 825 с.

306. Костоглотов А.А. Адаптивный экстраполятор / А.А. Костоглотов, С.И. Чурилов, и [др.] // ДГТУ журнал «Молодой исследователь Дона». – 2017.– № 6.

307. Костоглотов, А.А. Сравнительная оценка характеристик фильтра объединенного принципа максимума и вариантов реализации фильтра Калмана при сопровождении маневрирующей цели / А. А. Костоглотов, А.А. Кузнецов, А.А. Мурашов. // Радиотехника. — 2014. — № 8. — С. 45–49.

308. Сергиенко А.Б. Алгоритмы адаптивной фильтрации: особенности реализации в MatLAB. URL: <http://iglin.exponenta.ru/сайт> (дата обр.: 11.04.2018).

К 16 главе

309. Richard G. Michel F.C., Joël R. Supercritical Fluids in Thermoplastics Foaming: Facts or Fallacies? // Cellular Polymers. 2006. Vol.25. № 4. Pp. 199–220. Doi 10.1177/026248930602500401

310. Daily M. Medasani S., Behringer R., Trivedi M. Self–Driving Cars. // Computer. – Vol.50. – Pp. 18 – 23. – Doi 10.1109/MC.2017.4451204.

311. BMW ввела платные опции по подписке в России//Autonews [Электронный ресурс] URL: <https://www.autonews.ru/> (дата обращения: 22.07.20 22).

312. Yang J., Coughlin J.F. In–vehicle Technology for Self–Driving Cars: Advantages and Challenges for Aging Drivers // Int. Journal Automotaton Technologies.–2014.–Vol.15.–Pp. 333–340. – Doi 10.1007/s12239-014-0034-6

313. Graham D., Sol H., Christopher C., Nicole H. O’D., Jay H. What Drives Support for Self–Driving Car Technology in the United States? // Journal of Risk Research. 2020. – Vol. 23. – № 3. – Pp. 275–287. Doi 10.1080/13669877.2018.1517384

314. Что нужно знать об ADAS? // Электронный журнал Авто3н URL: <https://mag.auto3n.ru/> (дата обращения: 12.07.2022).

315. Как работает автопилот Tesla в 2021 году // ECARS24 URL: <https://ecars24.info/> (дата обращения: 13.07.2022).

316. The 6 Levels of Vehicle Autonomy Explained // Synopsys URL: <https://www.synopsys.com/> (дата обращения: 13.07.2022).

317. Navya's Fully Self-Driving Taxi Looks Straight out of Robocop // Mashable URL: <https://mashable.com/> (дата обращения: 13.07.2022)
318. Generative Adversarial Networks Serve Safety and Cybersecurity // Towards Data Science. 2021. URL: <https://towardsdatascience.com/> (дата обр.: 24.07.20 22).
319. Peng Y. The Ideological Divide in Public Perceptions of Self-Driving Cars // Public Understanding of Science. – 2020. – Vol. 29. – Pp. 436–451. Doi 10.1177/ 0963662520917339.
320. Zhao J., Liang B., Chen Q. The Key Technology toward the Self- Driving Car // International Journal of Intelligent Unmanned Systems. – 2018. – Vol.6. – Pp. 2–20. – Doi 10.1108/IJIUS-08-2017-0008.
321. Canis B., Issues in Autonomous Vehicle Testing and Deployment (CRS Report R45985) (updated Nov. 27, 2019).
322. Uvarov K., Ponomarev A. Driver Identification with OBD-II Public Data // Conference of Open Innovations Association, FRUCT.–2021.–№ 28.–Pp. 495–501.
323. Сараева И.Ю. Диагностирование электронных блоков управления автомобиля // Автомобильный транспорт. – 2013. № 33. – С. 19–22.
324. Car Hacking: Так ли безопасны системы безопасности автомобиля? // Хабр URL: <https://habr.com/> (дата обращения: 28.06.2022).
325. Delgrossi, L. Connected Vehicles AND CYBERSECURITY / Delgrossi L., Zhang T. // Usdot. – 2012. – Pp. 32–43.
326. Connected Vehicle Reference Implementation Architecture // CVRIA Connected Vehicle Reference Implementation Architecture URL: <http://local.iteris.com/cvria/> (дата обращения: 03.06.2022)
327. Li Y. An overview of the DSRC / WAVE technology // Social-Informatics and Telecommunications Engineering. – 2012. – Pp. 9 – 21
328. Road safety in the European Union. – Brussels: Mobility and Transport DG. – 2015 – P.24
328. Raw, R.S., Kumar M., Singh N. Security Challenges, Issues and Their Solutions for VANET // International Journal of Network Security & Its Applications. – 2013 Vol. 5. – No. 5. – Pp. 95–105.
329. Mejri, M.N. Survey on VANET Security Challenges and Possible Cryptographic Solutions / Mejri M. N., Ben-Othman J., Hamdi M. // Vehicular Communications. – 2014. – Vol. 1. – No. 2. – Pp. 53 – 66.
330. United States Government Accountability Office. Intelligent Transportation Systems: Vehicle-to-Infrastructure Technologies Expected to Offer Benefits, but Deployment Challenges Exist. No. – 2015. – P. 57.

331. United States Government Accountability Office. Intelligent Transportation Systems: Vehicle-to-Infrastructure Technologies Expected to Offer Benefits, but Deployment Challenges Exist. No. – 2015. – Pp. 57.

332. Mishra R., Singh A., Kumar R. "VANET Security: Issues, Challenges and Solutions" // 2016 International Conference on Electrical, Electronics, and Optimization Techniques (ICEEOT). – 2016. – Pp. 1050 – 1055.

333. Sumra, I.A., Ahmad I., Hasbullah H., and Bin Ab Manan J.L. Classes of Attacks in VANET. // Saudi International Electronics, Communications and Photonics Conference 2011, SIECPC 2011.

334. Hu Y.C., Patel M., Sabella D., Sprecher N., Young V. Mobile Edge Computing Key Technology towards 5G. ETSI White Paper No // 11 Mobile. – No. 11. – 2015. – Pp. 1–16.

335. Ahmed A., Ahmed. E. Survey on Mobile Edge Computing Survey on Mobile Edge Computing // No. 1. 2016.

336. Greenberg A., Hjalmtysson G., Maltz D.A., etc. Clean Slate 4D Approach to Network Control and Management //ACM SIGCOMM Computer Communication Review. – 2005. – Vol. 35. – No. 3. – Pp. 41–54.

337. ECOMP (Enhanced Control, Orchestration, Management&Policy) Architecture White Paper//URL:<https://blockchainlab.com/pdf/ecomp.pdf> (дата обр.: 08. 04.2022).

338. Clark C., Lee W., Schimmel D., etc. Hardware Platform for Network Intrusion Detection and Prevention. // Workshop on Network Processors and Applications (NP3. – 2004. – Pp. 136–145.

339. Rawat, D.B. Bajracharya C., Gongjun Y., etc. Towards Intelligent Transportation Cyber–Physical Systems: Real–Time Computing and Communications Perspectives // IEEE SoutheastCon 2015. – Vol. 6. – Pp. 1–6.

340. Peter S. Anderson T., Roscoe T. The Operating System as Control Plane. / // Login: – 2013. – Vol. 38. – No. 4. – Pp. 44 – 47.

341. Hasbullah H. Soomro I.A., Manan J.A. Denial of Service (DOS) Attack and Its Possible Solutions in VANET//International Journal of Electrical, Computer, Energetic, Electronic and Communication Engineering. 2010. Vol. 4. No. 5. Pp. 411–415.

342. Fayaz, S., Tobioka Y., Sekar V., etc. Flexible and Elastic DDoS Defense // Proceedings of 24th USENIX Conference on Security Symposium.–2015.–Pp. 817–832.

343. Lu X.Y., Wang J. Multiple–Vehicle Longitudinal Collision Avoidance and Impact Mitigation by Active Brake Control // IEEE Intelligence. Vehicle Symposium. 2012. Proceeding. – Pp. 680–685.

ОГЛАВЛЕНИЕ

Введение	3
1. КРИПТОГРАФИЧЕСКИЙ ПРОТОКОЛ С ОТКРЫТЫМ КЛЮЧОМ ДИФФИ–ХЕЛЛМАНА С ПРИМЕНЕНИЕМ НЕЙРОННОЙ СЕТИ.....	5
1.1. Теоретические основы создания нейронных сетей.....	6
1.2. Взаимодействующие нейронные сети.....	9
1.3. Протокол Диффи – Хеллмана на базе синхронизации двух древовидных машин чётности.....	11
1.4. Безопасность протокола Диффи – Хеллмана, основанного на синхронизации двух древовидных машин чётности.....	13
1.5. Обзор существующих протоколов обмена ключами.....	14
1.6. Алгоритмическое конструирование программного средства создания общего закрытого ключа.....	19
1.7. Программная реализация протокола обмена ключами.....	25
1.8. Тестирование разработанного программного обеспечения.....	32
2. АЛГОРИТМ ХЕШИРОВАНИЯ ИЗОБРАЖЕНИЙ В БАЗЕ ДАННЫХ НА ОСНОВЕ ИСКУССТВЕННОЙ НЕЙРОННОЙ СЕТИ.....	38
2.1. Обзор существующих программных решений.....	38
2.2. Сравнение методов извлечения главных признаков изображения.....	51
2.3. Алгоритмическое конструирование программного средства.....	58
2.4. Программное конструирование разрабатываемого средства.....	69
2.5. Демонстрация работы программного средства.....	77
3. РАСПОЗНАВАНИЕ ДЕСТРУКТИВНЫХ ЭМОЦИЙ ЧЕЛОВЕКА ПО ЕГО ИЗОБРАЖЕНИЮ НА ОСНОВЕ НЕЙРОСЕТЕВЫХ АЛГОРИТМОВ.....	83
3.1. Анализ предметной области анализа эмоций.....	84
3.2. Средства реализации программного продукта.....	97
3.3. Разработка программного средства и описание его структуры.....	105
4. МОБИЛЬНОЕ ПРИЛОЖЕНИЕ РАСПОЗНАВАНИЯ ЭМОЦИЙ ЧЕЛОВЕКА НА ОСНОВЕ НЕЙРОСЕТЕВЫХ АЛГОРИТМОВ.....	117
4.1. Существующие аналоги алгоритмов распознавания эмоций.....	119
4.2. Объективные характеристики проявления эмоций в речи.....	123
4.3. Извлечение эмоциональных характеристик из речевого сигнала.....	128
4.4. Разработка оптимального алгоритма распознавания эмоций.....	137
4.5. Выбор оптимальной среды программирования.....	140
4.6. Реализация мобильного приложения распознавания эмоций.....	143

5.	НЕЙРОННЫЕ СЕТИ ДЛЯ МОНИТОРИНГА И РАСПОЗНАВАНИЯ ОБЪЕКТОВ, ПРЕДСТАВЛЯЮЩИХ УГРОЗУ, НА ИЗОБРАЖЕНИИ	155
5.1.	Анализ принципов работы искусственных нейронных сетей и их применение для распознавания объектов на изображении.....	156
5.2.	Анализ программных средств реализации.....	168
5.3.	Выбор и реализация алгоритма для нахождения объекта.....	172
5.4.	Обучение свёрточной нейронной сети, и оценка точности реализации алгоритма нахождения объекта.....	176
6.	МОНИТОРИНГ ДЕСТРУКТИВНОГО ПОВЕДЕНИЯ ОБУЧАЮЩИХСЯ ПРИ ПРОВЕДЕНИИ АТТЕСТАЦИОННЫХ МЕРОПРИЯТИЙ.....	182
6.1.	Аналитический обзор систем онлайн–прокторинга.....	185
6.2.	Алгоритмическое конструирование разрабатываемой системы.....	189
6.3.	Программное конструирование системы онлайн–прокторинга.....	201
7.	НЕЙРОННАЯ СЕТЬ ДЛЯ РАСПОЗНАВАНИЯ ДЕСТРУКТИВНЫХ ЧЕРТ ХАРАКТЕРА ЧЕЛОВЕКА ПО ЕГО РУКОПИСНОМУ ПОЧЕРКУ.....	207
7.1.	Анализ существующих систем и их применение.....	209
7.2.	Выбор программных средств системы графологического анализа.....	213
7.3.	Алгоритмическое конструирование программного средства.....	217
7.4.	Разработка и кодирование программного средства.....	219
8.	ПРОГРАММНОЕ СРЕДСТВО СЕМАНТИЧЕСКОГО АНАЛИЗА ТЕКСТА ДЛЯ РЕШЕНИЯ ЗАДАЧИ РАСПОЗНАВАНИЯ КОНТЕНТА WEB–САЙТОВ С ПОМОЩЬЮ НЕЙРОСЕТЕВЫХ ТЕХНОЛОГИЙ.....	226
8.1.	Аналитический обзор программных средств семантического анализа.....	228
8.2.	Алгоритмическое построение средства семантического анализа.....	230
8.3.	Программная реализация средства семантического анализа.....	240
9.	ПОИСК ПОТЕНЦИАЛЬНО ОПАСНЫХ КОНСТРУКЦИЙ И УЯЗВИМОСТЕЙ В ИСХОДНЫХ ТЕКСТАХ ПРОГРАММ С ПОМОЩЬЮ ИСКУССТВЕННЫХ НЕЙРОННЫХ СЕТЕЙ	247
9.1.	Необходимость сертификации программного обеспечения.....	249
9.2.	Обзор программных реализаций текстовых анализаторов.....	251
9.3.	Искусственные нейронные сети для поиска уязвимостей и опасных конструкций в исходных текстах программного кода.....	258
9.4.	Алгоритмическая реализация процесса анализа исходных текстов программного обеспечения.....	263
9.5.	Программное конструирование программы–анализатора.....	267
9.6.	Тестирование модулей разработанного программного средства.....	271

10.	ПОДСИСТЕМА ПОДДЕРЖКИ ПРИНЯТИЯ РЕШЕНИЙ ПРИ ИДЕНТИФИКАЦИИ ОБЪЕКТОВ КРИТИЧЕСКОЙ ИНФОРМАЦИОННОЙ ИНФРАСТРУКТУРЫ.....	277
10.1.	Теоретический анализ проблемы обеспечения безопасности критической инфраструктуры и методологии теории принятия решений.....	280
10.2.	Подсистема поддержки принятия решений идентификации объектов критической информационной инфраструктуры.....	289
10.3.	Программная реализация подсистемы поддержки принятия решений по идентификации объектов критической инфраструктуры.....	295
11.	СИСТЕМА ПОДДЕРЖКИ ПРИНЯТИЯ РЕШЕНИЙ ПРИ ИДЕНТИФИКАЦИИ МНОЖЕСТВА ДЕМАСКИРУЮЩИХ ПРИЗНАКОВ ЗАЩИЩАЕМОГО ОБЪЕКТА ОРГАНИЗАЦИИ.....	300
11.1	Анализ демаскирующих признаков объектов защиты.....	302
11.2.	Обоснование выбора и описание основных демаскирующих признаков.....	309
11.3.	Разработка подсистемы поддержки принятия решений Идентификации множества демаскирующих признаков.....	325
12.	РАЗРАБОТКА FUZZY–СИСТЕМЫ ИДЕНТИФИКАЦИИ ДЕМАСКИРУЮЩИХ ПРИЗНАКОВ ОБЪЕКТА ЗАЩИТЫ.....	339
12.1.	Теоретические сведения о построении системы идентификации демаскирующих признаков.....	340
12.2.	Программная реализация адаптивной нейро–нечёткой системы идентификации демаскирующих признаков.....	356
12.3.	Обучение нейро–нечёткой (fuzzy) системы.....	374
13.	ПОДСИСТЕМА ПОДДЕРЖКИ ПРИНЯТИЯ РЕШЕНИЙ ИДЕНТИФИКАЦИИ ТЕХНИЧЕСКИХ КАНАЛОВ УТЕЧКИ ИНФОРМАЦИИ В КОМПЛЕКСНОЙ СИСТЕМЕ ЗАЩИТЫ.....	384
13.1.	Технические каналы утечки информации.....	386
13.2.	Анализ методов защиты от утечки по техническим каналам.....	402
13.3.	Разработка подсистемы поддержки принятия решений в процессе идентификации технических каналов утечки информации.....	410
14.	РАЗРАБОТКА АДАПТИВНОГО FUZZY–АЛГОРИТМА ИДЕНТИФИКАЦИИ ТЕХНИЧЕСКИХ КАНАЛОВ УТЕЧКИ ЗАЩИЩАЕМОЙ ИНФОРМАЦИИ УЧРЕЖДЕНИЯ	420
14.1.	Применение нейронных сетей в поиске технических каналов утечки информации.....	420
14.2.	Реализация программного обеспечения и сравнение работы нейронной сети и подсистемы поддержки принятия решений.....	432
14.3.	Достоинства и недостатки подсистемы поддержки принятия решений в сравнении с нейро – нечёткой сетью	447

15.	ИНТЕЛЛЕКТУАЛЬНЫЙ АНАЛИЗ ДАННЫХ С УЧЁТОМ СВОЙСТВ ДИНАМИЧЕСКИХ ПРОЦЕССОВ. РАЗРАБОТКА АЛГОРИТМА ОЦЕНКИ ПАРАМЕТРОВ ДВИЖЕНИЯ В ЗАДАЧАХ СОПРОВОЖДЕНИЯ.....	451
15.1.	Анализ методов и моделей динамической оценки данных.....	452
15.2.	Модели экстраполяторов в фильтрах сопровождения.....	473
15.3.	Исследование алгоритмов обработки информации на основе объединённого принципа максимума.....	492
16.	СИСТЕМА БЕЗОПАСНОСТИ ИНФОРМАЦИОННЫХ СИСТЕМ БЕСПИЛОТНЫХ ТРАНСАОРТНЫХ СРЕДСТВ.....	505
16.1.	Уровни автоматизации беспилотных автомобилей.....	506
16.2.	Беспилотные автомобили и уязвимости их кибербезопасности.....	509
16.3.	Исследования безопасности системы обмена информацией V2I.....	516
16.4.	Разработка системы CVGuard.....	521
16.5.	Тематическое исследование приложения Stop Sign Gap Assist (SSGA).....	526
16.6.	Предотвращение атак с помощью CVGuard.....	531
16.7.	Оценка работы системы CVGuard в условиях DDoS-атаки.....	532
	Заключение.....	536
	Библиографический список.....	539
	Оглавление.....	566

КОЛЛЕКТИВНАЯ МОНОГРАФИЯ

**Короченцев Денис Александрович
Черкесова Лариса Владимировна (ред.)
Болдырихин Николай Вячеславович
Костоглотов Андрей Александрович
Куликова Ольга Витальевна
Ревакина Елена Александровна
Савельев Василий Александрович
Сафарьян Ольга Александровна
Большев Вадим Евгеньевич
Гаранин Евгений Олегович
Ефременко Инесса Николаевна
Израелян Гарри Михайлович
Лимаренко Николай Владимирович
Портнова Елена Александровна
Скубак Павел Геннадиевич**

ПРИМЕНЕНИЕ ТЕХНОЛОГИЙ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА И ПОДДЕРЖКИ ПРИНЯТИЯ РЕШЕНИЙ В ЗАДАЧАХ ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТИ

Редактор: Е.В. Хейгетян
Компьютерная обработка: Е.В. Хейгетян

В печать: Дата
Формат: 60 × 84 / 16. Объём ??? усл. п. л.
Тираж 100 экз. Заказ № ??? Цена свободная

Издательский центр ДГТУ
Адрес университета и полиграфического предприятия:
344000, г. Ростов–на–Дону, пл. Гагарина, 1.